# Working Time 🤓

L5: Data wrangling

Es hora de que pongas en práctica todo lo aprendido. 🤓
Este apartado tiene el objetivo de ayudarte a seguir potenciando tus habilidades, por lo que a continuación encontrarás diferentes **desafíos** que podrás resolver de forma independiente y a tu ritmo.

Más adelante conseguirás las resoluciones para que valides tus respuestas y puedas monitorear tu progreso. 😉

**¡Manos a la obra!**

1. **Desafío 🎯**

   *Este desafío consiste en la* ***transformación, organización y limpieza de datos*** *mediante técnicas de* ***Data Wrangling*** *en Pandas. Aprenderás a manipular estructuras de datos para optimizar su análisis.*

   - ***Carga y exploración del dataset:***
     - *Importa un dataset en formato* ***CSV****.*
     - *Muestra las primeras 5 filas y obtén una descripción general.*
     - *Identifica valores nulos y el tipo de datos de cada columna.*
   - ***Ordenamiento y manipulación de datos:***
     - *Ordena los datos según una o más columnas.*
     - *Aplica una* ***permutación aleatoria*** *a los registros.*
     - *Realiza una selección de columnas relevantes.*
   - ***Detección y eliminación de duplicados:***
     - *Identifica registros duplicados.*
     - *Elimina duplicados y verifica la reducción en el tamaño del dataset.*
   - ***Reemplazo de valores y discretización:***
     - *Reemplaza valores inconsistentes en columnas categóricas.*
     - *Divide una columna numérica en rangos (binning).*
   - ***Enriquecimiento de datos:***
     - *Crea una nueva columna a partir de cálculos entre otras columnas.*
     - *Aplica una función personalizada a una columna con* `.apply()`*.*
     - *Utiliza una expresión lambda para transformar datos.*
   - ***Manipulación de la estructura del DataFrame:***
     - *Agrega y elimina columnas.*

    - *Redimensiona el DataFrame seleccionando un subconjunto de datos.*
    - *Renombra columnas para mejorar la legibilidad.*
- ***Exportación de datos:***
    - *Guarda el dataset transformado en **CSV** y **Excel**.*

2. **¿Dónde se lleva a cabo?** 👩‍💻

   *Visual Studio Code*

3. **Tiempo de dedicación** ⏳

   *2 horas*

4. **Recursos**🛠️

   *Documentación de Pandas: https://pandas.pydata.org/docs/*

5. **Plus** ➕

   - *Automatiza la limpieza de datos mediante funciones reutilizables.*
   - *Experimenta exportando los datos en formatos como JSON o Parquet.*

6. ⚠️**Condición**

   Esta práctica o ejercitación **no requiere ser entregada y/o evaluada** por el mentor. No obstante puedes compartir tus resultados con el resto de los bootcampers y construir conocimiento en conjunto.

# Resolución del desafío 👇

1. Carga y exploración del dataset

```python
import pandas as pd

# Cargar el dataset
df = pd.read_csv('dataset.csv')

# Mostrar las primeras filas
display(df.head())

# Obtener información general
df.info()

# Identificar valores nulos
df.isnull().sum()
```

2. Ordenamiento y manipulación de datos

```python
# Ordenar por una columna
df = df.sort_values(by='columna_numerica', ascending=True)

# Permutar aleatoriamente las filas
df = df.sample(frac=1, random_state=42)

# Seleccionar columnas relevantes
df = df[['columna1', 'columna2', 'columna3']]
```

3. Detección y eliminación de duplicados

```python
# Identificar duplicados
duplicados = df.duplicated().sum()
print(f"Registros duplicados: {duplicados}")

# Eliminar duplicados
df = df.drop_duplicates()
```

4. Reemplazo de valores y discretización

```python
# Reemplazar valores en columnas categóricas
df['columna_categorica'].replace({'valor_incorrecto': 'valor_correcto'}, inplace=True)

# Discretización de una columna numérica en rangos
df['rango'] = pd.cut(df['columna_numerica'], bins=[0, 10, 20, 30],
                     labels=['Bajo', 'Medio', 'Alto'])
```

5. Enriquecimiento de datos

```python
# Crear una nueva columna a partir de un cálculo
df['nueva_columna'] = df['columna1'] * df['columna2']

# Aplicar función con apply
def calcular_valor(x):
    return x * 2

df['valor_doble'] = df['columna_numerica'].apply(calcular_valor)

# Aplicar transformación con lambda
df['columna_modificada'] = df['columna_texto'].apply(lambda x: x.upper())
```

6. Manipulación de la estructura del DataFrame

```python
# Agregar una nueva columna
df['nueva_info'] = 'Dato agregado'

# Eliminar una columna
df.drop(columns=['columna_a_eliminar'], inplace=True)

# Redimensionar el DataFrame
df = df.iloc[:100, :]

# Renombrar columnas
df.rename(columns={'columna_vieja': 'columna_nueva'}, inplace=True)
```

7. Exportación de datos

```python
# Guardar el dataset transformado
df.to_csv('datos_transformados.csv', index=False)
df.to_excel('datos_transformados.xlsx', index=False)
```