Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😁

alkemy

Clase grabada

Manejo de valores perdidos y outliers - Parte I

Aprendizaje Esperado 4: Aplicar técnicas para la identificación y tratamiento de valores perdidos en un set de datos utilizando librerías de python para la resolución de un problema.

Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**

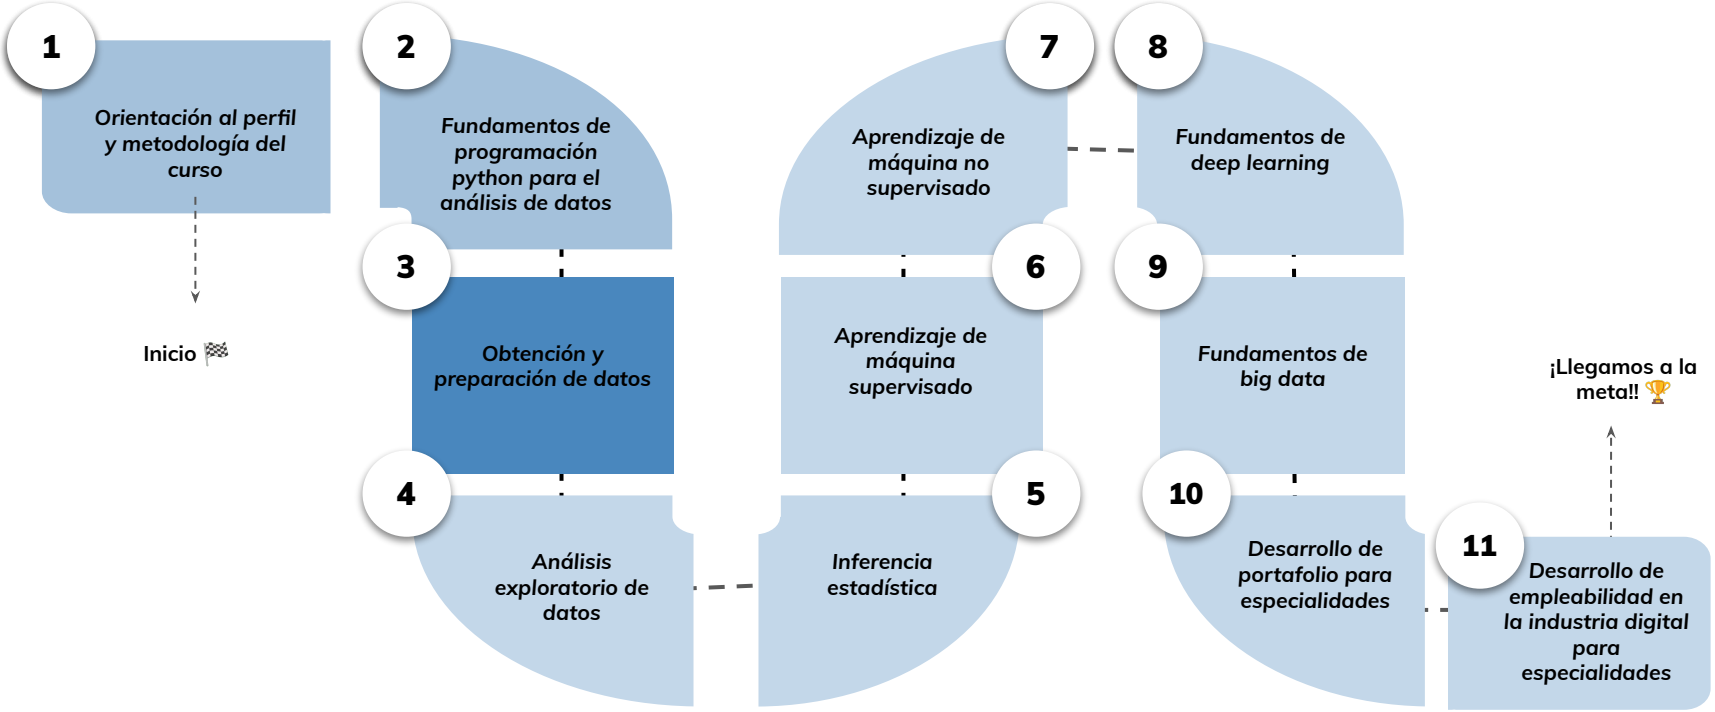

alkemy

Roadmap de lecciones

*¿Cuáles **lecciones** estaremos estudiando en este módulo?*

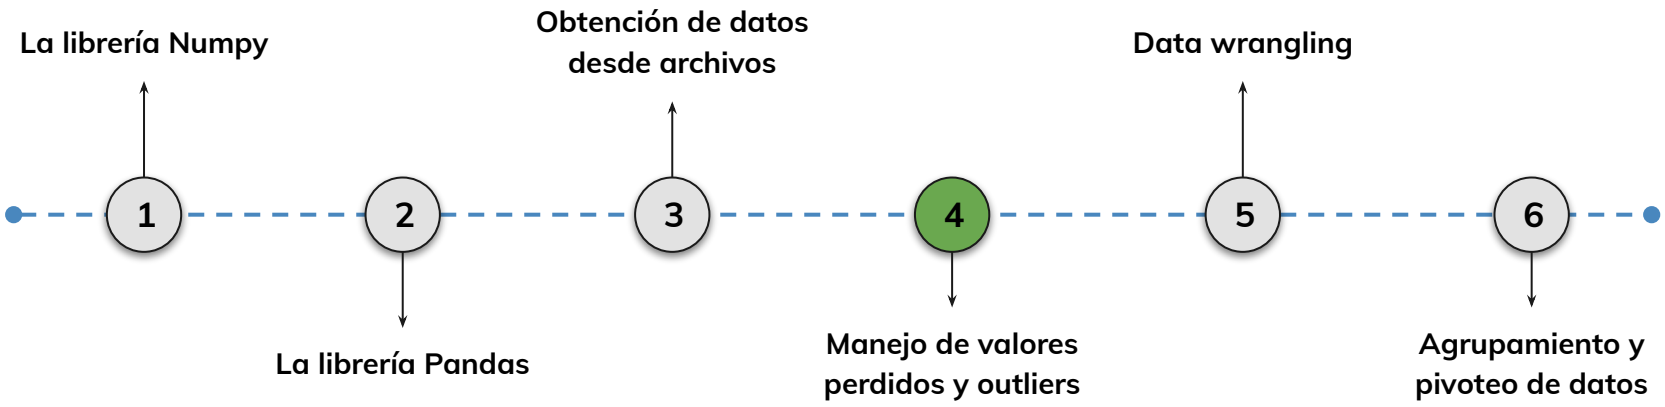

alkemy

Learning Path

¿Cuáles temas trabajaremos hoy?

4.

Tratamiento de valores perdidos y outliers en datasets

Aprenderemos a identificar, visualizar y tratar valores perdidos y atípicos en conjuntos de datos usando Pandas y librerías de visualización, aplicando métodos de eliminación e imputación.

- **Valores perdidos**
  - **Qué son y causas comunes.**
  - **Identificación con Pandas (isnull(), sum()).**
- **Outliers (valores atípicos)**
  - **Definición y causas.**
  - **Decisión: eliminación, ajuste o conservación según contexto.**

Objetivos de aprendizaje

¿Qué aprenderás?

- Detectar valores perdidos en un DataFrame.
- Visualizar patrones de datos ausentes.
- Aplicar técnicas de eliminación e imputación según el contexto.
- Identificar outliers con métodos estadísticos y gráficos.
- Decidir estrategias de manejo para mejorar la calidad del dataset.

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos 📚:

→ *Leímos archivos grandes optimizando memoria con chunksize, usecols y dtype.*

→ *Convertimos datos entre múltiples formatos: CSV, Excel, JSON y Parquet.*

→ *Automatizamos la obtención de datos con schedule y datetime.*

→ *Integramos información desde diversas fuentes: CSV, Excel, Web, API y bases de datos SQL.*

Manejo de valores perdidos y outliers

Manejo de valores Perdidos y Outliers

El análisis de datos es un proceso crítico en la toma de decisiones en múltiples industrias, desde el sector financiero hasta la investigación médica y la inteligencia artificial. Uno de los principales desafíos en este proceso es la **calidad de los datos**, ya que un conjunto de datos incompleto o contaminado con valores atípicos puede llevar a conclusiones erróneas y modelos predictivos poco precisos.

Introducción a los problemas de Calidad de Datos

Dos de los problemas más comunes que afectan la calidad de los datos son los **valores perdidos** y los **outliers**. Los valores perdidos pueden surgir por diversas razones, como fallos en la recopilación de datos, errores de ingreso o incluso restricciones en la captura de información. Ignorar estos valores puede generar análisis sesgados o incluso hacer que algunos modelos de machine learning fallen por completo.

Por otro lado, los **outliers** o valores atípicos son datos que se desvían significativamente de la tendencia general del conjunto de datos. Estos valores pueden ser resultado de errores en la medición o representar información valiosa sobre eventos extremos o anomalías en el fenómeno estudiado. Identificar y manejar adecuadamente los outliers es fundamental para mejorar la precisión de los modelos analíticos y garantizar interpretaciones confiables.

¿Qué es un Valor Perdido?

Un **valor perdido** se refiere a la ausencia de información en un conjunto de datos. En términos computacionales, Pandas representa los valores perdidos como NaN (*Not a Number*) o como valores nulos (None). Estos valores pueden aparecer por múltiples razones:

1

Errores en la captura de datos

Sensores defectuosos, problemas en formularios digitales o pérdida de paquetes de información.

2

Falta de respuesta

Encuestas incompletas, datos que no fueron proporcionados por los participantes.

3

Integración de bases de datos

Fusión de varias fuentes donde algunas contienen información parcial.

Más causas de valores perdidos

1

Reglas de negocio

Campos opcionales que no siempre se completan en sistemas empresariales.

2

Problemas de formato

Datos mal formateados que no son reconocidos por el sistema.

3

Errores humanos

Ocurren cuando los datos se ingresan manualmente y algunos valores se omiten por accidente.

4

Fallas tecnológicas

En sistemas de recopilación de datos automatizados, pueden producirse errores que impidan la captura completa de información.

La presencia de valores perdidos afecta la interpretación de los datos, las visualizaciones y los modelos predictivos. Dependiendo de la cantidad de datos faltantes y la importancia de la variable afectada, es crucial tomar decisiones sobre cómo tratarlos.

Ejemplo de DataFrame con Valores Perdidos

En este ejemplo podemos observar un DataFrame de Pandas que contiene valores perdidos representados como NaN. Estos valores ausentes pueden afectar significativamente cualquier análisis que se realice sobre estos datos si no son tratados adecuadamente.

```
import pandas as pd
import numpy as np

# Creación de un DataFrame con valores nulos
datos = {'Nombre': ['Ana', 'Luis', 'Carlos', 'Sofía', np.nan],
         'Edad': [25, None, 30, 28, 22],
         'Ciudad': ['Madrid', 'Barcelona', np.nan, 'Sevilla', 'Bilbao']}

df = pd.DataFrame(datos)
print(df)
```

Identificación de valores perdidos

Para detectar valores perdidos en Pandas, se pueden utilizar diversas funciones que permiten cuantificar y visualizar la cantidad de datos ausentes en un DataFrame.

Funciones básicas de Pandas

- df.isnull() - Devuelve un DataFrame de booleanos donde True indica un valor nulo
- df.isnull().sum() - Cuenta el número de valores nulos por columna
- df.isnull().sum().sum() - Cuenta el número total de valores nulos en el DataFrame

Visualización de valores perdidos

- Bibliotecas como missingno permiten crear visualizaciones específicas
- Seaborn puede utilizarse para crear mapas de calor que muestren patrones
- Matplotlib para gráficos personalizados que resalten valores ausentes

Visualización de valores perdidos

En este gráfico, los valores ausentes aparecen en color diferente, lo que permite identificar patrones en la distribución de los datos faltantes. Las visualizaciones son herramientas poderosas para comprender la estructura de los valores perdidos en conjuntos de datos grandes.

```
import missingno as msno
import matplotlib.pyplot as plt

# Visualizar los valores perdidos en un gráfico de matriz
msno.matrix(df)
plt.show()
```

Patrones de valores nulos

Este gráfico de calor muestra correlaciones entre columnas con valores faltantes, lo que puede indicar relaciones en la estructura de los datos. Identificar estos patrones es fundamental para determinar la estrategia más adecuada para el tratamiento de los valores perdidos.

```
msno.heatmap(df)
plt.show()
```

Filtrado de la Data Perdida

Eliminación de Filas o Columnas con Valores Perdidos

Identificar valores perdidos

Utilizar funciones como df.isnull() para detectar dónde están los valores ausentes

Evaluar el porcentaje

Calcular qué porcentaje del conjunto de datos está afectado por valores perdidos

Eliminar si es apropiado

Si los valores faltantes representan una fracción muy pequeña del conjunto de datos, se pueden eliminar para evitar sesgos

Si una columna entera tiene un alto porcentaje de valores nulos, puede ser eliminada. Este método es útil cuando la eliminación no afecta significativamente la información general.

Métodos de Eliminación en Pandas

df.dropna()

Elimina filas que contienen al menos un valor NaN

```
# Eliminar filas con valores nulosdf_clean = df.dropna()
```

df.dropna(axis=1)

Elimina columnas que contienen al menos un valor NaN

```
# Eliminar columnas con valores nulosdf_clean = df.dropna(axis=1)
```

df.dropna(thresh=n)

Elimina filas que no tienen al menos n valores no nulos

```
# Mantener filas con al menos 5 valores no nulosdf_clean = df.dropna(thresh=5)
```

Imputación de Datos

En muchos casos, eliminar datos no es la mejor opción, por lo que se recurre a la imputación, es decir, completar los valores faltantes con estimaciones basadas en otros datos. La imputación de datos permite conservar la mayor cantidad posible de información y evitar la reducción del tamaño del conjunto de datos, lo que es especialmente útil en situaciones donde la eliminación de valores perdidos podría causar sesgos o afectar negativamente los análisis.

Métodos de Imputación

Existen diversos métodos para la imputación de datos, cada uno adecuado para distintos tipos de conjuntos de datos y contextos analíticos. La selección del método correcto depende de la naturaleza de la variable afectada, la cantidad de valores faltantes y el impacto que estos pueden tener en el análisis posterior.

Imputación estadística

Utiliza medidas como la media, mediana o moda para reemplazar valores perdidos

Imputación categórica

Métodos específicos para variables cualitativas como la moda o nueva categoría

Imputación con ML

Utiliza algoritmos de aprendizaje automático para predecir los valores faltantes

Imputación con valores estadísticos

Una de las formas más comunes de imputación es el uso de valores estadísticos, donde se reemplazan los valores perdidos con medidas de tendencia central, como la media, la mediana o la moda. Esta técnica es ampliamente utilizada debido a su facilidad de implementación y efectividad en muchos casos.

1

Imputación con la media

Se utiliza cuando los datos siguen una distribución normal. La media es útil para mantener la coherencia en distribuciones simétricas, aunque puede verse afectada por la presencia de outliers.

2

Imputación con la mediana

Se recomienda cuando los datos contienen outliers, ya que la mediana es menos sensible a valores extremos.

3

Imputación con la moda

Se emplea principalmente en datos categóricos, donde los valores faltantes se reemplazan con la categoría más frecuente.

Ejemplo

Imputación con media y mediana

```
# Imputación con la media
df['Edad'].fillna(df['Edad'].mean(), inplace=True)
# Imputación con la mediana
df['Salario'].fillna(df['Salario'].median(),
inplace=True)
```

En este ejemplo, los valores faltantes en la columna **Edad** se reemplazan con la media de la columna, mientras que los valores de **Salario** se imputan con la mediana.

alkemy

Imputación de valores Categóricos con la Moda

Cuando se trabaja con datos categóricos, la imputación con la moda es una estrategia común. Dado que las categorías no tienen valores numéricos, no es posible calcular una media o mediana, por lo que el método más sencillo es asignar la categoría más frecuente a los valores perdidos.

```
# Imputación con la moda
df['Producto'].fillna(df['Producto'].mode()[0],
inplace=True)df['Marca'].fillna(df['Marca'].mode()[0],
inplace=True)
```

En este caso, los valores ausentes en la columna **Producto** y **Marca** se reemplazan con la categoría más frecuente de cada columna.

Imputación con una Nueva Categoría

Otra estrategia para manejar valores perdidos en datos categóricos es la creación de una **nueva categoría** que represente los datos ausentes. Esto es útil en encuestas o bases de datos donde la ausencia de un valor tiene un significado particular.

```
# Imputación con nueva
categoríadf['Respuesta'].fillna('No respondió',
inplace=True)df['Preferencia'].fillna('Sin preferencia',
inplace=True)
```

Este método permite diferenciar los valores imputados de los datos originales y es útil en modelos donde la ausencia de un dato puede ser un factor relevante.

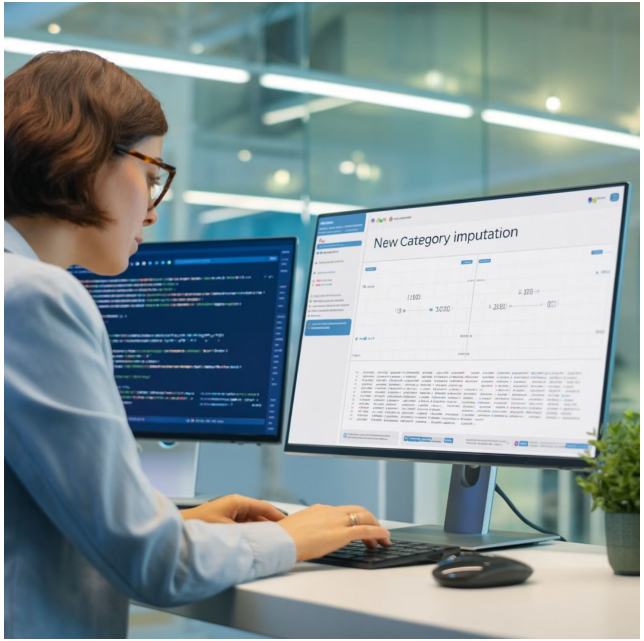

Imputación basada en relaciones con otras variables

Cuando los valores faltantes tienen una relación con otras variables en el conjunto de datos, es posible imputarlos utilizando esas relaciones. Por ejemplo, en un dataset de salarios, el salario de una persona puede estar correlacionado con su nivel educativo o experiencia laboral.

```
# Agrupar por edad y calcular el salario promedio
salario_por_edad = df.groupby('Edad')['Salario'].mean()

# Imputar valores faltantes de salario según la edad
for idx, row in df.iterrows():
  if pd.isna(row['Salario']):
    edad = row['Edad']
    if edad in salario_por_edad:
      df.at[idx, 'Salario'] = salario_por_edad[edad]
```

En este caso, los valores faltantes en **Salario** se imputan con el salario promedio de personas con la misma edad.

Imputación mediante modelos predictivos

Los modelos de machine learning también pueden usarse para predecir los valores faltantes. Algoritmos como regresión lineal, árboles de decisión o k-vecinos más cercanos (**KNN**) pueden estimar valores ausentes con base en otras características del conjunto de datos.

```
from sklearn.impute import KNNImputer
import pandas as pd
# Crear el imputador KNN
imputer = KNNImputer(n_neighbors=5)
# Aplicar la imputación
df_imputed = pd.DataFrame(
    imputer.fit_transform(df),
    columns=df.columns
)
```

Este método es más avanzado y requiere entrenamiento previo, pero puede ser útil en datasets complejos con múltiples relaciones entre variables.

Imputación de Valores Cualitativos

Los valores cualitativos o categóricos en un conjunto de datos pueden contener valores faltantes, lo que puede afectar análisis exploratorios y modelos predictivos. A diferencia de los valores numéricos, que pueden completarse con estadísticas como la media o la mediana, los valores cualitativos requieren enfoques diferentes para su imputación.

Características de los datos cualitativos

Los datos cualitativos pueden representar categorías como nombres de ciudades, tipos de productos, clasificaciones o respuestas de encuestas. La ausencia de estos valores puede ser problemática, ya que afecta análisis de segmentación, modelos de machine learning y generación de reportes.

Tipos de datos cualitativos

- Nominales: categorías sin orden (colores, países)
- Ordinales: categorías con orden (bajo, medio, alto)
- Binarios: solo dos categorías (sí/no, verdadero/falso)

Desafíos en la imputación

- No se pueden calcular promedios
- La frecuencia puede no ser representativa
- Pueden existir relaciones complejas con otras variables

Métodos de imputación para valores cualitativos

1

Imputación con la moda

Se reemplazan los valores faltantes con la categoría más frecuente en la columna.

2

Imputación con una nueva categoría

Se asigna un valor como "Desconocido" o "Otro" para representar los valores faltantes.

3

Imputación basada en agrupaciones

Se rellenan los valores en función de otra variable relacionada.

4

Imputación con modelos predictivos

Se usan modelos de machine learning para estimar los valores faltantes.

Ejemplo Práctico de Imputación con la Moda

La imputación con la moda es una solución rápida y efectiva cuando los datos tienen una categoría dominante. Sin embargo, en casos donde las categorías están distribuidas equitativamente, se recomienda evaluar otros métodos.

```
import pandas as pd

# Crear un DataFrame con valores categóricos faltantes
datos = {'Producto': ['Laptop', 'Tablet', None, 'Smartphone', 'Tablet'],
         'Marca': ['Dell', 'Apple', 'Samsung', None, 'Apple']}

df = pd.DataFrame(datos)

# Imputar valores faltantes con la moda
df['Producto'].fillna(df['Producto'].mode()[0], inplace=True)
df['Marca'].fillna(df['Marca'].mode()[0], inplace=True)

print(df)
```

Imputación con una Nueva Categoría

Este método es útil en análisis donde la presencia de valores nulos puede tener un significado particular, como en encuestas o registros administrativos. La creación de una categoría específica para valores faltantes permite mantener la información sobre la ausencia de datos, lo que puede ser relevante para ciertos análisis.

```
df['Producto'].fillna('Desconocido', inplace=True)
df['Marca'].fillna('Sin Marca', inplace=True)
```

¿Qué es un Outlier?

Un outlier o valor atípico es un dato que se aleja significativamente del resto de los valores. Puede deberse a errores en la medición o representar eventos inusuales.

Los outliers pueden detectarse utilizando métodos estadísticos:

- Regla de 1.5 veces el IQR
- Desviación estándar
- Diagramas de caja (Boxplots)

Definición detallada de Outlier

Un outlier o valor atípico es una observación que se encuentra significativamente separada del resto de los datos. Estos valores pueden surgir debido a errores en la medición, fallas en los sensores, entrada incorrecta de datos o, en algunos casos, representar eventos genuinos pero extremos.

Los outliers pueden sesgar análisis estadísticos, afectar la precisión de modelos de machine learning y generar visualizaciones distorsionadas. Por ello, es fundamental identificarlos y decidir si deben eliminarse, ajustarse o conservarse.

Métodos de Detección de Outliers

Existen varias técnicas para detectar outliers en un conjunto de datos:

1

Método del rango intercuartil (IQR)

Se basa en los percentiles 25 y 75 para identificar valores extremos.

$$Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR$$

2

Z-score

Detecta valores que se alejan más de un cierto número de desviaciones estándar de la media.

3

Diagramas de caja (Boxplots)

Visualizan la distribución de los datos y resaltan valores extremos.

Método del Rango Intercuartil (IQR)

El método IQR es una técnica robusta para detectar outliers que no se ve afectada por los valores extremos mismos:

1. Calcular Q1 (percentil 25) y Q3 (percentil 75)
2. Calcular IQR = Q3 - Q1
3. Definir límites: Inferior = Q1 - 1.5*IQR, Superior = Q3 + 1.5*IQR
4. Identificar outliers: valores < límite inferior o > límite superior

```python
import pandas as pd

# Simulación de datos
data = pd.DataFrame({'valor': [10, 12, 13, 14, 15, 16, 17, 80]})

# Calcular IQR
Q1 = data['valor'].quantile(0.25)
Q3 = data['valor'].quantile(0.75)
IQR = Q3 - Q1

# Filtrar outliers
outliers = data[(data['valor'] < Q1 - 1.5 * IQR) | (data['valor'] > Q3 + 1.5 * IQR)]
print("Outliers por IQR:\n", outliers)
```

Método Z-score

El Z-score mide cuántas desviaciones estándar se aleja un valor de la media:

$$Z = \frac{X - \mu}{\sigma}$$

```python
from scipy.stats import zscore

data['z_score'] = zscore(data['valor'])
outliers_z = data[(data['z_score'] > 3) | (data['z_score'] < -3)]
print("Outliers por Z-score:\n", outliers_z)
```

Donde:

- X es el valor a evaluar
- μ es la media de la población
- σ es la desviación estándar

Se considera outlier un dato con un Z-score > 3 o < -3.

Diagramas de Caja (Boxplots)

Explicación: El boxplot muestra la mediana, cuartiles y outliers como puntos fuera de los "bigotes". Esta visualización permite identificar rápidamente valores atípicos y comprender la distribución general de los datos.

```
import seaborn as sns
import matplotlib.pyplot as plt

sns.boxplot(x=data['valor'])
plt.title("Boxplot de valores")
plt.show()
```

Histogramas y gráficos de dispersión

Histograma

Explicación: Permite observar si existen valores extremos con baja frecuencia.

```
import matplotlib.pyplot as
pltplt.hist(df['Columna'],
bins=30)plt.title('Histograma')plt.show()
```

Gráfico de Dispersión

```
# Simulamos un eje x
data['indice'] = range(len(data))
plt.scatter(data['indice'], data['valor'], color='orange')
plt.title("Gráfico de dispersión")
plt.xlabel("Indice")
plt.ylabel("Valor")
plt.show()
```

Explicación: Útil para detectar outliers en relación con la posición o el tiempo.

Live Coding

¿En qué consistirá la Demo?

Aplicaremos paso a paso técnicas de detección, visualización y tratamiento de valores perdidos y outliers en un dataset real.

1. *Generar un dataset de ejemplo.*
2. *Detectar valores perdidos con isnull() y contarlos.*
3. *Visualizar datos faltantes con missingno y Seaborn.*
4. *Eliminar filas o columnas con dropna().*
5. *Imputar datos numéricos con media y mediana, y categóricos con moda o nueva categoría.*
6. *Detectar outliers con IQR y Z-score.*
7. *Visualizar outliers con boxplots y scatter plots.*

Tiempo: 25 Minutos

Momento:

Time-out!

⏰5 -10 min.

alkemy

Ejercicio N° 1

Limpieza y depuración de datos

Limpieza y depuración de datos

Contexto: 🙌

Trabajarás con un dataset que contiene valores faltantes y atípicos. El objetivo es limpiarlo para que esté listo para su análisis posterior.

Consigna: ✍️

1. Identifica valores perdidos y visualiza sus patrones.
2. Aplica al menos dos métodos de imputación.
3. Detecta outliers con el método IQR y visualízalos con boxplots.
4. Decide qué hacer con los outliers (eliminarlos, ajustarlos o conservarlos) y justifica tu decisión.

Paso a paso: ⚙️

1. Cargar y explorar el dataset.
2. Aplicar detección y visualización de valores perdidos.
3. Imputar o eliminar según corresponda.
4. Detectar y analizar outliers.

Tiempo 🕐**:** *45 Minutos*

¿Alguna consulta?

alkemy

Resumen

¿Qué logramos en esta clase?

- ✓ ***Detectamos y cuantificamos valores perdidos en datasets.***
- ✓ ***Visualizamos patrones de datos ausentes para entender su distribución.***
- ✓ ***Aplicamos estrategias de eliminación e imputación.***
- ✓ ***Identificamos outliers mediante métodos estadísticos y gráficos.***
- ✓ ***Mejoramos la calidad del dataset para futuros análisis y modelados.***

¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las ***actividades disponibles en la plataforma.*** *Estas propuestas son clave para afianzar lo trabajado y* ***forman parte obligatoria del recorrido de aprendizaje.***

💪 Análisis de caso ——— 💪 Selección Múltiple

💪 Comprensión lectora

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

alkemy

< ¡Muchas gracias! >

alkemy