Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😁

alkemy

Clase grabada

› Manejo de valores perdidos y outliers - Parte II

Aprendizaje Esperado 4: Aplicar técnicas para la identificación y tratamiento de valores perdidos en un set de datos utilizando librerías de python para la resolución de un problema.

alkemy

Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**

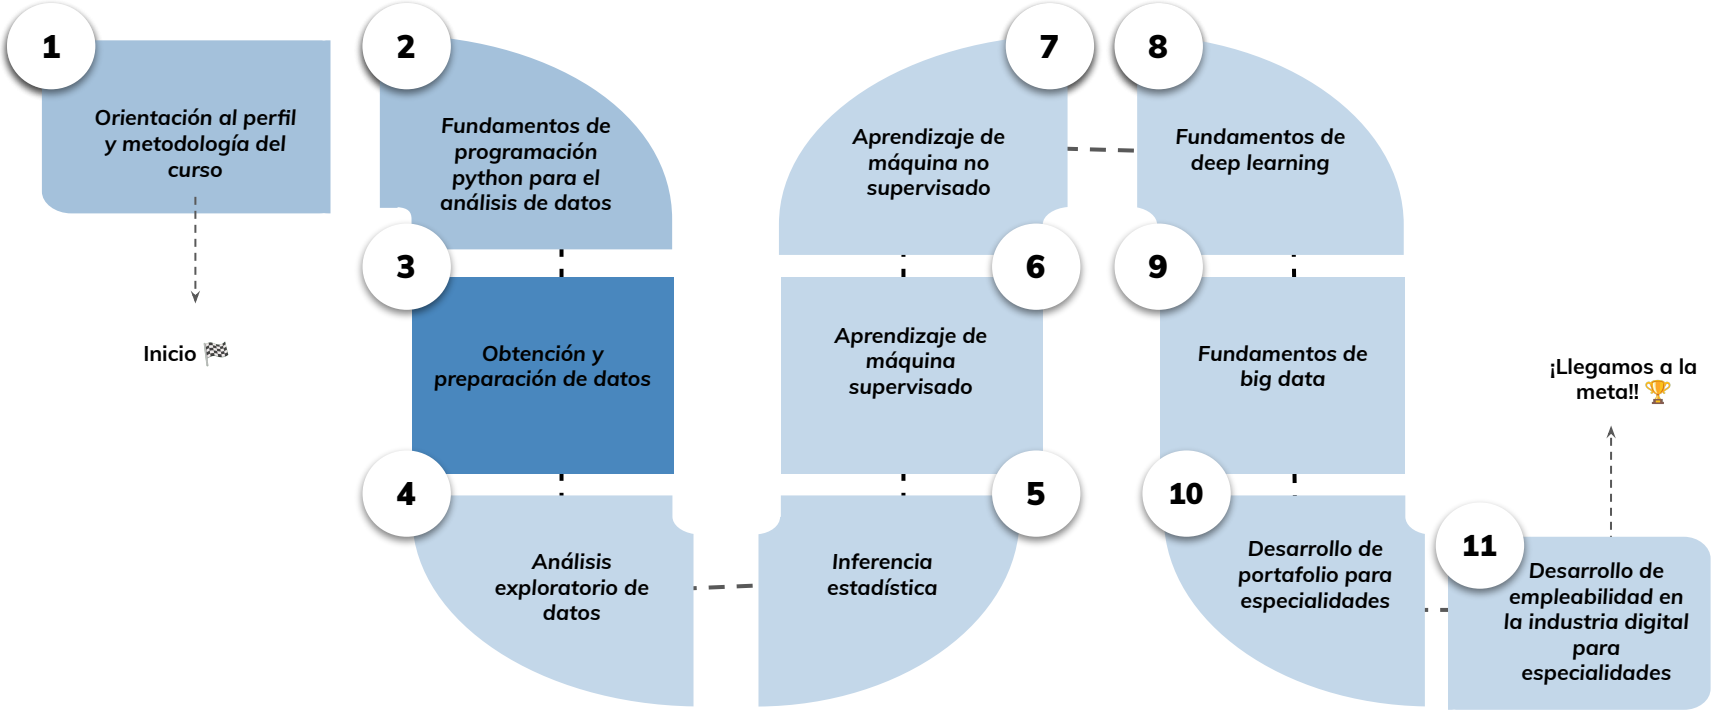

alkemy

Roadmap de lecciones

*¿Cuáles **lecciones** estaremos estudiando en este módulo?*

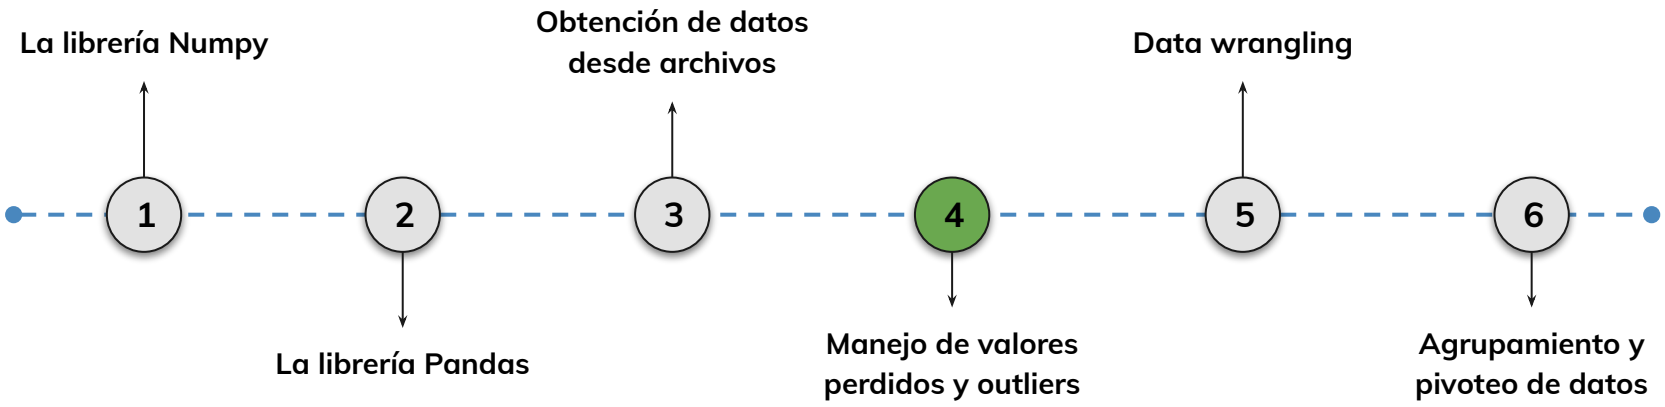

alkemy

Learning Path

¿Cuáles temas trabajaremos hoy?

4.

Tratamiento avanzado y estrategias combinadas para valores perdidos y outliers

Profundizaremos en métodos avanzados para el tratamiento de valores perdidos y outliers, incluyendo técnicas basadas en machine learning, transformaciones, winsorización y uso de algoritmos robustos.

- **Detección y tratamiento avanzado de outliers**
  - **Isolation Forest y algoritmos de detección de anomalías.**
  - **Modelos robustos menos sensibles a valores atípicos.**
- **Estrategias combinadas y mejores prácticas**
  - **Integración del tratamiento de valores perdidos y outliers.**
  - **Evaluación del impacto en el análisis y modelos de ML.**

Objetivos de aprendizaje

¿Qué aprenderás?

- Aplicar algoritmos de machine learning para la detección de outliers.
- Implementar técnicas de winsorización y transformaciones para reducir impacto de valores atípicos.
- Usar modelos robustos como RANSAC y árboles de decisión.
- Integrar el tratamiento de valores perdidos y outliers en un flujo de limpieza de datos.
- Documentar y evaluar el impacto de las decisiones tomadas.

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos 📚:

→ *Detectamos valores perdidos con isnull() y visualizamos patrones con missingno y Seaborn.*

→ *Aplicamos estrategias de eliminación (dropna) e imputación (media, mediana, moda, nuevas categorías).*

→ *Detectamos outliers con métodos estadísticos como IQR y Z-score.*

→ *Visualizamos outliers usando boxplots e histogramas.*

Manejo de valores perdidos y outliers

Modelos basados en aprendizaje automático

Algoritmos como Isolation Forest pueden detectar anomalías en conjuntos de datos grandes.

```
from sklearn.ensemble import
IsolationForest# Crear y entrenar el
modelomodel =
IsolationForest(contamination=0.05)model.fit
(df[['Columna1', 'Columna2']])# Predecir
outliers (-1 para outliers, 1 para
inliers)outliers =
model.predict(df[['Columna1', 'Columna2']])
```

Estos métodos son especialmente útiles para:

- Conjuntos de datos multidimensionales
- Cuando las relaciones entre variables son complejas
- Detección de anomalías en tiempo real
- Datos con distribuciones no normales

```
import numpy as npimport pandas as pd# Datos de ejemplodatos =
[25, 29, 30, 31, 32, 35, 37, 120, 300]df = pd.DataFrame(datos,
columns=['Valor'])# Calcular Q1, Q3 e IQRQ1 =
df['Valor'].quantile(0.25)Q3 = df['Valor'].quantile(0.75)IQR =
Q3 - Q1# Definir límiteslimite_inferior = Q1 - 1.5 *
IQRlimite_superior = Q3 + 1.5 * IQR# Filtrar outliersoutliers =
df[(df['Valor'] < limite_inferior) |               (df['Valor']
> limite_superior)]print("Outliers:",
outliers['Valor'].tolist())# Datos sin outliersdatos_limpios =
df[(df['Valor'] >= limite_inferior) &
(df['Valor'] <= limite_superior)]
```

Ejemplo práctico de detección de outliers con IQR

En este ejemplo, se eliminan los valores 120 y 300, que son significativamente diferentes del resto de los datos.

alkemy

Detección de Outliers con Z-score

Otra forma de detectar valores atípicos es utilizando la puntuación Z-score, que mide cuántas desviaciones estándar está un valor con respecto a la media.

```
from scipy import statsimport numpy as npimport pandas as pd# Datos de ejemplodatos = [25, 29, 30, 31, 32, 35, 37, 120, 300]df = pd.DataFrame(datos, columns=['Valor'])# Calcular Z-scorez_scores = stats.zscore(df['Valor'])df['Z-score'] = z_scores# Identificar outliers (|z| > 3)outliers = df[abs(df['Z-score']) > 3]print("Outliers:", outliers['Valor'].tolist())# Datos sin outliersdatos_limpios = df[abs(df['Z-score']) <= 3]
```

El Z-score es útil cuando los datos siguen una distribución normal y permite ajustar el umbral de detección según la aplicación.

Eliminación de Outliers

Después de identificar los outliers, se debe decidir si eliminarlos, ajustarlos o transformarlos. En algunos casos, los outliers contienen información valiosa y no deben eliminarse arbitrariamente.

Cuándo eliminar outliers

- Cuando son claramente errores de medición
- Cuando distorsionan significativamente los análisis estadísticos
- Cuando afectan negativamente el rendimiento de modelos predictivos

Cuándo conservar outliers

- Cuando representan eventos reales aunque poco comunes
- En detección de fraudes o anomalías donde son el foco del análisis
- Cuando la muestra es pequeña y cada observación es valiosa

Métodos para Tratar Outliers

Eliminación

Remover completamente los valores atípicos del conjunto de datos

Transformación

Aplicar funciones como logaritmo o raíz cuadrada para reducir el impacto

Winsorización

Reemplazar valores extremos por el percentil más cercano (ej. P95 o P5)

Modelado robusto

Usar algoritmos menos sensibles a outliers (ej. regresión robusta)

Ejemplo de Winsorización

```
from scipy import statsimport numpy as
npimport pandas as pd# Datos de ejemplodatos
= [25, 29, 30, 31, 32, 35, 37, 120, 300]df =
pd.DataFrame(datos, columns=['Valor'])#
Winsorización al 5% y 95%winsorized =
stats.mstats.winsorize(df['Valor'],
limits=[0.05, 0.05])df['Winsorizado'] =
winsorizedprint(df)
```

La winsorización reemplaza los valores extremos por los percentiles especificados, reduciendo su impacto sin eliminarlos completamente.

Transformación de datos para reducir Outliers

Las transformaciones matemáticas pueden reducir el impacto de los outliers sin eliminarlos:

- Transformación logarítmica: log(x)
- Raíz cuadrada: sqrt(x)
- Box-Cox: familia de transformaciones potencia

Estas transformaciones comprimen los valores altos y expanden los bajos, reduciendo la influencia de outliers en análisis estadísticos.

```
import numpy as np# Transformación logarítmicadf['log_valor'] =
np.log1p(df['Valor'])  # log(1+x)# Transformación raíz cuadradadf['sqrt_valor'] =
np.sqrt(df['Valor'])
```

Uso de Algoritmos Robustos

Algunos algoritmos están diseñados para ser menos sensibles a la presencia de outliers:

Regresión robusta

Utiliza funciones de pérdida que penalizan menos los errores grandes, como Huber o RANSAC

```
from sklearn.linear_model import RANSACRegressormodel =
RANSACRegressor()model.fit(X, y)
```

Árboles de decisión

Naturalmente robustos a outliers ya que dividen el espacio en regiones

```
from sklearn.tree import DecisionTreeRegressormodel =
DecisionTreeRegressor()model.fit(X, y)
```

alkemy

Consideraciones especiales para Outliers

En algunos escenarios, los outliers contienen información valiosa y no deben eliminarse arbitrariamente.

Detección de fraudes

En sistemas financieros, los outliers pueden representar transacciones fraudulentas que son precisamente el objetivo del análisis.

Monitoreo de redes

En seguridad informática, patrones de tráfico inusuales pueden indicar intentos de intrusión o ataques.

Investigación médica

Respuestas atípicas a tratamientos pueden revelar información importante sobre subgrupos de pacientes o efectos secundarios raros.

Evaluación del Impacto de Outliers

Antes de decidir cómo tratar los outliers, es importante evaluar su impacto en el análisis:

1. Realizar análisis con y sin outliers
2. Comparar estadísticas descriptivas (media, desviación estándar)
3. Evaluar el rendimiento de modelos predictivos
4. Examinar visualizaciones para entender la naturaleza de los outliers

Documentación del Tratamiento de Outliers

Es fundamental documentar todas las decisiones tomadas respecto al tratamiento de outliers:

Qué documentar

- Métodos utilizados para detectar outliers
- Criterios de decisión para su tratamiento
- Cantidad y porcentaje de datos afectados
- Impacto en los resultados del análisis

Por qué es importante

- Garantiza la reproducibilidad del análisis
- Permite evaluar la validez de las conclusiones
- Facilita la comunicación con otros analistas
- Cumple con estándares de buenas prácticas en ciencia de datos

Estrategias Combinadas para Valores Perdidos y Outliers

En muchos casos, los conjuntos de datos presentan tanto valores perdidos como outliers, lo que requiere un enfoque integrado:

Exploración inicial

Analizar la distribución de datos, identificar patrones de valores perdidos y posibles outliers

Tratamiento de valores perdidos

Aplicar técnicas de imputación adecuadas según el tipo de variable y contexto

Detección de outliers

Utilizar métodos estadísticos o basados en machine learning para identificar valores atípicos

Tratamiento de outliers

Decidir si eliminar, transformar o mantener los outliers según su naturaleza e impacto

Validación

Evaluar el impacto de las transformaciones en los resultados del análisis

Herramientas para el Manejo de Valores Perdidos y Outliers

Pandas

Biblioteca principal para manipulación de datos en Python, con funciones específicas para detectar y tratar valores nulos

Scikit-learn

Ofrece herramientas de imputación y detección de anomalías como SimpleImputer, KNNImputer e IsolationForest

Missingno

Biblioteca especializada en la visualización de patrones de valores perdidos en conjuntos de datos

SciPy

Proporciona funciones estadísticas para la detección de outliers y transformaciones como la winsorización

Mejores prácticas para el manejo de datos faltantes

Comprender el origen

Investigar por qué faltan los datos antes de decidir cómo tratarlos. La causa puede influir en la estrategia de imputación.

Evaluar el patrón

Determinar si los datos faltan completamente al azar (MCAR), al azar (MAR) o no al azar (MNAR), ya que esto afecta la validez de diferentes métodos de imputación.

Documentar el proceso

Mantener un registro detallado de todas las transformaciones aplicadas para garantizar la reproducibilidad del análisis.

Validar resultados

Comparar los resultados antes y después de la imputación para evaluar el impacto en el análisis final.

Mejores prácticas para el manejo de Outliers

Análisis contextual

Evaluar si los outliers tienen sentido en el contexto del problema y el dominio específico.

Múltiples métodos

Utilizar varios métodos de detección para confirmar la presencia de outliers y reducir falsos positivos.

Enfoque conservador

Ser cauteloso al eliminar datos; considerar transformaciones o técnicas robustas antes de descartar observaciones.

Análisis de sensibilidad

Evaluar cómo diferentes tratamientos de outliers afectan los resultados finales del análisis.

Impacto en Modelos de Machine Learning

El tratamiento de valores perdidos y outliers puede tener un efecto significativo en el rendimiento de los modelos de machine learning:

Precisión

La presencia de outliers puede reducir la precisión de modelos sensibles como regresión lineal

Sobreajuste

Los modelos pueden ajustarse excesivamente a outliers, perdiendo capacidad de generalización

Entrenamiento

Los valores perdidos pueden impedir el entrenamiento de algunos algoritmos que no los toleran

Sesgo

La imputación incorrecta puede introducir sesgos en las predicciones

Sensibilidad de Algoritmos a Outliers

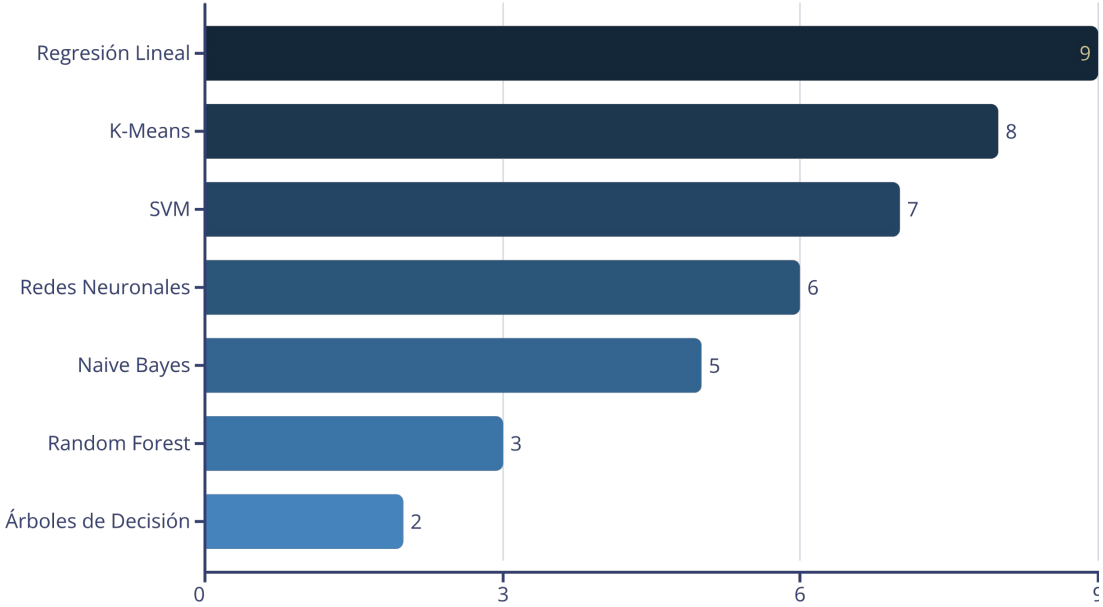

Algunos algoritmos son naturalmente más robustos frente a outliers, mientras que otros pueden verse significativamente afectados. Es importante considerar esta sensibilidad al seleccionar modelos para conjuntos de datos con valores atípicos.

Casos de Estudio: Valores Perdidos

Encuestas de satisfacción

En encuestas con preguntas opcionales, la falta de respuesta puede indicar indiferencia o desconocimiento. La imputación con una nueva categoría "No respondió" puede ser más informativa que usar la moda.

Datos de sensores IoT

En series temporales de sensores, los valores perdidos suelen deberse a fallos de comunicación. La imputación mediante interpolación temporal o métodos basados en la tendencia reciente suele ser efectiva.

Registros médicos

En historiales clínicos, la ausencia de ciertos valores puede tener significado médico. La colaboración con expertos del dominio es crucial para determinar la estrategia de imputación adecuada.

Casos de Estudio: Outliers

Detección de fraudes

En transacciones financieras, los outliers pueden representar actividades fraudulentas. Algoritmos como Isolation Forest o Local Outlier Factor son efectivos para identificar patrones inusuales sin eliminarlos.

Control de calidad

En procesos industriales, los outliers pueden indicar fallos en la maquinaria o defectos en productos. La detección temprana permite intervenciones preventivas.

Análisis de rendimiento deportivo

En estadísticas deportivas, los outliers pueden representar actuaciones excepcionales. En lugar de eliminarlos, suelen estudiarse para identificar factores de éxito.

Desafíos en el manejo de valores perdidos

Datos faltantes no al azar

Cuando la ausencia de datos está relacionada con el valor mismo (MNAR), la imputación puede introducir sesgos significativos.

Alto porcentaje de valores perdidos

Cuando más del 50% de los datos están ausentes, cualquier método de imputación puede ser cuestionable.

Variables categóricas con muchas categorías

La imputación con la moda puede no ser representativa cuando hay muchas categorías con frecuencias similares.

Relaciones complejas entre variables

Cuando existen dependencias no lineales entre variables, los métodos simples de imputación pueden no capturar estas relaciones.

Desafíos en el manejo de Outliers

Definición contextual

Lo que constituye un outlier puede variar según el dominio y el contexto específico del análisis.

Datos multidimensionales

En espacios de alta dimensionalidad, la detección de outliers se vuelve más compleja debido a la "maldición de la dimensionalidad".

Outliers en grupos

Algunos outliers pueden formar clusters propios, lo que dificulta su detección con métodos tradicionales.

Cambios temporales

En series temporales, lo que se considera normal puede cambiar con el tiempo, complicando la identificación de valores atípicos.

Tendencias futuras en el manejo de datos

Imputación con IA avanzada

Modelos generativos como GANs y transformers están siendo utilizados para crear imputaciones más precisas que preservan las relaciones complejas entre variables

AutoML para limpieza

Herramientas automatizadas que seleccionan y aplican los mejores métodos de imputación y tratamiento de outliers según las características de los datos

Detección en tiempo real

Sistemas que identifican y manejan valores perdidos y outliers en flujos de datos continuos, críticos para aplicaciones IoT y monitoreo

Aprendizaje federado

Técnicas que permiten imputar datos sin compartir información sensible entre organizaciones, preservando la privacidad

Evaluación de Métodos de Imputación

Para determinar la efectividad de diferentes métodos de imputación, se pueden utilizar varias técnicas de evaluación:

1

Validación cruzada

Eliminar artificialmente valores conocidos, imputarlos con diferentes métodos y comparar con los valores originales

2

Métricas de error

Utilizar RMSE, MAE u otras métricas para cuantificar la precisión de la imputación

3

Impacto en modelos

Evaluar cómo diferentes métodos de imputación afectan el rendimiento de modelos predictivos posteriores

4

Preservación de distribuciones

Verificar si la imputación mantiene las características estadísticas de los datos originales

Evaluación de Métodos de Detección de Outliers

La efectividad de los métodos de detección de outliers puede evaluarse mediante:

1

Datos sintéticos

Crear conjuntos de datos con outliers conocidos para evaluar la precisión de detección

2

Validación por expertos

Solicitar a especialistas del dominio que revisen los outliers detectados para confirmar su validez

3

Métricas de clasificación

Utilizar precisión, recall y F1-score cuando se dispone de etiquetas de outliers

4

Estabilidad

Evaluar si el método identifica consistentemente los mismos outliers en diferentes submuestras de los datos

Consideraciones Éticas

El manejo de valores perdidos y outliers también implica consideraciones éticas importantes:

Transparencia

Documentar y comunicar claramente todos los métodos utilizados para tratar datos faltantes y atípicos, especialmente en investigaciones científicas y aplicaciones críticas.

Sesgo potencial

Evaluar si los métodos de imputación pueden introducir o amplificar sesgos existentes en los datos, particularmente en aplicaciones que afectan a personas.

Representatividad

Asegurar que el tratamiento de valores perdidos y outliers no silencia voces minoritarias o casos poco comunes pero importantes.

Impacto en decisiones

Considerar cómo las técnicas aplicadas pueden afectar las decisiones basadas en los datos, especialmente en áreas sensibles como salud, finanzas o justicia.

Flujo de Trabajo Recomendado

1. **Exploración inicial**

   Analizar la distribución de datos, identificar patrones de valores perdidos y posibles outliers mediante visualizaciones y estadísticas descriptivas

2. **Comprensión del contexto**

   Investigar las causas de los valores perdidos y outliers, consultando con expertos del dominio cuando sea posible

3. **Estrategia de tratamiento**

   Definir métodos específicos para cada variable según su tipo, importancia y patrón de valores perdidos/outliers

4. **Implementación**

   Aplicar las técnicas seleccionadas, documentando cada paso del proceso

5. **Validación**

   Evaluar el impacto de las transformaciones en los resultados del análisis y ajustar si es necesario

6. **Documentación final**

   Registrar detalladamente todos los métodos utilizados, decisiones tomadas y su justificación

Glosario de Términos

MCAR (Missing Completely At Random)

Valores que faltan de forma totalmente aleatoria, sin relación con otras variables o con el valor mismo.

MNAR (Missing Not At Random)

Valores cuya ausencia está relacionada con el valor mismo que falta, lo que puede introducir sesgos significativos.

Z-score

Medida que indica cuántas desviaciones estándar se aleja un valor de la media.

MAR (Missing At Random)

Valores cuya ausencia está relacionada con otras variables observadas, pero no con el valor faltante mismo.

IQR (Rango Intercuartil)

Diferencia entre el tercer y primer cuartil, utilizada para detectar outliers.

Winsorización

Técnica que reemplaza valores extremos por percentiles específicos para reducir el impacto de outliers.

Conclusiones sobre el Manejo de Valores Perdidos

El manejo de valores perdidos y la imputación de datos son procesos fundamentales en el análisis y preparación de datos. La presencia de valores faltantes puede afectar significativamente la calidad de los modelos predictivos y la interpretación de los resultados. En este manual, hemos explorado diversas técnicas para identificar, eliminar e imputar valores nulos en conjuntos de datos estructurados.

La selección del método de imputación adecuado depende del tipo de dato afectado y del contexto del análisis. En el caso de datos numéricos, la imputación mediante la media, la mediana o modelos predictivos como KNN puede ser efectiva. Para datos categóricos, la moda o la asignación de una nueva categoría permiten preservar la integridad del conjunto de datos sin introducir sesgos significativos.

Es crucial que los analistas de datos evalúen el impacto de la imputación en sus modelos y realicen pruebas para determinar la estrategia más apropiada. La decisión de eliminar valores faltantes o imputarlos debe tomarse en función del porcentaje de datos ausentes y la relevancia de la variable en el estudio.

Conclusiones sobre el Manejo de Outliers

Además, la detección y el tratamiento de valores atípicos juegan un papel importante en la calidad del análisis. Los outliers pueden representar errores en los datos o, en algunos casos, eventos de interés. Utilizar herramientas como el rango intercuartílico (IQR) y el Z-score permite identificar y manejar adecuadamente estos valores atípicos para evitar sesgos en los resultados.

El enfoque para tratar outliers debe ser cuidadosamente considerado, evaluando si representan errores genuinos que deben corregirse o fenómenos reales que deben preservarse. En muchos casos, los outliers contienen información valiosa sobre eventos extremos o comportamientos inusuales que pueden ser el foco principal del análisis.

En última instancia, tanto el manejo de valores perdidos como el tratamiento de outliers deben formar parte de un proceso integral de preparación de datos que garantice la calidad y confiabilidad de los análisis posteriores. La documentación clara de todas las decisiones tomadas durante este proceso es esencial para la reproducibilidad y validez de los resultados.

Live Coding

¿En qué consistirá la Demo?

Implementaremos diferentes métodos para tratar outliers, desde estadísticos hasta basados en machine learning, y combinaremos estos procesos con imputación de valores perdidos.

1. *Generación de un dataset de ejemplo.*
2. *Detección de outliers con Isolation Forest.*
3. *Aplicación de winsorización para reducir el impacto de valores extremos.*
4. *Transformación de datos con logaritmo y raíz cuadrada.*
5. *Uso de un modelo robusto (RANSAC) para minimizar el impacto de outliers.*
6. *Integración del tratamiento de outliers y valores perdidos en un pipeline de limpieza.*

Tiempo: 25 Minutos

Momento:

Time-out!

⏰5 -10 min.

alkemy

Ejercicio N° 1

Tratamiento avanzado de valores perdidos y outliers

Tratamiento avanzado de valores perdidos y outliers

Contexto: 🙌

Trabajarás con un dataset que presenta simultáneamente valores faltantes y outliers. El objetivo es implementar un flujo de limpieza que permita preparar los datos para un análisis o modelado posterior.

Consigna: ✍️

1. Detecta valores perdidos y aplica técnicas de imputación adecuadas según el tipo de variable.
2. Identifica outliers con al menos dos métodos diferentes (uno estadístico y uno basado en ML).
3. Aplica winsorización o transformaciones para reducir el impacto de valores extremos.
4. Documenta el flujo y justifica las decisiones tomadas.

Tiempo 🕐**:** *45 Minutos*

Tratamiento avanzado de valores perdidos y outliers

Paso a paso: ⚙️

1. Cargar y explorar el dataset.
2. Aplicar imputación de valores perdidos.
3. Detectar outliers con métodos estadísticos y de ML.
4. Tratar los outliers según la estrategia elegida.
5. Guardar los datos limpios y documentar el proceso.

¿Alguna consulta?

alkemy

Resumen

¿Qué logramos en esta clase?

- ✓ ***Implementamos detección de outliers con Isolation Forest.***
- ✓ ***Aplicamos winsorización y transformaciones para reducir su impacto.***
- ✓ ***Utilizamos modelos robustos para minimizar el efecto de valores atípicos.***
- ✓ ***Integramos tratamiento de valores perdidos y outliers en un único flujo.***
- ✓ ***Documentamos el proceso y consideramos implicancias éticas y prácticas.***

¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las ***actividades disponibles en la plataforma.*** *Estas propuestas son clave para afianzar lo trabajado y* ***forman parte obligatoria del recorrido de aprendizaje.***

💪 Análisis de caso ——— 💪 Selección Múltiple

💪 Comprensión lectora

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

alkemy

< ¡Muchas gracias! >

alkemy