Conceptos básicos de estadística descriptiva

M4: Análisis exploratorio de datos

|**AE2**: Aplicar los conceptos fundamentales de estadística descriptiva para la caracterización de un conjunto de datos a partir de un problema dado.

alkemy

Introducción 🧑‍💻

En el análisis de datos, la estadística descriptiva cumple un rol esencial: permite comprender y resumir la información de una muestra o población de forma ordenada, facilitando su interpretación. Mediante diversas técnicas y representaciones, esta rama de la estadística nos brinda una primera aproximación sobre la distribución, dispersión y comportamiento de los datos antes de aplicar modelos más complejos.

Esta lección tiene como objetivo principal brindarte las herramientas necesarias para caracterizar un conjunto de datos a partir de un problema dado. A través del estudio de variables, medidas de centralización, dispersión y representación gráfica, estarás en condiciones de identificar patrones, detectar valores atípicos y comunicar hallazgos relevantes.

El dominio de estos conceptos resulta fundamental para cualquier disciplina que trabaje con datos: desde la ciencia hasta el marketing, pasando por salud, economía o tecnología.

Aprendizaje esperado

Cuando finalices la lección serás capaz de:

- Explicar los elementos básicos de la estadística descriptiva.
- Distinguir entre población y muestra, y aplicar la corrección de Bessel si corresponde.
- Construir tablas de frecuencia correctamente.
- Calcular media, mediana, moda, varianza, desviación estándar y rango de variación.
- Interpretar cuartiles, deciles, quintiles y percentiles.
- Generar gráficos de histogramas y boxplots para representar datos numéricos.

Conceptos básicos de estadística descriptiva

Tipos de variable

En estadística, una **variable** es una característica o propiedad que puede adquirir diferentes valores en un conjunto de datos. Estas variables permiten medir y describir fenómenos del mundo real, y son el punto de partida para cualquier análisis estadístico. Según su naturaleza, las variables pueden clasificarse principalmente en **categóricas** y **cuantitativas**. Esta distinción es fundamental ya que determina el tipo de análisis y representaciones gráficas que se pueden aplicar.

Las **variables categóricas** (también llamadas cualitativas) agrupan datos en categorías o grupos. No representan cantidades numéricas, sino cualidades o atributos. Pueden ser **nominales**, si no tienen un orden lógico (como "color de ojos"), o **ordinales**, si presentan un orden natural (como "nivel educativo": primario, secundario, terciario). Estas variables se analizan principalmente con frecuencias y proporciones, y se visualizan mediante gráficos de barras o sectores.

Por otro lado, las **variables cuantitativas** (o numéricas) representan cantidades medibles. Se subdividen en **discretas**, que toman valores enteros (por ejemplo, número de hijos), y **continuas**, que pueden tomar cualquier valor dentro de un intervalo (como el peso o la altura). Estas variables permiten el uso de operaciones matemáticas y estadísticas más complejas como promedios, desviaciones estándar y correlaciones.

Cuadro comparativo:

Tipo de Variable	**Subtipo**	**Ejemplo**	**Operaciones válidas**	**Representación común**
Categórica	Nominal	Color: rojo, azul	No	Gráfico de barras

Categórica	Ordinal	Nivel: bajo, medio	Parcialmente	Gráfico de barras
Cuantitativa	Discreta	N° hijos: 0,1,2,3...	Sí	Histograma, gráfico de líneas
Cuantitativa	Continua	Peso: 65.3 kg	Sí	Histograma, boxplot

Ejemplo práctico aplicado:
Supongamos que estás analizando datos de una encuesta de bienestar laboral. Algunas variables que podrías registrar son:

- **Edad** (cuantitativa continua)
- **Cantidad de hijos** (cuantitativa discreta)
- **Nivel de satisfacción laboral** (categórica ordinal: baja, media, alta)
- **Departamento de trabajo** (categórica nominal: ventas, finanzas, recursos humanos).

Cada tipo de variable requerirá distintos métodos de análisis: para edad podrías calcular la media y la desviación estándar; para satisfacción, usar porcentajes de frecuencia; y para cantidad de hijos, construir una tabla de frecuencia discreta.

Tablas de frecuencia

Las **tablas de frecuencia** son una herramienta esencial en estadística descriptiva para organizar y resumir un conjunto de datos. Permiten visualizar cuántas veces ocurre cada valor o grupo de valores de una variable, facilitando la comprensión del comportamiento general del conjunto. Se pueden aplicar tanto a variables categóricas como a variables cuantitativas, y son el punto de partida para construir representaciones gráficas como histogramas, diagramas de barras o sectores.

Una tabla de frecuencia típica incluye varias columnas:

- **Frecuencia absoluta (f)**: número de veces que se repite un valor en el conjunto de datos.

- **Frecuencia relativa (fr)**: proporción o porcentaje respecto al total de datos.

- **Frecuencia acumulada (fa)**: suma acumulativa de las frecuencias absolutas hasta un valor dado.

- **Frecuencia relativa acumulada (fra)**: equivalente acumulado en porcentaje.

Este tipo de organización es especialmente útil cuando se trabaja con grandes volúmenes de datos, ya que permite detectar patrones, identificar valores más comunes (moda), y observar la distribución general.

Ejemplo teórico-práctico:
Supongamos que se recogen las edades de 20 personas en una sala de espera:
25, 26, 28, 25, 30, 26, 28, 30, 32, 25, 25, 26, 30, 32, 28, 25, 26, 28, 30, 25.
Podemos construir una tabla de frecuencia como la siguiente:

Edad	**f**	**fr (%)**	**fa**	**fra (%)**
25	6	30	6	30
26	4	20	10	50
28	4	20	14	70
30	4	20	18	90
32	2	10	20	100

Esta tabla indica, por ejemplo, que el 50% de las personas tienen hasta 26 años, y que la edad más frecuente es 25 (la moda).

En el caso de **variables continuas**, en lugar de listar cada valor se agrupan en **intervalos de clase**. Esto es útil cuando hay muchos valores distintos o una alta dispersión. Por ejemplo, al analizar los sueldos de 200 empleados, podríamos agrupar en intervalos como: $0–$500, $501–$1000, etc., y construir una tabla similar pero por rangos.

Medidas de tendencia central: media, mediana y moda

Las **medidas de tendencia central** son estadísticas que permiten identificar un valor representativo en un conjunto de datos. Su función principal es resumir en un solo número la información más "típica" o común de una distribución. Las tres medidas más utilizadas son la **media**, la **mediana** y la **moda**, y cada una ofrece una perspectiva distinta sobre el comportamiento central de los datos.

La **media aritmética** (o simplemente promedio) se calcula sumando todos los valores y dividiendo por la cantidad total de observaciones. Es la medida más conocida y fácil de calcular, pero también la más sensible a valores extremos (outliers). Por ejemplo, si un conjunto de ingresos mensuales tiene un caso excepcionalmente alto, la media puede dar una impresión errónea de la realidad general.

La **mediana** es el valor que ocupa la posición central de un conjunto de datos ordenados. Si hay una cantidad impar de datos, es el valor del medio; si es par, es el promedio de los dos del centro. Su principal ventaja es que **no se ve afectada por valores extremos**, por lo que se utiliza cuando hay asimetrías en la distribución. En contextos como ingresos, puntuaciones o precios, es especialmente útil.

La **moda** es el valor que aparece con mayor frecuencia. Puede haber más de una (bimodal o multimodal) o ninguna (cuando todos los valores son distintos). Aunque suele asociarse a variables categóricas, también se utiliza en distribuciones numéricas para detectar concentraciones.

Comparativo de aplicación:

Medida	**Ideal cuando...**	**Ejemplo práctico**

Media	Distribución simétrica y sin outliers	Estimar el promedio de edad de una clase
Mediana	Datos asimétricos o con valores extremos	Ingresos de una población
Moda	Datos categóricos o búsqueda de frecuencia alta	Producto más vendido en una tienda

Ejemplo práctico:
Un grupo de estudiantes obtiene las siguientes notas en una prueba:
3, 6, 8, 9, 10, 10, 10, 4, 5

- Media: (3+6+8+9+10+10+10+4+5)/9 = 75/9 ≈ 8.33
- Mediana: Ordenando: 3, 4, 5, 6, 8, 9, 10, 10, 10 → Mediana = 8
- Moda: 10 (se repite 3 veces)

Medidas de dispersión: rango, varianza y desviación estándar

Mientras que las medidas de tendencia central resumen el comportamiento "promedio" de un conjunto de datos, las **medidas de dispersión** permiten evaluar **cuánto varían los datos respecto a ese centro**. Son fundamentales para entender la **homogeneidad o heterogeneidad** de una distribución y detectar si los valores están muy agrupados o dispersos.

La medida más simple de dispersión es el **rango**, que se calcula como la diferencia entre el valor máximo y el mínimo. Aunque útil como primera aproximación, tiene la desventaja de depender únicamente de dos valores, lo que puede ser engañoso si hay outliers.

La **varianza** representa el promedio de las diferencias cuadráticas entre cada valor y la media. Al elevar al cuadrado las diferencias, se evita que los signos negativos se anulen entre sí. Para poblaciones completas se divide entre *n*, y para muestras, entre *n-1* (esta es la **corrección de Bessel**, que se aplicará más

adelante).
Fórmula de varianza muestral:

$$s^2 = \frac{\sum(x_i - \bar{x})^2}{n-1}$$

La **desviación estándar** es la raíz cuadrada de la varianza, lo que la devuelve a las mismas unidades que los datos originales (por ejemplo, si los datos están en kilogramos, la varianza está en kg² y la desviación en kg). Es ampliamente utilizada porque permite interpretar rápidamente la dispersión promedio alrededor de la media.

Ejemplo práctico:
Notas de un grupo: 6, 6, 7, 7, 7, 8, 9

- Media = 7
- Rango = 9 - 6 = 3
- Varianza ≈ 1
- Desviación estándar ≈ 1

Otro grupo con: 3, 5, 7, 7, 9, 10, 11 (también media = 7)

- Varianza ≈ 9
- Desviación estándar ≈ 3
  Aunque ambos grupos tienen la misma media, el segundo tiene mayor dispersión. La desviación estándar permite detectar esto fácilmente.

Comparativo:

Métrica	**Qué mide**	**Cuándo usarla**
Rango	Extremos del conjunto	Primer vistazo rápido

Varianza	Variabilidad respecto a la media	Análisis más profundo (teórico)
Desviación estándar	Dispersión en unidades originales	Comparación directa con los datos

Población, muestra y corrección de Bessel

En estadística, es fundamental distinguir entre los conceptos de **población** y **muestra**, ya que de ello depende la forma en que se calculan muchas métricas. Una **población** representa el conjunto total de elementos u observaciones de interés en un estudio (por ejemplo, todos los habitantes de un país). En cambio, una **muestra** es un subconjunto representativo extraído de esa población, sobre el cual se realiza el análisis debido a que recolectar datos de toda la población suele ser costoso o inviable.

Cuando se trabaja con una muestra, los cálculos estadísticos deben ajustarse para evitar sesgos. Aquí entra en juego la **corrección de Bessel**, una modificación que se aplica al cálculo de la varianza y la desviación estándar muestral. Esta corrección consiste en dividir por n−1n - 1n−1 en lugar de por nnn al calcular la varianza, lo que compensa el hecho de que las muestras tienden a subestimar la variabilidad real de la población.

Matemáticamente, la varianza muestral se expresa como:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Donde xix_ixi son los valores individuales, x¯\bar{x}x¯ es la media de la muestra y nnn es el número de datos. Esta fórmula ajustada con Bessel asegura una estimación más fiel de la varianza poblacional.

Ejemplo práctico aplicado:
Imaginá que estás analizando el tiempo promedio que tardan 5 personas en completar una tarea: 12, 14, 15, 13 y 16 minutos.

- Media = 14

- Varianza muestral (con Bessel):

$$s^2 = \frac{(12-14)^2 + (14-14)^2 + (15-14)^2 + (13-14)^2 + (16-14)^2}{5-1} = \frac{10}{4} = 2.5$$

Importancia práctica:
El uso correcto de la corrección de Bessel marca la diferencia entre un análisis riguroso y uno que podría conducir a decisiones erróneas. Es especialmente crucial en estudios con muestras pequeñas, donde la subestimación de la variabilidad podría afectar conclusiones importantes, como rangos de confianza o evaluación de riesgos.

En síntesis, entender cuándo se trabaja con muestras o poblaciones no es solo un detalle técnico: es una base crítica para que todo el análisis estadístico posterior sea confiable y replicable.

Medidas de posición (cuartil, quintil, decil, percentil)

Las **medidas de posición** son herramientas estadísticas que permiten dividir un conjunto de datos ordenados en partes iguales para ubicar una observación relativa dentro de su contexto. A diferencia de las medidas de tendencia central, que se enfocan en un valor representativo del conjunto, estas medidas se centran en **la distribución de los datos** y en la ubicación de cada valor dentro de esa distribución. Son especialmente útiles para comparaciones, segmentaciones o análisis de rendimiento.

Los **cuartiles** dividen los datos en cuatro partes iguales:

- **Q1**: primer cuartil, representa el 25% de los datos.
- **Q2**: segundo cuartil, coincide con la mediana (50%).
- **Q3**: tercer cuartil, representa el 75%.

Los **quintiles** y **deciles** dividen los datos en cinco y diez partes iguales, respectivamente. Los **percentiles**, por su parte, dividen el conjunto en 100 partes. Así, el percentil 90 indica que el 90% de los datos están por debajo de ese valor. Estos indicadores se utilizan frecuentemente en contextos educativos, de salud, rendimiento físico y economía.

Ejemplo aplicado:
Supongamos que los tiempos de entrega de un servicio (en días) para 20 clientes son:
2, 2, 3, 3, 3, 4, 4, 5, 5, 6, 6, 6, 7, 7, 8, 9, 10, 10, 12, 14

- **Q1** ≈ 4 (el 25% de los datos están por debajo)
- **Q2** = 6 (mediana)
- **Q3** ≈ 9
- **Percentil 90** ≈ 12
  Esto indica que el 90% de los clientes recibieron su pedido en 12 días o menos.

Cuadro comparativo:

Medida	**División**	**Interpretación**	**Aplicación común**
Cuartil	4 partes	Posición relativa (25%, 50%, 75%)	Comparar salarios, calificaciones
Quintil	5 partes	Segmentos del 20%	Estudios sociales, segmentación
Decil	10 partes	10% por grupo	Análisis de ingresos o desempeño
Percentil	100 partes	Precisión fina (P1 a P99)	Educación, salud, logística

Estas medidas son de enorme valor para análisis comparativos, ya que permiten ubicar a un individuo o dato en relación con la distribución general, lo cual es clave para la toma de decisiones informadas.

Puntos atípicos

Los **puntos atípicos** o **outliers** son valores que se encuentran significativamente alejados del resto de los datos. Su presencia puede indicar un error de medición, una entrada incorrecta o simplemente una variación natural y válida dentro del conjunto. Detectarlos es crucial porque pueden alterar drásticamente los resultados de análisis estadísticos como la media, la desviación estándar y las regresiones.

Un valor se considera atípico si cae muy lejos del rango intercuartílico. Una forma común de detectarlos es utilizando los **cuartiles**:

- Se calcula el **rango intercuartílico (IQR)** como Q3−Q1Q3 - Q1Q3−Q1.

- Se considera outlier cualquier valor que esté por debajo de Q1−1.5×IQRQ1 - 1.5 \times IQRQ1−1.5×IQR o por encima de Q3+1.5×IQRQ3 + 1.5 \times IQRQ3+1.5×IQR.

Otra forma de detección puede ser visual, utilizando un **boxplot** (diagrama de caja), donde los puntos fuera de los "bigotes" del gráfico suelen representar valores atípicos.

Ejemplo aplicado:
En un conjunto de ingresos mensuales:
$800, $850, $880, $890, $900, $910, $920, $930, $10,000
La mayoría de los valores se agrupan alrededor de los $900, pero hay uno (10,000) que es claramente un outlier. Este valor aumentaría la media significativamente, haciendo que el promedio no sea representativo del grupo.

Comparativo entre efectos de un outlier:

Métrica	**Sin outlier**	**Con outlier (10,000)**
Media	896.25	1,776.67
Mediana	905	905

Desviación estándar	Baja	Mucho más alta

Comprender y gestionar correctamente los valores atípicos es fundamental para evitar conclusiones erróneas o sesgadas, sobre todo en análisis predictivos y modelos de machine learning.

Gráficos y diagramas: histograma y boxplot

Las **representaciones gráficas** son una herramienta clave en estadística descriptiva, ya que permiten visualizar rápidamente la distribución y características de un conjunto de datos. Entre las más utilizadas para datos cuantitativos están el **histograma** y el **boxplot** (o diagrama de caja), ya que facilitan el análisis visual de la tendencia central, la dispersión y la presencia de valores atípicos.

Un **histograma** es un gráfico de barras donde el eje horizontal representa los intervalos de valores (clases) y el eje vertical la frecuencia (absoluta o relativa). Es ideal para variables numéricas continuas, ya que muestra la forma de la distribución (simétrica, sesgada, uniforme, etc.) y permite detectar acumulaciones o huecos de datos. No debe confundirse con el gráfico de barras: el histograma trabaja con intervalos y **las barras están unidas**, porque representa continuidad.

Un **boxplot** resume cinco estadísticas importantes: el mínimo, Q1 (primer cuartil), mediana (Q2), Q3 (tercer cuartil) y el máximo. Visualmente representa una “caja” entre Q1 y Q3, con una línea en la mediana, y dos líneas (“bigotes”) que se extienden hasta los valores mínimos y máximos dentro del rango aceptado. Cualquier valor fuera de los bigotes se representa como puntos, los cuales se consideran **outliers**.

Ejemplo práctico:
Supongamos que analizas los puntajes de 100 estudiantes en un examen.

- Con un **histograma** podrías ver si la mayoría obtuvo notas medias o si hay agrupamientos en puntajes bajos o altos.

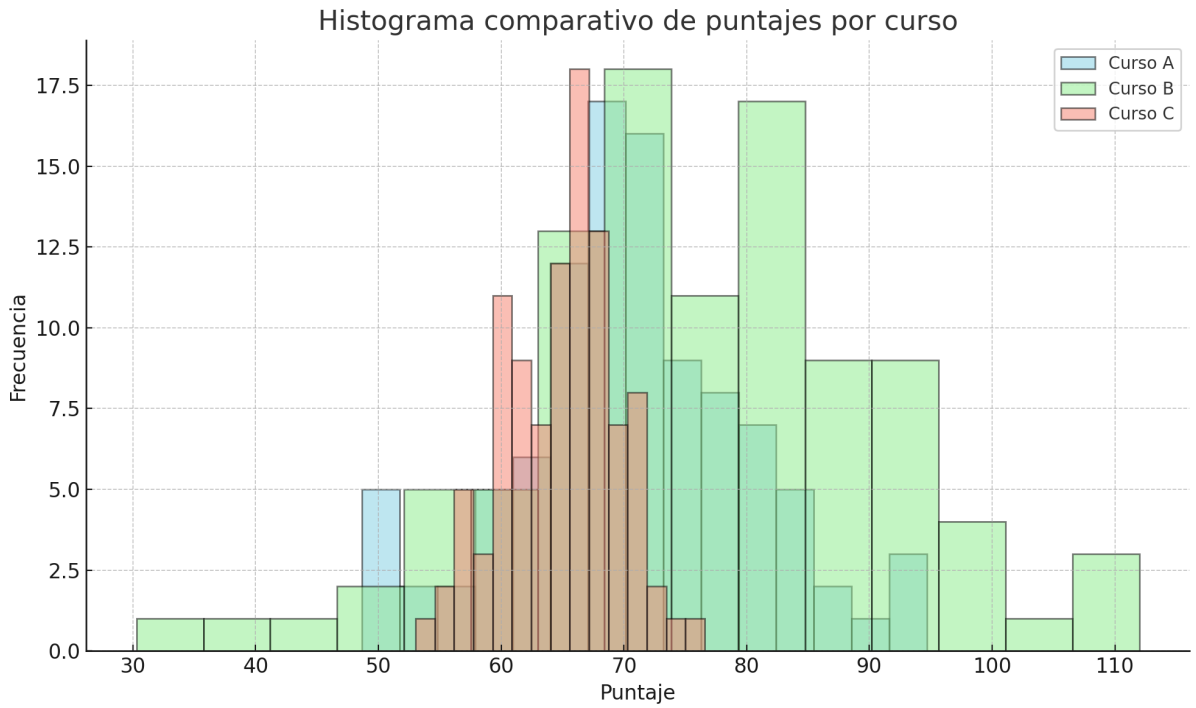

Aquí tenés el **histograma comparativo** de los puntajes de los tres cursos:

- 🔵 **Curso A** se agrupa alrededor del puntaje 70.
- 🟢 **Curso B** presenta una distribución más amplia, extendida hacia valores más altos.
- 🔴 **Curso C** se concentra más estrechamente en valores cercanos a 65.

Este gráfico te permite observar **cómo se distribuyen los datos dentro de cada grupo** y detectar fácilmente si hay concentraciones, simetrías o dispersiones distintas. Ideal para complementar el análisis del boxplot.

- Con un **boxplot**, podrías comparar en paralelo los resultados de varios cursos para ver cuál tuvo mayor dispersión o valores extremos.

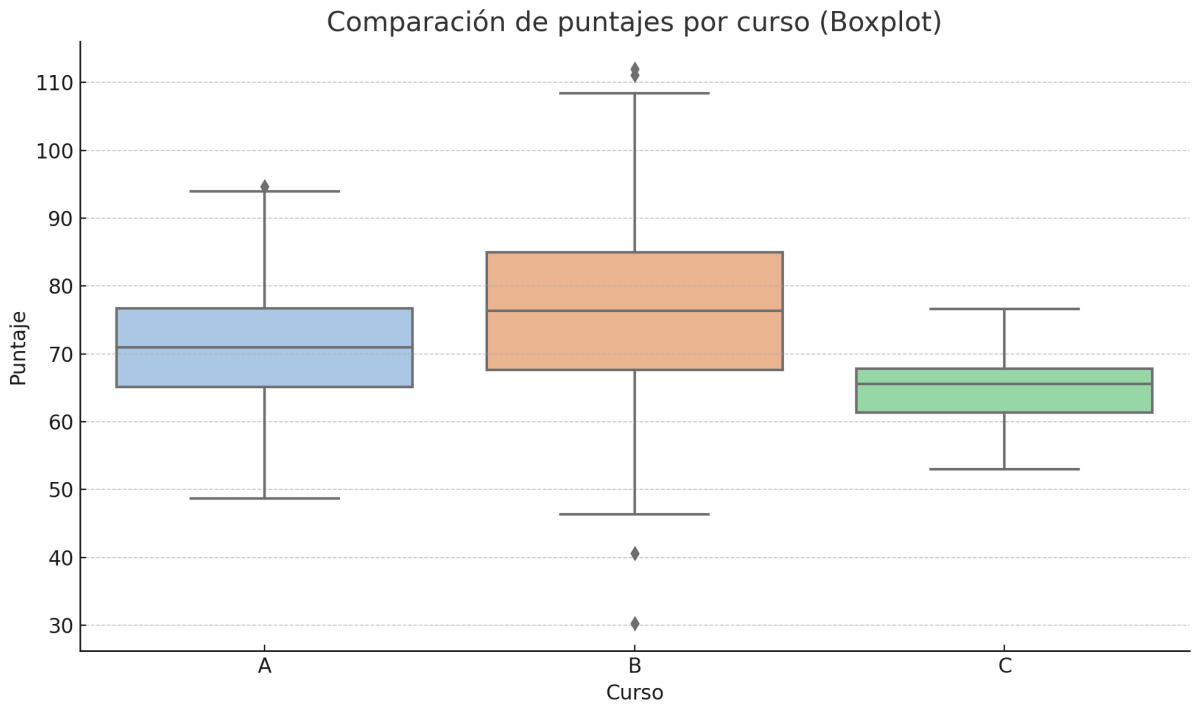

Aquí tenés el **boxplot comparativo** para el ejemplo práctico:

- 📘 **Curso A**: distribución más estable, centrada en 70 con poca variación.
- 📗 **Curso B**: mayor dispersión y presencia de algunos valores más extremos.
- 📙 **Curso C**: puntajes más concentrados, con menor varianza que los otros dos.

Este gráfico permite **visualizar de forma clara cuál curso tiene mayor variabilidad, si hay valores atípicos y cómo se comparan las medianas** entre grupos.

Comparación directa:

Característica	**Histograma**	**Boxplot**
Tipo de datos	Cuantitativos continuos	Cuantitativos (distribución resumida)

Información mostrada	Frecuencia de clases	Mediana, cuartiles, outliers
Ideal para	Ver forma de la distribución	Comparar grupos o detectar atípicos

Estos gráficos son herramientas fundamentales no solo en exploración inicial de datos, sino también en la comunicación de resultados, ya que ofrecen una forma clara y eficaz de explicar fenómenos complejos a públicos técnicos o no técnicos.

Cierre ✍️

La estadística descriptiva nos permite tomar decisiones más informadas a partir de la observación organizada de los datos. A lo largo de este manual, aprendiste a clasificar variables, organizar información mediante tablas, calcular medidas de tendencia central y dispersión, identificar valores atípicos y representar los datos gráficamente.

Estas herramientas son fundamentales para comprender la estructura de un conjunto de datos, anticipar comportamientos y comunicar hallazgos con claridad. Además, su correcta aplicación contribuye a mejorar procesos en diversos ámbitos como la educación, el comercio, la salud o la tecnología.

Dominar estos fundamentos te prepara para enfrentar desafíos de análisis más complejos, y te brinda la capacidad de interpretar el mundo desde una perspectiva basada en evidencia cuantitativa.

¡Nos vemos de nuevo, más adelante! 👋

Referencias📚

- Khan Academy. (s.f.). *Estadística y probabilidad*. https://es.khanacademy.org/math/statistics-probability
- Statology. (2023). *Descriptive statistics overview*. https://www.statology.org/descriptive-statistics/
- Nuclio Digital School. (2023, marzo 9). *Exploratory Data Analysis (EDA): Qué es y cómo aplicarlo en ciencia de datos*. https://nuclio.school/blog/eda-exploratory-data-analysis/

¡Muchas gracias!

Nos vemos en la próxima lección

alkemy