Correlación

M4: Análisis exploratorio de datos

|**AE3**: Aplicar los conceptos de correlación para la caracterización de un conjunto de datos de una población a partir de un problema dado.

alkemy

Introducción🧑‍💻

La correlación es una herramienta estadística que permite analizar la relación entre dos variables cuantitativas. Comprender si existe una asociación entre variables —y cómo se comporta— es clave para caracterizar conjuntos de datos en estudios de salud, economía, ciencias sociales, educación y más.

Este manual te guiará en el proceso de identificación, representación y análisis de la correlación. Trabajaremos con representaciones gráficas como el **scatterplot**, herramientas como las **tablas de contingencia**, y el **coeficiente de correlación de Pearson (R)** para cuantificar la fuerza de la relación. Finalmente, profundizaremos en una distinción crítica: **correlación no implica causalidad**.

Aprendizaje esperado

Cuando finalices la lección serás capaz de:

- Comprender el concepto de correlación entre variables y su importancia en el análisis de datos.
- Representar gráficamente relaciones entre variables utilizando diagramas de dispersión (scatterplot).
- Utilizar tablas de contingencia para representar relaciones categóricas.
- Calcular e interpretar el coeficiente de correlación de Pearson.
- Diferenciar entre correlación y causalidad en estudios de datos.

¿Qué es la correlación?

La **correlación** es una herramienta estadística que permite analizar la relación entre dos variables cuantitativas. Evalúa si al cambiar una de ellas, la otra tiende a cambiar también, y en qué dirección. Esta relación puede ser:

- **Positiva**: ambas variables aumentan o disminuyen juntas.
- **Negativa**: una variable aumenta mientras la otra disminuye.
- **Nula**: no se observa una relación clara entre ambas.

La correlación **no implica causalidad**, es decir, aunque dos variables estén relacionadas, no significa que una cause la otra. Es un punto de partida para generar hipótesis y explorar tendencias.

📌 Tipos de correlación

Tipo	Relación	Ejemplo
Positiva	Ambas variables aumentan	Horas de estudio y nota de examen
Negativa	Una sube mientras otra baja	Temperatura y consumo de calefacción
Nula	No hay relación clara	Número de zapatos y nivel de estrés

📈 Visualización

El siguiente conjunto de gráficos muestra ejemplos claros de los tres tipos principales de correlación:

- **Izquierda**: Correlación positiva — los puntos siguen una tendencia ascendente.

- **Centro**: Correlación negativa — la nube de puntos desciende.
- **Derecha**: Sin correlación — los puntos están completamente dispersos.

Estas visualizaciones ayudan a identificar rápidamente patrones en conjuntos de datos y son especialmente útiles en la etapa de análisis exploratorio.

Visualización programada

Para mostrar ejemplos de correlación positiva, negativa y nula, usá este código:

```
import numpy as np
import matplotlib.pyplot as plt

np.random.seed(0)
x = np.linspace(0, 10, 50)
y_pos = 2 * x + np.random.normal(0, 2, 50)
y_neg = -2 * x + np.random.normal(0, 2, 50)
y_none = np.random.normal(10, 5, 50)

fig, ax = plt.subplots(1, 3, figsize=(18, 5))
ax[0].scatter(x, y_pos, color='green')
ax[0].set_title("Correlación positiva")
ax[1].scatter(x, y_neg, color='red')
ax[1].set_title("Correlación negativa")
ax[2].scatter(x, y_none, color='gray')
ax[2].set_title("Sin correlación")
plt.tight_layout()
plt.show()
```

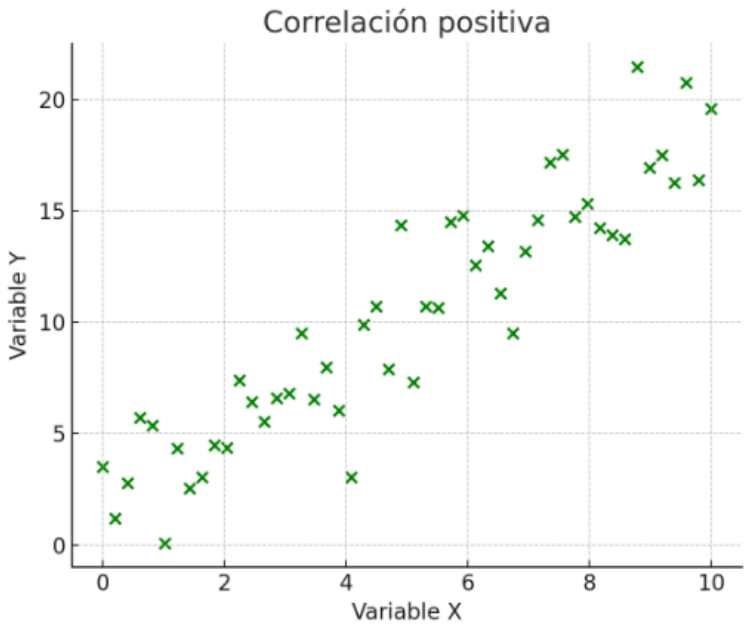

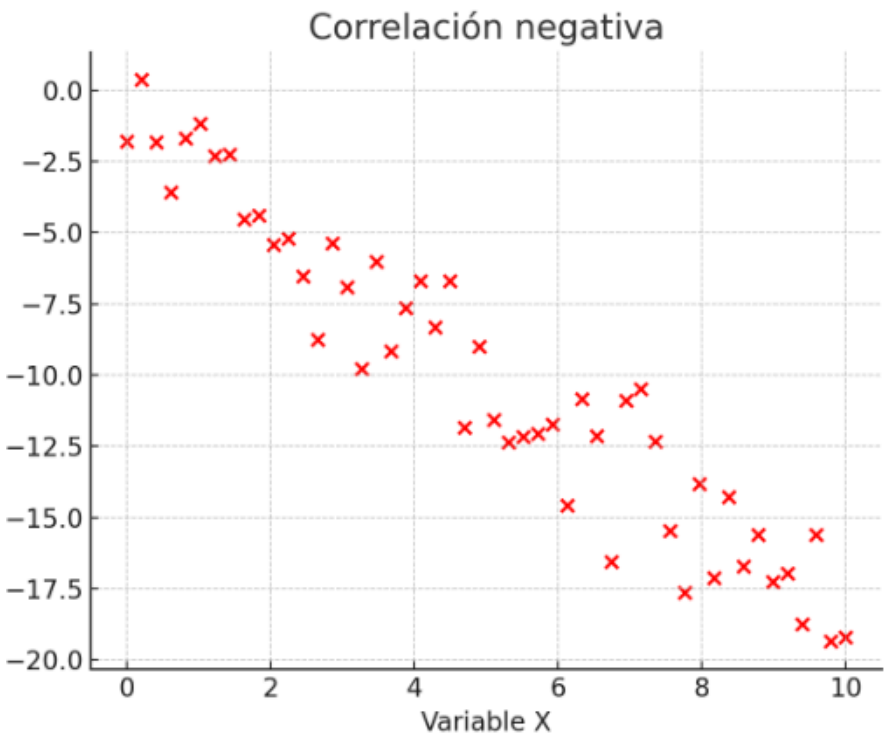

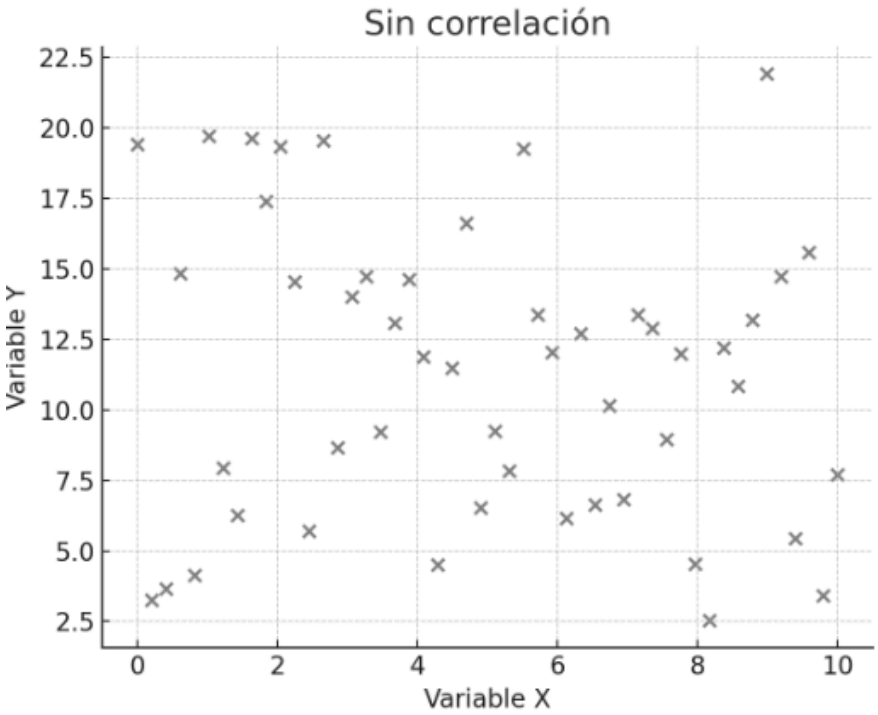

📋 Tablas de contingencia

Las **tablas de contingencia** son una herramienta fundamental en el análisis exploratorio de datos categóricos. Permiten observar cómo se distribuyen dos variables cualitativas entre sí. Son especialmente útiles para identificar asociaciones o patrones entre grupos o categorías.

Cada celda de la tabla muestra el número de observaciones que comparten una combinación específica de categorías entre dos variables. También pueden incluir porcentajes por fila, columna o total, para facilitar la interpretación.

🧾 **Ejemplo teórico:**

Supongamos que realizamos una encuesta a 10 personas preguntándoles su **preferencia de transporte** y su **género**. Los datos se resumen en la siguiente tabla de contingencia:

Género	Auto	Bicicleta	Bus
Femenino	1	1	2
Masculino	2	1	1
Otro	1	1	0

Esta tabla muestra cuántas personas de cada género prefieren cada tipo de transporte. Por ejemplo, 2 hombres prefieren auto, 2 mujeres eligen bus, y no hay personas del género "otro" que hayan elegido bus.

📊 **Representación gráfica**

La tabla de contingencia también puede visualizarse mediante un gráfico de **barras apiladas**, como el que te presento arriba. Este tipo de gráfico permite comparar categorías y observar rápidamente qué grupo presenta mayor preferencia por cada opción.

En este ejemplo, se puede ver que:

- El bus es preferido por más mujeres.
- El auto es más elegido por hombres.
- Bicicleta tiene una distribución equilibrada.

Estas observaciones son valiosas para entender comportamientos o segmentar audiencias.

Visualización programada

Para mostrar una tabla de contingencia como gráfico de barras apiladas:

```
import pandas as pd
import matplotlib.pyplot as plt

data = {
    "Preferencia": ["Auto", "Auto", "Bus", "Bicicleta", "Bus", "Bicicleta", "Auto", "Bus", "Auto", "Bicicleta"],
    "Género": ["Masculino", "Femenino", "Femenino", "Masculino", "Masculino", "Femenino", "Otro", "Femenino", "Masculino", "Otro"]
}

df = pd.DataFrame(data)
contingencia = pd.crosstab(df["Género"], df["Preferencia"])

contingencia.plot(kind='bar', stacked=True, colormap='Paired')
plt.title("Preferencia de transporte por género")
plt.xlabel("Género")
plt.ylabel("Cantidad")
plt.tight_layout()
plt.show()
```

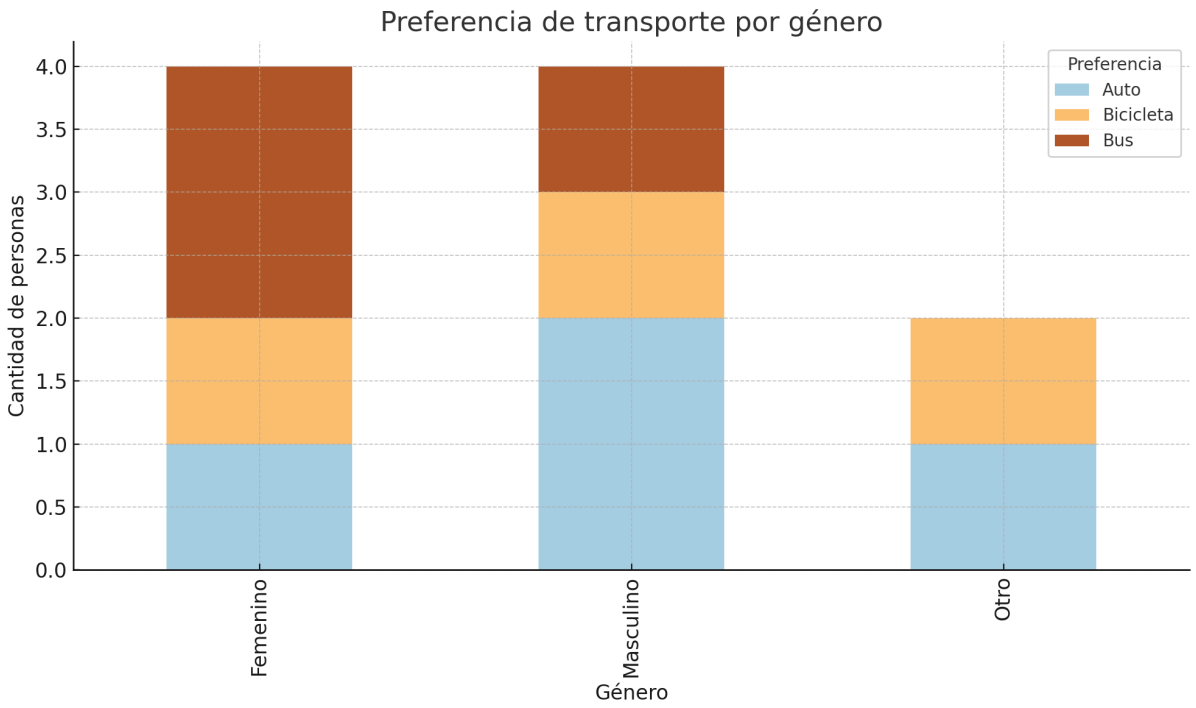

Diagramas de dispersión (scatterplot)

El **scatterplot** o **diagrama de dispersión** es una herramienta gráfica clave en el análisis de correlación. Permite representar la relación entre dos variables numéricas. Cada punto del gráfico representa una observación: su posición horizontal indica el valor de una variable, y su posición vertical el valor de otra.

Este tipo de gráfico es útil para:

- Detectar relaciones (lineales o no lineales).
- Identificar patrones ascendentes, descendentes o nulos.

- Visualizar outliers o valores atípicos.
- Prever posibles correlaciones para cuantificar luego.

Tabla de datos (muestra)

A continuación, se muestra un fragmento de un conjunto de datos donde se analizan las horas de estudio y la nota obtenida en un examen:

Horas de estudio	Nota en el examen
4.75	22.90
7.48	33.03
1.00	5.22
3.72	21.52
2.32	6.10

Estos datos corresponden a una simulación donde la nota tiende a aumentar con las horas de estudio, aunque existe algo de dispersión debido a factores aleatorios (como motivación, salud, etc.).

Visualización gráfica

El gráfico de dispersión presentado arriba muestra:

- Cada punto representa un estudiante.
- El eje X indica las horas de estudio.
- El eje Y muestra la nota obtenida.
- La línea azul representa la **tendencia lineal**, indicando una correlación positiva.

Esta representación visual permite observar que a mayor cantidad de estudio, la nota tiende a subir, aunque con variabilidad. Es un ejemplo clásico de correlación positiva moderada/fuerte.

Visualización programada

Para mostrar un scatterplot con línea de tendencia:

```
import seaborn as sns

np.random.seed(1)
horas = np.random.uniform(1, 10, 30)
nota = 5 * horas + np.random.normal(0, 5, 30)
df = pd.DataFrame({"Horas de estudio": horas, "Nota en el examen": nota})

sns.regplot(data=df, x="Horas de estudio", y="Nota en el examen", scatter_kws={"color": "orange"}, line_kws={"color": "blue"})
plt.title("Relación entre horas de estudio y nota de examen")
plt.grid(True)
plt.show()
```

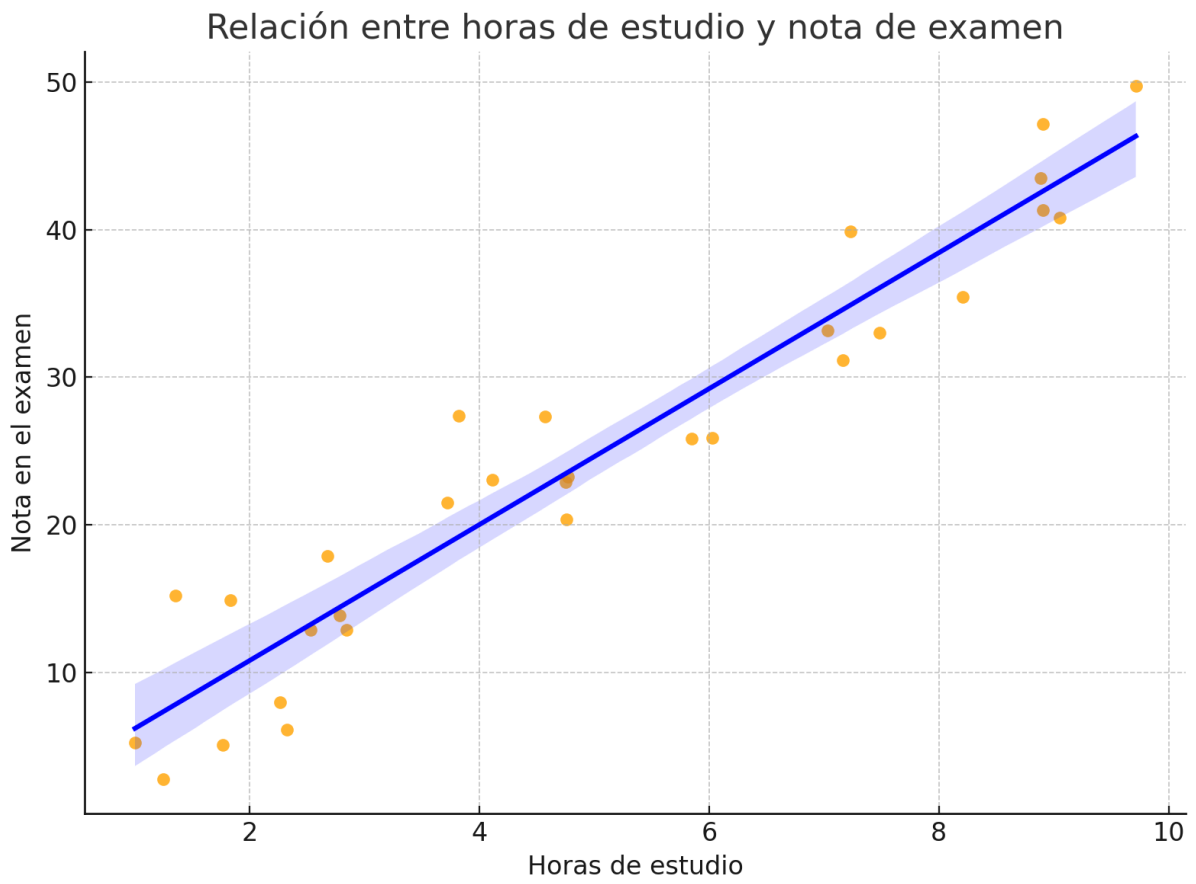

📏 Coeficiente de correlación de Pearson (R)

El **coeficiente de correlación de Pearson** mide la fuerza y dirección de la relación **lineal** entre dos variables numéricas. Su valor varía entre -1 y 1:

- **+1** → relación positiva perfecta
- **0** → sin relación lineal
- **–1** → relación negativa perfecta

Este coeficiente permite cuantificar lo que vemos en un gráfico de dispersión. Se basa en la **covarianza** de las variables, estandarizada por sus desviaciones estándar, lo que lo hace insensible a la escala de los datos.

🧪 Cálculo real

A partir del conjunto de datos anterior (horas de estudio vs. nota de examen), obtuvimos el siguiente resultado:

Indicador	Valor
Coeficiente de correlación (R)	0.96
Significado	Relación positiva fuerte

Este valor de **0.96** indica que existe una **fuerte correlación positiva** entre las horas de estudio y las calificaciones. Es decir, los estudiantes que estudiaron más horas tienden a obtener mejores resultados.

📌 Interpretación

Una correlación de 0.96 implica que los puntos en el scatterplot se alinean de forma bastante cercana a una recta ascendente. Esto sugiere una tendencia consistente: a medida que aumenta una variable (estudio), también lo hace la otra (nota).

En contextos prácticos, este tipo de resultado puede utilizarse para:

- Identificar predictores fuertes.
- Construir modelos de regresión.

- Establecer estrategias de mejora (por ejemplo, incentivar el tiempo de estudio)

⚠️ Correlación vs. Causalidad

Una de las confusiones más comunes en el análisis de datos es asumir que una **correlación implica causalidad**. La **correlación** sólo indica que existe una asociación entre dos variables, mientras que la **causalidad** implica que un cambio en una variable produce directamente un cambio en la otra.

📉 Ejemplo de correlación espuria

En el gráfico que se muestra arriba, vemos cómo las **ventas de helado** y los **casos de ahogamiento** parecen aumentar y disminuir en los mismos días del mes. Es posible que, al calcular el coeficiente de correlación entre ambas variables, obtengamos un valor alto y positivo.

Día	Ventas de helado	Casos de ahogamiento
1	109.67	3.36
2	111.93	6.54
3	118.20	4.98
4	121.25	3.76
5	107.80	5.02

Sin embargo, esto **no significa** que el consumo de helado cause ahogamientos. En realidad, ambas variables están influenciadas por una **tercera variable oculta**: el **calor del verano**. Esta relación no causal es un ejemplo clásico de lo que se conoce como **correlación espuria**.

Visualización programada

Para representar una correlación espuria:

```
dias = np.arange(1, 31)
helado = 100 + 15 * np.sin(dias / 2) + np.random.normal(0, 5, 30)
ahogo = 3 + 2 * np.sin(dias / 2) + np.random.normal(0, 1, 30)
df = pd.DataFrame({"Día": dias, "Helado": helado, "Ahogamiento": ahogo})

plt.plot(df["Día"], df["Helado"], label="Ventas de helado", marker='o')
plt.plot(df["Día"], df["Ahogamiento"], label="Casos de ahogamiento", marker='s')
plt.title("Ejemplo de correlación espuria")
plt.legend()
plt.grid(True)
plt.show()
```

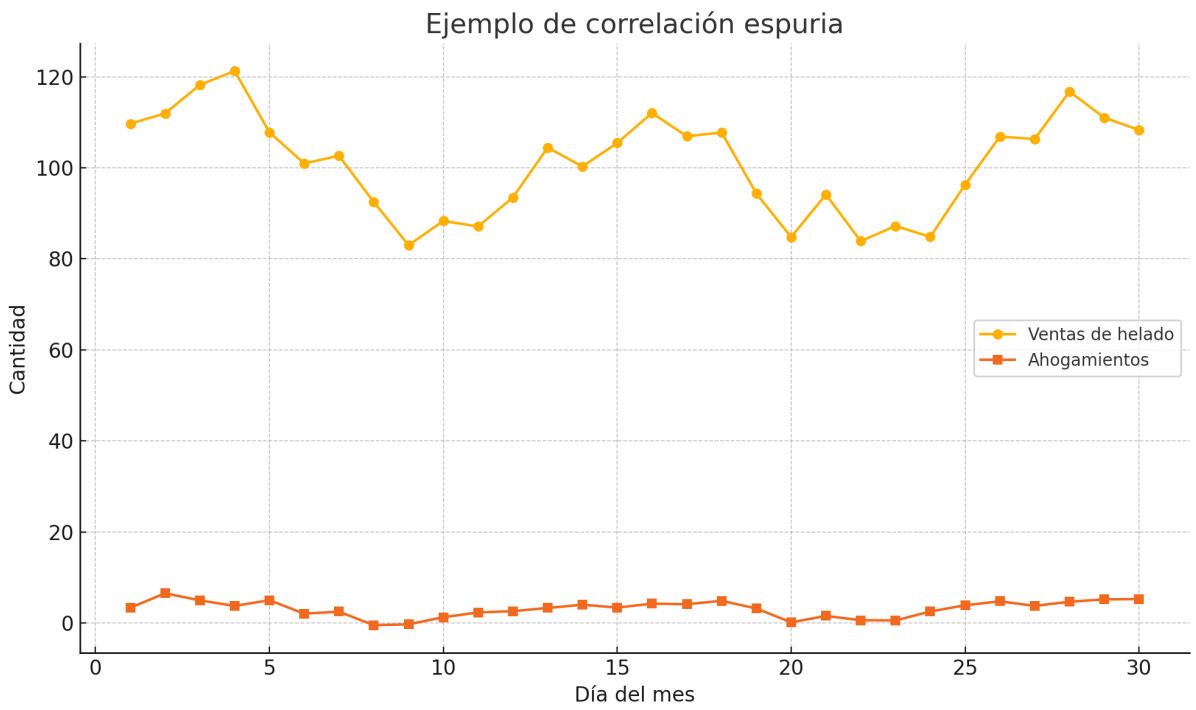

🎯 ¿Cómo evitar este error?

Para establecer una relación de causalidad, se necesitan condiciones más rigurosas, como:

- Un diseño experimental (por ejemplo, estudios controlados).
- Evidencia temporal clara (una variable ocurre antes que la otra).
- Eliminación de variables confusas o externas.
- Modelos estadísticos más complejos (regresión, control de covariables).

Este ejemplo demuestra que la correlación es una herramienta poderosa para **detectar patrones**, pero que debe ser usada con cuidado para **evitar interpretaciones erróneas**. Siempre que se observe una correlación, se deben considerar otros factores y no sacar conclusiones apresuradas.

Cierre ✍️

A lo largo de este manual aprendiste a identificar y analizar relaciones entre variables utilizando herramientas estadísticas como tablas de contingencia, diagramas de dispersión y el coeficiente de correlación de Pearson. Estas herramientas permiten descubrir asociaciones relevantes dentro de un conjunto de datos y obtener una primera aproximación sobre su comportamiento conjunto.

También reconociste que no toda correlación implica una causa. Comprender esta diferencia es esencial para evitar conclusiones erróneas o precipitadas, sobre todo en contextos donde las decisiones pueden afectar políticas públicas, intervenciones sociales o estrategias comerciales.

Aplicar estos conocimientos te permitirá interpretar patrones en datos reales con mayor solidez, formular hipótesis fundamentadas y comunicar hallazgos de forma crítica y profesional. La correlación es un punto de partida poderoso para entender la estructura de la información en el análisis estadístico moderno.

¡Nos vemos de nuevo, más adelante! 👋

Referencias📚

- Khan Academy. (s.f.). *Correlación y regresión*. https://es.khanacademy.org/math/statistics-probability/describing-relationships-quantitative-data
- Statology. (2023). *Guía del coeficiente de correlación de Pearson*. https://www.statology.org/pearson-correlation-coefficient/
- Laerd Statistics. (s.f.). *Correlation*. https://statistics.laerd.com/statistical-guides/pearson-correlation-coefficient-statistical-guide.php

¡Muchas gracias!

Nos vemos en la próxima lección

alkemy