Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😁

alkemy

Clase grabada

› Regresiones lineales- Parte I

Aprendizaje Esperado 4: Implementar un modelo de regresión lineal para el análisis de la dependencia de variables utilizando lenguaje python.

Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**

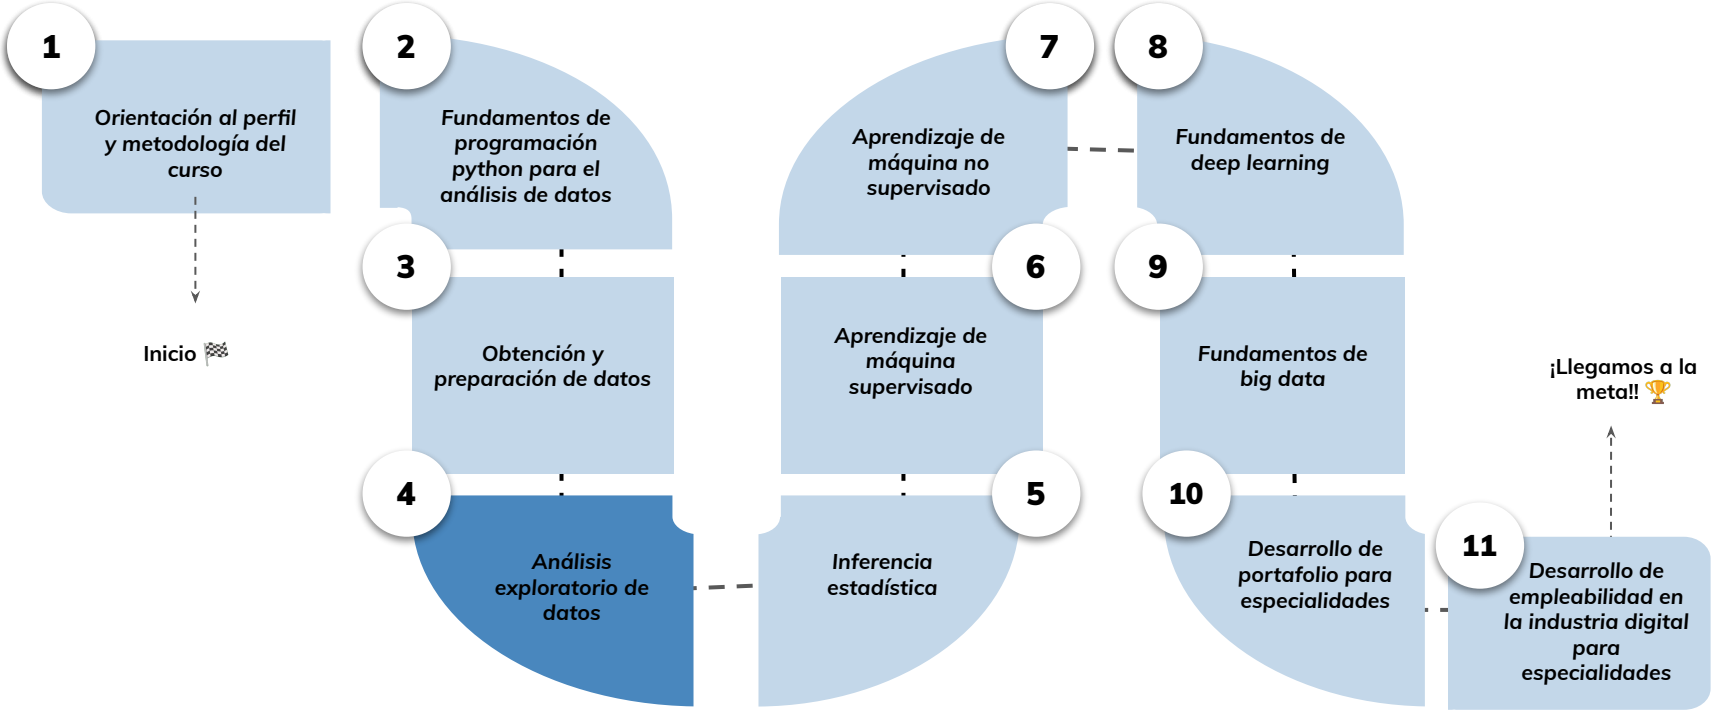

alkemy

Roadmap de lecciones

*¿Cuáles **lecciones** estaremos estudiando en este módulo?*

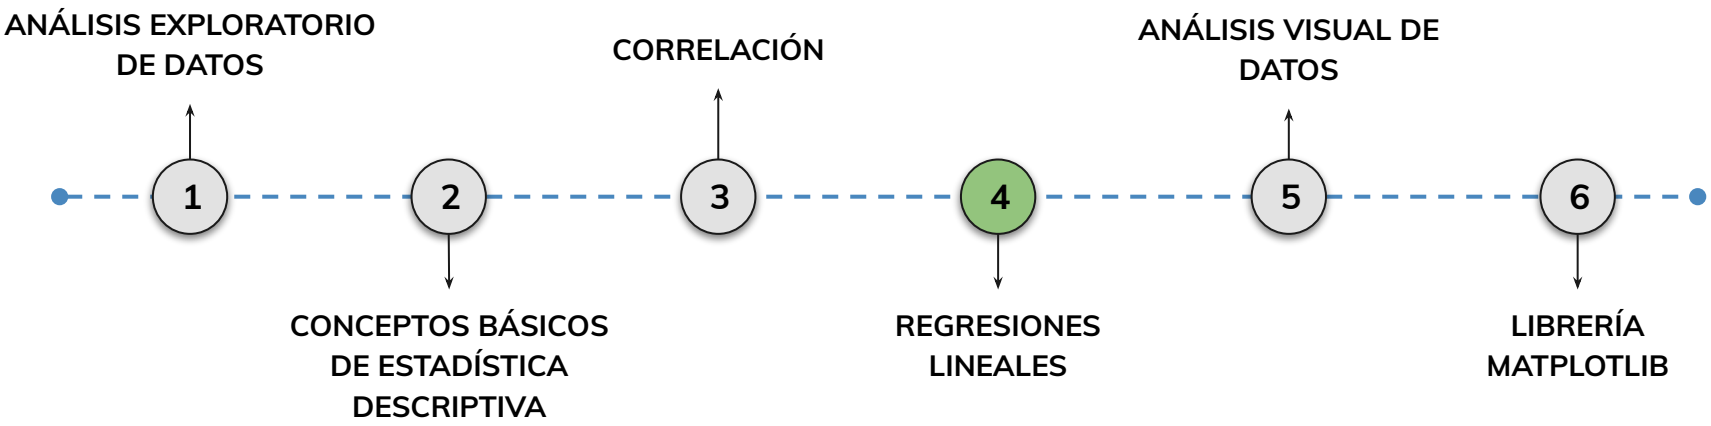

alkemy

Learning Path

¿Cuáles temas trabajaremos hoy?

4.

Análisis de regresión lineal con Python

Aprenderás a implementar y evaluar modelos de regresión lineal simple y múltiple en Python, representando los resultados mediante gráficos generados con Seaborn y evaluando su ajuste con métricas estadísticas.

- **Regresión Lineal Simple**
  - **Fundamentos del modelo**
  - **Implementación en Python**
- **Regresión Lineal Múltiple**
  - **Supuestos del modelo**
  - **Evaluación del ajuste y métricas**

alkemy

Objetivos de aprendizaje

¿Qué aprenderás?

- Comprender los principios fundamentales de la regresión lineal.
- Aplicar el modelo de regresión lineal simple y múltiple con statsmodels.
- Evaluar el ajuste del modelo con métricas como R^2, MAE y MSE.
- Visualizar las relaciones entre variables con gráficos de Seaborn.
- Interpretar correctamente los coeficientes del modelo ajustado.

Repaso clase anterior

¿Quedó alguna duda?

- ✓ *Aplicamos un modelo de regresión lineal múltiple a datos simulados.*
- ✓ *Evaluamos el ajuste del modelo con R^2 y R^2 ajustado.*
- ✓ *Verificamos los supuestos de normalidad del error, homocedasticidad y multicolinealidad.*
- ✓ *Utilizamos criterios como AIC y BIC para comparar modelos y seleccionar el más eficiente.*

Regresiones lineales

Introducción

La visualización de datos es una herramienta esencial en el análisis estadístico, ya que permite interpretar información compleja de forma intuitiva y efectiva. Cuando se combina con modelos estadísticos como la regresión lineal, su utilidad se multiplica, ya que facilita la comprensión de patrones, tendencias y relaciones entre variables. Una de las bibliotecas más potentes para este propósito en el ecosistema Python es **Seaborn**, que ofrece una gran variedad de funciones para realizar análisis visuales detallados.

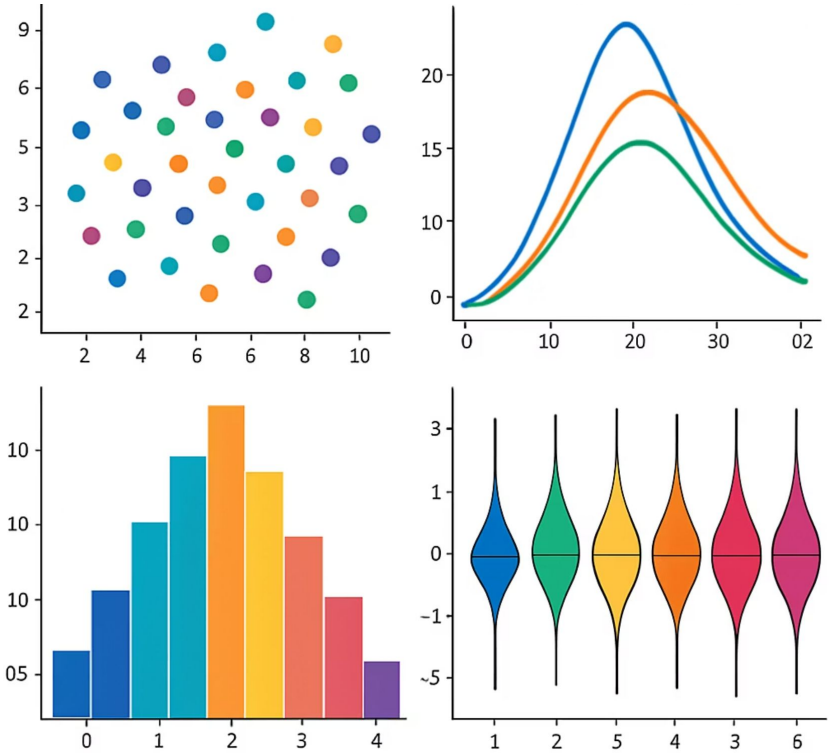

alkemy

Enfoque del Manual

Regresiones Lineales

Este manual se centra en la aplicación de **regresiones lineales simples y múltiples**, junto al uso de Seaborn para la representación de estas relaciones.

Supuestos del Modelo

Se explorarán los supuestos que deben cumplirse en un modelo lineal para garantizar resultados confiables.

Herramientas de Análisis

Uso de la librería **Statsmodels** para ajustar e interpretar modelos de regresión.

Métricas de Evaluación

Análisis de métricas como el R^2, el MSE y el MAE para evaluar el desempeño de los modelos.

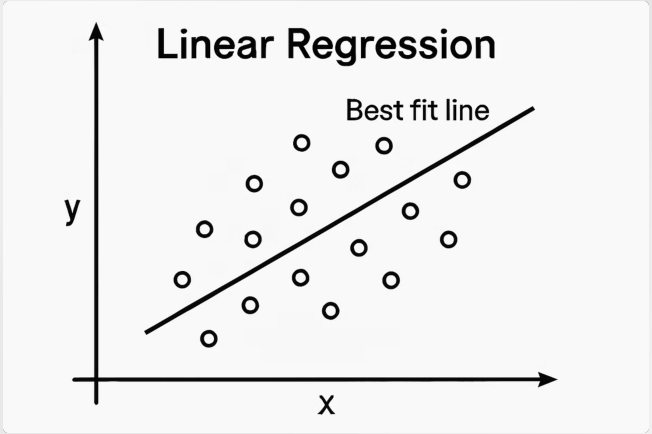

Regresiones Lineales

Las regresiones lineales son técnicas estadísticas que permiten modelar la relación entre variables, buscando patrones lineales que ayuden a entender cómo una o más variables independientes influyen en una variable dependiente.

alkemy

¿Qué es una regresión lineal simple?

La regresión lineal simple es un método estadístico que permite modelar la relación entre una variable independiente (predictora) y una variable dependiente (respuesta) mediante una línea recta. Esta técnica busca encontrar la mejor recta que se ajuste a los datos observados, con el objetivo de predecir el valor de la variable respuesta a partir de un nuevo valor de la variable predictora.

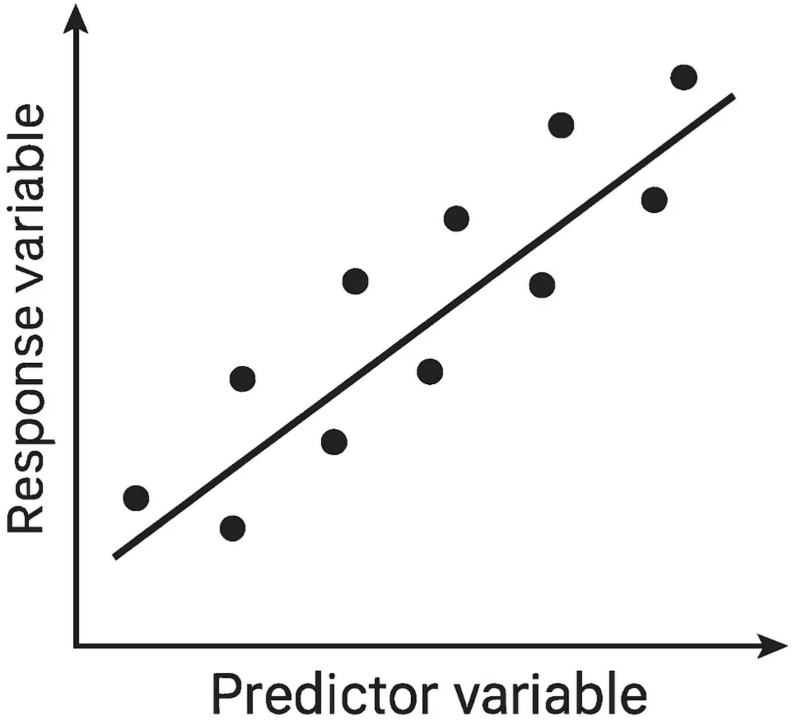

alkemy

Ecuación de la Regresión Lineal Simple

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Donde:

- β_0 es el intercepto (ordenada al origen)
- β_1 es el coeficiente de la pendiente
- ε es el término de error aleatorio

Esta fórmula permite hacer inferencias sobre el comportamiento de la variable dependiente según los cambios en la independiente.

Visualización con Seaborn

Para representar visualmente una regresión lineal simple, Seaborn ofrece funciones como sns.lmplot() o sns.regplot(). Estas funciones generan un scatterplot con la línea de regresión ajustada, permitiendo observar visualmente la relación entre las dos variables.

```
import seaborn as sns
import matplotlib.pyplot as plt

sns.regplot(x="total_bill", y="tip", data=sns.load_dataset("tips"))
plt.title("Relación entre total de cuenta y propina")
plt.show()
```

alkemy

Ajuste Estadístico con Statsmodels

Complementariamente, la regresión puede ser ajustada de forma estadística utilizando la librería statsmodels. Esto permite obtener los coeficientes β_0 y β_1, junto con otras estadísticas relevantes.

```
import statsmodels.api as sm
import pandas as pd

data = sns.load_dataset("tips")
X = sm.add_constant(data["total_bill"])
y = data["tip"]
modelo = sm.OLS(y, X).fit()
print(modelo.summary())
```

Este resumen incluye valores de R^2, p-valores, errores estándar y otros parámetros que permiten evaluar la calidad del modelo.

alkemy

Determinación de los Coeficientes de Regresión

1

Significado de los Coeficientes

Los coeficientes de regresión representan los parámetros del modelo que describen la relación entre la variable independiente y la variable dependiente.

2

Intercepto (β_0)

Indica el valor esperado de la variable dependiente cuando la variable independiente es cero.

3

Pendiente (β_1)

Indica cuánto cambia la variable dependiente por cada unidad de cambio en la independiente.

alkemy

Método de los Mínimos Cuadrados

Los coeficientes se calculan utilizando el método de los mínimos cuadrados ordinarios (OLS), que minimiza la suma de los cuadrados de las diferencias entre los valores observados y los valores predichos por el modelo.

Esta técnica garantiza que la recta ajustada sea la que mejor se adapta a los datos disponibles, en términos de error cuadrático medio.

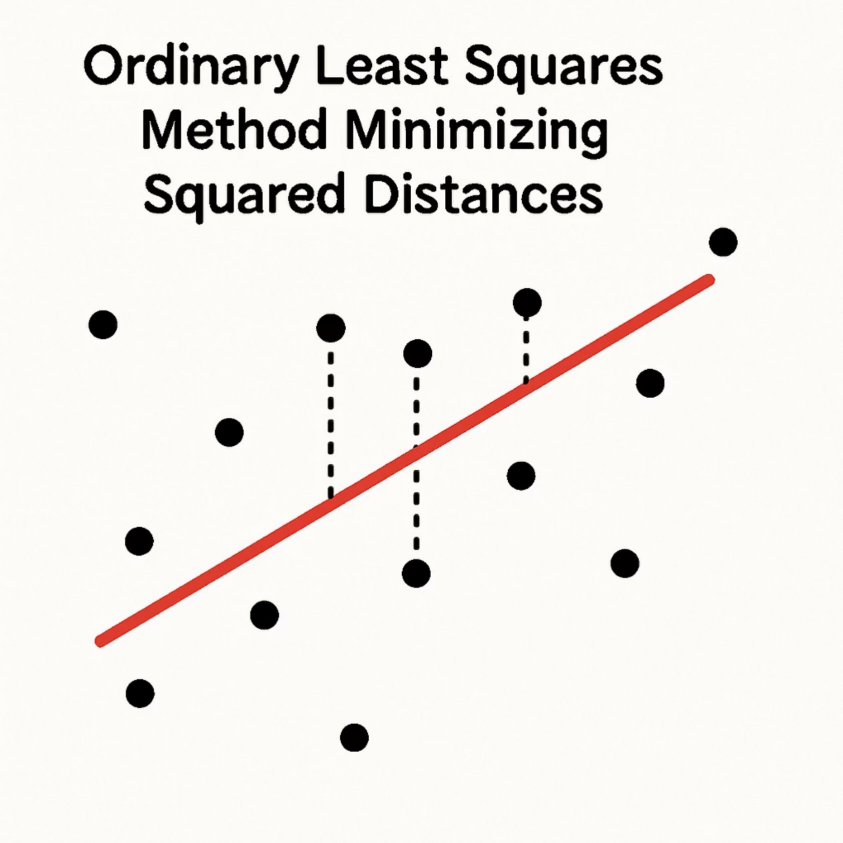

alkemy

Obtención de Coeficientes con Statsmodels

Con la librería statsmodels, podemos obtener los coeficientes de forma sencilla. Usando el modelo ajustado, el método .params devuelve los valores de β_0 y β_1.
Además, el método .summary() proporciona información detallada, incluyendo errores estándar, t-estadísticos y p-valores, que son útiles para evaluar la significancia de cada coeficiente.

```
const         0.920270
total_bill    0.105025
dtype: float64
```

alkemy

Interpretación de Coeficientes

La interpretación de estos resultados es fundamental: el coeficiente de total_bill indica que por cada unidad monetaria adicional en la cuenta total, se espera que la propina aumente en promedio 0.105 unidades monetarias, manteniendo las demás condiciones constantes.

El valor del intercepto sugiere cuál sería la propina estimada si la cuenta fuese cero, aunque en muchos contextos, este valor no tiene un significado práctico y solo sirve como parte del ajuste estadístico del modelo.

Métricas de Error

La evaluación de un modelo de regresión no se limita a observar su ecuación o sus coeficientes; es fundamental contar con métricas que midan su precisión y capacidad predictiva.

Error Absoluto Medio (MAE)

Calcula el promedio de las diferencias absolutas entre los valores observados y los valores predichos.

Error Cuadrático Medio (MSE)

Eleva al cuadrado las diferencias antes de promediarlas, lo que penaliza más fuertemente los errores grandes.

Raíz del Error Cuadrático Medio (RMSE)

Es la raíz cuadrada del MSE, lo que lo convierte en una métrica en las mismas unidades que la variable dependiente, facilitando su interpretación.

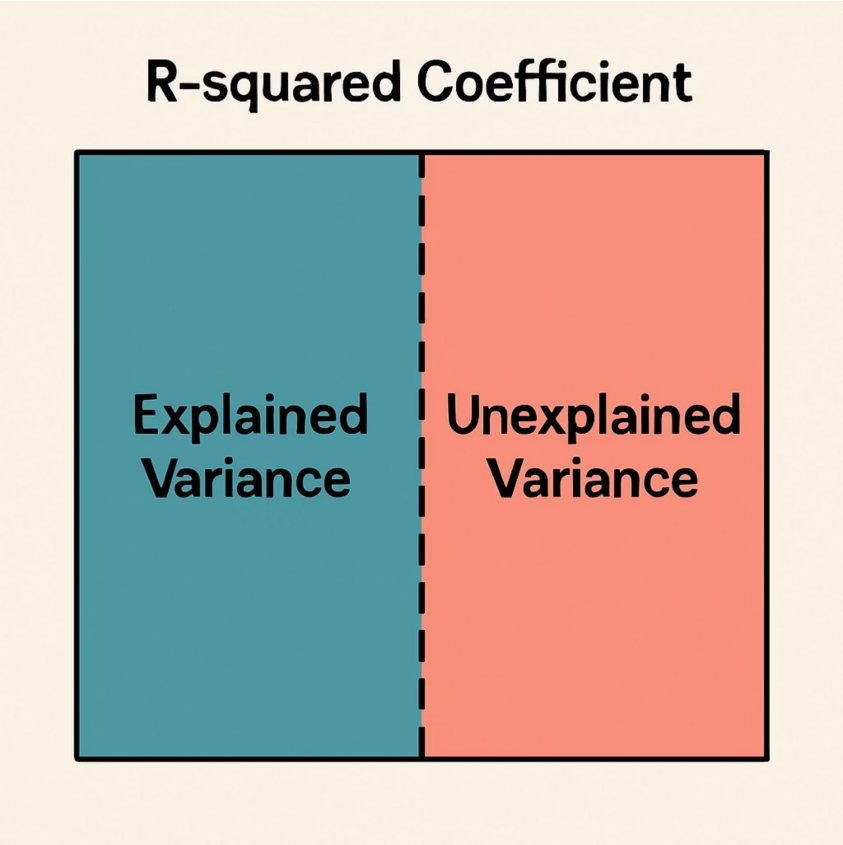

Coeficiente de Determinación R^2

Otra métrica clave es el **coeficiente de determinación R^2**, que indica qué proporción de la variabilidad de la variable dependiente puede explicarse por el modelo.

- Su valor va de 0 a 1
- Un valor cercano a 1 indica un buen ajuste
- Permite comparar diferentes modelos

alkemy

Cálculo de Métricas en Python

```
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score

# Predicciones del modelo
y_pred = model.predict(X)

# Cálculo de métricas
mae = mean_absolute_error(y, y_pred)
mse = mean_squared_error(y, y_pred)
rmse = np.sqrt(mse)
r2 = r2_score(y, y_pred)

print(f"MAE: {mae:.4f}")
print(f"MSE: {mse:.4f}")
print(f"RMSE: {rmse:.4f}")
print(f"R²: {r2:.4f}")
```

alkemy

Uso Práctico de las Métricas

Identificación de Problemas

Un MSE muy alto puede sugerir outliers o que el modelo no representa bien la relación entre variables.

Selección de Variables

El R^2 también puede disminuir si se agregan variables irrelevantes en regresiones múltiples, lo que resalta la importancia de seleccionar bien los predictores.

Evaluación Integral

Al evaluar un modelo, siempre es recomendable combinar estas métricas con la inspección visual y la validación cruzada.

```python
import statsmodels.api as sm
import numpy as np

# Generate sample data
X = np.linesace(0, 10, 100)
y = 2 * X + np.random.normal(ize=100)
X = sm.add_constant(X)
# Add a constant (interceept) to the model
model = sm.OLS(y, X).fit()
# Fit the linear regression model
print(model.summary()
```

Implementación en Python con Librería Statsmodels

La implementación de modelos de regresión en Python puede realizarse de forma eficiente y detallada utilizando la librería statsmodels, que permite ajustar modelos estadísticos y obtener informes completos con métricas clave.

alkemy

Preparación de Datos

```
import pandas as pd
import numpy as np
import statsmodels.api as sm
import seaborn as sns
import matplotlib.pyplot as plt

# Cargar datos
tips = sns.load_dataset('tips')

# Definir variables
X = tips[['total_bill']]y = tips['tip']

# Agregar constante para el intercepto
X = sm.add_constant(X)
```

Para comenzar, se debe importar la base de datos y preparar las variables. En este ejemplo, se utiliza el dataset "tips" disponible en Seaborn, donde se buscará predecir el monto de la propina (tip) en función del total de la cuenta (total_bill).

Ajuste del Modelo

```
# Ajustar el modelomodel = sm.OLS(y, X).fit()#
Obtener resumen
estadísticoprint(model.summary())
```

```
import statsmodels.api as sm
import seaborn as sns

data = sns.load_dataset("tips")
X = sm.add_constant(data["total_bill"])
y = data["tip"]
modelo = sm.OLS(y, X).fit()
```

Una vez ajustado el modelo, se puede acceder a un resumen estadístico completo utilizando .summary().

alkemy

Interpretación del Resumen Estadístico

Este reporte incluye:

- Coeficientes estimados
- Intervalos de confianza
- Estadísticos t
- P-valores
- R^2 y R^2 ajustado

Esta información es esencial para interpretar la relación entre variables y determinar si los coeficientes son estadísticamente significativos.

alkemy

Predicciones con el Modelo

```
# Crear un nuevo dato para predicción
nuevo_dato = sm.add_constant(pd.DataFrame({'total_bill': [30]}))

# Realizar predicción
prediccion = model.predict(nuevo_dato)

print(f"Propina estimada para una cuenta de $30: ${prediccion[0]:.2f}")
```

Finalmente, el modelo puede utilizarse para hacer predicciones con nuevos datos. Por ejemplo, si queremos estimar la propina para una cuenta de $30.

Regresión Lineal Múltiple: Definición

La regresión lineal múltiple es una extensión del modelo lineal simple que permite incluir más de una variable predictora en el análisis. Su objetivo es modelar la relación entre una variable dependiente y varias independientes para mejorar la capacidad predictiva y captar relaciones más complejas.

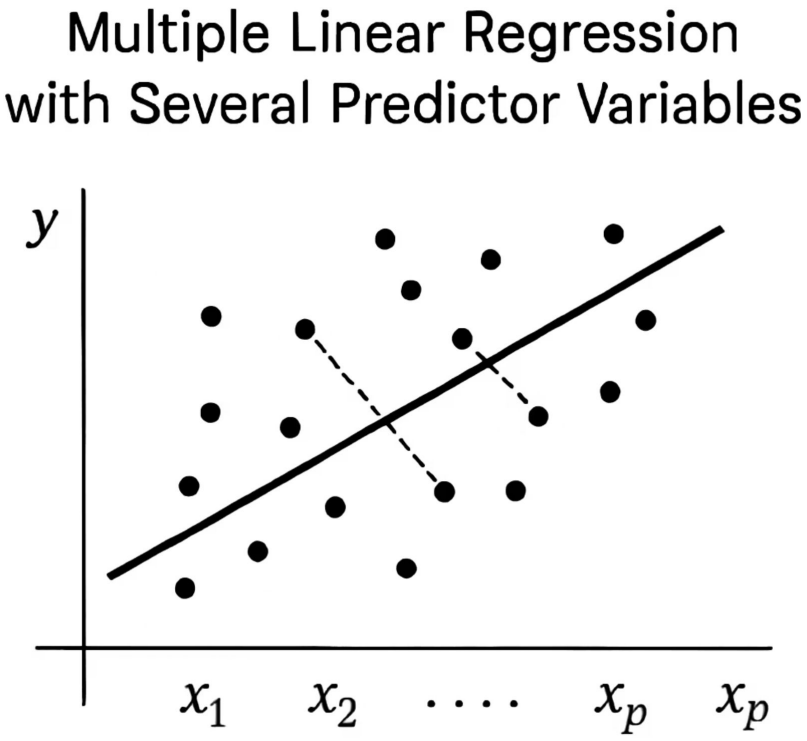

alkemy

Fórmula de la Regresión Múltiple

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p + \varepsilon$$

Donde:

- β_0 es el intercepto
- $\beta_1, \beta_2, \ldots, \beta_p$ son los coeficientes de cada variable predictora
- $x_1, x_2, \ldots, x_p$ son las variables predictoras
- ε es el término de error aleatorio

Cada coeficiente β_i representa el efecto de su variable asociada x_i, manteniendo constantes las demás.

alkemy

Aplicación de la Regresión Múltiple

Este tipo de análisis es especialmente útil cuando se sospecha que múltiples factores influyen sobre una variable. Por ejemplo, si queremos predecir el monto de una propina, podríamos considerar variables como:

Total de la Cuenta

El monto total facturado al cliente

Tamaño del Grupo

Cantidad de personas en la mesa

Día de la Semana

Si es día laborable o fin de semana

Género del Servidor

Si el cliente fue atendido por una moza mujer o no

Incluir múltiples predictores permite una modelización más precisa.

Implementación de Regresión Múltiple

```
# Definir múltiples predictores
X_multi = tips[['total_bill', 'size']]
X_multi = sm.add_constant(X_multi)

# Ajustar modelo múltiple
model_multi = sm.OLS(y, X_multi).fit()

# Ver resumen
print(model_multi.summary())
```

En Python, la implementación de una regresión múltiple con statsmodels es muy similar a la regresión simple. Basta con incluir múltiples columnas como predictores en el DataFrame.

Visualización de Relaciones Parciales

También es útil representar gráficamente las relaciones parciales para analizar si existen tendencias lineales entre cada predictor y la variable respuesta.

Aunque Seaborn no permite visualizar directamente modelos múltiples en un solo gráfico, podemos usar pairplot() o lmplot() de forma desagregada para explorar cada relación individual.

```
# Visualizar relación entre tamaño del grupo y propinasns.lmplot(x='size',
y='tip', data=tips)plt.title('Relación entre tamaño del grupo y
propina')plt.show()
```

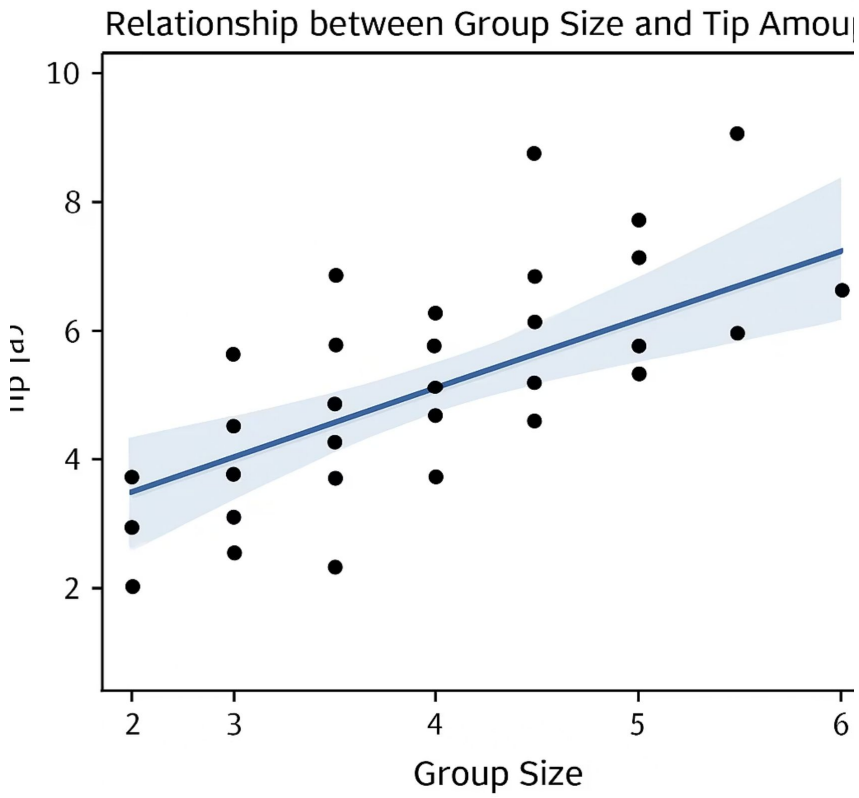

alkemy

Supuestos de una Regresión Múltiple

Para que un modelo de regresión múltiple sea válido y útil, debe cumplir ciertos supuestos estadísticos. Estos supuestos permiten que las estimaciones de los coeficientes sean consistentes, insesgadas y eficientes.

Linealidad

La relación entre cada predictor y la variable dependiente debe ser lineal.

Independencia de los Errores

Los errores de las observaciones deben ser independientes entre sí.

Homocedasticidad

La varianza del error es constante a lo largo de todos los valores de las variables independientes.

Normalidad del Error

Los residuos del modelo deben seguir una distribución normal.

Ausencia de Multicolinealidad

Las variables independientes no deben estar altamente correlacionadas entre sí.

alkemy

Live Coding

¿En qué consistirá la Demo?

En esta demo vamos a construir, ajustar y evaluar un modelo de regresión lineal múltiple utilizando Python.

1. *Cargaremos el dataset "tips" de Seaborn.*
2. *Prepararemos las variables predictoras y la respuesta.*
3. *Ajustaremos un modelo de regresión múltiple con statsmodels.*
4. *Visualizaremos las relaciones entre variables.*
5. *Calcularemos métricas de evaluación (MAE, MSE, R^2).*
6. *Interpretaremos los coeficientes del modelo.*
7. *Realizaremos una predicción con datos nuevos.*
8. *Mostraremos el resumen estadístico del modelo.*

Tiempo: 25 Minutos

Momento:

Time-out!

⏰5 -10 min.

alkemy

Ejercicio

Predicción de Ventas Semanales con Regresión Lineal Múltiple

Predicción de Ventas Semanales con Regresión Lineal Múltiple

Contexto: 🙌

Un equipo de marketing digital está analizando cómo influyen El monto invertido en publicidad online (en dólares) y La cantidad de visitas al sitio web en esa semana. en el número de ventas semanales de un producto.

El objetivo es determinar si existe una relación lineal y predecir las ventas futuras en base a estas dos variables.

Consigna: ✍️

1. Genere los datos usando numpy:
   - publicidad_usd: entre 500 y 10,000
   - visitas_web: entre 1,000 y 20,000
   - ventas: combinación lineal + ruido aleatorio (por ejemplo: ventas = 0.3*publicidad + 0.05*visitas + error)
2. Arme un DataFrame con pandas.

Tiempo 🕐**:** *45 Minutos*

alkemy

Predicción de Ventas Semanales con Regresión Lineal Múltiple

Paso a paso: ⚙️

1. Genere los datos usando numpy:
- publicidad_usd: entre 500 y 10,000
- visitas_web: entre 1,000 y 20,000
- ventas: combinación lineal + ruido aleatorio (por ejemplo: ventas = 0.3*publicidad + 0.05*visitas + error)
2. Arme un DataFrame con pandas
3. Explore visualmente los datos con histogramas y sns.pairplot.
4. Ajuste el modelo con statsmodels.OLS.
5. Calcule y reporta R^2, MAE, MSE y RMSE.
6. Predece las ventas para una semana con 7,500 USD de publicidad y 15,000 visitas.
7. Analizá qué variable tiene mayor peso en el modelo según los coeficientes.

¿Alguna consulta?

alkemy

Resumen

¿Qué logramos en esta clase?

- ✓ ***Aplicamos regresión lineal múltiple para predecir valores.***
- ✓ ***Visualizamos gráficamente las relaciones predictoras-respuesta.***
- ✓ ***Ajustamos el modelo utilizando statsmodels.***
- ✓ ***Evaluamos el modelo con métricas estadísticas clave.***

¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las ***actividades disponibles en la plataforma.*** *Estas propuestas son clave para afianzar lo trabajado y* ***forman parte obligatoria del recorrido de aprendizaje.***

💪 Análisis de caso ——— 💪 Selección Múltiple

💪 Comprensión lectora

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

alkemy

< ¡Muchas gracias! >

alkemy