Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😁

alkemy

Clase grabada

› Regresiones lineales- Parte II

Aprendizaje Esperado 4: Implementar un modelo de regresión lineal para el análisis de la dependencia de variables utilizando lenguaje python.

alkemy

Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**

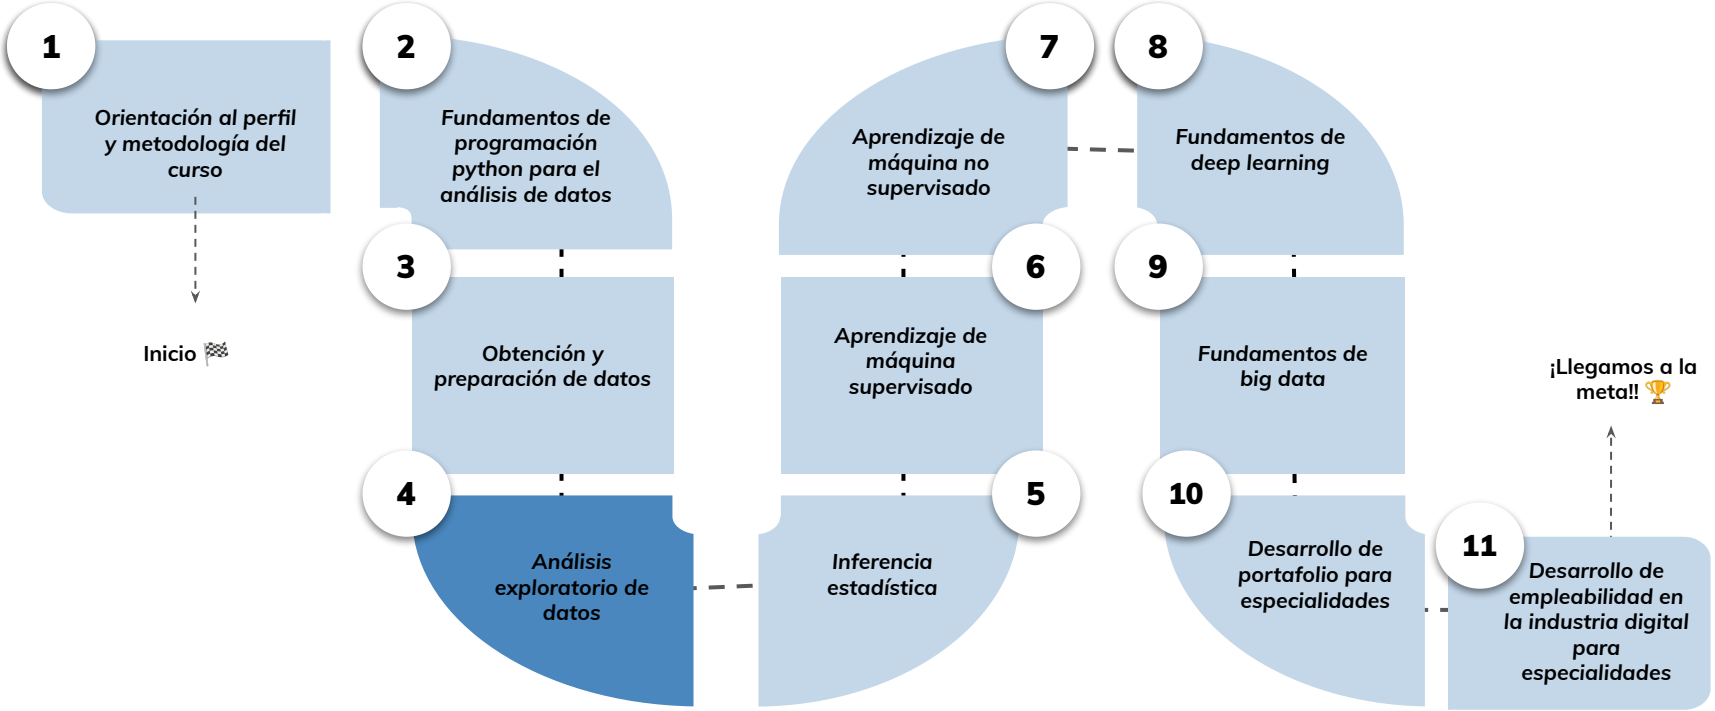

alkemy

Roadmap de lecciones

*¿Cuáles **lecciones** estaremos estudiando en este módulo?*

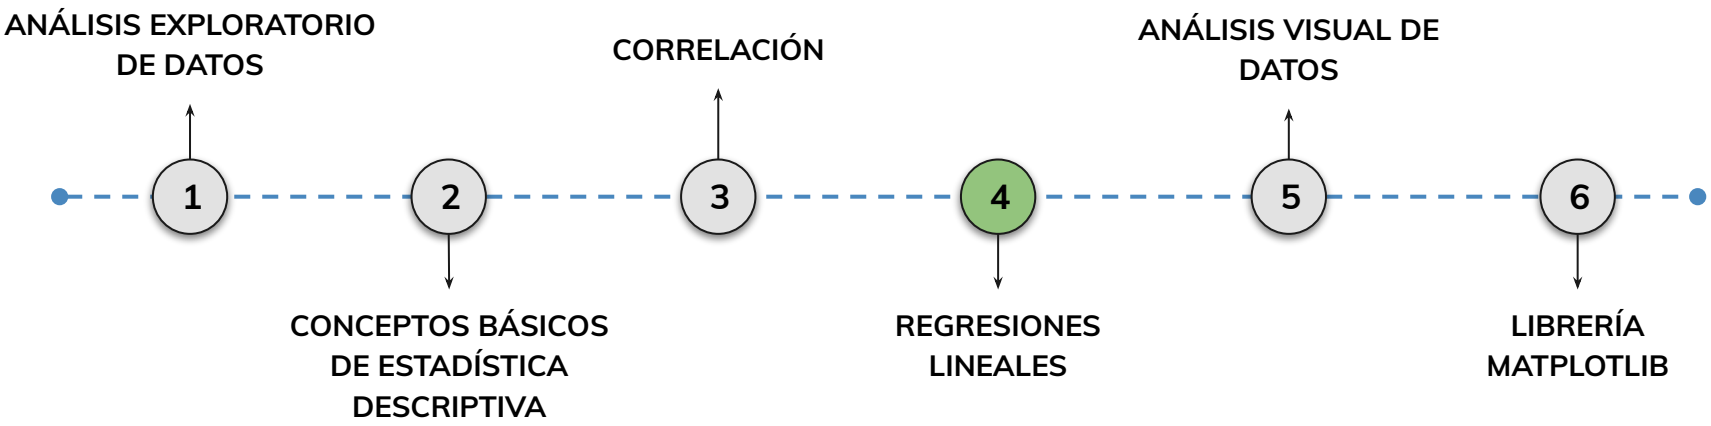

alkemy

Learning Path

¿Cuáles temas trabajaremos hoy?

4.

Implementación de modelos de regresión lineal en Python.

En esta segunda parte del trayecto, vamos a enfocarnos en validar modelos de regresión lineal aplicando métricas estadísticas y comprobando los supuestos clásicos del modelo. Profundizaremos en la interpretación del R^2 ajustado, en la selección de variables mediante criterios como AIC y BIC, y en herramientas para revisar normalidad del error y multicolinealidad.

- **Verificación de supuestos**
  - **linealidad, homocedasticidad**
  - **normalidad, multicolinealidad**
- **Interpretación del R^2 ajustado.**
  - **Selección de variables predictoras relevantes.**
  - **Métricas estadísticas: AIC y BIC.**

alkemy

Objetivos de aprendizaje

¿Qué aprenderás?

- Verificar los principales supuestos de un modelo de regresión lineal.
- Calcular e interpretar métricas de evaluación como R^2 ajustado, AIC y BIC.
- Analizar visualmente residuos y errores de predicción.
- Utilizar pruebas estadísticas como QQ-plot o VIF para validar modelos.
- Aplicar criterios estadísticos para la selección del mejor modelo predictivo.

Repaso clase anterior

¿Quedó alguna duda?

- → *Exploramos el concepto de regresión lineal simple y múltiple, entendiendo su función en el análisis de dependencia entre variables.*
- → *Implementamos modelos de regresión con la librería statsmodels y visualizamos relaciones con seaborn.*
- → *Interpretamos coeficientes, evaluamos métricas como R^2, MAE y MSE para medir el desempeño.*
- → *Analizamos la importancia del análisis visual previo y validamos nuestros resultados mediante gráficos y métricas estadísticas.*

alkemy

Regresiones lineales

Verificación de Linealidad

El supuesto de **linealidad** establece que la relación entre cada predictor y la variable dependiente debe ser lineal. Este supuesto puede verificarse visualmente mediante gráficos de dispersión entre cada variable independiente y la dependiente.

Si las relaciones no son lineales, es posible que se requieran transformaciones de las variables (como logaritmos) o el uso de modelos no lineales.

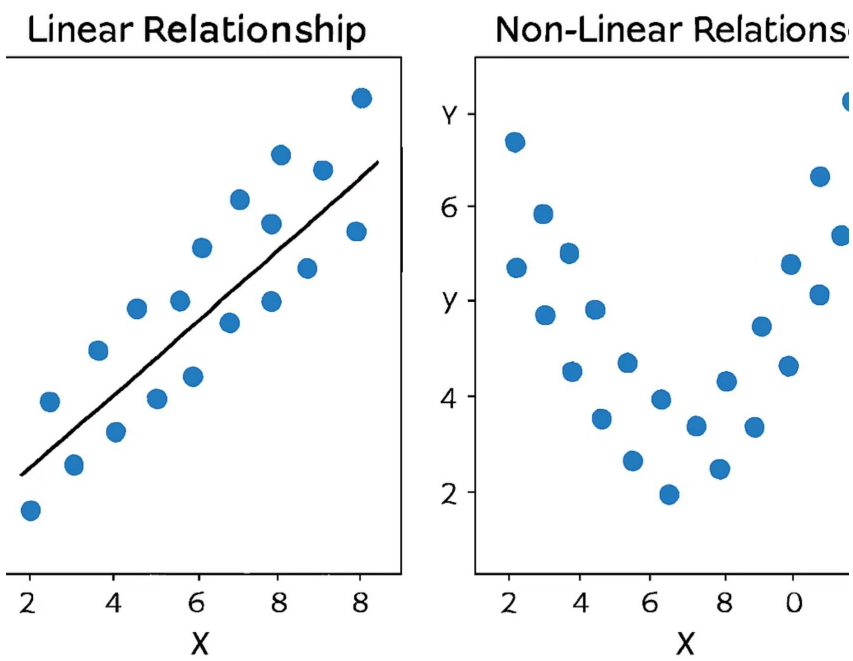

alkemy

Verificación de Homocedasticidad

El supuesto de **homocedasticidad** implica que la varianza del error es constante a lo largo de todos los valores de las variables independientes. Para evaluarlo, se puede graficar los residuos del modelo frente a los valores predichos.

```
import matplotlib.pyplot as plt

residuos = modelo_multi.resid
fitted = modelo_multi.fittedvalues
plt.scatter(fitted, residuos)
plt.axhline(0, color="red")
plt.xlabel("Valores predichos")
plt.ylabel("Residuos")
plt.title("Gráfico de residuos vs valores predichos")
plt.show()
```

Si los residuos muestran un patrón aleatorio en torno a la línea 0, el supuesto está cumplido. Si, en cambio, se observa un patrón en forma de embudo o curva, podría estar presente heterocedasticidad.

Verificación de Normalidad del Error

La **normalidad del error** se refiere a que los residuos del modelo deben seguir una distribución normal. Esto se puede comprobar con un QQ-plot.

```
import scipy.stats as stats
import matplotlib.pyplot as plt

stats.probplot(residuos, dist="norm", plot=plt)
plt.title("QQ-Plot de residuos")
plt.show()
```

Si los puntos se alinean aproximadamente sobre la línea diagonal, el supuesto se cumple. De lo contrario, puede ser necesario aplicar transformaciones o revisar la presencia de valores atípicos.

Verificación de Multicolinealidad

Finalmente, la **ausencia de multicolinealidad** se asegura revisando que las variables independientes no estén altamente correlacionadas entre sí. Esto puede evaluarse con el **factor de inflación de la varianza (VIF)**.
Un VIF superior a 5 o 10 puede indicar problemas de multicolinealidad.

```
from statsmodels.stats.outliers_influence
import variance_inflation_factor# Calcular VIF
para cada variablevif_data =
pd.DataFrame()vif_data["Variable"] =
X_multi.columnsvif_data["VIF"] =
[variance_inflation_factor(X_multi.values, i)
for i in
range(X_multi.shape[1])]print(vif_data)
```

alkemy

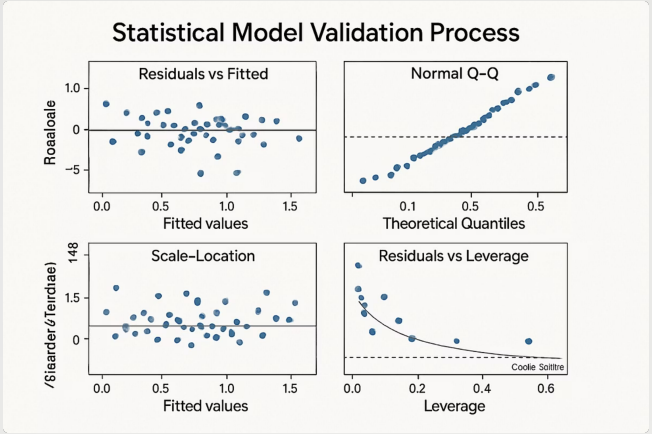

Importancia de los Supuestos

El cumplimiento de estos supuestos es clave para asegurar la validez de las inferencias que se extraen del modelo. Ignorarlos puede conducir a conclusiones erróneas o predicciones poco confiables.

alkemy

Indicador R² Ajustado

El coeficiente de determinación R² mide la proporción de la varianza en la variable dependiente que puede ser explicada por el modelo. Aunque esta métrica es útil para evaluar el ajuste general, tiene una limitación importante: **siempre aumenta al agregar más variables al modelo**, incluso si estas variables no son relevantes.

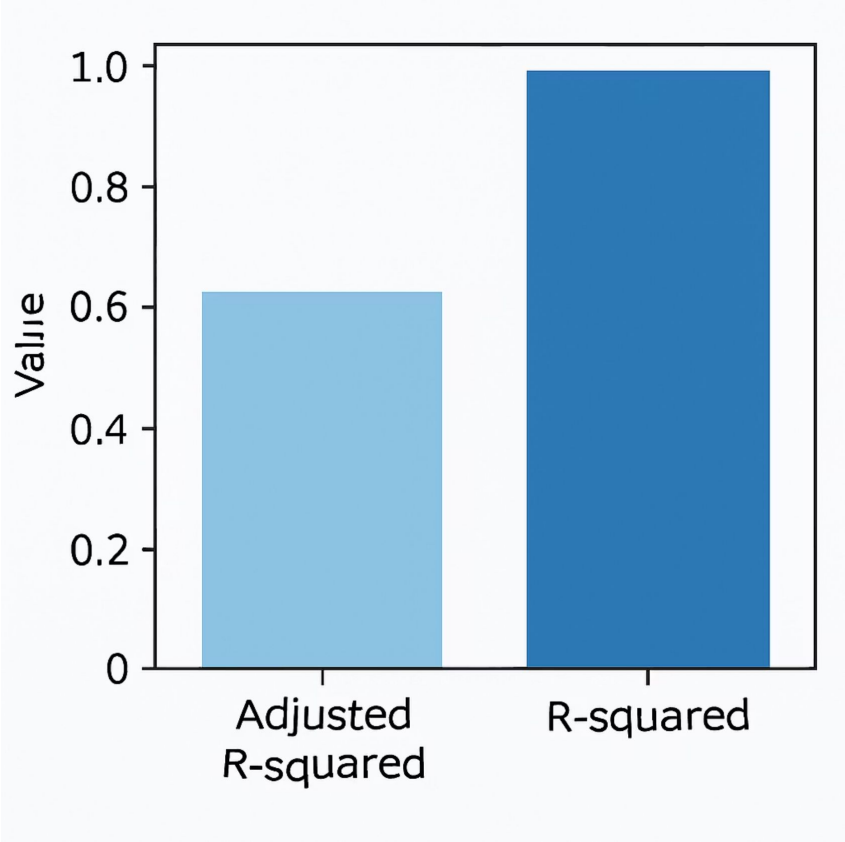

alkemy

Ventajas del R^2 Ajustado

Penalización por Complejidad

El R^2 ajustado penaliza la inclusión de predictores innecesarios, ajustando su valor según la cantidad de variables y observaciones.

Comparación Justa

Esto lo convierte en una métrica más realista al comparar modelos con distinto número de variables.

Disponibilidad

En Python, al utilizar .summary() de statsmodels, el valor de Adj. R-squared ya aparece junto al R^2 tradicional.

Ejemplo de R^2 Ajustado

Al revisar el resumen de un modelo, podemos observar tanto el R^2 como el R^2 ajustado, lo que nos permite evaluar si la adición de variables realmente mejora el modelo o solo lo hace más complejo sin beneficios significativos.

```
print(modelo_multi.rsquared)        # R²
print(modelo_multi.rsquared_adj)    # R² ajustado
```

alkemy

Selección del Modelo

Para seleccionar el mejor modelo, se recomienda probar distintas combinaciones de predictores y comparar sus métricas. No se debe buscar sólo maximizar el R^2, sino también considerar:

Significancia Estadística

Evaluar la significancia de los coeficientes mediante sus p-valores

Cumplimiento de Supuestos

Verificar que se cumplan los supuestos del modelo lineal

Interpretabilidad

Considerar la facilidad para interpretar y explicar el modelo

Riesgo de Sobreajuste

Evitar modelos demasiado complejos que se ajusten excesivamente a los datos de entrenamiento

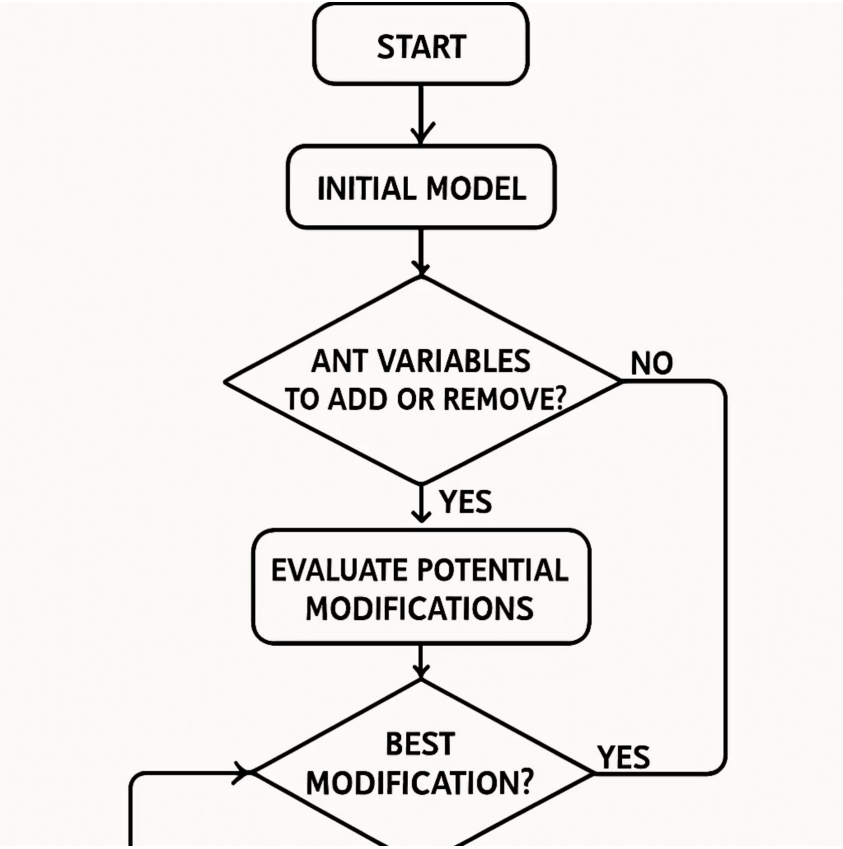

Técnica de Selección Stepwise

Una técnica frecuente es la **selección stepwise**, que agrega o elimina variables según su impacto estadístico. Existen tres variantes principales:

Forward selection: comienza sin variables y las agrega una a una

Backward elimination: comienza con todas las variables y las elimina una a una

Stepwise selection: combina ambos enfoques

alkemy

Criterios de Información

Además, el uso de información de criterio como el **AIC (Akaike Information Criterion)** o **BIC (Bayesian Information Criterion)** es útil. Estos valores penalizan la complejidad del modelo. Cuanto menor sea el AIC/BIC, mejor es el modelo en términos de equilibrio entre ajuste y simplicidad.

```
print("AIC:", modelo_multi.aic)
print("BIC:", modelo_multi.bic)
```

alkemy

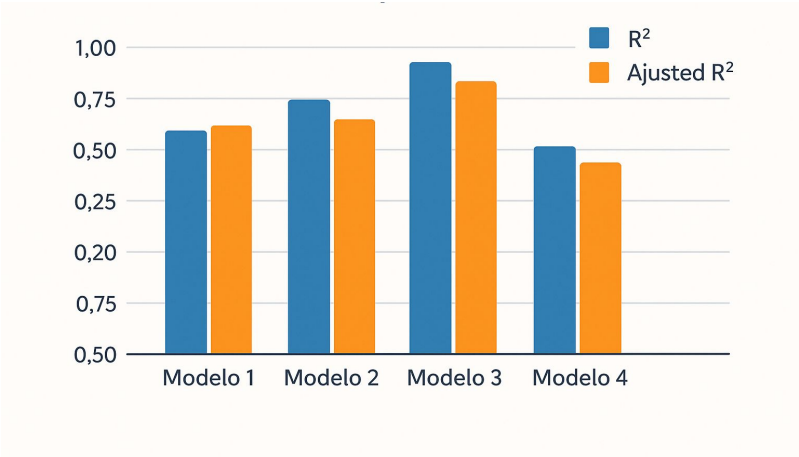

Visualización Comparativa de Modelos

Finalmente, se recomienda **visualizar el rendimiento comparado** de los modelos mediante un gráfico de barras de R^2 y R^2 ajustado o mediante validación cruzada. Esto permite tomar decisiones más informadas, evitando modelos sobre ajustados o poco explicativos.

La selección de modelos debe equilibrar precisión, parquedad y robustez.

alkemy

Test de Normalidad del Error

Uno de los supuestos fundamentales de los modelos de regresión es que los errores (residuos) del modelo estén distribuidos normalmente. Este supuesto es esencial para que las inferencias estadísticas (como los intervalos de confianza y los tests de significancia) sean válidas.

Si los errores no son normales, los estimadores aún pueden ser insesgados, pero las pruebas de hipótesis podrían ser incorrectas.

Métodos de Evaluación de Normalidad

QQ-Plot

Compara los cuantiles de los residuos con los de una distribución normal. Si los puntos siguen una línea recta, los errores pueden considerarse normales.

Test de Shapiro-Wilk

Prueba estadística específica para evaluar normalidad, especialmente útil para muestras pequeñas.

Test de Kolmogorov-Smirnov

Compara la distribución acumulada de los residuos con la de una distribución normal.

Test de Anderson-Darling

Prueba que da más peso a las colas de la distribución, donde suelen aparecer las desviaciones de la normalidad.

alkemy

Implementación del QQ-Plot

En Python, se puede implementar un QQ-Plot con scipy.stats:

```
import scipy.stats as stats# Obtener
residuosresiduos = model.resid# Crear QQ-Plotfig, ax
= plt.subplots(figsize=(8,
6))stats.probplot(residuos,
plot=ax)plt.title('QQ-Plot de los
residuos')plt.show()
```

```
import scipy.stats as stats
import matplotlib.pyplot as plt

stats.probplot(modelo_multi.resid, dist="norm", plot=plt)
plt.title("QQ-Plot de residuos")
plt.show()
```

alkemy

Pruebas Estadísticas de Normalidad

```
# Test de Shapiro-Wilkshapiro_test = stats.shapiro(residuos)print(f"Test de Shapiro-Wilk -
Estadístico: {shapiro_test[0]:.4f}, p-valor: {shapiro_test[1]:.4f}")# Test de
Kolmogorov-Smirnovks_test = stats.kstest(residuos, 'norm', args=(np.mean(residuos), np.std(residuos,
ddof=1)))print(f"Test de Kolmogorov-Smirnov - Estadístico: {ks_test[0]:.4f}, p-valor:
{ks_test[1]:.4f}")
```

Estas pruebas devuelven un p-valor que se interpreta como en cualquier test de hipótesis: si es menor que 0.05, se rechaza la normalidad.

alkemy

Interpretación de Resultados

1

P-valor > 0.05

No se rechaza la hipótesis de normalidad. Los residuos pueden considerarse normalmente distribuidos.

2

P-valor < 0.05

Se rechaza la hipótesis de normalidad. Los residuos no siguen una distribución normal.

3

Acciones Correctivas

Si se rechaza la normalidad, se pueden aplicar transformaciones sobre la variable dependiente (logaritmo, raíz cuadrada, Box-Cox, etc.) o considerar modelos no lineales más robustos a la no normalidad.

alkemy

Importancia de la Normalidad

Verificar la normalidad del error no es solo una formalidad técnica: si el modelo será usado para predicción o inferencia (como estimar efectos o calcular intervalos), es crucial asegurar que este supuesto se cumpla.

En resumen, el test de normalidad completa el proceso de validación de un modelo lineal, asegurando que los resultados estadísticos derivados del mismo sean confiables.

Resumen: Análisis Visual y Modelos Estadísticos

A lo largo de este manual, exploramos el poder del análisis visual de datos combinado con modelos estadísticos de regresión, centrándonos en las técnicas de regresión lineal simple y múltiple implementadas con Python.

alkemy

Aspectos Clave Abordados

Coeficientes de Regresión

Abordamos el cálculo e interpretación de coeficientes, entendiendo su significado estadístico y práctico.

Métricas de Error

Exploramos métricas como el MAE, MSE y R^2, comprendiendo su utilidad para evaluar modelos.

Evaluación de Modelos

Evaluamos la calidad de los modelos mediante criterios estadísticos y visuales, como los gráficos de residuos y QQ-Plots.

alkemy

Supuestos de los Modelos Regresivos

También estudiamos los supuestos clave que deben cumplirse para garantizar que los modelos regresivos sean válidos:

- **Linealidad**
- **Independencia**
- **Homocedasticidad**
- **Normalidad**
- **No Multicolinealidad**

alkemy

Herramientas Utilizadas

Python

Lenguaje de programación principal para implementar los modelos y análisis.

Seaborn

Biblioteca para visualización estadística que facilita la creación de gráficos informativos.

Statsmodels

Biblioteca especializada en modelos estadísticos que proporciona herramientas para ajustar e interpretar regresiones.

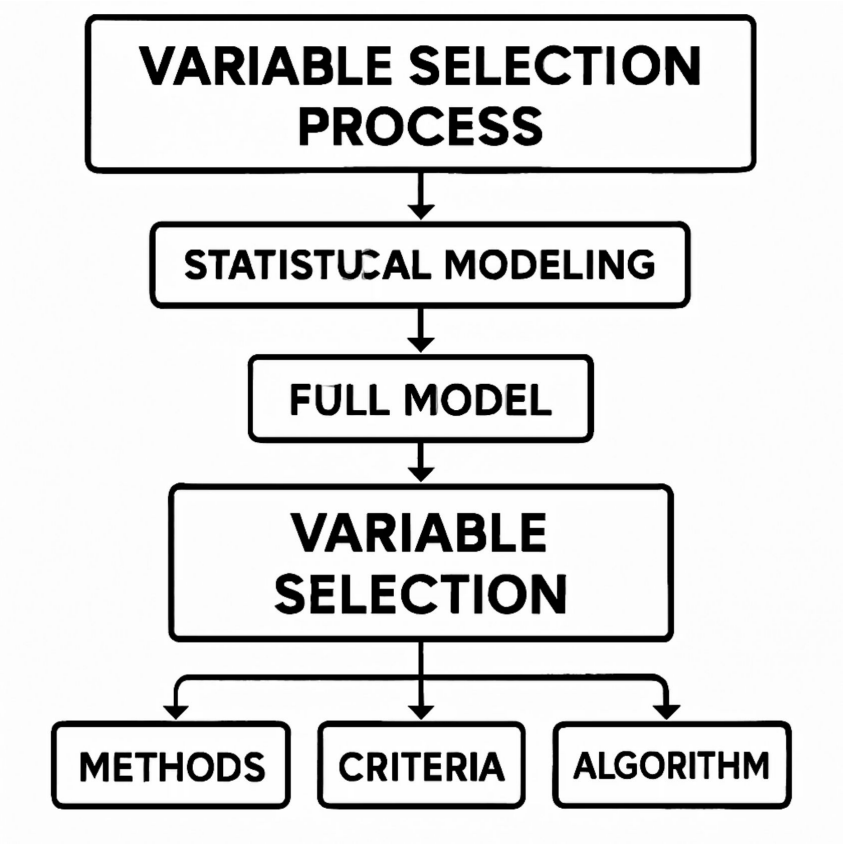

Selección de Variables y Modelos

Finalmente, profundizamos en la importancia de la selección de variables y del uso del R^2 ajustado, AIC y BIC para construir modelos más robustos.

Este conocimiento resulta fundamental para cualquier analista de datos o profesional que desee generar insights válidos a partir de datos reales.

alkemy

Aplicaciones Prácticas

Predicción de Ventas

Estimar ventas futuras basadas en variables como publicidad, temporada y precios.

Análisis de Factores

Identificar qué variables tienen mayor impacto en un resultado específico.

Optimización de Procesos

Ajustar parámetros para maximizar eficiencia basándose en modelos predictivos.

Investigación Científica

Establecer relaciones entre variables en estudios experimentales.

Visualización de Resultados

La visualización efectiva de los resultados es crucial para comunicar hallazgos y facilitar la toma de decisiones basada en datos.

alkemy

Próximos Pasos

Práctica con Datasets Reales

Aplicar los conceptos aprendidos a conjuntos de datos de tu área de interés.

Explorar Técnicas Avanzadas

Profundizar en métodos como regresión polinómica, regularización (Ridge, Lasso) o modelos no lineales.

Integrar con Machine Learning

Combinar regresión con técnicas de aprendizaje automático para análisis más sofisticados.

Consejos Prácticos

Exploración Previa

Siempre realiza un análisis exploratorio de datos antes de ajustar modelos para entender mejor las relaciones entre variables.

Validación Cruzada

Utiliza técnicas de validación cruzada para evaluar la robustez de tus modelos y evitar el sobreajuste.

Interpretación Contextual

Interpreta los resultados en el contexto del problema específico, considerando el significado práctico de los coeficientes y predicciones.

Documentación Clara

Documenta claramente tus decisiones de modelado, supuestos y limitaciones para facilitar la reproducibilidad y comunicación.

Herramientas Complementarias

Además de las bibliotecas mencionadas, existen otras herramientas que pueden complementar tu análisis de regresión, como Matplotlib para visualizaciones personalizadas, Scikit-learn para implementaciones de machine learning, y Jupyter Notebooks para documentación interactiva.

Conclusión

La regresión lineal es una herramienta poderosa para el análisis de datos que, cuando se implementa correctamente, puede proporcionar insights valiosos sobre las relaciones entre variables. Al combinar técnicas de visualización con métodos estadísticos rigurosos, los analistas pueden construir modelos robustos y comunicar sus hallazgos de manera efectiva.

Este manual ha proporcionado las bases para implementar, evaluar e interpretar modelos de regresión lineal en Python, sentando las bases para análisis más avanzados en el futuro.

Live Coding

¿En qué consistirá la Demo?

Aplique un modelo de regresión lineal múltiple y verificar los principales supuestos (linealidad, homocedasticidad, normalidad del error, multicolinealidad).

1. *Simule o cargue un dataset con 2-3 predictores y 1 variable dependiente (puede usarse tips o un dataset propio generado).*
2. *Ajuste el modelo de regresión lineal múltiple con statsmodels.*
3. *Verifique el supuesto de linealidad mediante gráficos de dispersión entre predictores y la variable dependiente.*
4. *Verifique homocedasticidad graficando residuos vs. valores ajustados.*
5. *Verifique normalidad del error con QQ-plot y test de Shapiro-Wilk.*
6. *Calcule VIF para revisar multicolinealidad.*
7. *Discute los resultados con los estudiantes y propone mejoras en caso de supuestos no cumplidos.*

Tiempo: 25 Minutos

Momento:

Time-out!

⏰5 -10 min.

alkemy

Ejercicio

Validación y selección de un modelo de regresión óptimo

Validación y selección de un modelo de regresión óptimo

Contexto: 🙌

Una empresa de entregas está diseñando una nueva herramienta de predicción para mejorar su eficiencia logística. Actualmente tienen registros de las distancias recorridas, el peso del pedido, el número de paradas intermedias, y el tiempo total de entrega.

Tu rol como analista es implementar un modelo de regresión lineal que no solo se ajuste bien, sino que cumpla los supuestos estadísticos, y permita elegir correctamente qué variables utilizar para obtener las mejores predicciones.

Consigna: ✍️

A partir de un conjunto de datos simulado, construye un modelo de regresión lineal múltiple para predecir el tiempo de entrega de pedidos.

Valide los supuestos clave del modelo, evalúe su desempeño y realice comparaciones entre posibles variantes del modelo utilizando criterios estadísticos.

Tiempo 🕐**:** *45 Minutos*

alkemy

Validación y selección de un modelo de regresión óptimo

Paso a paso: ⚙️

1. Simulación de datos: Genere un DataFrame con al menos 3 variables predictoras (distancia_km, peso_kg, paradas) y una respuesta (tiempo_entrega_dias).
2. Visualización inicial: Use pairplot, histplot o scatterplot para explorar la relación entre variables.
3. Ajuste del modelo: Utilice statsmodels.OLS() para construir la regresión lineal múltiple.
4. Evaluación métrica: Calcule R^2, R^2 ajustado, MAE, MSE, RMSE.
5. Verificación de supuestos:

- QQ-plot para normalidad del error
- Gráfico de residuos vs valores ajustados
- Cálculo de VIF para revisar multicolinealidad

6. Comparación de modelos:

- Propon al menos dos versiones del modelo (una con todas las variables y otra con solo las significativas)
- Compare usando AIC y BIC

7. Conclusión final: Justifique qué modelo se ajusta mejor y qué variables deberían mantenerse o descartarse.

¿Alguna consulta?

alkemy

Resumen

¿Qué logramos en esta clase?

- ✓ ***Aplicamos un modelo de regresión lineal múltiple a datos simulados.***
- ✓ ***Evaluamos el ajuste del modelo con R^2 y R^2 ajustado.***
- ✓ ***Verificamos los supuestos de normalidad del error, homocedasticidad y multicolinealidad.***
- ✓ ***Utilizamos criterios como AIC y BIC para comparar modelos y seleccionar el más eficiente.***

¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las ***actividades disponibles en la plataforma.*** *Estas propuestas son clave para afianzar lo trabajado y* ***forman parte obligatoria del recorrido de aprendizaje.***

💪 Análisis de caso ——— 💪 Selección Múltiple

💪 Comprensión lectora

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

alkemy

< ¡Muchas gracias! >

alkemy