# INFORME TÉCNICO DE ANÁLISIS EXPLORATORIO DE DATOS

## Proyecto: Análisis exploratorio de datos para decisiones comerciales - ComercioYA

---

**INFORMACIÓN DEL PROYECTO**

- **Cliente**: ComercioYA - Empresa de ventas en línea
- **Unidad solicitante**: Dirección de Análisis Estratégico
- **Periodo de análisis**: 2022 - 2024
- **Dataset**: ecommerce_sales_data-2.csv
- **Fecha de entrega**: Enero 2026
- **Módulo**: Análisis Exploratorio de Datos (Módulo 4)

---

## 1. RESUMEN EJECUTIVO

ComercioYA requiere comprender el comportamiento histórico de sus ventas para tomar decisiones estratégicas basadas en evidencia. Este informe presenta un análisis exploratorio de datos (EDA) sobre las transacciones registradas entre 2022 y 2024, identificando patrones de ventas, rentabilidad por categoría y región, y relaciones clave entre variables operativas.

Los hallazgos principales revelan que:

- Las categorías Electronics y Accessories representan la mayor parte de las ventas.
- Existe variabilidad significativa en la rentabilidad entre regiones.
- La correlación entre ventas y ganancia es positiva pero no perfecta, evidenciando oportunidades de optimización de márgenes.
- Modelos de regresión lineal confirman que las ventas son el principal predictor de ganancia, aunque la cantidad vendida aporta información complementaria.

---

## 2. CONTEXTO Y OBJETIVOS

### 2.1 Situación inicial

ComercioYA ha recolectado datos históricos de comportamiento de clientes (compras, montos, productos, regiones), pero el equipo directivo no tiene claridad sobre cómo interpretarlos ni qué variables son relevantes para mejorar la estrategia de ventas y marketing.

### 2.2 Objetivos del análisis

- Aplicar técnicas de Análisis Exploratorio de Datos (EDA) para identificar patrones, relaciones y valores atípicos.
- Calcular estadísticas descriptivas y correlaciones entre variables clave.
- Ajustar modelos de regresión lineal para explicar la ganancia en función de ventas y cantidad.
- Generar visualizaciones profesionales que comuniquen hallazgos relevantes.
- Entregar recomendaciones estratégicas sustentadas en evidencia.

---

## 3. METODOLOGÍA

El análisis se estructuró en 6 lecciones progresivas siguiendo la consigna del módulo:

| Lección | Enfoque | Técnicas aplicadas |
|---|---|---|
| 1. EDA inicial | Comprensión de datos | Identificación de tipos de variables, detección de nulos |
| 2. Estadística descriptiva | Medidas de centralidad | Media, mediana, desviación, cuartiles, boxplots |
| 3. Correlación | Relaciones entre variables | Coeficiente de Pearson, matrices, scatterplots |
| 4. Regresión lineal | Modelado predictivo | Regresión simple y múltiple, $R^2$, MSE |
| 5. Visualización Seaborn | Análisis visual avanzado | Pairplot, violinplot, jointplot, heatmap |
| 6. Matplotlib | Personalización gráfica | Subplots, títulos, anotaciones, exportación |

Table 1: Estructura metodológica del análisis

**Herramientas utilizadas:**

- Python 3.8+
- Librerías: pandas, numpy, seaborn, matplotlib, statsmodels
- Entorno: Visual Studio Code con Jupyter Notebook

---

## 4. DESCRIPCIÓN DE LOS DATOS

### 4.1 Estructura del dataset

El archivo ecommerce_sales_data-2.csv contiene 1,000 registros de transacciones con las siguientes columnas:

| Columna | Tipo | Descripción |
|---|---|---|
| Order Date | Fecha | Fecha de la transacción (2022-2024) |
| Product | Categórica | Nombre del producto (Laptop, Mouse, Printer, etc.) |
| Category | Categórica | Categoría (Electronics, Accessories, Office) |
| Region | Categórica | Región de venta (North, South, East, West) |
| Quantity | Numérica | Unidades vendidas |
| Sales | Numérica | Monto de ventas en USD |
| Profit | Numérica | Ganancia generada en USD |

Table 2: Estructura del dataset

### 4.2 Calidad de los datos

- Valores faltantes: 0% en todas las columnas.
- Consistencia: No se detectaron inconsistencias en formatos o rangos de valores.
- Periodo temporal: Datos distribuidos entre enero 2022 y diciembre 2024.

---

## 5. ANÁLISIS Y RESULTADOS

### 5.1 Análisis exploratorio inicial (Lección 1)

**Variables identificadas:**

- Numéricas: Quantity, Sales, Profit
- Categóricas: Product, Category, Region

**Variables derivadas creadas:**

- Year: Año de la transacción
- Month: Mes de la transacción

**Primeros hallazgos:**

- Transacciones distribuidas uniformemente entre 2022-2024.
- Amplio rango de valores en Sales (desde $10 hasta más de $10,000).
- Profit presenta casos negativos y valores extremos positivos.

---

### 5.2 Estadística descriptiva (Lección 2)

**Medidas de tendencia central y dispersión:**

| Variable | Media | Mediana | Desv. Estándar | Mín | Máx |
|---|---|---|---|---|---|
| Quantity | 5.0 | 5.0 | 2.6 | 1 | 9 |
| Sales | 3,078 | 2,472 | 2,498 | 10 | 10,656 |
| Profit | 541 | 422 | 493 | 10 | 2,799 |

Table 3: Estadísticas descriptivas de variables numéricas

**Observaciones clave:**

- Sales presenta alta dispersión (coeficiente de variación ~81%), indicando gran variabilidad en montos de transacción.
- Profit muestra distribución asimétrica con concentración en valores bajos y cola larga hacia valores altos.
- Se detectaron aproximadamente 50 outliers en Profit (valores extremadamente altos o bajos según IQR).

**Distribuciones por categoría:**

- Electronics concentra las ventas de mayor monto promedio.
- Accessories tiene mayor frecuencia de transacciones pero montos menores.
- Office presenta el comportamiento más estable en ganancia.

---

## 5.3 Análisis de correlación (Lección 3)

**Matriz de correlación (Pearson):**

| | Quantity | Sales | Profit |
|---|---|---|---|
| Quantity | 1.00 | 0.52 | 0.46 |
| Sales | 0.52 | 1.00 | 0.88 |
| Profit | 0.46 | 0.88 | 1.00 |

Table 4: Matriz de correlación entre variables numéricas

**Hallazgos principales:**

- Sales y Profit tienen correlación muy alta ($r = 0.88$), lo cual es esperado: mayores ventas tienden a generar mayores ganancias.
- Quantity tiene correlación moderada con Sales ($r = 0.52$) y Profit ($r = 0.46$), sugiriendo que el valor unitario de los productos varía considerablemente.
- No se detectaron correlaciones espurias evidentes.

**Análisis visual:**

- Los scatterplots confirman relación lineal positiva entre Sales y Profit, con mayor dispersión en valores altos.
- Existen productos de alto volumen (Quantity) con márgenes bajos y viceversa.

---

### 5.4 Modelos de regresión lineal (Lección 4)

**Modelo 1: Regresión simple - Profit ~ Sales**

$$R^2 = 0.77$$

Coeficiente Sales: 0.173 ($p < 0.001$)

Intercepto: 9.12 ($p < 0.001$)

**Interpretación:**

- El modelo explica el 77% de la variabilidad en Profit.
- Por cada dólar adicional en Sales, se espera un incremento de $0.17 en Profit.
- El predictor es altamente significativo ($p < 0.001$).

**Modelo 2: Regresión múltiple - Profit ~ Sales + Quantity**

$$R^2 = 0.78$$

Coeficiente Sales: 0.169 ($p < 0.001$)

Coeficiente Quantity: 16.8 ($p < 0.001$)

**Interpretación:**

- Agregar Quantity mejora ligeramente el $R^2$ (de 0.77 a 0.78).
- Ambos predictores son significativos.
- Controlando por Sales, cada unidad adicional vendida agrega aproximadamente $17 al Profit.

---

### 5.5 Visualización avanzada (Lecciones 5 y 6)

**Gráficos generados:**

1. Pairplot: Confirma relaciones lineales entre variables numéricas.
2. Violinplot (Profit por Region): La región East muestra mayor concentración de ganancias altas.
3. Jointplot (Sales vs Profit): Densidad máxima en rango medio de ventas ($2,000-$4,000).
4. FacetGrid: Distribución de Sales varía significativamente entre regiones y categorías.
5. Subplots de resumen: Sales por año muestra crecimiento sostenido de 2022 a 2024.

---

## 6. HALLAZGOS CLAVE

### 6.1 Comportamiento por categoría

- Electronics genera el mayor volumen de ventas y ganancias absolutas.
- Accessories tiene alta frecuencia de transacciones pero márgenes más bajos.
- Office presenta el comportamiento más estable y predecible.

### 6.2 Comportamiento por región

- East y West concentran la mayor parte de las ganancias.
- North muestra potencial de crecimiento con ventas moderadas pero márgenes competitivos.
- South tiene volumen intermedio con oportunidades de optimización de precios.

### 6.3 Relación ventas-ganancia

- Correlación fuerte (r = 0.88) pero no perfecta: existen productos de alto volumen con márgenes bajos.
- La presencia de outliers sugiere productos premium con rentabilidad excepcional.
- El modelo de regresión explica 77-78% de la variabilidad, dejando espacio para factores no capturados.

### 6.4 Evolución temporal

- Tendencia positiva de ventas de 2022 a 2024.
- No se observan patrones estacionales claros en el periodo analizado.

---

## 7. RECOMENDACIONES ESTRATÉGICAS

### 7.1 Optimización de portafolio

- Priorizar productos de Electronics con alta demanda y buenos márgenes.
- Revisar productos de Accessories con muchas ventas pero baja ganancia: ajustar precios o reducir costos.
- Expandir línea Office aprovechando su estabilidad y potencial de crecimiento.

### 7.2 Estrategia regional

- Fortalecer presencia en East y West con campañas focalizadas en productos premium.
- Incrementar inversión en North con promociones de volumen para captar mercado.
- Analizar costos operativos en South para mejorar márgenes sin sacrificar volumen.

### 7.3 Gestión de márgenes

- Identificar productos con Sales alto y Profit bajo: revisar estructura de costos.
- Potenciar productos outliers (alta ganancia relativa): aumentar visibilidad y disponibilidad.
- Implementar análisis ABC para priorizar esfuerzos comerciales y logísticos.

### 7.4 Analítica avanzada

- Incorporar datos de clientes individuales (frecuencia, recencia, valor de vida).
- Añadir variables de devoluciones y reseñas para análisis de satisfacción.
- Construir modelos predictivos de demanda y segmentación de clientes.
- Implementar dashboards en tiempo real para seguimiento de KPIs.

---

# 8. LIMITACIONES DEL ESTUDIO

- Datos agregados a nivel transacción: No se dispone de información de clientes individuales.
- Ausencia de costos desagregados: No es posible analizar estructura de costos por producto y región.
- Periodo limitado: 3 años pueden no capturar ciclos económicos completos.
- Variables externas no consideradas: Competencia, estacionalidad, campañas de marketing.

---

# 9. CONCLUSIONES

Este análisis exploratorio ha permitido identificar patrones claros en el comportamiento de ventas y rentabilidad de ComercioYA. Las categorías Electronics y Accessories son los pilares del negocio, mientras que las regiones East y West presentan mayor rentabilidad.

La relación positiva entre ventas y ganancia confirma que el crecimiento en volumen tiende a mejorar los resultados financieros, aunque existen oportunidades de optimización en productos específicos con márgenes bajos.

Las recomendaciones entregadas proporcionan una hoja de ruta clara para mejorar la toma de decisiones, priorizar inversiones comerciales y preparar el terreno para análisis más avanzados de segmentación y predicción.

---

# 10. PRÓXIMOS PASOS

1. Validación de hallazgos con equipo directivo y comercial.
2. Implementación de dashboards con indicadores clave (ventas, margen, evolución).
3. Ampliación del dataset con variables de clientes, devoluciones y reseñas.
4. Desarrollo de modelos predictivos para pronóstico de demanda.
5. Pruebas A/B en estrategias de precios y promociones en productos identificados.

---

# ANEXOS

## A. Gráficos de referencia

- Histogramas de Sales, Profit y Quantity
- Boxplots por Category y Region
- Matriz de correlación (heatmap)
- Scatterplots Sales vs Profit
- Regresión lineal simple
- Pairplot de variables numéricas
- Jointplot Sales vs Profit
- FacetGrid por Region y Category
- Resumen visual (3 subplots)

## B. Código fuente

Disponible en repositorio GitHub del proyecto.

## C. Dataset utilizado

ecommerce_sales_data-2.csv (1,000 registros, periodo 2022-2024)

---

**FIN DEL INFORME TÉCNICO**

Documento generado: Enero 2026

Proyecto: Análisis Exploratorio de Datos - ComercioYA

Módulo 4: Análisis Exploratorio de Datos