Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😁

alkemy

Clase grabada

› Data wrangling - Parte II

Aprendizaje Esperado 5: Aplicar técnicas de data wrangling para la manipulación, enriquecimiento y transformación de datos en una estructura de tipo serie o dataframe para la resolución de un problema.

Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**

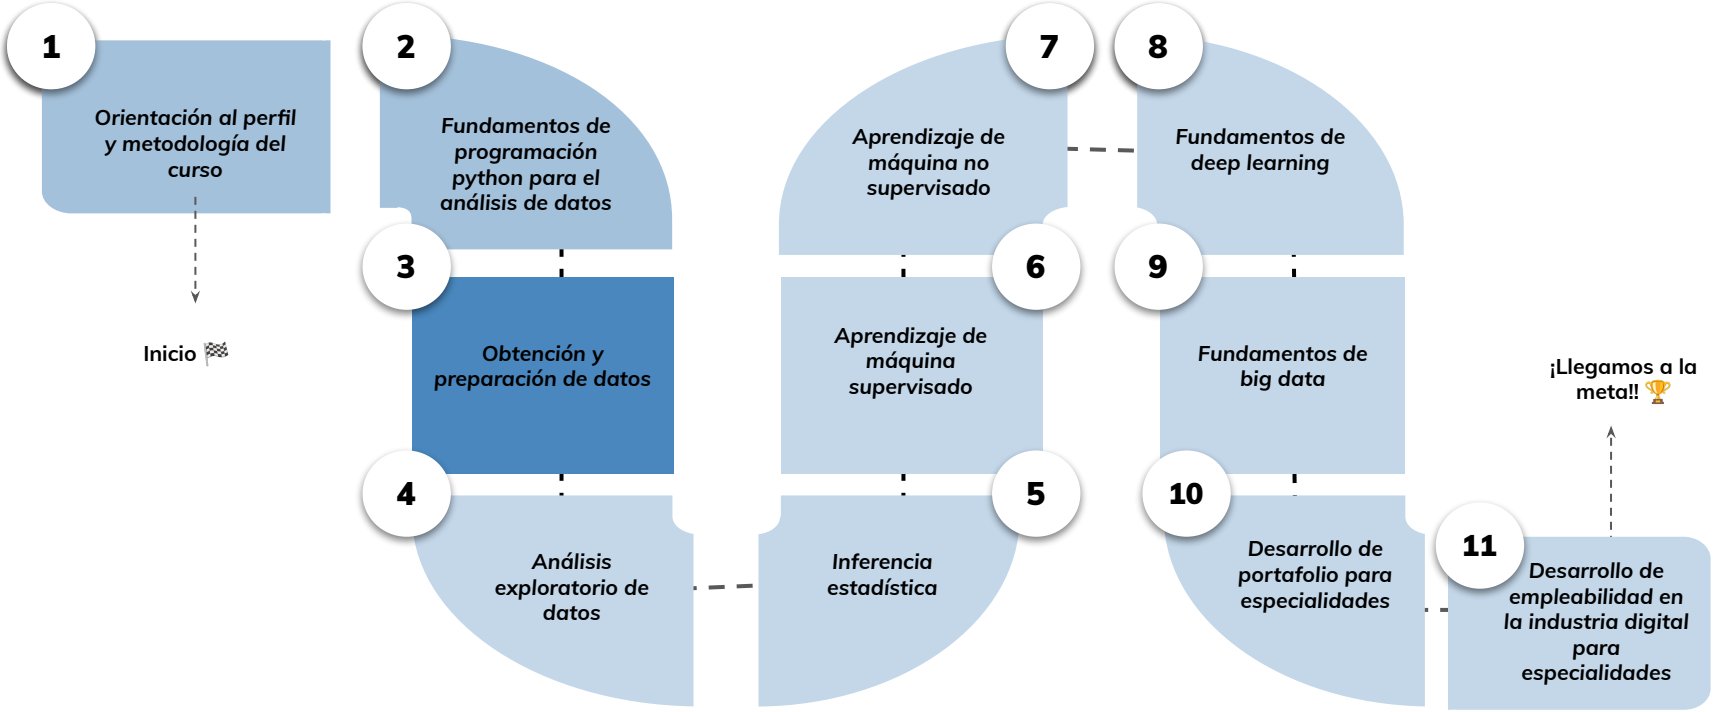

alkemy

Roadmap de lecciones

*¿Cuáles **lecciones** estaremos estudiando en este módulo?*

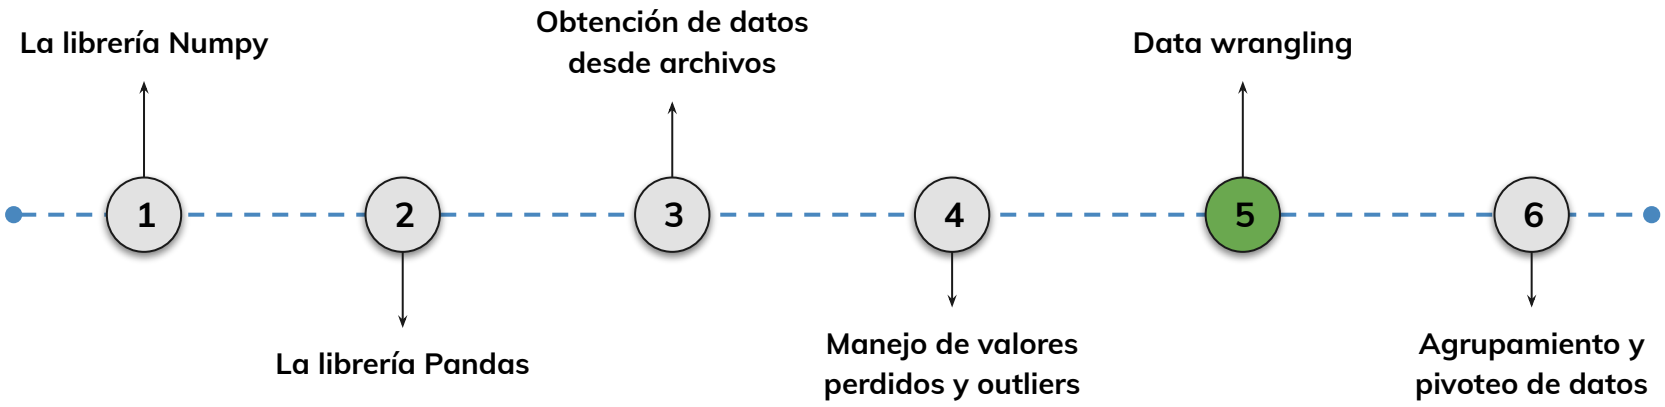

alkemy

Learning Path

¿Cuáles temas trabajaremos hoy?

5.

Reestructuración de datos en DataFrames

Desarrollarás habilidades para modificar la estructura interna de un DataFrame: agregar o eliminar columnas, redefinir índices, convertir formatos y aplicar funciones de limpieza que preparan los datos para análisis más complejos.

- **Modificación estructural**
  - Agregar y eliminar columnas
  - Conversión de tipos
- **Redefinición y renombramiento**
  - Cambio de índice
  - Renombrar columnas y automatizar procesos

alkemy

Objetivos de aprendizaje

¿Qué aprenderás?

- Manipular estructuras de un DataFrame.
- Aplicar redimensión, cambio de índices y renombramiento.
- Automatizar procesos de limpieza.

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos 📚:

→ *Qué es data wrangling.*

→ *Técnicas básicas con Pandas.*

→ *Eliminación de duplicados y reemplazo.*

→ *Enriquecimiento con funciones.*

MANIPULACIÓN DE LA ESTRUCTURA DE UN DATAFRAME

Manipulación de la estructura de un dataframe

La manipulación de la estructura de un DataFrame permite reorganizar, modificar y optimizar los datos para facilitar su análisis y comprensión.

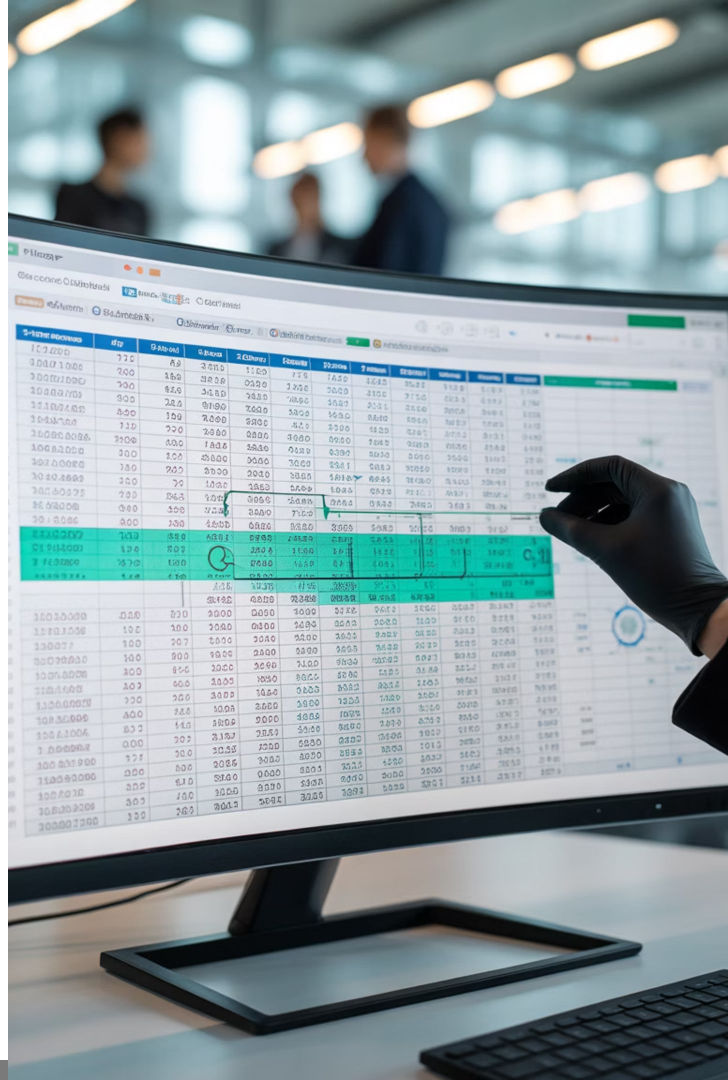

Agregar o eliminar columnas

En Pandas, se pueden agregar o eliminar columnas fácilmente utilizando las funciones assign(), drop() y la asignación directa de valores.

alkemy

```python
# Crear un DataFrame
df = pd.DataFrame({'Nombre': ['Ana', 'Luis', 'Carlos'],
                   'Edad': [25, 30, 28]})

# Agregar una nueva columna
df['Ciudad'] = ['Madrid', 'Barcelona', 'Sevilla']
print(df)
```

Ejemplo de agregar una nueva columna

En este ejemplo se muestra cómo agregar una nueva columna a un DataFrame utilizando la asignación directa de valores.

alkemy

```python
# Eliminar la columna 'Ciudad'
df = df.drop(columns=['Ciudad'])
print(df)
```

Ejemplo de eliminar una columna

En este ejemplo se muestra cómo eliminar una columna de un DataFrame utilizando el método drop().

Redimensión de un dataframe

El tamaño de un DataFrame puede modificarse mediante la selección de filas y columnas específicas.

```python
# Seleccionar solo las columnas 'Nombre' y 'Edad'
df_reducido = df[['Nombre', 'Edad']]
print(df_reducido)
```

Ejemplo de selección de un subconjunto de columnas

En este ejemplo se muestra cómo seleccionar un subconjunto de columnas de un DataFrame.

```python
# Seleccionar las primeras dos filas
df_subset = df.iloc[:2]
print(df_subset)
```

Ejemplo de selección de filas específicas

También es posible seleccionar filas específicas mediante índices.

alkemy

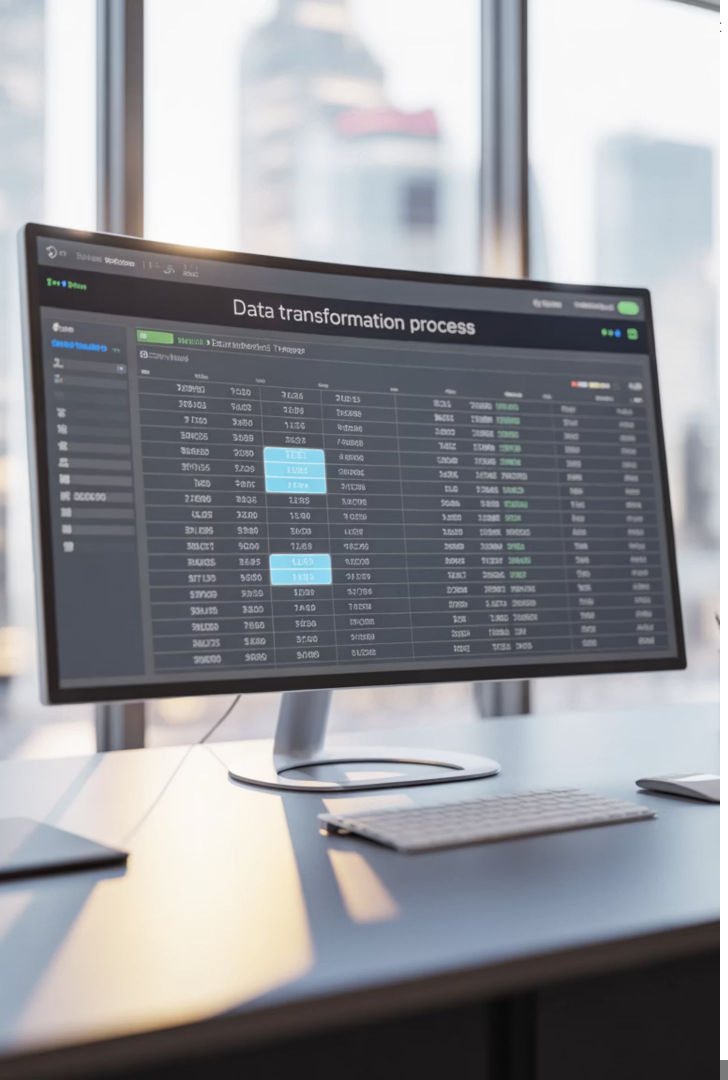

Convertir el tipo de dato de una columna

A veces, es necesario cambiar el tipo de datos de una columna para su correcta manipulación.

alkemy

Ejemplo de conversión de tipos

En este ejemplo se muestra cómo convertir el tipo de datos de una columna utilizando el método astype().

```python
# Crear un DataFrame con datos en formato de texto
df = pd.DataFrame({'ID': ['1', '2', '3'], 'Precio': ['1000', '500', '800']})

# Convertir a tipos numéricos
df['ID'] = df['ID'].astype(int)
df['Precio'] = df['Precio'].astype(float)
print(df.dtypes)
```

Definir y resetear índices

El índice en Pandas se puede definir y modificar para mejorar la organización de los datos.

```python
# Definir la columna 'ID' como índice
df.set_index('ID', inplace=True)
print(df)
```

Ejemplo de definición de índice

En este ejemplo se muestra cómo definir una columna como índice de un DataFrame utilizando el método set_index().

alkemy

```python
# Resetear el índice
df.reset_index(inplace=True)
print(df)
```

Ejemplo de reseteo de índice

Para resetear el índice, se utiliza el método reset_index().

Renombrar columnas e índices

Pandas permite renombrar columnas e índices utilizando .rename().

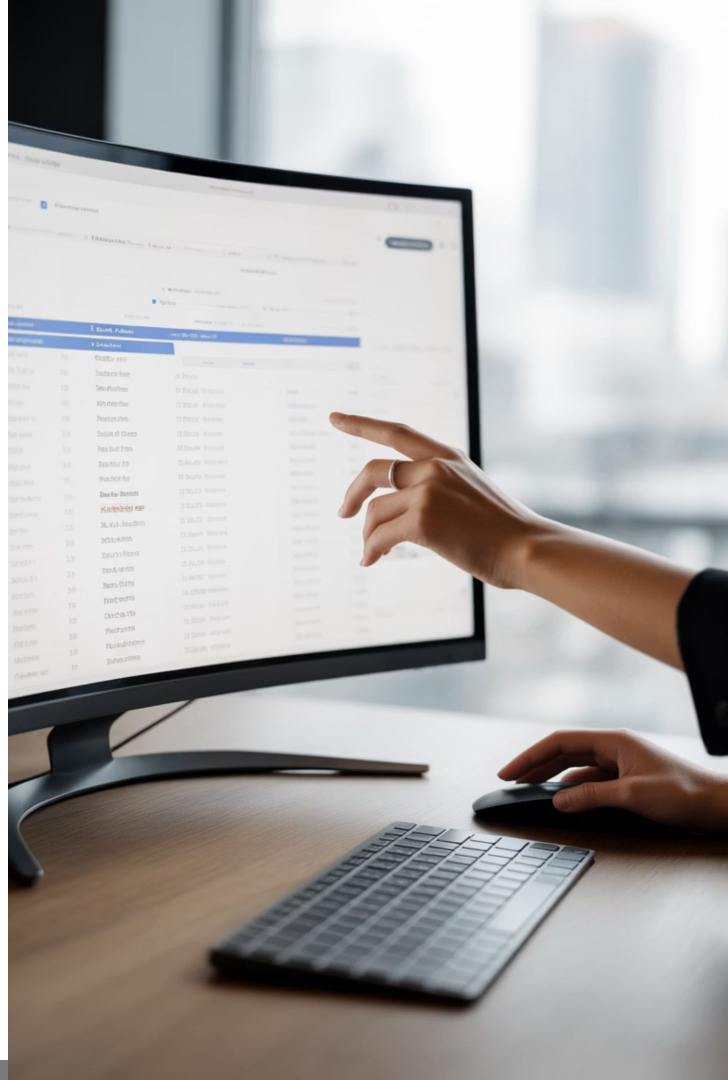

```python
# Renombrar columnas
df = df.rename(columns={'Precio': 'Costo'})
print(df)
```

Ejemplo de renombrar columnas

En este ejemplo se muestra cómo renombrar las columnas de un DataFrame utilizando el método rename().

alkemy

Remover duplicados

Los datos pueden contener registros duplicados que deben eliminarse para evitar errores en el análisis.

```python
# Crear un DataFrame con datos duplicados
df = pd.DataFrame({'Nombre': ['Ana', 'Luis', 'Ana', 'Carlos'],
                   'Edad': [25, 30, 25, 28]})

# Eliminar duplicados
df_sin_duplicados = df.drop_duplicates()
print(df_sin_duplicados)
```

Ejemplo de eliminación de duplicados

En este ejemplo se muestra cómo eliminar registros duplicados de un DataFrame utilizando el método drop_duplicates().

Resumen de técnicas de Data Wrangling

Ordenamiento

Reorganización de datos según criterios específicos

Filtrado

Selección de subconjuntos de datos según condiciones

Transformación

Modificación de valores y formatos

Limpieza

Eliminación de errores y duplicados

Enriquecimiento

Adición de nueva información derivada

alkemy

Beneficios del Data Wrangling

1

Mejora de la calidad de datos

Garantiza que los datos sean precisos, completos y coherentes, reduciendo errores en el análisis.

2

Optimización del análisis

Facilita la exploración y modelado de datos al tenerlos en formatos adecuados y estructurados.

3

Automatización de procesos

Permite crear flujos de trabajo reproducibles que ahorran tiempo en tareas repetitivas.

4

Toma de decisiones informadas

Proporciona una base sólida para el análisis, generando insights más confiables.

Herramientas para Data Wrangling

Pandas

Biblioteca de Python especializada en manipulación y análisis de datos, con potentes funciones para transformación de DataFrames.

- Funciones de limpieza y transformación
- Manejo eficiente de datos estructurados
- Integración con otras bibliotecas de análisis

Otras herramientas para Data Wrangling

NumPy

Biblioteca fundamental para computación científica en Python, proporciona soporte para arrays y matrices multidimensionales.

Dplyr (R)

Paquete de R para manipulación de datos con una sintaxis clara y consistente.

SQL

Lenguaje de consulta estructurado para manipular y transformar datos en bases de datos relacionales.

OpenRefine

Herramienta de código abierto para limpieza y transformación de datos con interfaz gráfica.

Flujo de trabajo en Data Wrangling

Importación

Carga de datos desde diversas fuentes (CSV, Excel, bases de datos, APIs)

Exploración

Análisis inicial para identificar problemas y patrones en los datos

Limpieza

Corrección de errores, manejo de valores nulos y eliminación de duplicados

Transformación

Reestructuración y enriquecimiento de los datos

Exportación

Almacenamiento de los datos procesados en formatos adecuados

Mejores prácticas en Data Wrangling

Documentar el proceso

Mantener un registro detallado de todas las transformaciones realizadas para garantizar la reproducibilidad.

Preservar los datos originales

Siempre trabajar con copias de los datos originales para evitar pérdidas de información.

Automatizar tareas repetitivas

Crear scripts o funciones para procesos que se realizan frecuentemente.

Validar resultados

Verificar que las transformaciones realizadas produzcan los resultados esperados.

Desafíos comunes en Data Wrangling

Datos incompletos

Manejo de valores faltantes que pueden afectar el análisis.

Inconsistencias

Variaciones en formatos, unidades o convenciones de nombres.

Escalabilidad

Procesamiento eficiente de grandes volúmenes de datos.

Integración

Combinación de datos de múltiples fuentes con estructuras diferentes.

Aplicaciones del Data Wrangling

Ciencia de datos

Preparación de datos para modelos de machine learning y análisis estadístico.

Inteligencia de negocios

Transformación de datos para dashboards y reportes ejecutivos.

Análisis financiero

Limpieza y estructuración de datos para análisis de riesgos y tendencias.

alkemy

Cierre

El Data Wrangling es un proceso esencial en el análisis de datos, ya que permite transformar conjuntos de datos crudos en información estructurada, limpia y lista para el análisis. A lo largo de este manual, hemos explorado diferentes técnicas que facilitan la manipulación, enriquecimiento y optimización de los datos utilizando la biblioteca Pandas en Python.

Desde la limpieza de registros hasta la reestructuración de DataFrames, cada técnica presentada contribuye a mejorar la calidad y confiabilidad de los datos. La correcta aplicación de estos métodos no solo optimiza el análisis estadístico y la modelización de datos, sino que también garantiza la precisión de los resultados y la toma de decisiones informadas.

La capacidad de transformar y preparar datos de manera eficiente es una de las habilidades más valoradas en el mundo del análisis de datos y la ciencia de datos. Dominar las herramientas de Data Wrangling permite a los analistas e investigadores desarrollar procesos de análisis más sólidos, reducir errores y automatizar tareas repetitivas.

Live Coding

¿En qué consistirá la Demo?

Ajuste completo de un DataFrame

1. *Eliminar columnas innecesarias.*
2. *Convertir columnas de string a datetime.*
3. *Aplicar .set_index() y .reset_index().*
4. *Eliminar duplicados y documentar el proceso.*

Tiempo: *20 min.*

#Momentode Preguntas...

¿ ?

¿Cómo se agrega una columna en Pandas?

¿ ?

¿Qué método se usa para eliminar columnas?

¿ ?

¿Cómo se cambia el tipo de dato de una columna?

¿ ?

¿Qué hace .set_index()?

Momento:

Time-out!

⏰5 -10 min.

alkemy

Ejercicio N° 1

Preparación de datos para visualización

Preparación de datos para visualización

Contexto: 🙌

Se recibe un dataset de usuarios.

Consigna: ✍️

1. Eliminar columnas innecesarias.
2. Convertir “fecha de registro” a datetime.
3. Crear índice con “id_usuario”.
4. Cambiar nombres de columnas con .rename()
5. Eliminar duplicados según combinación de nombre y fecha.

Tiempo 🕐**:** *25 minutos*

Plataforma: Jupyter Notebook / Google Colab

¿Alguna consulta?

alkemy

Resumen

¿Qué logramos en esta clase?

- ✓ ***Aplicaste redimensionamiento de estructuras.***
- ✓ ***Convertiste tipos de datos correctamente.***
- ✓ ***Configuraste y reseteaste índices.***
- ✓ ***Generaste procesos de limpieza reutilizables.***

¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las ***actividades disponibles en la plataforma.*** *Estas propuestas son clave para afianzar lo trabajado y* ***forman parte obligatoria del recorrido de aprendizaje.***

💪 Análisis de caso ——— 💪 Selección Múltiple

💪 Comprensión lectora

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

alkemy

< ¡Muchas gracias! >

alkemy