Working Time 🤓

L4: Manejo de valores perdidos y outliers

Es hora de que pongas en práctica todo lo aprendido. 🤓
Este apartado tiene el objetivo de ayudarte a seguir potenciando tus habilidades, por lo que a continuación encontrarás diferentes **desafíos** que podrás resolver de forma independiente y a tu ritmo.

Más adelante conseguirás las resoluciones para que valides tus respuestas y puedas monitorear tu progreso. 😉

¡Manos a la obra!

1. **Desafío 🎯**

   *Este desafío consiste en la identificación, tratamiento y corrección de **valores perdidos** y **outliers** en un conjunto de datos utilizando **Pandas** y **NumPy**. Aprenderás a limpiar y optimizar los datos para su posterior análisis.*

   - ***Carga y exploración del dataset:***
     - *Importa el dataset desde un archivo **CSV**.*
     - *Muestra las primeras 5 filas y obtén una descripción general.*
     - *Identifica la cantidad de valores nulos y el tipo de datos de cada columna.*
   - ***Manejo de valores perdidos:***
     - *Imputa valores numéricos usando **la media, la mediana y la moda**.*
     - *Rellena valores nulos en columnas categóricas con la **moda**.*
     - *Evalúa la opción de eliminar filas con valores faltantes.*
   - ***Detección y tratamiento de outliers:***
     - *Identifica outliers en columnas numéricas usando **el rango intercuartil (IQR)**.*
     - *Visualiza los outliers con gráficos de **boxplot**.*
     - *Aplica estrategias para el manejo de outliers:*
       - *Eliminación de registros atípicos.*
       - *Sustitución con valores límite.*
       - *Transformación de datos (logaritmo o normalización).*
   - ***Validación de datos limpios:***
     - *Verifica que no queden valores nulos en el dataset.*
     - *Revisa la distribución de los datos tras la limpieza.*

- ***Exportación de datos:***
    - *Guarda el dataset limpio en un archivo* ***CSV****.*

2. **¿Dónde se lleva a cabo?** 👩‍💻

   Visual Studio Code

3. **Tiempo de dedicación** ⏳

   2 horas

4. **Recursos**🛠️

   - *Documentación de Pandas: https://pandas.pydata.org/docs/*
   - *Documentación de NumPy: https://numpy.org/doc/*

5. **Plus** ➕

   - *Implementa un script automatizado para la detección y corrección de valores perdidos y outliers.*
   - *Experimenta con diferentes estrategias de imputación y comparación de resultados.*

6. ⚠️**Condición**

   Esta práctica o ejercitación **no requiere ser entregada y/o evaluada** por el mentor. No obstante puedes compartir tus resultados con el resto de los bootcampers y construir conocimiento en conjunto.

Resolución del desafío 👇

1. Carga y exploración del dataset

```python
import pandas as pd
import numpy as np

# Cargar el dataset
df = pd.read_csv('dataset.csv')

# Mostrar las primeras filas
display(df.head())

# Obtener información general
df.info()

# Identificar valores nulos
df.isnull().sum()
```

2. Manejo de valores perdidos

```python
# Imputar valores numéricos con la media
df['columna_numerica'].fillna(df['columna_numerica'].mean(), inplace=True)

# Imputar valores numéricos con la mediana
df['columna_numerica'].fillna(df['columna_numerica'].median(), inplace=True)

# Imputar valores categóricos con la moda
df['columna_categorica'].fillna(df['columna_categorica'].mode()[0], inplace=True)
```

3. Detección y tratamiento de outliers

```python
import seaborn as sns
import matplotlib.pyplot as plt

# Visualización de outliers con boxplot
sns.boxplot(x=df['columna_numerica'])
plt.show()

# Cálculo del rango intercuartil (IQR)
Q1 = df['columna_numerica'].quantile(0.25)
Q3 = df['columna_numerica'].quantile(0.75)
IQR = Q3 - Q1

# Identificación de outliers
outliers = df[(df['columna_numerica'] < (Q1 - 1.5 * IQR)) |
(df['columna_numerica'] > (Q3 + 1.5 * IQR))]
print("Número de outliers:", outliers.shape[0])

# Eliminación de outliers
df_sin_outliers = df[~df.index.isin(outliers.index)]
```

4. Validación de datos limpios

```python
# Verificar valores nulos después de la limpieza
df_sin_outliers.isnull().sum()

# Revisar la distribución de los datos post-limpieza
sns.boxplot(x=df_sin_outliers['columna_numerica'])
plt.show()
```

5. Exportación de datos

```python
# Guardar el dataset limpio
df_sin_outliers.to_csv('datos_limpiados.csv', index=False)
```