Probabilidad y estadística

M5: Inferencia estadística

|**AE2**: Aplicar los principales conceptos de probabilidad asociados a un evento aleatorio según el análisis estadístico.

alkemy

Introducción🧑‍💻

La estadística moderna no se comprende completamente sin el apoyo de la teoría de la probabilidad. Este campo matemático proporciona las herramientas necesarias para modelar la incertidumbre y tomar decisiones fundamentadas en contextos donde intervienen factores aleatorios. Desde estudios científicos hasta predicciones en economía o salud, la probabilidad es la base que permite interpretar la variabilidad y estimar riesgos.

En este manual, profundizaremos en conceptos clave como los experimentos aleatorios, el espacio muestral, los eventos, las reglas de unión e intersección, así como los distintos tipos de muestreo. También exploraremos el uso de árboles de probabilidad como herramienta gráfica para representar situaciones complejas.

Comprender estos conceptos no solo permite analizar datos de forma rigurosa, sino también desarrollar un pensamiento crítico frente a la incertidumbre, algo fundamental en la era del big data.

Aprendizaje esperado

Cuando finalices la lección serás capaz de:

- Interpretar el comportamiento de eventos aleatorios mediante la teoría de la probabilidad.
- Diferenciar entre tipos de muestreo y seleccionar el adecuado para una situación dada.
- Representar gráficamente situaciones probabilísticas usando árboles.
- Aplicar la noción de espacio muestral y eventos para resolver problemas simples.
- Identificar sesgos comunes y evitar errores en la recolección de datos.

Probabilidad y estadística

La **teoría de la probabilidad** es una rama de las matemáticas que se encarga de estudiar los fenómenos aleatorios, es decir, aquellos cuyo resultado no se puede prever con certeza, aunque sí se puede estimar con base en patrones observados. Su origen se remonta al estudio de los juegos de azar en el siglo XVII, pero actualmente tiene aplicaciones fundamentales en ciencias naturales, ingeniería, medicina, economía, inteligencia artificial, entre otras disciplinas.

La idea central de la probabilidad es asignar un número entre 0 y 1 a un evento, indicando la "certeza" de que ocurra. Un valor de 0 representa un evento imposible, mientras que un valor de 1 representa un evento seguro. Si un dado tiene seis caras con igual probabilidad, la probabilidad de que salga un número específico (por ejemplo, un 4) es:

$$P(4) = \frac{1}{6} \approx 0.167$$

Esta interpretación se denomina **frecuentista**, y se basa en la frecuencia relativa de un resultado a largo plazo, tras repetir el experimento muchas veces. Según esta visión, si lanzamos un dado justo muchas veces, cada número debería aparecer aproximadamente el mismo número de veces.

Además del enfoque frecuentista, existe el enfoque **bayesiano**, que interpreta la probabilidad como un grado de creencia racional. Este enfoque es útil cuando no se pueden repetir los experimentos muchas veces, o cuando se desea incorporar información previa (como estudios anteriores o experiencia experta) para actualizar las probabilidades.

Ejemplo: si sabemos que históricamente el 80% de los autos de una fábrica pasan el control de calidad, podemos decir que la probabilidad de que un auto al azar pase dicho control es 0.8. Pero si tenemos información adicional (por ejemplo, que ese auto en particular proviene de un lote con problemas), la probabilidad puede ajustarse usando el enfoque bayesiano.

También existen distintas **reglas básicas** para operar con probabilidades. La más simple es la probabilidad de un evento simple, pero también se pueden combinar eventos. Por ejemplo, si A y B son eventos mutuamente excluyentes (no pueden ocurrir al mismo tiempo), entonces:

$$P(A \cup B) = P(A) + P(B)$$

Si A y B no son excluyentes, se debe restar la intersección para no contarla dos veces:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Este marco teórico permite analizar, predecir y tomar decisiones en contextos donde reina la incertidumbre, lo que convierte a la teoría de la probabilidad en un pilar fundamental del análisis estadístico.

Experimento aleatorio y determinístico

Un **experimento determinístico** es aquel cuyo resultado puede predecirse con total certeza. No existe incertidumbre en su ejecución y, por tanto, no se requiere probabilidad para su análisis. Por ejemplo, calcular el área de un rectángulo de base 10 cm y altura 5 cm siempre dará 50 cm², sin importar cuántas veces se repita el cálculo.

En contraste, un **experimento aleatorio** es aquel en el que, incluso bajo condiciones idénticas, el resultado no se puede predecir con certeza. Esto ocurre porque influyen factores imprevisibles o porque el fenómeno tiene múltiples resultados posibles. Ejemplos típicos son lanzar un dado, extraer una carta al azar o realizar una encuesta de opinión.

Desde el punto de vista matemático, en un experimento aleatorio se definen un **espacio muestral** (conjunto de resultados posibles) y eventos (subconjuntos de dicho espacio). Cada ejecución del experimento se denomina **ensayo** o **repetición**.

Ejemplo comparativo:

Tipo de experimento	**Ejemplo**	**Resultado siempre igual**	**Usa probabilidad**
Determinístico	3 × 4	Sí	No
Aleatorio	Lanzar una moneda	No	Sí

La identificación del tipo de experimento es crucial para saber si se requiere aplicar técnicas probabilísticas o simplemente deterministas.

Ejemplo práctico: si medimos el tiempo de llegada del transporte público a una estación, observaremos variabilidad por el tráfico, clima, y otros factores. Cada medición es un experimento aleatorio. En cambio, sumar dos números siempre dará el mismo resultado.

Espacio muestral

El **espacio muestral** (denotado por SSS o Ω\OmegaΩ) es el conjunto de todos los posibles resultados de un experimento aleatorio. Conocer este conjunto es el primer paso para calcular probabilidades, ya que todo análisis probabilístico se basa en contar resultados favorables y posibles.

El espacio puede ser:

- **Finito:** si tiene una cantidad limitada de resultados. Ej.: lanzar un dado → S={1,2,3,4,5,6}S = \{1,2,3,4,5,6\}S={1,2,3,4,5,6}

- **Infinito discreto:** como contar el número de llamadas recibidas en un call center (1, 2, 3, ...).

- **Continuo:** cuando los resultados pueden tomar infinitos valores en un intervalo. Ej.: medir la temperatura entre 20 y 25 °C.

Ejemplo 1 (moneda):
Lanzar una moneda → S={C,S}S = \{C, S\}S={C,S}

Ejemplo 2 (dado):
Lanzar un dado → S={1,2,3,4,5,6}S = \{1,2,3,4,5,6\}S={1,2,3,4,5,6}

Ejemplo 3 (dos monedas):
Lanzar dos monedas →
S={CC,CS,SC,SS}S = \{CC, CS, SC, SS\}S={CC,CS,SC,SS}

Los elementos del espacio muestral se denominan **resultados elementales**, y la probabilidad de un evento se calcula contando cuántos de estos resultados lo componen.

$$P(\text{evento}) = \frac{\text{nº de casos favorables}}{\text{nº total de casos posibles}}$$

Este concepto es clave en la resolución de ejercicios básicos y el diseño de simulaciones probabilísticas.

Eventos aleatorios

Un **evento aleatorio** es cualquier subconjunto del espacio muestral. Si el espacio contiene todos los resultados posibles, un evento representa uno o más de esos resultados. Algunos eventos tienen nombres especiales:

- **Evento seguro:** contiene todos los elementos del espacio muestral.
- **Evento imposible:** no contiene ningún elemento.
- **Evento elemental:** contiene un solo resultado.
- **Evento compuesto:** contiene varios resultados.

Ejemplo (dado):

- Espacio muestral: S={1,2,3,4,5,6}S = \{1,2,3,4,5,6\}S={1,2,3,4,5,6}

- Evento A: “número par” → A = {2, 4, 6}

- Evento B: “número mayor a 4” → B = {5, 6}

La **probabilidad de un evento** se calcula como:

$$P(A) = \frac{|A|}{|S|} = \frac{\text{número de elementos en A}}{\text{número total de elementos en S}}$$

Ejemplo práctico:
Evento C: “salga 1 o 2” → C = {1,2}

$$P(C) = \frac{2}{6} = \frac{1}{3}$$

Este enfoque permite modelar cualquier situación aleatoria como una combinación de eventos con probabilidades asociadas.

Árbol de probabilidades

Un **árbol de probabilidad** es una herramienta gráfica que representa todos los resultados posibles de un experimento secuencial. Es útil cuando hay varios pasos y cada uno depende de los anteriores o es independiente.

Cada rama del árbol representa un resultado parcial con su probabilidad. El **camino completo** desde la raíz hasta una hoja representa un resultado total, y su probabilidad se obtiene multiplicando las probabilidades de las ramas.

Ejemplo: lanzar una moneda y luego un dado.

- Nivel 1: Cara (C) y Sello (S)
- Nivel 2: 1 a 6 desde cada rama

Cada camino tiene probabilidad:

$$P(C \text{ y } 3) = P(C) \cdot P(3) = \frac{1}{2} \cdot \frac{1}{6} = \frac{1}{12}$$

En total hay 12 resultados posibles. El árbol permite:

- Identificar caminos favorables
- Aplicar reglas del producto (eventos independientes)
- Visualizar casos en eventos condicionales

Aplicación práctica: En biología, un árbol de probabilidad puede mostrar la probabilidad de heredar una enfermedad genética según distintos genotipos de los padres.

Unión e intersección de eventos

Cuando se combinan eventos, se aplican operaciones de conjunto:

- **Unión (A ∪ B):** ocurre si se cumple A, B o ambos.
- **Intersección (A ∩ B):** ocurre si se cumplen A y B al mismo tiempo.

Fórmulas importantes:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Si los eventos son **mutuamente excluyentes** (no pueden ocurrir juntos):

$$P(A \cap B) = 0 \Rightarrow P(A \cup B) = P(A) + P(B)$$

Ejemplo: lanzar un dado.

- A: “número par” → A = {2, 4, 6} → P(A) = 3/6
- B: “número < 4” → B = {1, 2, 3} → P(B) = 3/6
- A ∩ B = {2} → P(A ∩ B) = 1/6

$$P(A \cup B) = \frac{3}{6} + \frac{3}{6} - \frac{1}{6} = \frac{5}{6}$$

Estas reglas son esenciales en el análisis de combinaciones de eventos y la resolución de problemas de probabilidad compuesta.

Muestra y muestreo

En estadística, una **población** es el conjunto total de elementos sobre el que se desea obtener información. Sin embargo, en la mayoría de los casos es imposible o muy costoso estudiar a toda la población. Por eso, se recurre a una **muestra**, que es un subconjunto representativo de la población.

El proceso mediante el cual se selecciona una muestra se llama **muestreo**. Este proceso debe hacerse con cuidado para garantizar que la muestra refleje fielmente las características de la población. Existen dos grandes tipos de muestreo: **probabilístico** y **no probabilístico**. En este módulo nos enfocamos en el primero, ya que permite calcular probabilidades asociadas a la selección.

Para que una muestra sea válida, debe ser **representativa**, es decir, mantener las proporciones, estructuras o características claves de la población. De lo contrario, cualquier inferencia realizada a partir de esa muestra puede estar sesgada o ser errónea.

Ejemplo: Si queremos estimar el promedio de edad de los estudiantes universitarios de un país, no es práctico entrevistar a todos. Lo que se hace es seleccionar una muestra que incluya estudiantes de diferentes carreras, universidades, regiones y edades.

El tamaño de la muestra también es importante. Una muestra demasiado pequeña puede tener mucha variabilidad, mientras que una demasiado grande puede ser innecesariamente costosa. Existen fórmulas estadísticas para determinar el tamaño óptimo según el nivel de confianza y margen de error deseados:

$$n = \frac{Z^2 \cdot p \cdot (1-p)}{E^2}$$

donde:

- Z es el valor z asociado al nivel de confianza (por ejemplo, 1.96 para 95%),
- p es la proporción esperada,
- E es el margen de error aceptado.

Muestra aleatoria y sesgo de muestra

Una **muestra aleatoria** es aquella en la que cada elemento de la población tiene la misma probabilidad de ser seleccionado. Este tipo de muestra es fundamental para garantizar la validez estadística, ya que reduce al mínimo el **sesgo**.

El **sesgo de muestra** ocurre cuando ciertos individuos tienen más (o menos) posibilidades de ser elegidos. Esto puede suceder por errores en el diseño del muestreo, en la recolección de datos o en la interpretación. Un sesgo puede llevar a conclusiones falsas o exageradas, afectando gravemente la calidad del análisis.

Ejemplo de sesgo: Si se realiza una encuesta sobre uso de tecnología solamente a personas conectadas en redes sociales, la muestra estará sesgada, porque no representará a quienes no usan esas plataformas (como adultos mayores o personas con menor acceso digital).

El uso de herramientas como generadores de números aleatorios, software estadístico o sorteos físicos (bolillas, dados) puede ayudar a asegurar la aleatoriedad del proceso. Además, se recomienda documentar claramente cómo se seleccionó la muestra para garantizar transparencia y reproducibilidad.

Ejemplo práctico: Supongamos que una universidad quiere saber el nivel de satisfacción de sus estudiantes. Si solo encuesta a quienes están en clase en determinado momento, puede obtener un sesgo, ya que quienes no asisten pueden tener opiniones distintas. Un muestreo aleatorio garantiza que todos los estudiantes tengan la misma oportunidad de ser seleccionados.

Detectar y minimizar el sesgo es esencial para que las conclusiones extraídas de una muestra sean válidas para la población.

Buenas prácticas para obtener muestras representativas

Seleccionar una muestra representativa implica aplicar un método de muestreo probabilístico adecuado al contexto. A continuación, se describen las técnicas más comunes con sus características principales:

Muestreo aleatorio simple: Cada elemento tiene la misma probabilidad de ser seleccionado. Se puede realizar mediante números aleatorios o sorteos. Es fácil de entender, pero puede ser difícil de implementar si la población es grande o dispersa.

$$P(\text{selección}) = \frac{1}{N}$$

Muestreo aleatorio estratificado: La población se divide en grupos homogéneos llamados **estratos** (por ejemplo, por edad, género o región), y se toma una muestra aleatoria de cada estrato. Mejora la precisión y asegura representatividad de subgrupos importantes.

Ejemplo: Para estudiar el rendimiento académico, se puede dividir a los estudiantes por facultad y seleccionar proporcionalmente dentro de cada una.

Muestreo por conglomerados: La población se divide en grupos naturales o **conglomerados** (como escuelas, barrios o ciudades), y se seleccionan algunos de estos al azar. Luego se estudia a todos los elementos dentro de los conglomerados elegidos.

Es más eficiente en costos y logística cuando la población está geográficamente dispersa.

Muestreo de varias etapas: Combinación de métodos anteriores. Por ejemplo, primero se seleccionan regiones, luego escuelas dentro de esas regiones y luego estudiantes dentro de las escuelas. Se usa en encuestas nacionales complejas.

Ejemplo (tres etapas):

- Etapa 1: Elegir 5 provincias al azar.
- Etapa 2: Elegir 10 escuelas por provincia.
- Etapa 3: Elegir 30 estudiantes por escuela.

Técnica	**Ventaja principal**	**Cuándo usarla**
Aleatorio simple	Fácil de entender	Poblaciones pequeñas y accesibles
Aleatorio estratificado	Asegura representación proporcional	Grupos importantes dentro de la población
Por conglomerados	Reduce costos logísticos	Población grande y dispersa
De varias etapas	Flexible y eficiente	Estudios a gran escala

La selección adecuada del método de muestreo y su aplicación cuidadosa son fundamentales para garantizar resultados confiables y extrapolables a la población general.

Cierre ✍️

El estudio de la probabilidad y el muestreo es fundamental para el análisis estadístico moderno, ya que proporciona el marco conceptual necesario para modelar la incertidumbre y tomar decisiones basadas en datos. A lo largo de este módulo, se ha explorado desde los fundamentos teóricos de la probabilidad hasta los métodos más robustos para recolectar información válida mediante muestras representativas.

Comprender las diferencias entre experimentos aleatorios y determinísticos, saber identificar correctamente un espacio muestral y calcular probabilidades de eventos, permite a los estudiantes interpretar situaciones reales con mayor precisión y sentido crítico. Además, herramientas como el árbol de probabilidades y las operaciones de unión e intersección ofrecen estrategias claras para abordar problemas compuestos o secuenciales.

En paralelo, la capacidad de diseñar un muestreo adecuado, minimizar el sesgo y seleccionar una técnica apropiada (simple, estratificada, por conglomerados o por etapas) es indispensable para que los datos recolectados sean útiles, válidos y extrapolables. El dominio de estas técnicas también permite evaluar la calidad de encuestas, experimentos o informes que circulan en medios académicos, científicos o periodísticos.

La integración entre el razonamiento probabilístico y las buenas prácticas en el muestreo constituye un paso esencial en la formación estadística de cualquier estudiante o profesional. Con estas herramientas, no solo se fortalecen las competencias analíticas, sino también la capacidad de tomar decisiones más informadas en contextos reales.

¡Nos vemos de nuevo, más adelante! 👋

Referencias📚

- Khan Academy. (s. f.). *Introducción a la probabilidad*. https://es.khanacademy.org/math/statistics-probability/probability-library
- Wikipedia. (s. f.). *Espacio muestral*. https://es.wikipedia.org/wiki/Espacio_muestral
- Redalyc. (2024). *Inferencia estadística en los textos escolares: Una aproximación al pensamiento estadístico. Revista UBB Educación, 38*. https://www.redalyc.org/articulo.oa?id=475981034028
- Ministerio de Educación (Chile). (2021). *Cuadernillo de matemáticas: Probabilidad y estadística*. Recuperado de https://acceso.mineduc.cl/wp-content/uploads/2021/06/Cuadernillo-Matematica-eje-probabilidad-y-estadistica.pdf
- Explorable. (s. f.). *Método de muestreo estratificado*. Recuperado de https://explorable.com/es/muestreo-estratificado

¡Muchas gracias!

Nos vemos en la próxima lección

alkemy