Distribución muestral y teorema del límite central

M5: Inferencia estadística

|**AE4**: Realizar cálculos de probabilidad utilizando la distribución muestral para resolver un problema.

alkemy

Introducción 🧑‍💻

La estadística inferencial se fundamenta en la posibilidad de realizar afirmaciones sobre una población a partir del estudio de una muestra. Para ello, es esencial comprender cómo se comportan las estadísticas muestrales (como la media o la proporción) cuando se toman múltiples muestras de una misma población. Aquí es donde entran en juego la distribución muestral, la ley de los grandes números y el teorema del límite central. Estos conceptos son clave para entender la base matemática que permite estimar probabilidades y realizar inferencias confiables sobre los parámetros poblacionales.

La distribución muestral nos permite visualizar cómo varía una estadística de muestra (como la media o la proporción) entre diferentes muestras extraídas aleatoriamente. Por su parte, la ley de los grandes números garantiza que, a medida que se incrementa el tamaño muestral, la media muestral se aproxima cada vez más a la media poblacional. Finalmente, el teorema del límite central asegura que, bajo ciertas condiciones, la distribución de la media muestral tiende a ser normal, sin importar la forma original de la distribución de la población.

Este manual profundiza en cada uno de estos conceptos y proporciona las herramientas necesarias para realizar cálculos de probabilidad aplicados a situaciones reales.

Aprendizaje esperado

Cuando finalices la lección serás capaz de:

- Definir la distribución muestral y describir su importancia en la inferencia estadística.
- Explicar cómo la ley de los grandes números garantiza la estabilidad de las medias muestrales.
- Aplicar el teorema del límite central para resolver problemas estadísticos reales.
- Calcular probabilidades usando distribuciones muestrales en contextos aplicados.
- Utilizar la distribución muestral de proporciones para estimar características poblacionales.

Distribución de muestreo

La **distribución de muestreo** es la distribución de probabilidades de una estadística (como la media, proporción o desviación estándar) obtenida a partir de todas las posibles muestras aleatorias de un tamaño fijo extraídas de una misma población. Esta distribución es clave en la estadística inferencial porque permite predecir con qué frecuencia una determinada estadística muestral se aproxima al parámetro poblacional que intenta estimar.

Supongamos que se desea estudiar el ingreso promedio de una población de 100,000 personas. Es inviable encuestarlas a todas, por lo que se toman múltiples muestras aleatorias de, por ejemplo, 100 personas. Para cada muestra se calcula la media de ingreso. Al repetir este proceso muchas veces, se obtiene una distribución de medias muestrales: esa es la **distribución de muestreo de la media**.

Matemáticamente, si se tienen muchas muestras de tamaño nnn extraídas de una población con media μ y desviación estándar σ, la media de las medias muestrales será también μ, y su desviación estándar (llamada **error estándar**) estará dada por:

$\sigma_{\bar{x}} = \sigma / \sqrt{n}$

Este resultado muestra que a mayor tamaño de la muestra, menor será la variabilidad de las medias muestrales, lo cual mejora la precisión de nuestras estimaciones.

Una propiedad fundamental de la distribución muestral es que, incluso si la distribución original de la población no es normal, la distribución de las estadísticas muestrales tiende a ser normal si el tamaño de muestra es suficientemente grande (por ejemplo, $n \geq 30$). Esta observación es la base del Teorema del Límite Central, que veremos más adelante.

Ejemplo: Supongamos una población de estudiantes con una altura media de 170 cm y una desviación estándar de 10 cm. Si tomamos muestras aleatorias de 25 estudiantes, la media de todas las medias muestrales será 170, y el error estándar será:

$\sigma_{\bar{x}} = 10 / \sqrt{25} = 2$

Esto significa que, en promedio, la media de altura de una muestra de 25 estudiantes estará a unos 2 cm de la media poblacional.

En resumen, la distribución muestral permite estimar qué tan confiable es una estadística muestral, proporciona una medida de su variabilidad y sienta las bases para realizar inferencias estadísticas rigurosas sobre poblaciones grandes a partir de pequeñas muestras representativas.

Ley de los Grandes Números

La **Ley de los Grandes Números (LGN)** es un principio fundamental de la estadística que establece que, al aumentar el tamaño de una muestra aleatoria, el promedio de los valores observados se aproxima al valor esperado o media poblacional. Esta ley garantiza la estabilidad a largo plazo de las frecuencias relativas.

En términos formales, si X1,X2,...,Xn son variables aleatorias independientes e idénticamente distribuidas con media μ, entonces:

$$\lim_{n\to\infty} \frac{1}{n}\sum_{i=1}^{n} X_i = \mu$$

Esto implica que la media muestral X converge a la media poblacional μ a medida que el tamaño muestral nnn crece. Existen dos versiones de esta ley: la **débil**, que afirma la convergencia en probabilidad, y la **fuerte**, que asegura la convergencia casi segura.

Ejemplo práctico: Si lanzamos una moneda justa (probabilidad de cara = 0.5) muchas veces, la proporción de caras tenderá a acercarse a 0.5 a medida que aumentamos la cantidad de lanzamientos. Si al lanzar la moneda 10 veces se obtienen 7 caras, al lanzar 1,000 veces el número de caras estará mucho más cerca de 500, y así sucesivamente.

La LGN proporciona la justificación matemática para el uso de la media muestral como una buena estimación de la media poblacional, siempre y cuando se tome un número suficientemente grande de observaciones.

Teorema del Límite Central

El **Teorema del Límite Central (TLC)** es uno de los pilares de la estadística inferencial. Establece que, dado un número suficientemente grande de muestras aleatorias de una población con cualquier tipo de distribución (siempre que tenga

media y varianza finitas), la distribución de las medias muestrales se aproxima a una distribución normal.

Matemáticamente, si se toman muestras aleatorias de tamaño nnn, y se calcula la media muestral X, entonces:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{cuando } n \to \infty$$

Esto significa que, sin importar si la población original es asimétrica o tiene picos, la distribución de las medias muestrales se vuelve aproximadamente normal cuando n es suficientemente grande (comúnmente n≥30).

Ejemplo: Si la distribución de tiempos de espera en un hospital es altamente asimétrica, al tomar muchas muestras de 40 pacientes y calcular sus promedios, estos promedios seguirán una distribución cercana a la normal.

Este teorema justifica el uso de técnicas estadísticas basadas en la normalidad, como el cálculo de intervalos de confianza o pruebas de hipótesis, incluso cuando la distribución de los datos individuales no es normal.

Distribución de la población, distribución de la muestra y distribución muestral

Es fundamental diferenciar estos tres conceptos para evitar confusiones en el análisis de datos:

Concepto	Definición	Ejemplo
Distribución poblacional	Es la verdadera distribución de todos los elementos de una población	Todas las alturas de los habitantes de un país

Distribución de la muestra	Es la distribución de los valores observados en una única muestra	Las 50 alturas medidas en una sola muestra
Distribución muestral	Es la distribución de una estadística (media, proporción, etc.) en muchas muestras	Distribución de las medias de altura en 100 muestras de 50 personas

Estas distinciones permiten entender que trabajar con una muestra no implica conocer la población completa, pero sí que a través de muchas muestras se puede inferir el comportamiento poblacional.

Cálculo de probabilidades con la distribución muestral

Gracias al Teorema del Límite Central, podemos calcular probabilidades asociadas a medias muestrales como si fueran distribuciones normales. Para esto, usamos la siguiente transformación:

$$Z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}}$$

Donde:

- x es la media observada de la muestra
- μ es la media poblacional
- σ es la desviación estándar de la población
- n es el tamaño de la muestra

Ejemplo práctico: Supongamos que la media de espera en un banco es de 15 minutos con una desviación estándar de 5 minutos. Si se toma una muestra aleatoria de 36 personas, ¿cuál es la probabilidad de que el tiempo medio de espera sea mayor a 16 minutos?

Aplicamos la fórmula:

$$Z = \frac{16 - 15}{5/\sqrt{36}} = \frac{1}{0.833} \approx 1.20$$

Buscando en la tabla de la normal estándar:
P(Z > 1.20) ≈ 0.1151

Entonces, hay un 11.5% de probabilidad de que la media muestral supere los 16 minutos.

Este tipo de análisis es útil para evaluar si una muestra se comporta como se espera o si existen desviaciones significativas.

Distribución muestral de proporciones

Cuando se estudian proporciones (como el porcentaje de clientes satisfechos, votantes o enfermos), también se puede construir una distribución muestral. La proporción muestral p sigue, bajo ciertas condiciones, una distribución normal con media p y desviación estándar:

$$\sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$$

Esta fórmula permite calcular probabilidades respecto a proporciones, siempre que se cumpla np≥5 y n(1−p)≥5 , condiciones necesarias para la aproximación normal.

Ejemplo: Si se sabe que el 60% de los estudiantes aprueba un curso, ¿cuál es la probabilidad de que en una muestra de 100 estudiantes, menos del 55% apruebe?

- $p = 0.60, \hat{p} = 0.55, n = 100$
- $\sigma_{\hat{p}} = \sqrt{\frac{0.6(1-0.6)}{100}} = \sqrt{0.0024} = 0.049$
- $Z = \frac{0.55-0.6}{0.049} = -1.02$
- P(Z < -1.02) ≈ 0.1539

Por lo tanto, hay un 15.39% de probabilidad de que menos del 55% apruebe en la muestra.

Cierre ✍️

La distribución muestral es una herramienta esencial que permite conectar la teoría de la probabilidad con la práctica de la estadística inferencial. Gracias a la ley de los grandes números y al teorema del límite central, podemos confiar en que, con un tamaño muestral adecuado, nuestras estadísticas muestrales reflejan

fielmente a la población. Comprender estas nociones no solo mejora la interpretación de resultados estadísticos, sino que también fortalece la toma de decisiones fundamentadas en evidencia.

Mediante los ejemplos y fórmulas desarrolladas en este manual, se ha demostrado cómo estimar y calcular probabilidades con base en medias y proporciones muestrales, sentando las bases para métodos más complejos como la construcción de intervalos de confianza o la realización de pruebas de hipótesis.

¡Nos vemos de nuevo, más adelante! 👋

Referencias📚

- Khan Academy. (s. f.). *Ley de los grandes números*. https://es.khanacademy.org/math/statistics-probability/random-variables-stats-library/sampling-distribution/v/law-of-large-numbers
- Statistics LibreTexts. (2019). *Sampling distribution and the central limit theorem*. https://stats.libretexts.org/Bookshelves/Introductory_Statistics/Statistics_wi

th_Technology_2e_(Kozak)/06%3A_Continuous_Probability_Distributions/6.05%3A_Sampling_Distribution_and_the_Central_Limit_Theorem

- Harvard University. (s. f.). *Capítulo 14: Variables aleatorias — Ley de los grandes números*. https://rafalab.dfci.harvard.edu/dslibro/variables-aleatorias.html
- UMass Amherst. (s. f.). *Chapter 7: Sampling distributions and the central limit theorem*. https://people.math.umass.edu/~anna/stat515.F10/lecture/Chapter7.pdf
- LibreTexts Español. (2021). *La proporción de la muestra*. https://espanol.libretexts.org/Estadisticas/Estadisticas_Introductorias/Libro%3A_Estad%C3%ADsticas_Introductorias_(Shafer_y_Zhang)/06%3A_Distribuciones_de_muestreo/6.03%3A_La_Proporci%C3%B3n_de_la_Muestra

¡Muchas gracias!

Nos vemos en la próxima lección

alkemy