Inferencia e intervalos de confianza para la media

M5: Inferencia estadística

|**AE5**: Realizar la estimación de la media de una población utilizando intervalos de confianza a partir de una muestra aleatoria.

alkemy

Introducción👩‍💻

En el análisis estadístico, uno de los desafíos más comunes es inferir características de una población a partir de una muestra representativa. Debido a que, en la mayoría de los casos, resulta inviable estudiar a toda una población por motivos de tiempo, costo o accesibilidad, la inferencia estadística se convierte en una herramienta fundamental. Este proceso permite estimar parámetros poblacionales como la media o la proporción, utilizando información obtenida de un conjunto reducido de datos.

Una de las herramientas más utilizadas en este contexto es el **intervalo de confianza**, el cual permite establecer un rango de valores dentro del cual se espera que se encuentre el verdadero valor del parámetro poblacional con un determinado nivel de certeza. Estos intervalos se calculan utilizando distintas fórmulas, que dependen de si se conoce o no la desviación estándar de la población, o del tipo de parámetro que se desea estimar (media o proporción).

En este manual abordaremos en profundidad los conceptos necesarios para construir e interpretar intervalos de confianza, así como los fundamentos teóricos de la inferencia estadística. Se estudiarán los distintos tipos de distribuciones muestrales, se analizarán los factores que influyen en el tamaño de la muestra y se realizarán ejemplos detallados de cálculo paso a paso. Este conocimiento es esencial para tomar decisiones fundamentadas en el contexto de la ciencia de datos, la investigación científica y la estadística aplicada.

Aprendizaje esperado

Cuando finalices la lección serás capaz de:

- Explicar qué es un intervalo de confianza y para qué se utiliza en estadística inferencial.
- Estimar la media poblacional utilizando intervalos de confianza con diferentes niveles de certeza.
- Aplicar correctamente las fórmulas según si se conoce o no la desviación estándar de la población.
- Estimar proporciones poblacionales a partir de muestras y construir su respectivo intervalo de confianza.
- Calcular niveles de confianza y determinar el tamaño muestral adecuado según el contexto del estudio.

Inferencia estadística

La inferencia estadística es una rama fundamental de la estadística que se encarga de hacer generalizaciones o predicciones sobre una población basándose en el análisis de una muestra representativa. A diferencia de la estadística descriptiva, que se limita a describir y resumir datos observados, la inferencia busca ir más allá de los datos disponibles para estimar parámetros desconocidos o contrastar hipótesis.

La base de la inferencia radica en la aleatoriedad y la teoría de probabilidades. Cuando se extrae una muestra aleatoria de una población, es posible calcular estadísticas muestrales (como la media, la desviación estándar o la proporción), que son estimaciones de los verdaderos parámetros poblacionales. Estas estimaciones siempre contienen un grado de incertidumbre, que se puede expresar a través de intervalos de confianza o pruebas de hipótesis.

Una de las aplicaciones más comunes de la inferencia es la estimación de parámetros. Por ejemplo, si se desea conocer la media de horas que estudian los estudiantes de una universidad, no es necesario encuestar a todos. Basta con tomar una muestra aleatoria de, digamos, 100 estudiantes, calcular la media muestral y estimar la media poblacional con un intervalo de confianza.

La inferencia también permite contrastar hipótesis, es decir, comprobar si una afirmación sobre una población (por ejemplo, "el tiempo promedio de espera en una clínica es mayor a 15 minutos") es compatible con los datos observados. Esto se logra mediante pruebas estadísticas que usan distribuciones de probabilidad para evaluar la significancia de los resultados.

En resumen, la inferencia estadística es clave para tomar decisiones informadas en contextos reales, ya que permite hacer afirmaciones razonables sobre una población completa a partir de datos limitados, siempre controlando el nivel de incertidumbre involucrado.

Distribuciones muestrales: medias muestrales

Una distribución muestral describe cómo varía una estadística (como la media) cuando se toma muchas veces muestras aleatorias del mismo tamaño desde una

población. La distribución muestral de la media es especialmente importante, ya que permite estimar la media poblacional con base en una muestra.

Supongamos que la población tiene media μ y desviación estándar σ. Si tomamos muestras aleatorias de tamaño n y calculamos su media, la distribución de esas medias tendrá:

- Una media igual a μ.
- Una desviación estándar igual a $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$, conocida como error estándar.

Ejemplo práctico: si la estatura media de una población es 170 cm con una desviación estándar de 10 cm, y se toma una muestra de 25 personas, el error estándar será:

$$\sigma_{\bar{x}} = \frac{10}{\sqrt{25}} = \frac{10}{5} = 2 \text{ cm}$$

Esto significa que, en promedio, la media de las muestras estará a 2 cm de la media real.

Cuando el tamaño de la muestra es suficientemente grande ($n \geq 30$), la distribución muestral tiende a una forma normal, aunque la población no lo sea, gracias al Teorema del Límite Central. Esto justifica el uso de técnicas inferenciales basadas en la normalidad.

Distribuciones muestrales: proporciones muestrales

Además de las medias, es común estudiar proporciones muestrales. Estas representan la fracción de elementos de una muestra que tienen una determinada característica (por ejemplo, el porcentaje de personas que aprueban una política).

La proporción muestral se denota como p y su distribución muestral tiene:

- Media igual a p, la proporción poblacional.
- Error estándar igual a:

$$\sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$$

Ejemplo: si el 60% de una población está a favor de una medida (p = 0.6), y se toma una muestra de 100 personas:

$$\sigma_{\hat{p}} = \sqrt{\frac{0.6 \cdot 0.4}{100}} = \sqrt{\frac{0.24}{100}} = \sqrt{0.0024} \approx 0.049$$

Esto permite construir intervalos de confianza para estimar la proporción poblacional a partir de una muestra.

La normalidad de la distribución muestral de la proporción se garantiza si $np \geq 5$ y $n(1-p) \geq 5$, lo que permite usar aproximaciones normales.

Cálculo de intervalos de confianza para la media con desviación estándar de la población conocida

Cuando se conoce la desviación estándar poblacional σ\sigmaσ, el intervalo de confianza para la media se calcula con la distribución normal:

$$IC = \bar{x} \pm Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

Donde:

- $\bar{x}$: media muestral.
- $Z_{\alpha/2}$: valor crítico de la normal estándar (por ejemplo, 1.96 para 95%).
- $\frac{\sigma}{\sqrt{n}}$: error estándar.

Ejemplo: si x=100 , σ=15, n=36, y nivel de confianza 95%:

$$IC = 100 \pm 1.96 \cdot \frac{15}{\sqrt{36}} = 100 \pm 1.96 \cdot 2.5 = 100 \pm 4.9$$

$$\text{Intervalo: } [95.1; 104.9]$$

Este intervalo significa que hay un 95% de confianza de que la media poblacional esté en ese rango.

Cálculo de intervalos de confianza para la media con desviación estándar de la población desconocida

Cuando no se conoce σ, se utiliza la desviación estándar muestral sss, y la distribución t de Student:

$$IC = \bar{x} \pm t_{\alpha/2,n-1} \cdot \frac{s}{\sqrt{n}}$$

Donde:

- $t_{\alpha/2,n-1}$: valor crítico de la t-Student con n−1n-1n−1 grados de libertad.

Ejemplo: x=50, s=10, n=16, confianza del $95\% \rightarrow t_{0.025,15} \approx 2.131$

$$IC = 50 \pm 2.131 \cdot \frac{10}{\sqrt{16}} = 50 \pm 2.131 \cdot 2.5 = 50 \pm 5.3275$$

$$\text{Intervalo: } [44.67; 55.33]$$

Esto es más conservador que usar Z, ya que la t-Student tiene colas más gruesas.

Cálculo de intervalos de confianza para una proporción

Para una proporción p, el intervalo se calcula así:

$$IC = \hat{p} \pm Z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Ejemplo: en una muestra de 150 personas, 90 están de acuerdo con una política → p^=90/150=0.6:

$$IC = 0.6 \pm 1.96 \cdot \sqrt{\frac{0.6 \cdot 0.4}{150}} = 0.6 \pm 1.96 \cdot \sqrt{0.0016} = 0.6 \pm 1.96 \cdot 0.04$$

$$\text{Intervalo: } [0.5216; 0.6784]$$

Esto indica que el 52.16% a 67.84% de la población estaría a favor con un 95% de confianza.

Cálculo de niveles de confianza

El nivel de confianza representa la certeza con la que se desea estimar un parámetro. Los más comunes son:

- 90% → Z=1.64
- 95% → Z=1.96
- 99% → Z=2.576

Un mayor nivel de confianza amplía el intervalo. Por ejemplo:

- 95% confianza → x=70, σ=10, n=25:

$$IC = 70 \pm 1.96 \cdot \frac{10}{5} = 70 \pm 3.92 = [66.08; 73.92]$$

- 99% confianza → cambia a Z=2.576Z → intervalo más amplio: [64.72;75.28]

Esto ilustra el trade-off entre precisión y certeza.

Cálculo del tamaño muestral

Para lograr un determinado margen de error (E) y nivel de confianza, el tamaño muestral necesario para estimar una media se calcula así:

$$n = \left(\frac{Z_{\alpha/2} \cdot \sigma}{E}\right)^2$$

Ejemplo: para estimar una media con error máximo de ±2 unidades, σ=12, 95% confianza:

$$n = \left(\frac{1.96 \cdot 12}{2}\right)^2 = (11.76)^2 = 138.3 \Rightarrow n = 139$$

Esto indica que se necesitan 139 individuos para ese nivel de precisión.

Cierre ✍️

La inferencia estadística representa una de las herramientas más poderosas para estimar parámetros poblacionales a partir de muestras. A lo largo de este manual, se han abordado los fundamentos necesarios para comprender cómo la media y la proporción de una muestra pueden utilizarse para construir **intervalos de confianza**, ofreciendo una estimación con cierto nivel de certeza sobre los valores reales en la población.

Comprender la **distribución muestral de medias y proporciones** permite aplicar correctamente las fórmulas de estimación, ya sea con desviación estándar conocida o desconocida. Asimismo, se destacó la diferencia entre el uso de la **distribución normal** y la **t de Student**, haciendo énfasis en las condiciones para utilizar cada una.

El dominio de estos conceptos permite también calcular el **nivel de confianza**, seleccionar el **margen de error** deseado, y determinar el **tamaño muestral** necesario para realizar estudios estadísticos robustos. Estas competencias son claves para quienes trabajan en el análisis de datos, investigación científica, estudios sociales y en la toma de decisiones empresariales fundamentadas en evidencia cuantitativa.

Con la base teórica, ejemplos numéricos y fórmulas vistas en este módulo, estás preparado para aplicar correctamente los intervalos de confianza como parte esencial del análisis inferencial en diversas disciplinas.

¡Nos vemos de nuevo, más adelante! 👋

Referencias📚

- Stat Trek. (s.f.). *Confidence intervals*. https://stattrek.com/estimation/confidence-interval.aspx
- Illowsky, B., & Dean, S. (2013). *Introductory statistics*. OpenStax, Rice University. https://openstax.org/books/introductory-statistics/pages/8-introduction
- U.S. National Institute of Standards and Technology (NIST). (2023). *Confidence intervals*. https://www.itl.nist.gov/div898/handbook/eda/section3/eda352.html
- Universidad Politécnica de Madrid. (s. f.). *[Tema 6] Intervalos de confianza*. https://moodle.upm.es/en-abierto/course/view.php?id=111
- Universitat Politècnica de Catalunya. (2012). *[Tema 8] Intervalos de confianza*. https://upcommons.upc.edu/bitstream/handle/2117/186420/08_intervalos_de_confianza-5331.pdf
- Universidad Politécnica de Madrid. (s. f.). *[Tema 6] Intervalos de confianza*. https://moodle.upm.es/en-abierto/pluginfile.php/1164/mod_label/intro/%5BTEMA%206%5D-INTERVALOS%20DE%20CONFIANZA.pdf
- OpenStax. (2024). *Introducción a la estadística*. https://assets.openstax.org/oscms-prodcms/media/documents/Introduccion_al_la_estadistica_-_WEB.pdf

¡Muchas gracias!

Nos vemos en la próxima lección

alkemy