Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😁

alkemy

Clase grabada

Distribución de probabilidad Parte II

Aprendizaje Esperado 3: Utilizar las funciones de distribución de probabilidades identificando su campo de utilización en el análisis estadístico.

alkemy

Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**

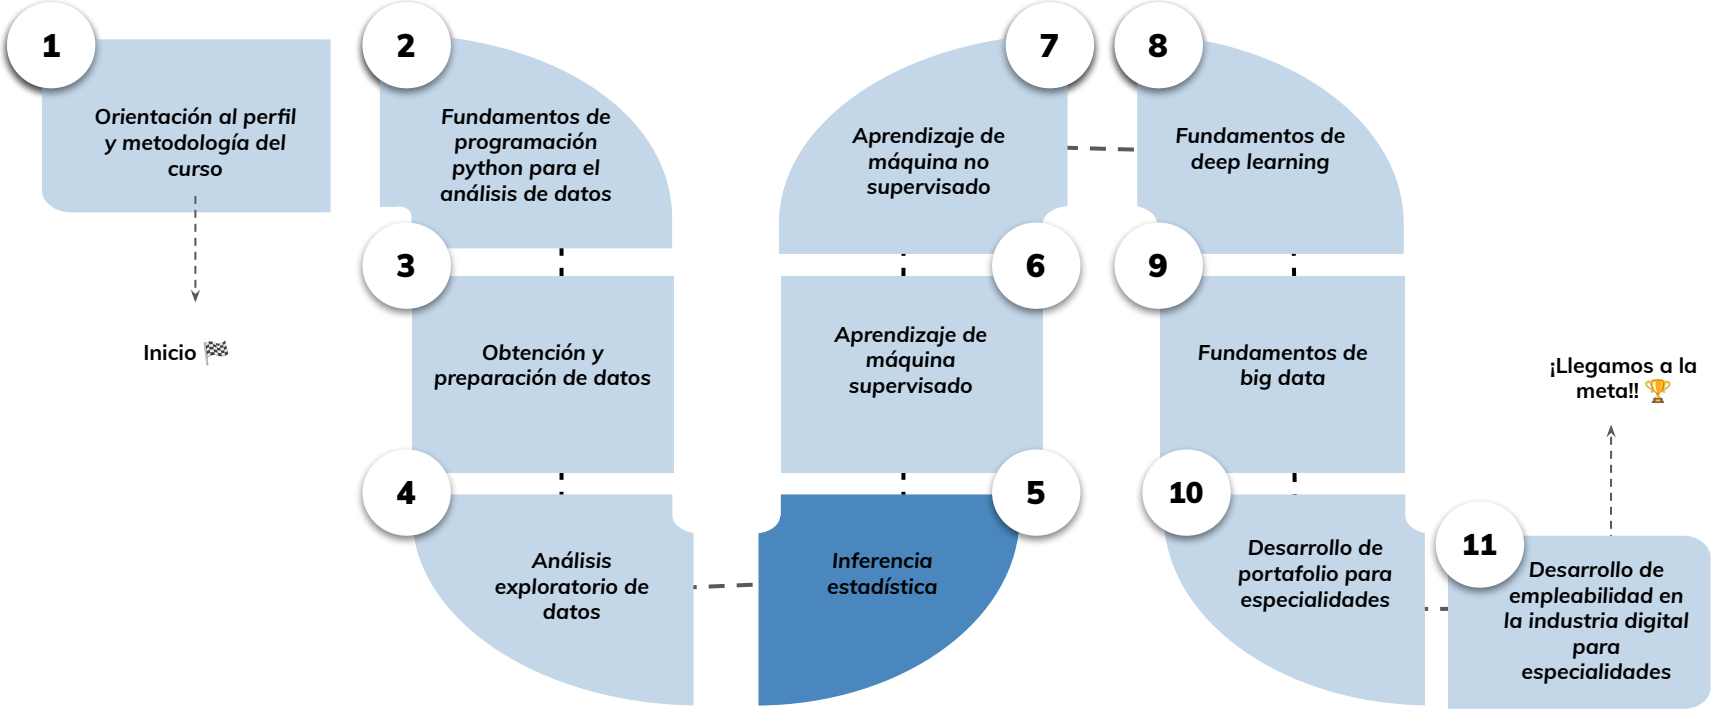

alkemy

Roadmap de lecciones

*¿Cuáles **lecciones** estaremos estudiando en este módulo?*

1. MÉTODO CIENTÍFICO Y ESTADÍSTICA
2. PROBABILIDAD Y ESTADÍSTICA
3. DISTRIBUCIÓN DE PROBABILIDAD
4. DISTRIBUCIÓN MUESTRAL Y TEOREMA DEL LÍMITE CENTRAL
5. INFERENCIA E INTERVALOS DE CONFIANZA PARA LA MEDIA
6. TEST DE SIGNIFICANCIA

Learning Path

¿Cuáles temas trabajaremos hoy?

3.

Seleccionar la distribución de probabilidad adecuada para un fenómeno aleatorio

- **Distribución binomial**
  - **Ensayos independientes y número de éxitos**
  - **Parámetros y fórmula**
- **Distribución Poisson**
  - **Conteo de eventos raros en intervalos**
  - **Parámetro lambda y forma de la distribución**

En esta clase continuaremos explorando distribuciones de probabilidad. Nos centraremos en dos distribuciones clave: binomial y Poisson, analizando sus características, fórmulas, diferencias y aplicaciones típicas. También veremos ejemplos en código y simulaciones.

alkemy

Objetivos de aprendizaje

¿Qué aprenderás?

- Reconocer la estructura de un experimento binomial
- Aplicar la fórmula de la distribución binomial
- Comprender la distribución de Poisson y su parámetro
- Diferenciar cuándo conviene usar binomial o Poisson
- Interpretar resultados y tomar decisiones estadísticas simples

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior conocimos 📚:

→ *Qué es una variable aleatoria y cómo modela la incertidumbre*

→ *Diferencias entre variables discretas y continuas*

→ *Qué es una distribución de probabilidad*

→ *Estudio de las distribuciones discretas: Uniforme discreta y Bernoulli*

→ *Asociamos fenómenos reales con estas distribuciones para tomar decisiones más informadas*

Distribución de probabilidad

Distribución chi-cuadrado (χ^2)

La **distribución chi-cuadrado** es una distribución asimétrica utilizada principalmente en pruebas de hipótesis, como la prueba de bondad de ajuste y la independencia en tablas de contingencia.

Sea $X \sim \chi^2(k)$, donde k son los **grados de libertad**. La distribución surge como la suma de los cuadrados de k variables normales estándar independientes.

La media y varianza son:

$$\mu = k \qquad \sigma^2 = 2k$$

alkemy

Aplicaciones de la distribución chi-cuadrado

Ejemplo: Si se tienen 5 grados de libertad, entonces $\mu=5$ y $\sigma^2=10$.

Esta distribución se aplica para verificar si una muestra se ajusta a una distribución teórica, o si dos variables categóricas son independientes.

A mayor k, más simétrica se vuelve la distribución. Es esencial en análisis de varianza (ANOVA).

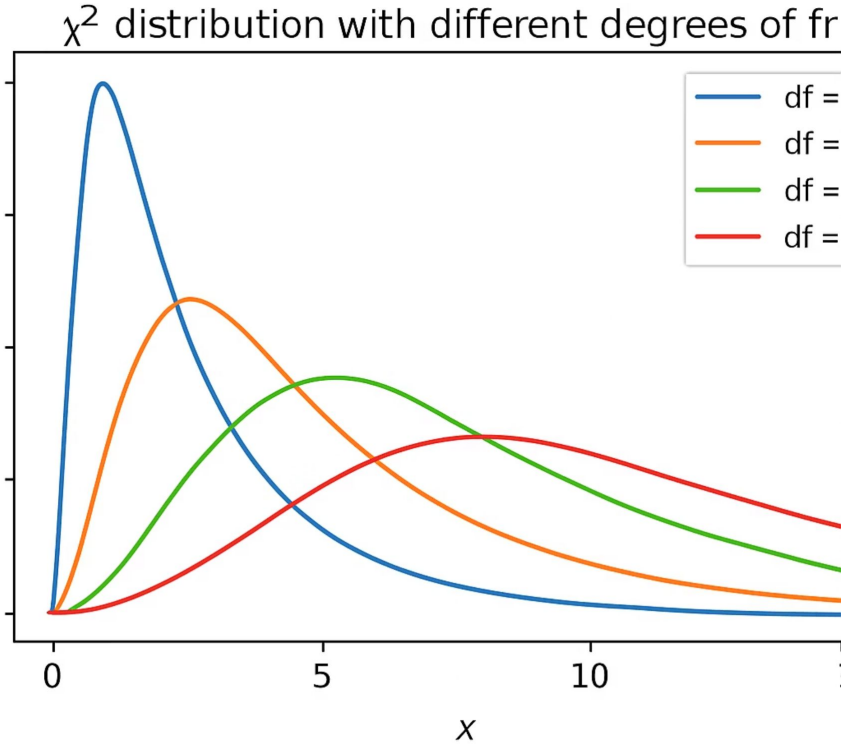

alkemy

Distribución t de Student

La **distribución t de Student** es usada cuando se estima la media de una población normal pero con tamaño de muestra pequeño y varianza desconocida.

Sea T~t(k), con k grados de libertad. La forma de la curva es similar a la normal, pero con colas más pesadas.

La fórmula de la variable t es:

$$t = \frac{\bar{X} - \mu}{s/\sqrt{n}}$$

donde:

- $\bar{X}$ es la media muestral.
- s es la desviación estándar muestral.
- n es el tamaño de muestra.

Ejemplo de distribución t de Student

Con una muestra de 10 personas y $\bar{X}$=75, s=8, estimar si esta media difiere de 70. Se calcula:

$$t = \frac{75 - 70}{8/\sqrt{10}} \approx 1.98$$

Con 9 grados de libertad, se compara el valor en la tabla t.

Se usa en inferencia estadística, especialmente en tests de hipótesis para medias.

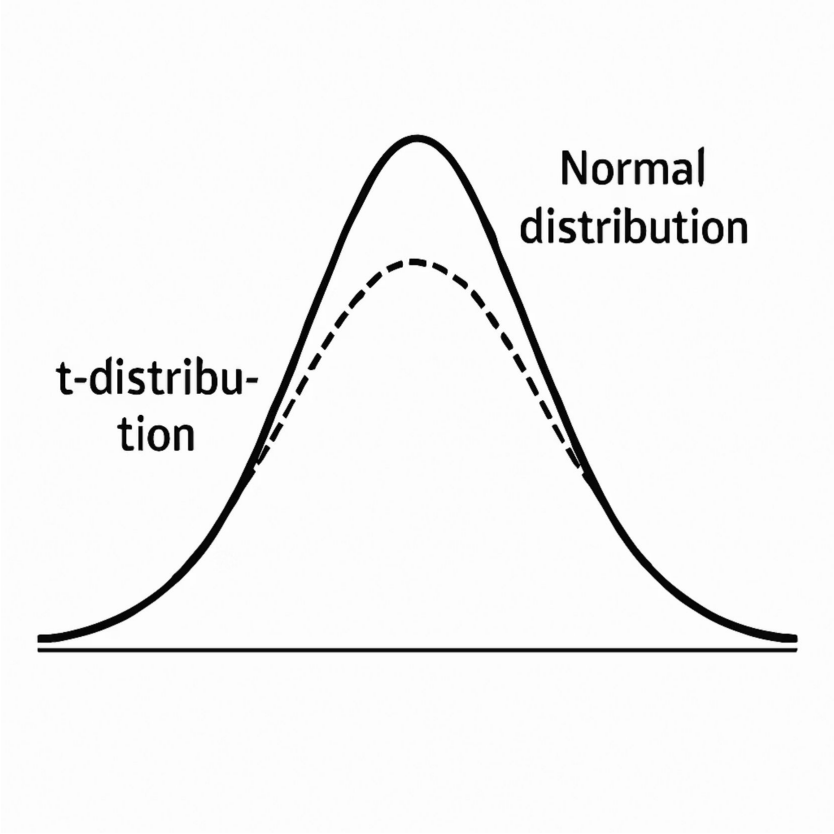

alkemy

Distribución de Fisher (F)

La **distribución F de Fisher-Snedecor** se emplea para comparar **dos varianzas** y en análisis de varianza (**ANOVA**). Es una distribución continua, no simétrica y siempre positiva.

Sea $F=S_1^2/S_2^2$ donde S_1^2 y S_2^2 son varianzas muestrales de dos poblaciones independientes. La distribución F se define por dos grados de libertad:

- d1: grados de libertad del numerador
- d2: grados de libertad del denominador

alkemy

Aplicación de la distribución F

La fórmula para su función de densidad es compleja, pero su uso se apoya en tablas o software estadístico. La media de la distribución F es d2/(d2-2) para d2>2.

Ejemplo: En un experimento, si se quiere comparar la variabilidad de dos tratamientos con n1=10 y n2=15, y se obtiene F=2.5, entonces:

Se consulta la tabla F con d1=9, d2=14 para ver si ese valor es significativo.

Es muy utilizada en pruebas F de igualdad de varianzas y en ANOVA para evaluar diferencias entre medias grupales considerando la variabilidad interna.

$$F = \frac{4}{2} = 2$$

alkemy

Distribución exponencial

La **distribución exponencial** es una distribución continua usada para modelar **el tiempo entre eventos** en un proceso de Poisson. Tiene un solo parámetro: la **tasa de ocurrencia** $\lambda>0$.

La función de densidad es:

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

Propiedades:

- Varianza: $\sigma^2 = \frac{1}{\lambda^2}$
- Media: $\mu = \frac{1}{\lambda}$

alkemy

Ejemplo de distribución exponencial

Si el tiempo promedio entre llamadas a una central es de 5 minutos (λ=1/5), la probabilidad de que la próxima llamada llegue antes de 2 minutos es:

$$P(X < 2) = 1 - e^{-0.2 \cdot 2} = 1 - e^{-0.4} \approx 0.33$$

La distribución es **asimétrica** y **decrece exponencialmente**, ideal para modelar eventos como fallas, llamadas telefónicas o llegadas a colas de espera.

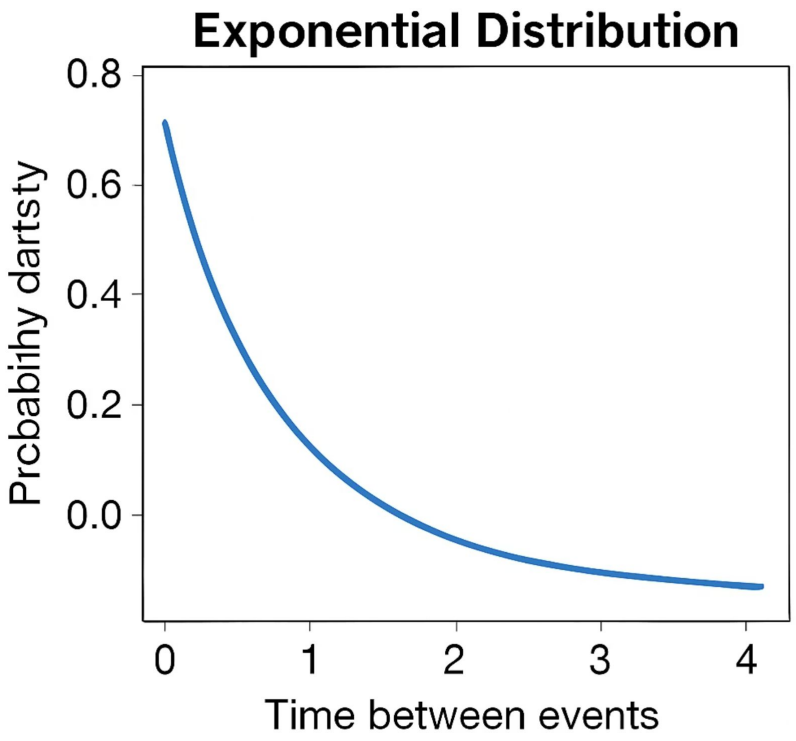

alkemy

Recomendaciones para la elección de una distribución

La correcta elección de una distribución depende del **tipo de variable**, la **naturaleza del fenómeno** y la **forma de la distribución empírica** observada.

Clasificar la variable
¿Es discreta o continua?

Analizar la forma de los datos
Simetría, sesgo, presencia de colas.

Verificar supuestos
Independencia, homogeneidad de varianza, normalidad.

Comparar con histogramas teóricos
Usando software como Excel, R o Python.

Aplicar pruebas de ajuste
Como Kolmogorov-Smirnov, Chi-cuadrado o Anderson-Darling.

alkemy

Ejemplos de selección de distribuciones

Conteo de eventos por tiempo

Si se cuentan eventos por unidad de tiempo → Distribución de Poisson.

Tiempo hasta ocurrencia

Si se mide tiempo hasta ocurrencia → Distribución Exponencial.

Medias de pequeñas muestras

Si se estudian medias de pequeñas muestras → Distribución t de Student.

Comparación de varianzas

Si se desea comparar varianzas → Distribución F de Fisher.

Variables continuas simétricas

Si la variable es continua y simétrica → Distribución Normal.

La elección adecuada mejora la precisión de inferencias, reduce errores tipo I y II, y permite aplicar modelos correctamente fundamentados.

Características de la distribución normal

La distribución normal tiene múltiples propiedades que la convierten en la **más utilizada en estadística**. Entre ellas:

Simetría

Respecto a su media μ. La mediana y la moda coinciden.

Campana de Gauss

Forma clásica de campana, donde la mayoría de valores se agrupan cerca de la media.

Regla empírica

El 68%, 95% y 99.7% de los datos están dentro de 1, 2 y 3 desviaciones estándar, respectivamente.

Continuidad

Permite calcular probabilidades mediante el área bajo la curva.

Función de densidad de la distribución normal

La función de densidad es:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Ejemplo: Si X~N(0,1), la probabilidad de que X esté entre -1 y 1 es:

$$P(-1 < X < 1) \approx 0.68$$

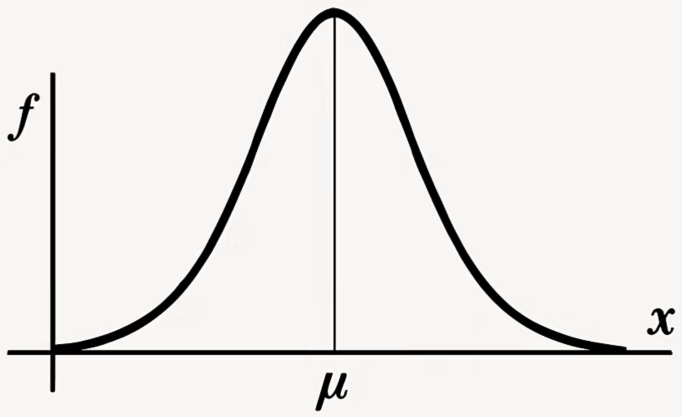

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Estas características hacen que la normal sea usada para inferencia, control de calidad, análisis de regresión, entre otros.

alkemy

Forma funcional y cálculo de probabilidad con la distribución normal

El cálculo de probabilidades con la distribución normal se basa en la integral de la función de densidad:

Sin embargo, esta integral no tiene solución analítica simple, por lo que se recurre a:

Tablas Z (cuando se usa la normal estándar).

Software como Excel, R, Python, SPSS.

$$P(a \leq X \leq b) = \int_a^b f(x)\,dx$$

alkemy

Normalización de variables

Para usar la tabla Z, primero se **normaliza** la variable:

$$Z = \frac{X - \mu}{\sigma}$$

Ejemplo: Si $X \sim N(80, 10^2)$, calcular $P(X < 95)$:

$$Z = \frac{95 - 80}{10} = 1.5 \Rightarrow P(Z < 1.5) \approx 0.9332$$

Si se busca $P(70 < X < 90)$, se transforman ambos valores:

$$Z_1 = \frac{70 - 80}{10} = -1 \quad Z_2 = \frac{90 - 80}{10} = 1 \Rightarrow P(-1 < Z < 1) \approx 0.6826$$

Estos cálculos permiten evaluar eventos en contextos reales como pruebas estandarizadas, procesos industriales y análisis financieros.

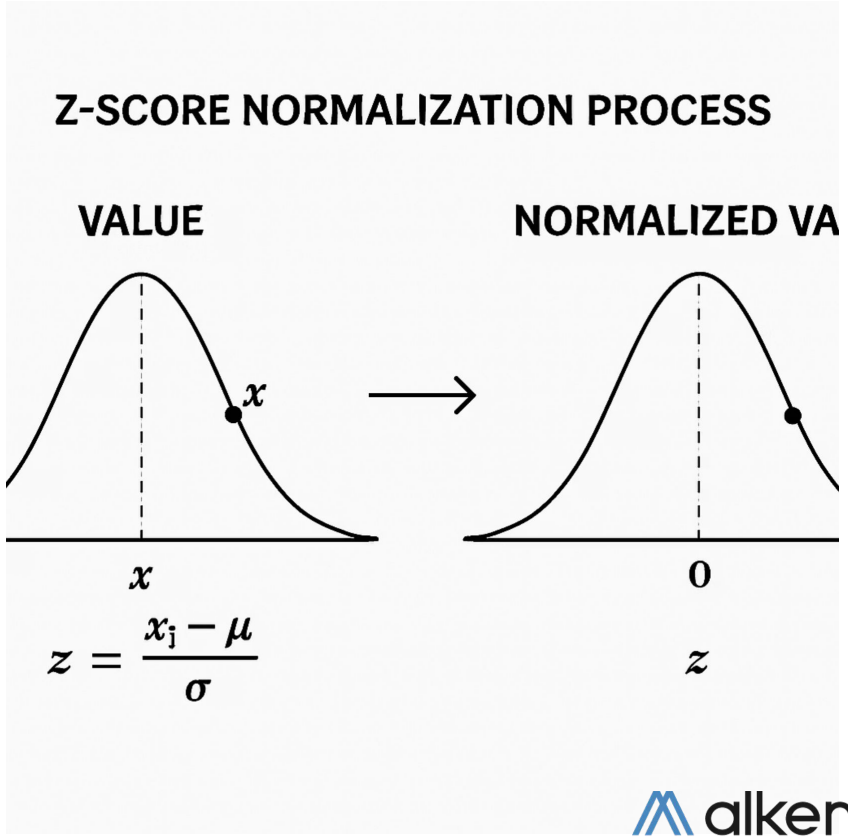

alkemy

Distribuciones de probabilidad en la práctica

El estudio de las distribuciones de probabilidad es un pilar fundamental del análisis estadístico. A lo largo de esta lección, se abordaron tanto las distribuciones **discretas** (como Bernoulli, binomial, Poisson) como las **continuas** (uniforme, normal, t-Student, chi-cuadrado, Fisher, exponencial), junto con las propiedades que permiten describir y predecir el comportamiento de variables aleatorias.

Aplicaciones de las distribuciones de probabilidad

Control de calidad
Monitoreo de procesos industriales y detección de anomalías

Investigación científica
Análisis de resultados experimentales y validación de hipótesis

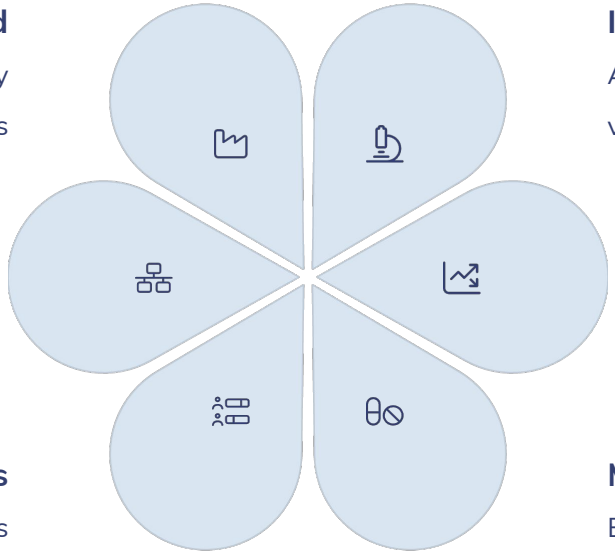

Telecomunicaciones
Análisis de tráfico y planificación de capacidad

Finanzas
Modelado de rendimientos y evaluación de riesgos

Ciencias sociales
Encuestas y estudios demográficos

Medicina
Ensayos clínicos y epidemiología

alkemy

Campos de aplicación específicos

Distribución binomial

- Control de calidad (piezas defectuosas)
- Encuestas de opinión
- Genética (herencia de características)
- Análisis de riesgos

Distribución normal

- Mediciones físicas (altura, peso)
- Errores de medición
- Calificaciones en exámenes
- Indicadores económicos

Distribución de Poisson

- Llegadas a un sistema (clientes, llamadas)
- Fallos en equipos
- Accidentes en un período
- Mutaciones genéticas

Importancia de la selección adecuada

Se mostró cómo cada distribución tiene su propio campo de aplicación, dependiendo del tipo de variable, el contexto del experimento y las condiciones del fenómeno observado. Asimismo, se introdujeron herramientas clave para el cálculo de probabilidades, especialmente con la distribución normal y su forma estandarizada.

El conocimiento y aplicación correcta de estas distribuciones permiten realizar inferencias estadísticas sólidas, diseñar experimentos adecuados y tomar decisiones fundamentadas. En este sentido, dominar este contenido fortalece la capacidad de análisis crítico y riguroso en escenarios reales.

Criterios para la selección de distribuciones

Naturaleza del fenómeno

¿Qué tipo de evento estamos midiendo? ¿Es un conteo, una medición, un tiempo de espera?

Características de los datos

¿Son discretos o continuos? ¿Tienen límites naturales? ¿Son simétricos o sesgados?

Verificación de supuestos

¿Los datos cumplen con las condiciones necesarias para aplicar una distribución específica?

Pruebas de ajuste

Aplicar tests estadísticos para confirmar que la distribución elegida se ajusta adecuadamente a los datos.

Herramientas para el análisis de distribuciones

1

Histogramas

Representación gráfica que muestra la frecuencia de los datos en intervalos, permitiendo visualizar la forma de la distribución.

2

Gráficos Q-Q

Comparan los cuantiles de los datos con los cuantiles teóricos de una distribución, útiles para verificar normalidad.

3

Pruebas de bondad de ajuste

Tests estadísticos como Kolmogorov-Smirnov, Chi-cuadrado o Shapiro-Wilk que evalúan formalmente si los datos siguen una distribución específica.

4

Software estadístico

Programas como R, Python, SPSS o Excel que facilitan el análisis de distribuciones y el cálculo de probabilidades.

alkemy

Distribuciones en el análisis de datos reales

En la práctica, los datos reales rara vez siguen perfectamente una distribución teórica. Sin embargo, las distribuciones de probabilidad siguen siendo modelos útiles que:

- Aproximan adecuadamente muchos fenómenos naturales y sociales
- Permiten hacer predicciones y estimaciones
- Facilitan la inferencia estadística
- Proporcionan un marco teórico para el análisis

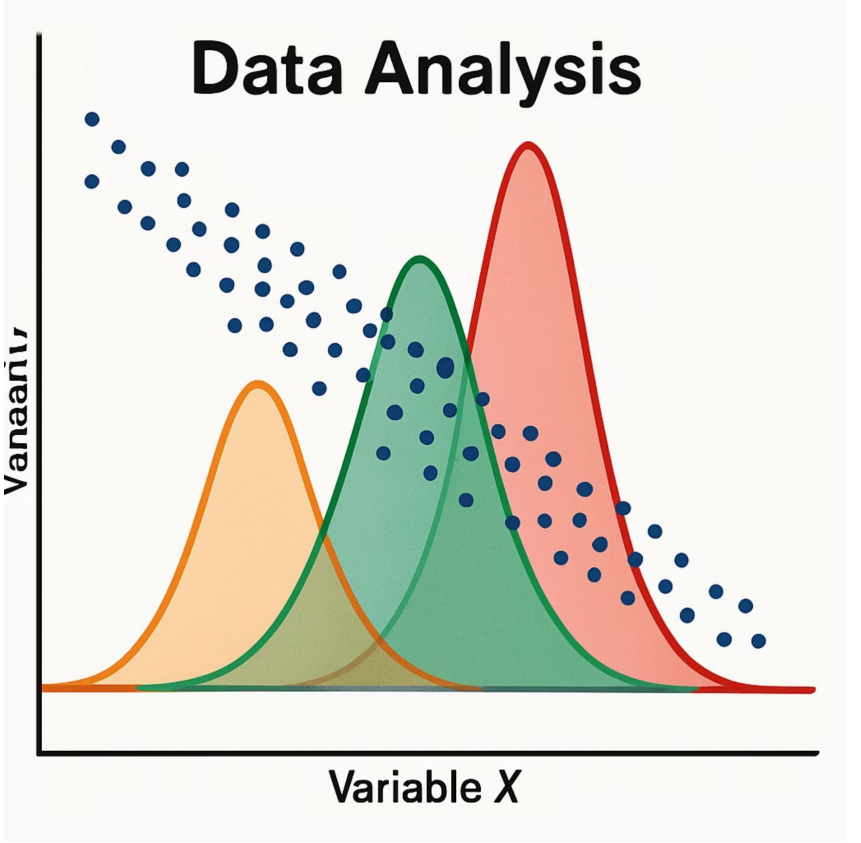

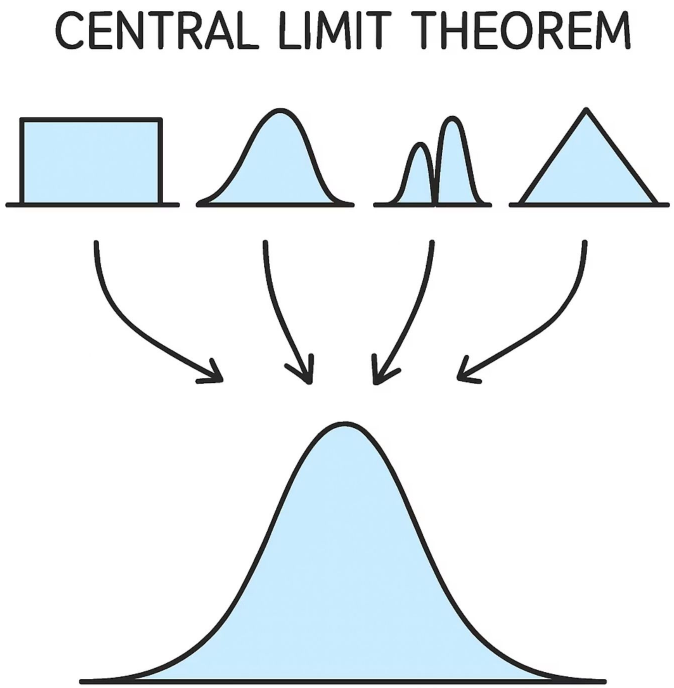

Distribuciones y el Teorema del Límite Central

El Teorema del Límite Central es uno de los resultados más importantes en estadística y explica por qué la distribución normal es tan prevalente:

> La suma (o promedio) de un gran número de variables aleatorias independientes e idénticamente distribuidas tiende a seguir una distribución normal, independientemente de la distribución original de estas variables.

Este teorema justifica el uso de métodos basados en la normalidad en muchas aplicaciones estadísticas, incluso cuando los datos originales no son normales.

alkemy

Distribuciones en la inferencia estadística

1

Estimación puntual

Uso de distribuciones para calcular estimadores de parámetros poblacionales como la media o la varianza.

2

Intervalos de confianza

Construcción de rangos que contienen el verdadero valor del parámetro con cierta probabilidad, basados en distribuciones como la normal o t de Student.

3

Pruebas de hipótesis

Evaluación de afirmaciones sobre parámetros poblacionales utilizando distribuciones como referencia para la toma de decisiones.

4

Análisis de varianza

Comparación de medias entre grupos utilizando la distribución F para evaluar la significancia de las diferencias.

alkemy

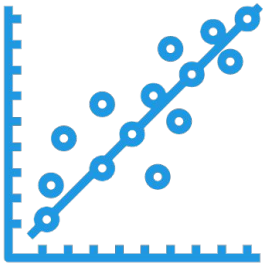

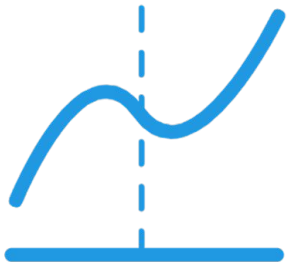

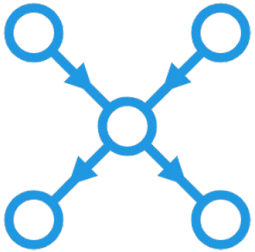

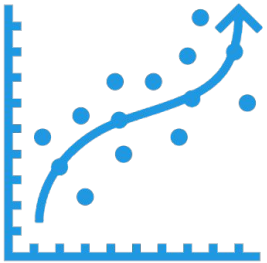

Distribuciones en el modelado estadístico

Las distribuciones de probabilidad son componentes esenciales en el desarrollo de modelos estadísticos avanzados:

- Modelos lineales generalizados
- Series temporales
- Análisis bayesiano
- Modelos de supervivencia
- Métodos de remuestreo

En estos modelos, la elección de la distribución adecuada es crucial para capturar correctamente la naturaleza de los datos y hacer inferencias válidas.

alkemy

Distribuciones en la era de los datos masivos

Incluso en la era del big data y el aprendizaje automático, las distribuciones de probabilidad siguen siendo relevantes:

Modelado de incertidumbre

Cuantificación de la incertidumbre en predicciones y estimaciones.

Detección de anomalías

Identificación de valores atípicos basada en distribuciones esperadas.

Generación de datos sintéticos

Creación de datos artificiales para entrenamiento o simulación.

Validación de modelos

Evaluación de residuos y errores en modelos predictivos.

Más allá de las distribuciones clásicas

Aunque este manual se ha centrado en las distribuciones más comunes, existen muchas otras distribuciones especializadas para casos específicos:

Distribución Weibull

Utilizada en análisis de fiabilidad y tiempo hasta el fallo.

Distribución Gamma

Modelado de tiempos de espera y precipitaciones.

Distribución Beta

Modelado de proporciones y probabilidades.

Distribución Lognormal

Común en finanzas e ingresos.

El estudio de estas distribuciones especializadas puede ser necesario en campos específicos o para modelar fenómenos particulares.

Consejos prácticos para el uso de distribuciones

1. **Explorar los datos antes de elegir una distribución**
   Siempre examine gráficamente sus datos y calcule estadísticas descriptivas antes de decidir qué distribución utilizar.

2. **Verificar los supuestos**
   Asegúrese de que los datos cumplen con los supuestos de la distribución elegida mediante pruebas formales.

3. **Considerar transformaciones**
   Si los datos no siguen una distribución deseada, considere transformaciones (logarítmica, raíz cuadrada, etc.) que puedan normalizarlos.

4. **Utilizar software estadístico**
   Aproveche las herramientas computacionales disponibles para ajustar y evaluar distribuciones.

Conclusiones sobre las distribuciones de probabilidad

Finalmente, recordar que el buen uso de las distribuciones no sólo implica conocer sus fórmulas, sino entender sus supuestos, reconocer sus aplicaciones y seleccionar con criterio cuál utilizar en cada situación. Este es un paso esencial en el camino hacia una práctica estadística profesional y confiable.
El conocimiento de las distribuciones de probabilidad proporciona una base sólida para el análisis estadístico y la toma de decisiones basada en datos, permitiendo extraer conclusiones válidas y confiables a partir de la información disponible.

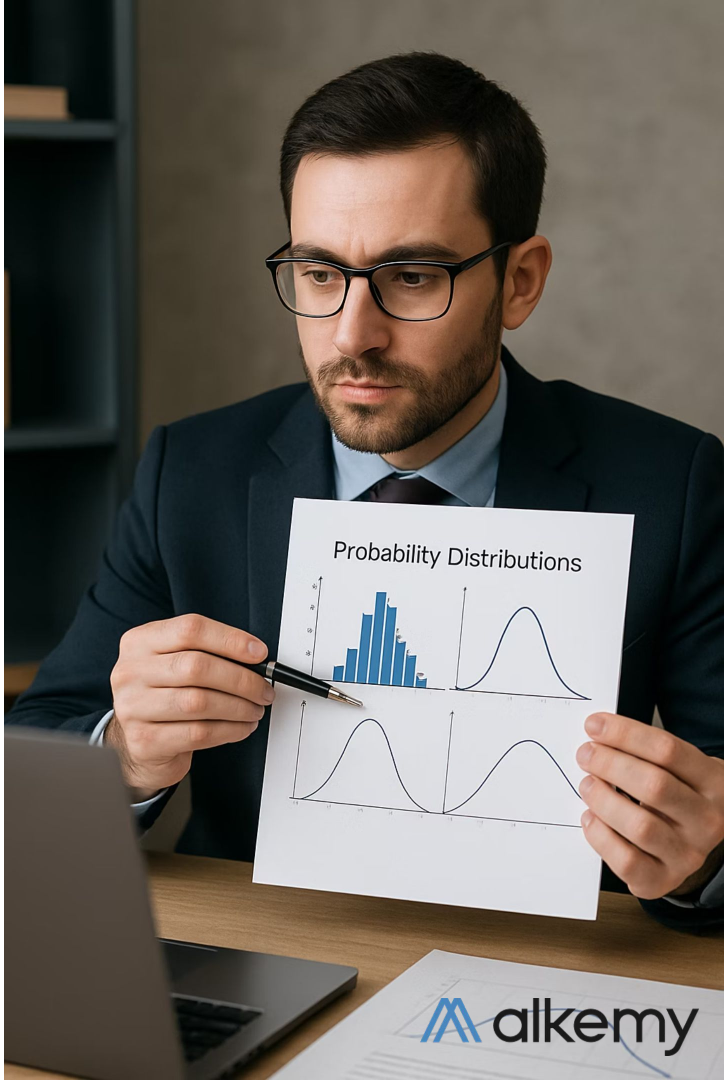

Despedida

El estudio de las distribuciones de probabilidad es un pilar fundamental del análisis estadístico. A lo largo de esta lección, se abordaron tanto las distribuciones **discretas** (como Bernoulli, binomial, Poisson) como las **continuas** (uniforme, normal, t-Student, chi-cuadrado, Fisher, exponencial), junto con las propiedades que permiten describir y predecir el comportamiento de variables aleatorias.

¡Nos vemos de nuevo, más adelante!

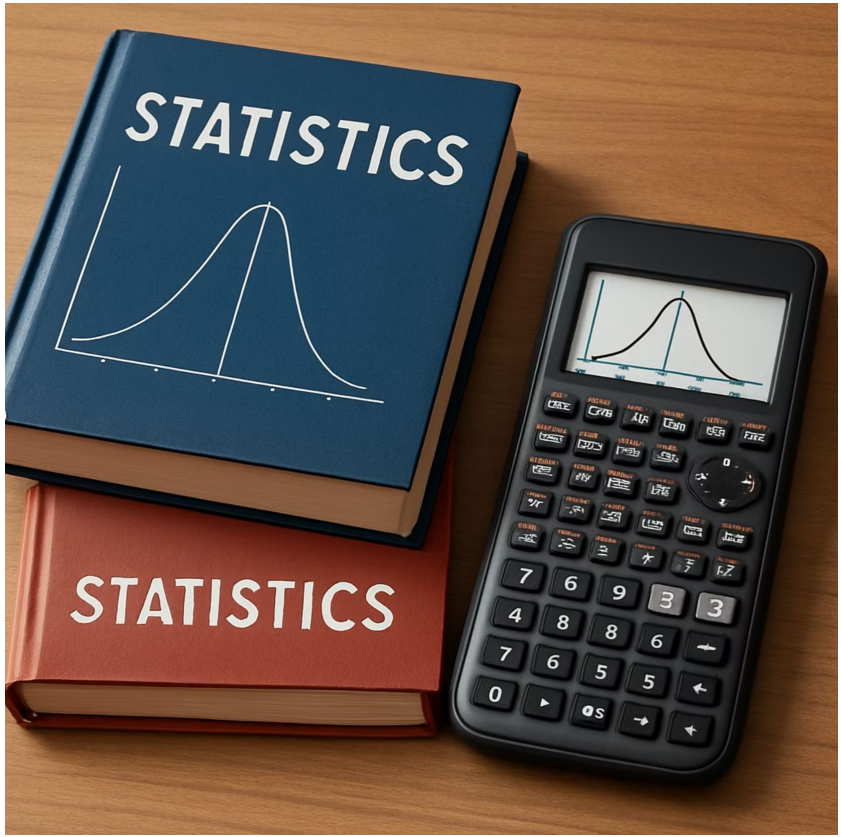

alkemy

Live Coding

¿En qué consistirá la Demo?

Simularemos experimentos usando scipy.stats en Python y compararemos binomial vs. Poisson:

1. *Usamos binom.pmf para calcular la probabilidad de obtener exactamente 3 éxitos en 10 intentos con p=0.5*
2. *Simulamos múltiples experimentos y graficamos histograma de resultados*
3. *Repetimos con poisson.pmf para $\lambda = 4$ (eventos por hora)*
4. *Comparamos las formas de ambas distribuciones y cuándo una se aproxima a la otra*

Tiempo: 20 Minutos

Momento:

Time-out!

⏰5 -10 min.

alkemy

Ejercicio

Elige tu distribución

Elegí tu distribución

Contexto: 🙌

Sos analista de datos y tienes que elegir la distribución adecuada para modelar estos fenómenos.

Consigna: ✍️

Casos a analizar:

1. Producción defectuosa en una línea de ensamblado:

   En una muestra de 20 piezas, la probabilidad de que una sea defectuosa es 0.1.

   → ¿Qué distribución te conviene usar?

2. Llegadas de mensajes de error por minuto en un servidor:

   En promedio, se reciben 2 por minuto.

   → ¿Qué distribución aplicarías?

3. Cantidad de respuestas correctas al azar en un test de opción múltiple de 10 preguntas:

   Cada pregunta tiene dos opciones y se responde sin saber.

   → ¿Qué distribución modela este fenómeno?

Tiempo 🕐**:** *40 Minutos*

alkemy

Elegí tu distribución

Paso a paso: ⚙️

1. Identifique si hay una cantidad fija de intentos o un intervalo de tiempo
2. Determine si los eventos son raros o tienen alta probabilidad
3. Asocie la distribución correcta: binomial o Poisson
4. Justifique tu elección con base en sus características
5. Grafique o esquematice cómo se vería la probabilidad en cada caso

¿Alguna consulta?

alkemy

Resumen

¿Qué logramos en esta clase?

- ✓ ***Comprendimos la estructura de la distribución binomial y cuándo se usa***
- ✓ ***Aplicamos la fórmula de la binomial a distintos problemas***
- ✓ ***Analizamos la distribución de Poisson para eventos en intervalos***
- ✓ ***Comparamos ambas distribuciones y seleccionamos la adecuada según el contexto***

¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las ***actividades disponibles en la plataforma.*** *Estas propuestas son clave para afianzar lo trabajado y* ***forman parte obligatoria del recorrido de aprendizaje.***

💪 Análisis de caso ——— 💪 Selección Múltiple

💪 Comprensión lectora

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

alkemy

< ¡Muchas gracias! >

alkemy