Working Time 🤓

L4: Regresiones lineales

Es hora de que pongas en práctica todo lo aprendido. 🤓
Este apartado tiene el objetivo de ayudarte a seguir potenciando tus habilidades, por lo que a continuación encontrarás diferentes **desafíos** que podrás resolver de forma independiente y a tu ritmo.

Más adelante conseguirás las resoluciones para que valides tus respuestas y puedas monitorear tu progreso. 😉

¡Manos a la obra!

1. **Desafío 🎯**

   Vas a trabajar con un conjunto de datos que contiene información sobre viviendas (precio, superficie, cantidad de habitaciones, etc.). El objetivo del desafío es construir un modelo de regresión lineal múltiple para predecir el precio de una vivienda en función de las demás variables. Deberás evaluar la calidad del modelo con las métricas vistas en clase, verificar sus supuestos y representar gráficamente la relación entre las variables.

   Tareas clave:

   - ➔ *Importar y explorar el dataset.*
   - ➔ *Construir un modelo de regresión lineal múltiple con statsmodels.*
   - ➔ *Evaluar su desempeño utilizando R^2, MAE, MSE y RMSE.*
   - ➔ *Verificar los supuestos del modelo (normalidad del error, homocedasticidad, multicolinealidad).*
   - ➔ *Representar gráficamente las relaciones clave con Seaborn.*

2. **¿Dónde se lleva a cabo? 🧑‍💻**

   Visual Studio Code

3. **Tiempo de dedicación ⏳**

   1 hora

4. **Recursos🛠️**

   - *Dataset simulado (podés usar el de sklearn.datasets.fetch_california_housing() o uno propio).*

- *Librerías:* pandas, statsmodels, matplotlib, seaborn, sklearn.

5. **Plus ➕**

   - *Incorporar una variable ficticia que creas relevante y analizar si mejora el modelo.*
   - *Comparar los resultados de un modelo simple vs. uno múltiple.*

6. **⚠️Condición**

   Esta práctica o ejercitación **no requiere ser entregada y/o evaluada** por el mentor. No obstante puedes compartir tus resultados con el resto de los bootcampers y construir conocimiento en conjunto.

Resolución del desafío 👇

- **Carga de librerías y dataset**

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
import statsmodels.api as sm
from sklearn.datasets import fetch_california_housing
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
```

```
# Cargar dataset de viviendas de California
datos = fetch_california_housing(as_frame=True)
df = datos.frame
df.head()
```

- **Selección de variables**

Usamos como variable objetivo el precio medio de la vivienda (MedHouseVal) y como predictoras:

➔ MedInc (ingreso medio)
➔ HouseAge (edad de la vivienda)
➔ AveRooms (número promedio de habitaciones)

```
X = df[["MedInc", "HouseAge", "AveRooms"]]
y = df["MedHouseVal"]
X = sm.add_constant(X)
```

- **Entrenamiento del modelo**

```
modelo = sm.OLS(y, X).fit()
print(modelo.summary())
```

- **Evaluación del modelo**

```
predicciones = modelo.predict(X)

mae = mean_absolute_error(y, predicciones)
mse = mean_squared_error(y, predicciones)
rmse = mean_squared_error(y, predicciones, squared=False)
r2 = r2_score(y, predicciones)

print(f"MAE: {mae:.4f}")
print(f"MSE: {mse:.4f}")
print(f"RMSE: {rmse:.4f}")
print(f"R2: {r2:.4f}")
```

- **Verificación de supuestos**

  ➔ Homocedasticidad

```
residuos = modelo.resid
plt.scatter(predicciones, residuos)
plt.axhline(0, color="red", linestyle="--")
plt.title("Residuos vs Valores predichos")
plt.xlabel("Valores predichos")
plt.ylabel("Residuos")
plt.show()
```

  ➔ Normalidad del error (QQ-Plot)

```
import scipy.stats as stats

stats.probplot(residuos, dist="norm", plot=plt)
plt.title("QQ-Plot de residuos")
plt.show()
```

  ➔ **Multicolinealidad (VIF)**

```
from statsmodels.stats.outliers_influence import variance_inflation_factor

vif = pd.DataFrame()
vif["Variable"] = X.columns
vif["VIF"] = [variance_inflation_factor(X.values, i) for i in range(X.shape[1])]
print(vif)
```

- **Visualización de relaciones**

```
sns.pairplot(df[["MedHouseVal", "MedInc", "HouseAge", "AveRooms"]])
plt.suptitle("Relaciones entre variables", y=1.02)
plt.show()

sns.regplot(x="MedInc", y="MedHouseVal", data=df)
plt.title("Ingreso medio vs Valor medio de vivienda")
plt.show()
```

- **Conclusión esperada**

  ➔ El modelo explica una parte significativa de la variación del precio de las viviendas.
  ➔ Las variables seleccionadas resultaron significativas con p-valores bajos.
  ➔ Los residuos no muestran patrones evidentes (homocedasticidad razonable).
  ➔ El QQ-plot muestra una distribución aproximadamente normal.
  ➔ No se detecta multicolinealidad severa.
  ➔ El modelo puede mejorar si se agregan otras variables relevantes (como ubicación).