Análisis de Caso

Preprocesamiento y escalamiento de datos👨‍💻

alkemy

Análisis de Caso

Nombre del tema: *Preprocesamiento y escalamiento de datos*

Situación inicial 📍

La empresa **RetailData Analytics**, dedicada a ofrecer soluciones basadas en datos para comercios minoristas, ha sido contratada por una cadena de supermercados para desarrollar un modelo predictivo que identifique el perfil de los clientes más propensos a realizar compras recurrentes.

Durante la fase inicial del proyecto, el equipo de ciencia de datos ha recibido un conjunto de datos que contiene información demográfica y de comportamiento de los clientes. Sin embargo, al analizar los datos, identificaron problemas como valores nulos, variables categóricas no codificadas y diferencias significativas en las escalas de las variables numéricas.

La empresa ha solicitado a tu equipo que realice un proceso completo de **preprocesamiento y escalamiento de datos** para garantizar que el conjunto de datos sea adecuado para ser utilizado en la etapa de modelado predictivo.

Descripción del Caso 🔎

En este caso, asumirás el rol de **Especialista en Preparación de Datos** dentro del equipo de RetailData Analytics. Tu responsabilidad principal será transformar y preparar el conjunto de datos recibido para su posterior análisis.

Tendrás que encargarte de limpiar los datos, codificar las variables categóricas y aplicar las técnicas de escalamiento apropiadas para las variables numéricas, asegurando que todas las transformaciones se realicen siguiendo las mejores prácticas aprendidas en la lección.

Instrucciones 💡

Para cumplir con este desafío, deberás realizar las siguientes tareas:

1. Analiza el siguiente fragmento de datos proporcionados por el cliente:

ID	Edad	Ciudad	Ingresos (USD)
1	25	Madrid	30000
2	45	Sevilla	50000
3	30	Madrid	NaN
4	40	Barcelona	40000

2. Realiza las siguientes tareas utilizando Python y Scikit-Learn:
    - **Imputa** el valor faltante en la columna **Ingresos** utilizando la media.
    - Transforma la columna **Ciudad** utilizando **Label Encoding** y **One-Hot Encoding**.
    - Aplica el método de **Variables Dummy** para la columna **Ciudad**.
    - Escala las columnas **Edad** e **Ingresos** utilizando:
        - **Normalización Min-Max**
        - **Estandarización Z-Score**
3. Reflexiona y responde brevemente:
    - ¿Por qué es importante realizar estas tareas antes de entrenar un modelo de Machine Learning?

    - ¿Qué diferencias observaste entre la normalización y la estandarización?

Entregables 📬

Al finalizar el análisis, deberás entregar los siguientes elementos:

- Un archivo `.py` o Notebook `.ipynb` con todo el código desarrollado.
- Un archivo `.csv` o `.xlsx` con el conjunto de datos transformado y preprocesado.
- Un breve informe (máximo 1 página) que incluya:
    - Descripción de cada etapa aplicada en el preprocesamiento.
    - Respuestas a las preguntas de reflexión.
    - Captura de pantalla con la visualización de los datos escalados.

¡Muchas gracias!

Nos vemos en la próxima lección

alkemy