Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😁

alkemy

Clase grabada

Métricas de desempeño de un algoritmo de regresión- Parte II

Aprendizaje Esperado 6: Aplicar métricas de desempeño para la evaluación de algoritmos de clasificación y regresión de acuerdo al caso planteado.

alkemy

Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**

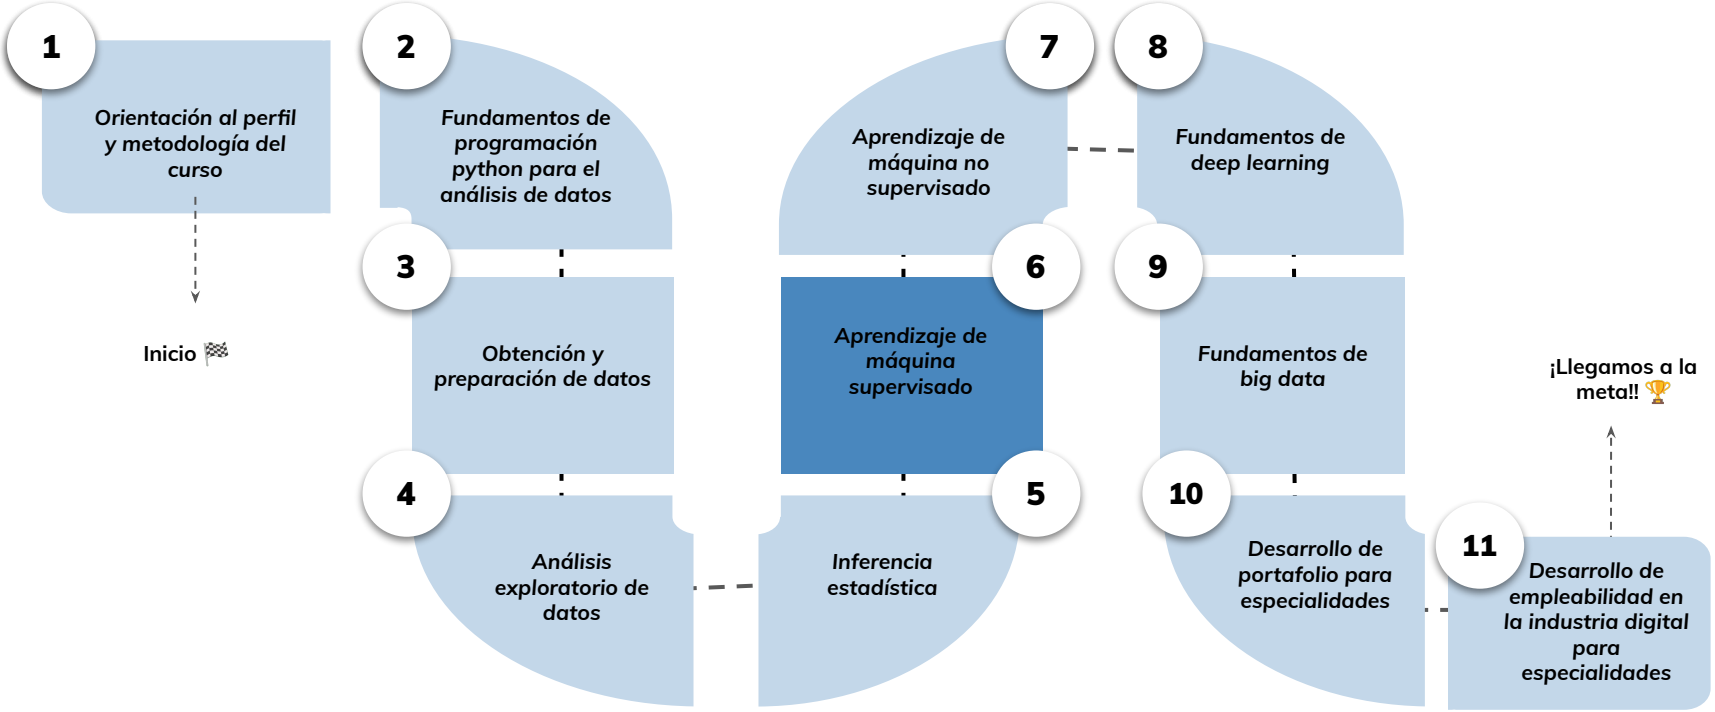

alkemy

Roadmap de lecciones

*¿Cuáles **lecciones** estaremos estudiando en este módulo?*

1. FUNDAMENTOS DEL APRENDIZAJE DE MÁQUINA
2. NIVEL DE AJUSTE DE UN MODELO Y VALIDACIÓN CRUZADA
3. PREPROCESAMIENTO Y ESCALAMIENTO DE DATOS
4. REGRESIONES
5. ALGORITMOS DE CLASIFICACIÓN
6. MÉTRICAS DE DESEMPEÑO DE UN ALGORITMO DE REGRESIÓN
7. OPTIMIZACIÓN DE UN MODELO
8. ALGORITMOS DE BOOSTING

alkemy

Learning Path

¿Cuáles temas trabajaremos hoy?

6.

Validación cruzada para evaluación de modelos

vamos a usar técnicas que nos permiten obtener métricas más confiables para comparar modelos.

- **K-Fold Cross Validation**
  - **¿Por qué usarlo?**
  - **Cómo implementarlo con cross_val_score**
- **Métricas de clasificación multiclase**
  - **Promedios micro, macro y weighted**
  - **Matriz de confusión multiclase**

alkemy

Objetivos de aprendizaje

¿Qué aprenderás?

- Comprender el uso de métricas específicas en contextos diversos (multiclase, no supervisado, series temporales).
- Aplicar validación cruzada para obtener métricas más robustas.
- Identificar métricas útiles para problemas reales: ranking, visión por computadora, generación de texto.
- Evaluar métricas de equidad, interpretabilidad y desempeño en producción.
- Integrar las métricas al ciclo completo del desarrollo de modelos.

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos 📚:

→ *Revisión general de métricas de regresión: MAE, MSE, RMSE y R^2.*

→ *Análisis del informe de clasificación (classification_report).*

→ *Uso de métricas en el flujo de trabajo de machine learning.*

→ *Introducción al sobreajuste y subajuste con métricas.*

Métricas de desempeño de un algoritmo de regresión

Informe de clasificación

Además, Scikit-Learn proporciona la función classification_report, que genera un informe detallado con varias métricas de evaluación, facilitando la interpretación y el análisis del desempeño del modelo.

```
from sklearn.metrics import classification_report# Valores reales y predichosy_true = [1, 0, 1, 0, 1]y_pred = [1, 0, 0, 0, 1]# Generar informe de clasificaciónreport = classification_report(y_true, y_pred)print(report)
```

```
 classification report

precision recall f1-scor

     0,75    0,71     0,73
     0,78    0,85     0,81
     0,72    0,70     0,71

macro avg    0,75     0,75
ghted avg    0,76     0,76

  support    200       200
```

Integración en el flujo de trabajo

Es recomendable integrar estas métricas dentro del flujo de trabajo de construcción del modelo, junto con el preprocesamiento de los datos y la validación cruzada. De esta forma, es posible garantizar que las métricas reflejan la capacidad real del modelo para generalizar a nuevos datos.

Preprocesamiento de datos

Limpieza, transformación y normalización de los datos de entrada.

Entrenamiento del modelo

Ajuste de los parámetros del modelo utilizando los datos de entrenamiento.

Validación cruzada

Evaluación del modelo utilizando diferentes particiones de los datos.

Cálculo de métricas

Evaluación del desempeño del modelo utilizando las métricas adecuadas.

Ajuste y optimización

Refinamiento del modelo basado en los resultados de las métricas.

Detección de problemas con métricas

El uso adecuado de estas métricas permite detectar posibles problemas de sobreajuste o subajuste, comparar diferentes algoritmos y ajustar los parámetros del modelo para mejorar su desempeño.

Sobreajuste (Overfitting)

Se detecta cuando el modelo tiene un excelente desempeño en los datos de entrenamiento pero pobre en los datos de prueba. Las métricas ayudan a identificar esta discrepancia.

Subajuste (Underfitting)

Se identifica cuando el modelo tiene un desempeño deficiente tanto en los datos de entrenamiento como en los de prueba. Las métricas muestran valores bajos en ambos conjuntos.

Comparación de algoritmos

Las métricas permiten comparar objetivamente diferentes algoritmos o configuraciones para seleccionar el más adecuado para el problema.

Ejemplo práctico completo

A continuación, se presenta un ejemplo completo de cálculo de métricas de desempeño para un modelo de clasificación y otro de regresión

```
import numpy as npfrom sklearn.datasets import make_classification, make_regressionfrom sklearn.model_selection import
train_test_splitfrom sklearn.linear_model import LogisticRegression, LinearRegressionfrom sklearn.metrics import ( confusion_matrix,
accuracy_score, precision_score, recall_score, roc_auc_score, mean_absolute_error, mean_squared_error, r2_score)# Ejemplo de
clasificaciónX, y = make_classification(n_samples=1000, random_state=42)X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.3, random_state=42)clf = LogisticRegression()clf.fit(X_train, y_train)y_pred = clf.predict(X_test)y_prob =
clf.predict_proba(X_test)[:, 1]# Métricas de clasificaciónconf_matrix = confusion_matrix(y_test, y_pred)accuracy =
accuracy_score(y_test, y_pred)precision = precision_score(y_test, y_pred)recall = recall_score(y_test, y_pred)auc =
roc_auc_score(y_test, y_prob)print("Matriz de Confusión:\n", conf_matrix)print(f"Exactitud: {accuracy:.4f}")print(f"Precisión:
{precision:.4f}")print(f"Sensibilidad: {recall:.4f}")print(f"AUC: {auc:.4f}")# Ejemplo de regresiónX, y =
make_regression(n_samples=1000, random_state=42)X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
random_state=42)reg = LinearRegression()reg.fit(X_train, y_train)y_pred = reg.predict(X_test)# Métricas de regresiónmae =
mean_absolute_error(y_test, y_pred)mse = mean_squared_error(y_test, y_pred)rmse = np.sqrt(mse)r2 = r2_score(y_test,
y_pred)print(f"\nMAE: {mae:.4f}")print(f"MSE: {mse:.4f}")print(f"RMSE: {rmse:.4f}")print(f"R²: {r2:.4f}")
```

alkemy

Flujo completo de evaluación

Este flujo completo permite calcular e interpretar todas las métricas clave para evaluar modelos de regresión y clasificación, facilitando la toma de decisiones basada en datos.

Conclusiones sobre métricas de regresión

Error Absoluto Medio (MAE)

Proporciona una medida directa del error promedio, siendo menos sensible a valores atípicos.

Error Cuadrático Medio (MSE)

Penaliza fuertemente los errores grandes, siendo útil cuando se desea evitar grandes desviaciones.

Raíz del Error Cuadrático Medio (RMSE)

Mantiene la misma unidad que la variable objetivo, facilitando la interpretación de los resultados.

Coeficiente de determinación R^2

Indica qué proporción de la variabilidad de los datos es explicada por el modelo, siendo útil para evaluar su capacidad predictiva.

Conclusiones sobre métricas de clasificación

Matriz de Confusión

Proporciona una visión detallada de los aciertos y errores del modelo en cada clase.

Precisión y Exactitud

Evalúan la proporción de predicciones correctas, siendo útiles para medir la calidad general del modelo.

Sensibilidad y Especificidad

Miden la capacidad del modelo para identificar correctamente las observaciones positivas y negativas, respectivamente.

Curva ROC-AUC

Evalúa el desempeño del modelo para diferentes umbrales de clasificación, proporcionando una medida robusta de su capacidad discriminativa.

Importancia de la selección de métricas

La elección de las métricas adecuadas es crucial para evaluar correctamente el desempeño de un modelo. Diferentes problemas y contextos pueden requerir diferentes métricas para capturar aspectos específicos del rendimiento del modelo.

Por ejemplo, en un problema médico donde es crítico no pasar por alto casos positivos, la sensibilidad puede ser más importante que la precisión. En cambio, en un sistema de filtrado de spam, la precisión puede ser prioritaria para evitar clasificar incorrectamente mensajes legítimos como spam.

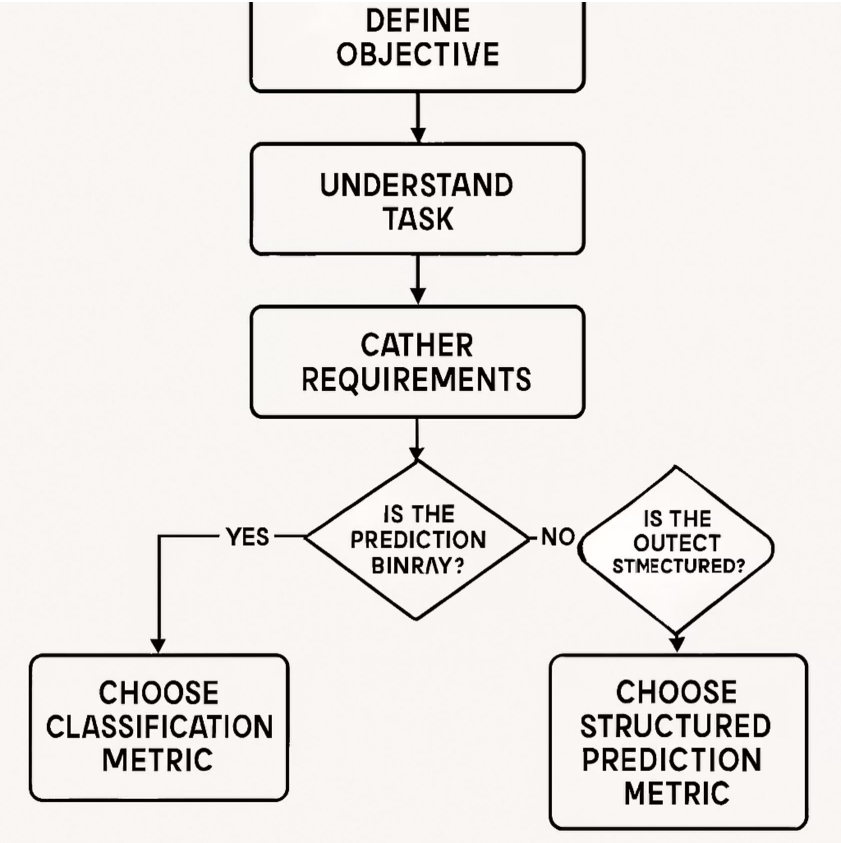

alkemy

Consideraciones para datos desbalanceados

En problemas con clases desbalanceadas, donde una clase es mucho más frecuente que otra, algunas métricas pueden ser engañosas. Por ejemplo, la exactitud puede ser alta simplemente porque el modelo predice siempre la clase mayoritaria.

F1-Score

Media armónica entre precisión y sensibilidad, útil cuando se busca un equilibrio entre ambas métricas en datos desbalanceados.

Curva Precision-Recall

Alternativa a la curva ROC que puede ser más informativa en casos de desbalance severo, ya que se centra en el desempeño de la clase minoritaria.

Métricas específicas por clase

Calcular métricas separadas para cada clase puede proporcionar una visión más clara del desempeño del modelo en clases específicas.

Validación cruzada para métricas robustas

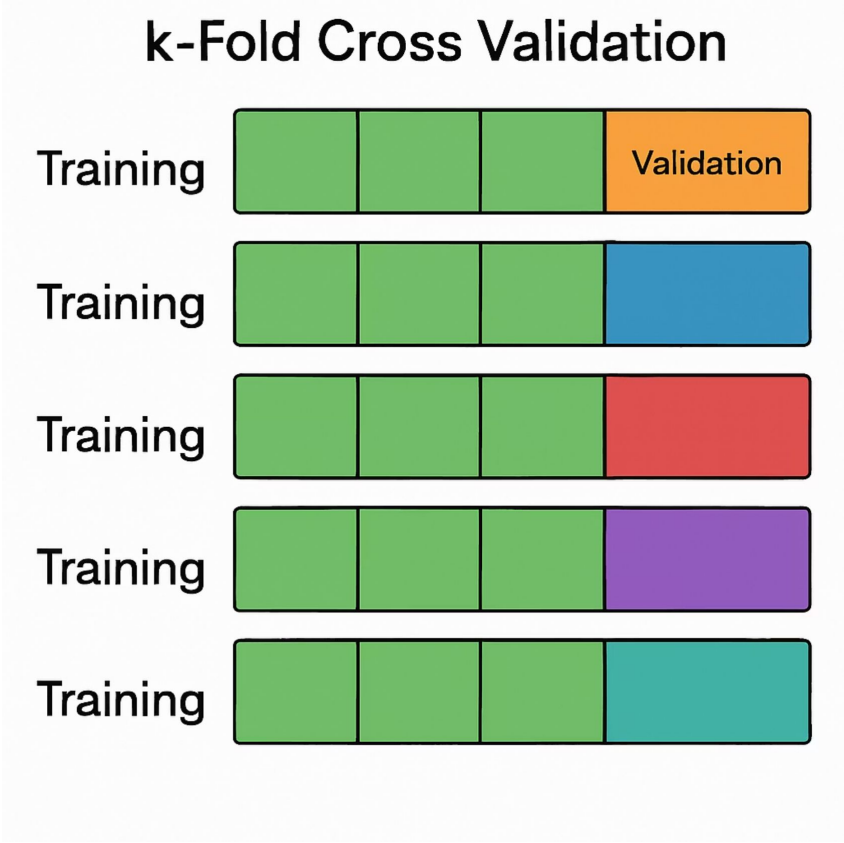

Para obtener estimaciones más robustas de las métricas de desempeño, es recomendable utilizar técnicas de validación cruzada como k-fold cross-validation. Esta técnica divide los datos en k subconjuntos y entrena k modelos diferentes, cada uno utilizando k-1 subconjuntos para entrenamiento y el subconjunto restante para validación.

La validación cruzada proporciona una estimación más confiable del desempeño del modelo en datos no vistos, reduciendo el riesgo de conclusiones sesgadas debido a una partición particular de los datos.

alkemy

Implementación de validación cruzada

```
from sklearn.model_selection import cross_val_scorefrom sklearn.linear_model import LogisticRegressionfrom
sklearn.datasets import make_classification# Generar datos de ejemploX, y = make_classification(n_samples=1000,
random_state=42)# Crear modelomodel = LogisticRegression()# Realizar validación cruzada con 5 foldsscores =
cross_val_score(model, X, y, cv=5, scoring='accuracy')# Mostrar resultadosprint(f"Exactitud por fold:
{scores}")print(f"Exactitud media: {scores.mean():.4f}")print(f"Desviación estándar: {scores.std():.4f}")
```

Este enfoque proporciona una estimación más robusta del desempeño del modelo, considerando múltiples particiones de los datos.

Métricas para problemas multiclase

En problemas de clasificación con más de dos clases, las métricas deben adaptarse para proporcionar información útil sobre el desempeño del modelo en todas las clases.

Matriz de confusión multiclase

Muestra las predicciones correctas e incorrectas para todas las clases, permitiendo identificar patrones de confusión entre clases específicas.

Micro-averaging

Calcula métricas agregando las contribuciones de todas las clases. Útil cuando las clases están desbalanceadas.

Macro-averaging

Calcula métricas independientemente para cada clase y luego toma el promedio. Trata todas las clases por igual, independientemente de su frecuencia.

Weighted-averaging

Similar al macro-averaging, pero ponderando por la frecuencia de cada clase. Proporciona un equilibrio entre micro y macro.

Métricas para aprendizaje no supervisado

Aunque nos hemos centrado en métricas para aprendizaje supervisado, existen también métricas específicas para evaluar modelos de aprendizaje no supervisado, como algoritmos de clustering o reducción de dimensionalidad.

Índice de Silhouette

Mide qué tan similar es un objeto a su propio cluster en comparación con otros clusters. Valores cercanos a 1 indican buena separación.

Índice Davies-Bouldin

Evalúa la separación entre clusters. Valores más bajos indican mejor clustering.

Varianza explicada

En reducción de dimensionalidad, mide qué proporción de la varianza original de los datos se conserva en la representación reducida.

Métricas para series temporales

Los modelos de predicción de series temporales requieren métricas específicas que tengan en cuenta la naturaleza secuencial de los datos.

Error Porcentual Absoluto Medio (MAPE)

Mide el error promedio en términos porcentuales, facilitando la comparación entre series de diferentes escalas.

Error Escalado Absoluto Medio (MASE)

Compara el error del modelo con el error de un modelo naïve (que predice el valor anterior), siendo útil para evaluar la mejora relativa.

Error Cuadrático Medio Escalado (SMSE)

Similar al MSE pero escalado para facilitar la comparación entre diferentes series temporales.

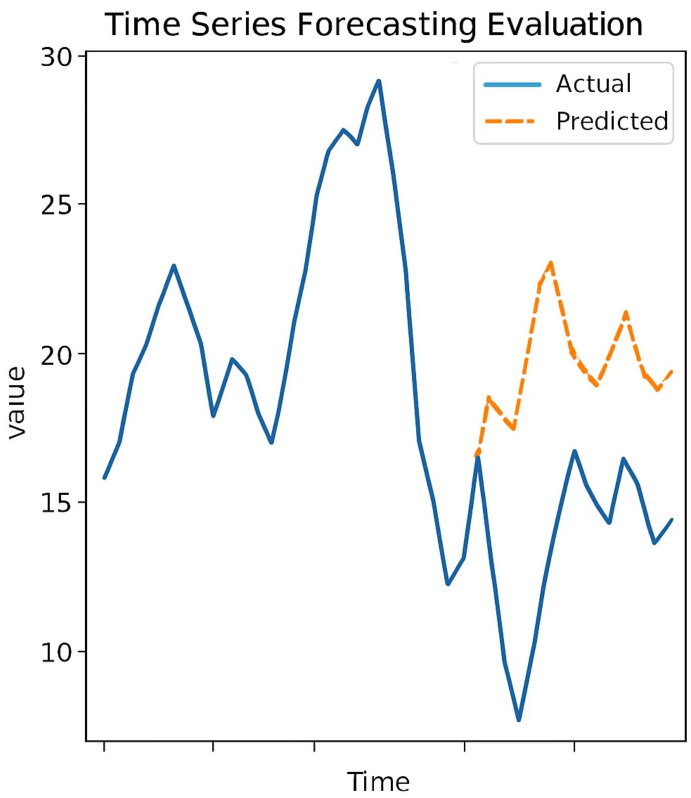

alkemy

Métricas para modelos de ranking

En problemas donde el objetivo es ordenar elementos según su relevancia, como en sistemas de recomendación o motores de búsqueda, se utilizan métricas específicas para evaluar la calidad del ranking.

Precisión en k (P@k)

Mide la proporción de elementos relevantes entre los primeros k elementos del ranking.

Ganancia Acumulada Descontada Normalizada (NDCG)

Evalúa la calidad del ranking considerando tanto la relevancia como la posición de los elementos, penalizando elementos relevantes que aparecen más abajo en la lista.

Mean Average Precision (MAP)

Promedio de la precisión en cada posición donde se encuentra un elemento relevante, proporcionando una medida global de la calidad del ranking.

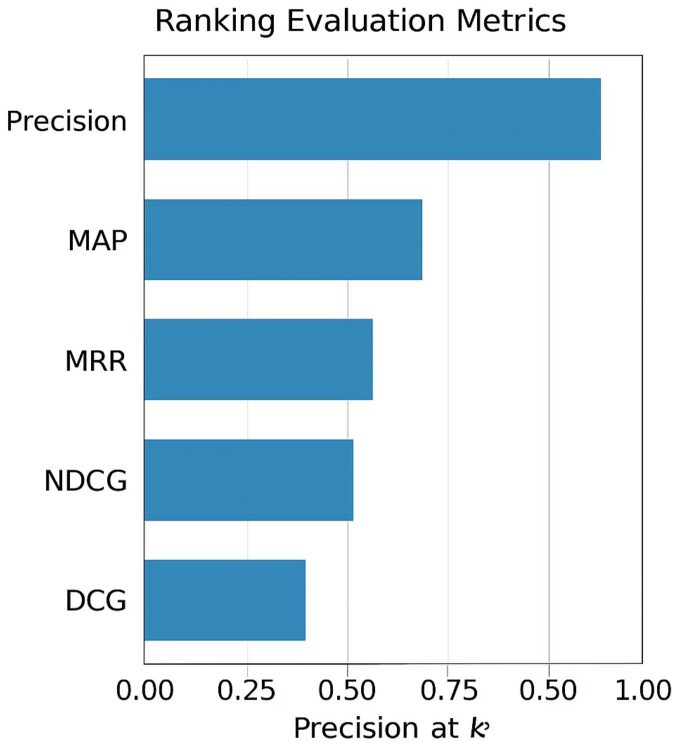

alkemy

Métricas para modelos de generación de texto

Los modelos de generación de texto, como los utilizados en traducción automática o resumen de textos, requieren métricas específicas que evalúen la calidad del texto generado.

BLEU (Bilingual Evaluation Understudy)

Compara el texto generado con una o varias referencias, midiendo la coincidencia de n-gramas. Ampliamente utilizado en traducción automática.

ROUGE (Recall-Oriented Understudy for Gisting Evaluation)

Conjunto de métricas que evalúan la calidad de resúmenes automáticos, midiendo la coincidencia de n-gramas, secuencias y pares con el texto de referencia.

Perplexity

Mide qué tan bien un modelo de lenguaje predice una muestra de texto, siendo útil para evaluar modelos generativos sin necesidad de referencias.

	BLEU	ROUGE	METEOR	BERT-Score
Matching Method	n-gram overlap	n-gram overlap	n-gram o syechym overlap	contextual embeddings
N-gram Precision	Yes	No	No	Yes
Semantic Similarity	No	No	Yes	Yes

alkemy

Métricas para modelos de visión por computadora

En tareas de visión por computadora, como detección de objetos o segmentación de imágenes, se utilizan métricas específicas que evalúan la precisión espacial de las predicciones.

Intersection over Union (IoU)

Mide la superposición entre las regiones predichas y las regiones reales, siendo fundamental en tareas de segmentación y detección.

Mean Average Precision (mAP)

Utilizada en detección de objetos, combina precisión y recall para diferentes umbrales de confianza y clases.

Dice Coefficient

Similar al IoU, mide la similitud entre dos conjuntos, siendo común en segmentación de imágenes médicas.

Equilibrio entre métricas

En muchos casos, no existe una única métrica que capture todos los aspectos relevantes del desempeño de un modelo. Es importante considerar múltiples métricas y encontrar un equilibrio que se alinee con los objetivos del proyecto.

Definir objetivos

Establecer claramente qué aspectos del desempeño son más importantes para el problema específico.

Seleccionar métricas

Elegir un conjunto de métricas que capturen diferentes aspectos del desempeño y se alineen con los objetivos.

Evaluar trade-offs

Analizar las compensaciones entre diferentes métricas y tomar decisiones informadas sobre qué aspectos priorizar.

Validar decisiones

Verificar que las decisiones basadas en las métricas seleccionadas conducen a resultados satisfactorios en el contexto real de aplicación.

Visualización de métricas

La visualización efectiva de las métricas puede facilitar la interpretación y comunicación de los resultados, especialmente para audiencias no técnicas.

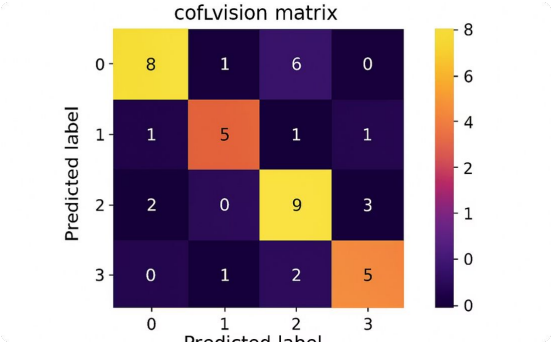

Matrices de confusión como mapas de calor

Facilitan la identificación visual de patrones de error entre clases.

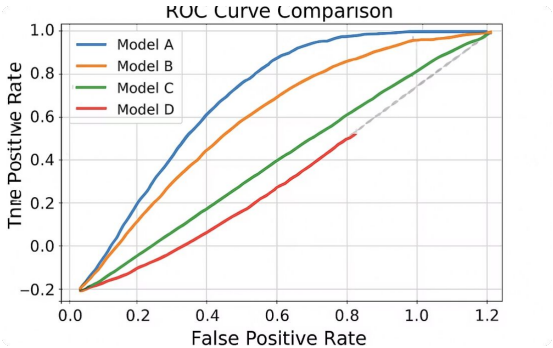

Comparación de curvas ROC

Permite comparar visualmente el desempeño de diferentes modelos en un solo gráfico.

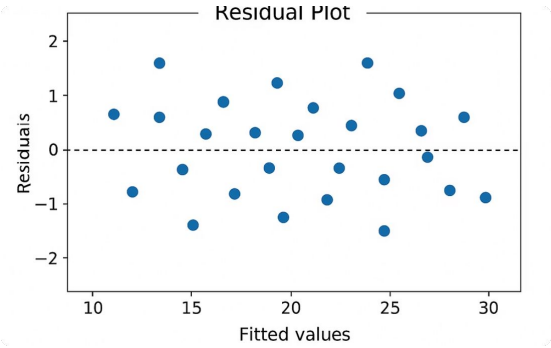

Gráficos de residuos

Ayudan a identificar patrones en los errores de modelos de regresión, revelando posibles mejoras.

alkemy

Automatización del cálculo de métricas

La automatización del cálculo y seguimiento de métricas puede facilitar el proceso de desarrollo y mejora continua de modelos.

Pipelines de evaluación

Crear flujos automatizados que calculen y registren métricas para cada versión del modelo.

Dashboards de monitoreo

Implementar paneles que muestren la evolución de las métricas a lo largo del tiempo y alerten sobre degradaciones.

Informes automáticos

Generar informes periódicos que resuman el desempeño del modelo según múltiples métricas.

Integración con CI/CD

Incorporar la evaluación de métricas en los procesos de integración y despliegue continuos.

Métricas de negocio vs. métricas técnicas

Es importante distinguir entre métricas técnicas, que evalúan el desempeño del modelo desde una perspectiva estadística, y métricas de negocio, que miden el impacto real del modelo en los objetivos de la organización.

Por ejemplo, un modelo de detección de fraude puede tener una alta precisión técnica, pero su valor real se mide en términos de reducción de pérdidas financieras o mejora en la experiencia del cliente.

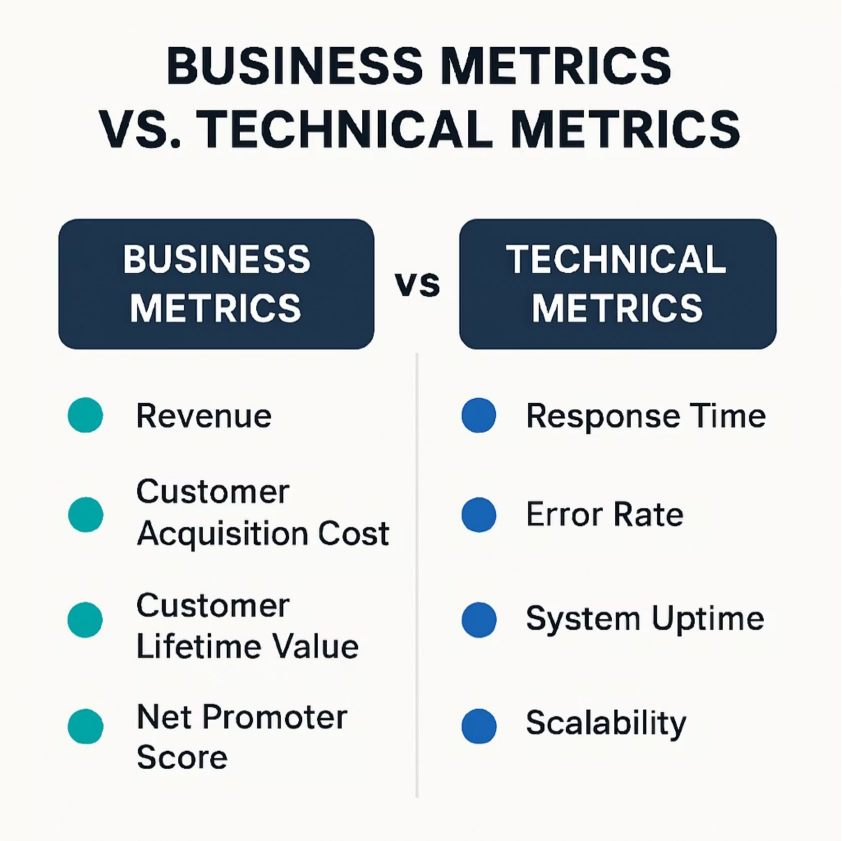

alkemy

Alineación de métricas con objetivos de negocio

Traducción de métricas técnicas

Convertir métricas como precisión o recall en términos comprensibles para stakeholders no técnicos, como "tasa de detección de fraude" o "reducción de falsos positivos".

Métricas de impacto

Desarrollar métricas que midan directamente el impacto del modelo en los objetivos de negocio, como incremento en ventas, reducción de costos o mejora en satisfacción del cliente.

Análisis de costo-beneficio

Evaluar el valor económico de mejoras en las métricas técnicas, considerando los costos asociados con diferentes tipos de errores.

Evolución de métricas en el tiempo

El desempeño de un modelo puede cambiar con el tiempo debido a cambios en los datos o en el entorno. Es importante monitorear las métricas continuamente para detectar degradaciones y tomar medidas correctivas.

1 Despliegue inicial

Establecer líneas base de desempeño utilizando métricas clave como referencia para comparaciones futuras.

2 Monitoreo continuo

Seguir la evolución de las métricas a lo largo del tiempo, identificando tendencias y patrones.

3 Detección de degradación

Implementar alertas que notifiquen cuando las métricas caigan por debajo de umbrales predefinidos.

4 Reentrenamiento

Actualizar el modelo con nuevos datos cuando se detecte una degradación significativa en las métricas.

alkemy

Métricas para modelos en producción

Una vez que un modelo está en producción, es importante monitorear no solo su desempeño predictivo, sino también aspectos operativos que afectan su utilidad práctica.

Latencia

Tiempo que tarda el modelo en generar predicciones, crucial para aplicaciones en tiempo real.

Throughput

Número de predicciones que el modelo puede generar por unidad de tiempo, importante para aplicaciones de alto volumen.

Disponibilidad

Porcentaje de tiempo que el modelo está operativo y generando predicciones correctamente.

Drift de datos

Cambios en la distribución de los datos de entrada que pueden afectar el desempeño del modelo con el tiempo.

Detección de drift en modelos

El drift o desviación en los datos es un fenómeno común que puede degradar el desempeño de un modelo con el tiempo. Existen métricas específicas para detectar diferentes tipos de drift.

Drift de datos

Cambios en la distribución de las variables de entrada, detectables mediante pruebas estadísticas como Kolmogorov-Smirnov o divergencia de Kullback-Leibler.

Drift de concepto

Cambios en la relación entre las variables de entrada y la variable objetivo, detectables mediante el seguimiento de métricas de desempeño en el tiempo.

Drift de predicción

Cambios en la distribución de las predicciones del modelo, que pueden indicar problemas incluso cuando no se dispone de etiquetas reales.

Métricas para modelos éticos y responsables

A medida que los modelos de aprendizaje automático se utilizan en decisiones cada vez más importantes, es crucial evaluar no solo su desempeño técnico, sino también su impacto ético y social.

Equidad (Fairness)

Métricas que evalúan si el modelo trata de manera justa a diferentes grupos demográficos, como paridad demográfica o igualdad de oportunidades.

Transparencia

Medidas de la interpretabilidad y explicabilidad del modelo, como la importancia de características o la fidelidad de las explicaciones.

Robustez

Evaluación de la resistencia del modelo a ataques adversarios o a pequeñas perturbaciones en los datos de entrada.

Privacidad

Métricas que evalúan el riesgo de filtración de información sensible a través de las predicciones del modelo.

Métricas de equidad (Fairness)

Las métricas de equidad evalúan si un modelo trata de manera justa a diferentes grupos demográficos, evitando discriminación algorítmica.

Paridad demográfica

Evalúa si la tasa de predicciones positivas es similar entre diferentes grupos demográficos, independientemente de la tasa real.

Igualdad de oportunidades

Mide si la tasa de verdaderos positivos es similar entre diferentes grupos, asegurando que individuos calificados tengan las mismas oportunidades.

Paridad predictiva

Evalúa si la precisión de las predicciones positivas es similar entre diferentes grupos, asegurando que las predicciones tengan el mismo significado.

Métricas de interpretabilidad

La interpretabilidad de un modelo es crucial para generar confianza y facilitar la detección y corrección de errores. Existen métricas específicas para evaluar diferentes aspectos de la interpretabilidad.

Fidelidad

Mide qué tan bien una explicación simplificada aproxima el comportamiento real del modelo complejo.

Estabilidad

Evalúa si explicaciones similares se generan para instancias similares, indicando consistencia en las interpretaciones.

Complejidad

Mide la simplicidad de las explicaciones generadas, considerando factores como el número de características utilizadas o la profundidad de un árbol de decisión.

Comprensibilidad humana

Evalúa qué tan fácilmente los usuarios humanos pueden entender y aplicar las explicaciones generadas.

Resumen de métricas clave

Regresión

MAE, MSE, RMSE, R^2

Clasificación

Precisión, Exactitud, Sensibilidad, Especificidad, ROC-AUC

Producción

Latencia, Throughput, Disponibilidad, Drift

Clustering

Silhouette, Davies-Bouldin, Calinski-Harabasz

Equidad

Paridad demográfica, Igualdad de oportunidades

Series temporales

MAPE, MASE, SMSE

alkemy

Conclusiones

Las métricas de desempeño son un elemento esencial en todo proyecto de aprendizaje automático. A lo largo de este manual, hemos revisado las principales métricas utilizadas tanto en problemas de regresión como en clasificación, entendiendo su definición, interpretación y aplicación práctica.

En los modelos de regresión, métricas como el **MAE**, **MSE**, **RMSE** y **R^2** permiten cuantificar el error cometido por el modelo y evaluar su capacidad para aproximarse a los valores reales. Estas métricas ayudan a identificar problemas de ajuste y a tomar decisiones informadas sobre la selección y ajuste del modelo.

En los modelos de clasificación, herramientas como la **matriz de confusión**, la **precisión**, la **exactitud**, la **sensibilidad**, la **especificidad** y la **curva ROC-AUC** ofrecen una visión detallada del desempeño del modelo, permitiendo detectar desequilibrios y ajustar el umbral de decisión para mejorar la clasificación.

La implementación práctica de estas métricas utilizando la librería **Scikit-Learn** simplifica el proceso de evaluación y facilita la integración de estas métricas en el flujo de trabajo de Machine Learning. El dominio de estas herramientas es clave para garantizar el éxito de los proyectos y obtener modelos confiables y efectivos.

Live Coding

¿En qué consistirá la Demo?

Vamos a construir un flujo de evaluación de modelo para clasificación, usando un dataset multiclase. Implementaremos validación cruzada, calcularemos múltiples métricas y analizaremos sus diferencias.

1. *Importar un dataset multiclase (load_wine de sklearn.datasets).*
2. *Entrenar un modelo con RandomForestClassifier.*
3. *Evaluar el modelo con cross_val_score usando accuracy y f1_macro.*
4. *Mostrar matriz de confusión total con confusion_matrix.*
5. *Usar classification_report para ver métricas completas.*
6. *Visualizar curvas ROC para cada clase (One-vs-Rest).*
7. *Explicar cuándo cada métrica resulta más útil.*
8. *Simular un pipeline productivo y evaluar su estabilidad con múltiples métricas.*

Tiempo: 25 Minutos

Momento:

Time-out!

⏰5 -10 min.

alkemy

Ejercicio

Evaluación multi aspecto de un modelo de clasificación

Evaluación multi aspecto de un modelo de clasificación

Contexto: 🙌

Una startup desarrolla un sistema de recomendación de productos. El equipo de ciencia de datos ha entrenado un modelo de clasificación binaria y ahora necesita evaluar su rendimiento para determinar si es apto para producción. La empresa requiere métricas que puedan traducirse en impacto de negocio, ya que cada error tiene un costo.

Consigna: ✍️

1. Cargue un dataset binario (puede ser generado con make_classification).
2. Entrene un modelo de clasificación (LogisticRegression, por ejemplo).
3. Calculá las siguientes métricas: accuracy, precision, recall, f1-score, roc_auc_score, y visualizá la curva ROC.
4. Use classification_report para generar el informe completo.
5. Implementá validación cruzada (5 folds) y reporte la media y desviación estándar de accuracy.
6. Finalmente, redacte una breve conclusión sobre qué métricas son más relevantes para este caso.

Tiempo 🕐**:** *45 Minutos*

alkemy

Evaluación multi aspecto de un modelo de clasificación

Paso a paso: ⚙️

1. Generar datos y dividir entre entrenamiento y test.
2. Entrenar el modelo.
3. Calcular métricas individuales.
4. Visualizar curva ROC.
5. Implementar validación cruzada.
6. Analizar resultados.

¿Alguna consulta?

alkemy

Resumen

¿Qué logramos en esta clase?

- ✓ ***Aplicamos validación cruzada para métricas robustas***
- ✓ ***Exploramos métricas para problemas complejos y reales***
- ✓ ***Entendimos métricas éticas y su integración al negocio***
- ✓ ***Implementamos un flujo completo de evaluación y automatización***

¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las ***actividades disponibles en la plataforma.*** *Estas propuestas son clave para afianzar lo trabajado y* ***forman parte obligatoria del recorrido de aprendizaje.***

💪 Análisis de caso ——— 💪 Selección Múltiple

💪 Comprensión lectora

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

alkemy

< ¡Muchas gracias! >

alkemy