Evaluación del módulo #6

Consigna del proyecto👨🏻‍💻

alkemy

Proyecto: Predicción inteligente de gasto en clientes e-commerce

Evaluación del módulo 6: APRENDIZAJE DE MÁQUINA SUPERVISADO

Situación inicial 📍

Unidad solicitante: Departamento de Analítica Comercial de una empresa de e-commerce.
La empresa busca optimizar su estrategia de marketing personalizando ofertas según el perfil de cada usuario. Para lograr esto, necesita construir un modelo de aprendizaje de máquina capaz de predecir el monto promedio de compra de un cliente en función de características como edad, comportamiento en el sitio y otras variables demográficas.

Los analistas internos tienen datos históricos pero no cuentan con un modelo predictivo robusto. Se requiere un equipo que pueda diseñar una solución integral aplicando técnicas de aprendizaje supervisado, evaluando el ajuste, rendimiento y mejorando progresivamente su desempeño.

Nuestro objetivo 📋

Diseñar e implementar un modelo predictivo de regresión que permita estimar el monto de compra esperado por un cliente. El objetivo es utilizar los datos históricos disponibles, aplicar preprocesamiento y técnicas de validación cruzada, seleccionar y entrenar algoritmos adecuados, evaluarlos con métricas específicas y optimizar su rendimiento hasta llegar a un modelo final funcional y confiable.

Requerimientos 🤝

- Cargar, limpiar y preparar los datos correctamente.
- Aplicar codificación y escalamiento según corresponda.
- Dividir los datos en conjuntos de entrenamiento y validación.
- Evaluar el modelo con métricas apropiadas (MAE, RMSE, R^2).
- Implementar y comparar distintos algoritmos (regresión lineal, KNN, boosting).
- Optimizar el modelo con ajuste de hiperparámetros.
- Justificar el modelo final elegido según desempeño y robustez.

Paso a paso 👣

Este proyecto refiere exclusivamente al **módulo 6**: *Aprendizaje de Máquina Supervisado*, y se compone de **8 etapas (lecciones)**, las cuales podrás avanzar de forma progresiva y escalonada con la ayuda de los manuales teóricos y los contenidos desarrollados en las clases en vivo.

Ten en cuenta de invertir **tiempo asincrónicos** para el desarrollo de cada etapa a modo de poder finalizar el módulo y realizar la entrega formal de tu propuesta. Cualquier consulta que surja compártela en los espacios sincrónicos para resolver las dudas en equipo.

A continuación encontrarás las consignas y tareas a desarrollar:

- **Lección 1**: *Fundamentos del Aprendizaje de Máquina*
    - 📌 **Objetivo:** Comprender los fundamentos del aprendizaje supervisado.
    - 📍 **Tareas a desarrollar:**
        - **Diferenciar problemas de clasificación y regresión.**
        - **Identificar las etapas del pipeline de un proyecto ML.**
        - **Definir el problema como regresión supervisada.**
- **Lección 2**: *Nivel de ajuste del modelo y validación cruzada*
    - 📌 **Objetivo:** Evaluar si el modelo está bien ajustado usando validación cruzada.
    - 📍 **Tareas a desarrollar:**
        - **Calcular y analizar los errores de entrenamiento y prueba.**
        - **Identificar sobreajuste y subajuste.**
        - **Implementar validación cruzada con K-Folds.**
- **Lección 3**: *Preprocesamiento y escalamiento de datos*
    - 📌 **Objetivo:** Preparar correctamente los datos para el entrenamiento del modelo.
    - 📍 **Tareas a desarrollar:**
        - **Tratar valores nulos y outliers.**

        - **Aplicar codificación a variables categóricas.**
        - **Normalizar y/o estandarizar los datos.**

- **Lección 4**: *Regresiones*
    - 📌 **Objetivo:** Implementar un modelo de regresión y comprender su funcionamiento.
    - 📍 **Tareas a desarrollar:**
        - **Entrenar un modelo de regresión lineal y uno polinomial.**
        - **Comparar su ajuste y precisión.**
        - **Interpretar los coeficientes del modelo.**
- **Lección 5**: *Algoritmos de clasificación*
    - 📌 **Objetivo:** Entender diferencias conceptuales con clasificación.
    - 📍 **Tareas a desarrollar:**
        - **Analizar por qué un problema de clasificación no es adecuado para esta tarea.**
        - **Implementar un clasificador KNN sobre un subconjunto simulado.**
        - **Comparar su comportamiento frente al modelo regresivo.**
- **Lección 6**: *Métricas de desempeño*
    - 📌 **Objetivo:** Evaluar objetivamente el rendimiento del modelo regresivo.
    - 📍 **Tareas a desarrollar:**
        - **Calcular MAE, MSE, RMSE y R^2.**
        - **Interpretar resultados y comparar modelos entrenados.**
        - **Elaborar una tabla comparativa de métricas.**
- **Lección 7**: *Optimización del modelo*
    - 📌 **Objetivo:** Mejorar el desempeño general del modelo mediante técnicas de ajuste.
    - 📍 **Tareas a desarrollar:**

        - **Realizar ingeniería de características.**
        - **Ajustar hiperparámetros usando GridSearchCV.**
        - **Aplicar regularización (Ridge, Lasso) y observar su impacto.**
- **Lección 8**: *Algoritmos de Boosting*
    - 📌 **Objetivo:** Implementar un modelo avanzado usando Gradient Boosting.
    - 📍 **Tareas a desarrollar:**
        - **Entrenar un modelo con GradientBoostingRegressor.**
        - **Comparar desempeño frente al modelo lineal optimizado.**
        - **Explicar ventajas y limitaciones del enfoque ensemble.**

¿Qué vamos a validar? 🔍

- Correcta implementación del pipeline de ML supervisado.
- Adecuación del modelo al tipo de problema (regresión).
- Razonamiento detrás de las decisiones técnicas (algoritmo, métricas, optimización).
- Calidad del código y presentación visual de resultados.
- Capacidad para comunicar el valor del modelo a audiencias no técnicas.

Referencias 🦺

- https://scikit-learn.org/stable/
- https://www.kaggle.com/code
- Manuales oficiales del curso M6.

Recursos 🎁

- Repositorios de GitHub con ejemplos similares.
- Tutoriales en YouTube sobre GridSearchCV y Boosting.

Entregables ✅

- Notebook en Visual Studio Code con el código comentado.
- Repositorio de GitHub
- Visualizaciones de métricas y resultados.
- Reporte técnico en PDF.

Portafolio 💼

Este proyecto puede incluirse como caso de éxito en tu portfolio, mostrando tus habilidades para desarrollar modelos supervisados de punta a punta. Se recomienda destacar:

- Objetivo del negocio
- Estrategia de modelado
- Evaluación de desempeño
- Comparación de algoritmos
- Código limpio y reproducible
- Repositorio del código

¡Éxitos!

Nos vemos más adelante

alkemy