Reducción dimensional

M7: Aprendizaje de máquina no supervisado

|**AE3**: Describir las principales características de las técnicas de reducción de dimensionalidad, sus principales algoritmos y problemas que resuelve.

alkemy

Introducción👩‍💻

La reducción de dimensionalidad es una técnica fundamental en el aprendizaje automático que permite simplificar conjuntos de datos complejos sin perder información relevante. Este enfoque es especialmente útil en contextos donde la alta dimensionalidad puede dificultar el análisis, afectar el rendimiento de los modelos o generar problemas como el sobreajuste.

Al reducir el número de variables o características, se mejora la eficiencia computacional, se facilita la visualización de los datos y se incrementa la interpretabilidad de los modelos. Esta técnica se ha convertido en una herramienta clave para científicos de datos que trabajan con grandes volúmenes de información.

En este manual, profundizaremos en los fundamentos de la reducción de dimensionalidad, sus algoritmos más relevantes como PCA y t-SNE, y las aplicaciones en las que este enfoque resulta esencial para resolver problemas reales de clasificación, agrupamiento y visualización.

Aprendizaje esperado

Cuando finalices la lección serás capaz de:

- Explicar la importancia de reducir dimensiones en conjuntos de datos.
- Comparar y aplicar PCA y t-SNE en escenarios específicos.
- Evaluar cuándo utilizar reducción de dimensionalidad para mejorar modelos predictivos.
- Interpretar visualizaciones y resultados obtenidos tras la reducción de características.

¿Qué es la reducción de dimensionalidad?

La reducción de dimensionalidad consiste en transformar un conjunto de datos con muchas variables (o características) en una representación de menor dimensión sin perder información significativa. Esta técnica es útil para combatir la "maldición de la dimensionalidad", un fenómeno en el que los datos se vuelven dispersos e ineficaces para muchos algoritmos de aprendizaje automático.

Existen dos enfoques principales: selección de características (elegir las más relevantes) y extracción de características (crear nuevas variables a partir de combinaciones de las existentes). En este manual nos centraremos en la segunda, que incluye métodos como PCA y t-SNE.

Reducir dimensiones mejora la capacidad de generalización de los modelos, permite representaciones gráficas en dos o tres dimensiones, y ayuda a identificar patrones ocultos. Sin embargo, también puede llevar a la pérdida de interpretabilidad o información importante si no se realiza correctamente.

Aplicar reducción de dimensionalidad requiere estandarizar los datos, elegir un algoritmo apropiado y validar que la nueva representación conserve la estructura del problema.

Esta técnica se utiliza en diversos dominios: genética, análisis de imágenes, minería de texto y más. Su versatilidad la convierte en una herramienta imprescindible para los analistas de datos.

Principales algoritmos de reducción de dimensionalidad

PCA (Análisis de Componentes Principales)

PCA es uno de los métodos más conocidos y utilizados. Transforma las variables originales en un nuevo conjunto de variables llamadas componentes principales, que son combinaciones lineales de las originales. Estos componentes están ordenados según la varianza que explican.

PCA permite conservar la mayor parte de la información del conjunto de datos en las primeras pocas componentes, lo cual lo hace ideal para análisis exploratorio, visualización y preprocesamiento antes de aplicar modelos supervisados o no supervisados.

Entre sus ventajas destacan la simplicidad, rapidez y utilidad en la detección de correlaciones. Sin embargo, su limitación radica en que solo capta relaciones lineales y su interpretación puede ser difícil si se usan muchos componentes.

PCA es útil cuando los datos presentan redundancia o correlaciones altas, permitiendo eliminar esas redundancias sin perder la esencia del fenómeno estudiado.

t-SNE (t-distributed Stochastic Neighbor Embedding)

t-SNE es una técnica no lineal especializada en la visualización de datos de alta dimensión en espacios bidimensionales o tridimensionales. A diferencia de PCA, preserva mejor la estructura local del conjunto de datos, agrupando observaciones similares.

Este algoritmo es muy utilizado en tareas exploratorias, especialmente cuando se trabaja con datos de texto, imágenes o secuencias genéticas. Es particularmente eficaz para identificar grupos o patrones que no serían evidentes con métodos lineales.

Sin embargo, t-SNE es computacionalmente costoso y sus resultados pueden variar según los hiperparámetros utilizados (como la perplejidad). Además, no es útil como técnica de preprocesamiento para modelos, ya que la transformación no es fácilmente invertible.

A pesar de sus limitaciones, t-SNE sigue siendo una herramienta poderosa para revelar estructuras ocultas y descubrir agrupaciones en datos complejos.

Comparación de PCA y t-SNE

Característica	PCA	t-SNE
Tipo de técnica	Lineal	No lineal
Velocidad	Alta	Media a baja

Preservación de estructura	Global	Local
Interpretabilidad	Alta	Baja
Uso común	Reducción previa, análisis	Visualización de datos complejos
Reproducibilidad	Alta	Baja (dependiente de parámetros)

Aplicaciones y casos resueltos con reducción de dimensionalidad

- Análisis de datos genéticos: reducir miles de genes a componentes significativos.
- Procesamiento de imágenes: disminuir la resolución sin perder información crítica.
- Minería de texto: representar documentos como vectores de menor dimensión.
- Visualización de clústeres: representar resultados de clusterización en 2D.
- Preprocesamiento para modelos: evitar el sobreajuste al eliminar ruido o redundancia.

Cierre ✍️

La reducción de dimensionalidad no solo es una técnica de eficiencia, sino una puerta hacia una mejor comprensión de los datos. Al aplicar estos métodos, logramos transformar complejidad en claridad, facilitando análisis y modelos más efectivos.

Con herramientas como PCA o t-SNE, es posible visualizar agrupaciones, identificar correlaciones y descubrir estructuras en conjuntos de datos aparentemente caóticos. Elegir el método adecuado es clave, según el objetivo y la naturaleza de los datos.

Dominar la reducción de dimensionalidad te permitirá abordar problemas reales con mayor confianza y habilidad, mejorando tus procesos analíticos y potenciando tus resultados predictivos.

¡Nos vemos de nuevo, más adelante! 👋

Referencias📚

- Scikit-learn. (s.f.). *Dimensionality reduction*. Recuperado el 28 de julio de 2025, de https://scikit-learn.org/stable/modules/unsupervised_reduction.html
- IBM. (2020). *Dimensionality reduction explained*. Recuperado el 28 de julio de 2025, de https://www.ibm.com/cloud/learn/dimensionality-reduction
- DataCamp. (s.f.). *Unsupervised learning in Python*. Recuperado el 28 de julio de 2025, de https://www.datacamp.com/courses/unsupervised-learning-in-python

¡Muchas gracias!

Nos vemos en la próxima lección

alkemy