Técnicas de reducción dimensional

M7: Aprendizaje de máquina no supervisado

|**AE5**: Implementar un modelo predictivo utilizando técnicas de reducción dimensional utilizando python para resolver un problema.

alkemy

Introducción 🧑‍💻

En el mundo del aprendizaje automático, los conjuntos de datos suelen tener una gran cantidad de variables o características, lo cual puede dificultar el análisis, aumentar los tiempos de procesamiento y llevar a problemas como el sobreajuste. Para abordar estos inconvenientes, se emplean técnicas de reducción de dimensionalidad que permiten simplificar los datos sin perder información relevante.

La reducción de dimensionalidad es especialmente útil en tareas de visualización, compresión de datos y mejora de la eficiencia de los algoritmos. En este manual abordaremos dos de las técnicas más utilizadas: PCA (Análisis de Componentes Principales) y t-SNE (t-distributed Stochastic Neighbor Embedding).

Aprenderás cuándo conviene aplicar cada método, sus ventajas, limitaciones y cómo implementarlos en Python usando bibliotecas como `scikit-learn`. Con ejemplos prácticos y visuales, vas a poder identificar la técnica adecuada según tus datos y objetivos analíticos.

Aprendizaje esperado

Cuando finalices la lección serás capaz de:

- Aplicar correctamente PCA y t-SNE en datasets reales.
- Comparar técnicas de reducción de dimensionalidad mediante visualizaciones.
- Evaluar el impacto de reducir dimensiones en la eficiencia y rendimiento del modelo.
- Determinar la cantidad óptima de componentes o dimensiones necesarias para tu problema.

¿Qué es la reducción de dimensionalidad?

La reducción de dimensionalidad es una técnica utilizada en ciencia de datos para disminuir el número de variables en un conjunto de datos, manteniendo al mismo tiempo la mayor cantidad de información relevante posible. Se emplea principalmente cuando los datos tienen muchas características, lo que puede dificultar el análisis e impactar negativamente en la eficiencia de los modelos.

Esta técnica ofrece múltiples beneficios. En primer lugar, facilita la visualización de los datos, ya que reduce las variables a dos o tres dimensiones comprensibles por humanos. En segundo lugar, mejora el rendimiento de los algoritmos de machine learning al disminuir la complejidad computacional. Finalmente, puede ayudar a combatir el sobreajuste eliminando ruido y redundancia.

Existen dos enfoques principales para la reducción de dimensionalidad: la selección de características y la extracción de características. La selección implica conservar únicamente las variables más relevantes. La extracción, en cambio, genera nuevas variables combinando las existentes. PCA y t-SNE pertenecen a este segundo grupo.

No todas las técnicas de reducción dimensional funcionan igual. Algunas son lineales (como PCA), mientras que otras son no lineales (como t-SNE). La elección adecuada dependerá de la estructura de los datos y del objetivo del análisis.

Es fundamental aplicar reducción de dimensionalidad de forma cuidadosa, evaluando el impacto de cada técnica en la estructura de los datos y su interpretabilidad posterior.

Análisis de Componentes Principales (PCA)

PCA (Principal Component Analysis) es una técnica estadística que transforma un conjunto de variables correlacionadas en un nuevo conjunto de variables no correlacionadas llamadas componentes principales. Estas nuevas variables representan direcciones de máxima varianza en los datos, permitiendo así conservar la mayor parte de la información en menos dimensiones.

Esta técnica es lineal y se basa en operaciones como la media, la matriz de covarianza y la descomposición en valores propios. Los primeros componentes principales explican la mayor cantidad de varianza, por lo que suelen bastar unos pocos para representar adecuadamente los datos.

Entre sus ventajas destaca su eficiencia computacional, simplicidad de implementación y capacidad para eliminar redundancia entre variables. Sin embargo, tiene limitaciones como su incapacidad para captar relaciones no lineales y la dificultad para interpretar los componentes en términos originales.

Ejemplo en Python:

```
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt

# Aplicar PCA con 2 componentes
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X)

# Visualización del resultado
plt.scatter(X_pca[:, 0], X_pca[:, 1])
plt.title("PCA: Reducción a 2 dimensiones")
plt.xlabel("PC1")
plt.ylabel("PC2")
plt.show()
```

Ventajas vs Desventajas:

Ventajas	Desventajas
Rápido y fácil de implementar	Solo captura relaciones lineales
Reduce redundancia	Difícil interpretación de los componentes
Mejora la eficiencia	Puede perder información importante

PCA se recomienda en fases tempranas de exploración, compresión de datos o como paso previo a otros modelos.

t-Distributed Stochastic Neighbor Embedding (t-SNE)

t-SNE es una técnica no lineal desarrollada para la visualización de datos de alta dimensión. A diferencia de PCA, que busca conservar la varianza, t-SNE se enfoca en preservar las relaciones de proximidad locales entre puntos. Utiliza una métrica probabilística para mapear datos en espacios de menor dimensión, generalmente 2D o 3D.

La principal fortaleza de t-SNE radica en su capacidad para revelar agrupaciones ocultas y estructuras complejas que otros métodos no detectan. Es ampliamente utilizado en bioinformática, análisis de texto y visión por computadora.

Ejemplo en Python:

```
from sklearn.manifold import TSNE
import matplotlib.pyplot as plt

# Aplicar t-SNE con 2 componentes
tsne = TSNE(n_components=2, perplexity=30, random_state=42)
X_tsne = tsne.fit_transform(X)

# Visualización del resultado
plt.scatter(X_tsne[:, 0], X_tsne[:, 1])
plt.title("t-SNE: Proyección bidimensional")
plt.xlabel("Dim 1")
plt.ylabel("Dim 2")
plt.show()
```

Ventajas vs Desventajas:

Ventajas	Desventajas
Excelente para visualizar agrupamientos	No reutilizable en nuevos datos

Captura relaciones no lineales	Requiere ajustes finos de hiperparámetros
Funciona bien en datos ruidosos	Tiempo de ejecución elevado

Debido a su enfoque visual, t-SNE no es adecuado para usar como entrada a modelos predictivos, pero sí para entender mejor la distribución y relaciones en los datos.

Cierre ✍️

Las técnicas de reducción dimensional, como PCA y t-SNE, son herramientas poderosas para simplificar datos complejos y mejorar la eficiencia de los procesos analíticos. Aplicarlas correctamente permite obtener representaciones más compactas, sin sacrificar el valor informativo esencial.

Mientras PCA resulta ideal para compresión y modelado supervisado, t-SNE ofrece ventajas inigualables en la visualización de agrupaciones y relaciones no evidentes. Conocer cuándo usar cada una es clave para lograr interpretaciones valiosas.

A lo largo de este manual, exploramos sus fundamentos teóricos, sus diferencias clave y cómo implementarlas en Python, incluyendo visualizaciones útiles que enriquecen el análisis.

Dominar estas técnicas brinda una ventaja significativa en proyectos de ciencia de datos y aprendizaje automático, especialmente cuando se trabaja con datasets amplios y de alta dimensión.

Se recomienda combinar estas herramientas con un análisis exploratorio previo y una validación cruzada posterior para asegurar que la transformación no distorsione la información crítica.

¡Nos vemos de nuevo, más adelante! 👋

Referencias📚

- Scikit-learn. (s.f.). *Principal component analysis (PCA)*. Recuperado el 28 de julio de 2025, de https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html
- Scikit-learn. (s.f.). *t-SNE*. Recuperado el 28 de julio de 2025, de https://scikit-learn.org/stable/modules/generated/sklearn.manifold.TSNE.html
- Analytics Vidhya. (2021). *Understanding PCA*. Recuperado el 28 de julio de 2025, de https://www.analyticsvidhya.com/blog/2016/03/pca-practical-guide-principal-component-analysis-python/

¡Muchas gracias!

Nos vemos en la próxima lección

alkemy