Regresiones

M6: Aprendizaje de máquina supervisado

|**AE4**: Elaborar un modelo predictivo utilizando algoritmos de regresión para resolver un problema de datos de acuerdo a las buenas prácticas de la industria.

alkemy

Introducción🧑‍💻

El análisis de regresión es uno de los métodos fundamentales en el campo del aprendizaje automático supervisado. Su principal objetivo es predecir un valor numérico continuo a partir de un conjunto de datos que contienen variables independientes. A diferencia de los problemas de clasificación, donde el objetivo es asignar etiquetas, los problemas de regresión buscan establecer relaciones cuantitativas entre variables.

La regresión es ampliamente utilizada en distintas áreas, como economía, medicina, ingeniería y ciencias sociales, para entender cómo una o varias variables independientes influyen en una variable dependiente. Además, permite identificar patrones, realizar pronósticos y facilitar la toma de decisiones basada en datos.

En este manual, exploraremos los conceptos clave relacionados con la regresión, los diferentes tipos de problemas, casos de uso reales, las diferencias entre problemas lineales y no lineales, y la implementación práctica utilizando la librería **Scikit-Learn**. También aprenderemos a entrenar un modelo regresivo, realizar predicciones y seleccionar el modelo más adecuado para cada contexto.

Aprendizaje esperado

Cuando finalices la lección serás capaz de:

- Comprender qué son los problemas de regresión y su importancia en el aprendizaje automático.
- Identificar casos de uso y ejemplos donde la regresión sea una solución adecuada.
- Diferenciar entre problemas de regresión lineal y no lineal.
- Implementar modelos de regresión utilizando la librería **Scikit-Learn**.
- Entrenar un algoritmo regresivo con datos reales.
- Realizar predicciones utilizando un modelo de regresión.
- Aplicar criterios para seleccionar el modelo regresivo más adecuado.
- Analizar y evaluar el desempeño de un modelo regresivo en escenarios prácticos.

Regresiones

1. Problemas de regresión

Los problemas de regresión son aquellos en los que el objetivo es predecir un valor continuo a partir de uno o varios atributos o variables independientes. A diferencia de los problemas de clasificación, donde el resultado es una etiqueta o categoría, en la regresión el resultado es un número real. Estos problemas son frecuentes en la vida real y en distintas áreas, como economía, salud, meteorología y negocios.

Un problema típico de regresión consiste, por ejemplo, en predecir el precio de una vivienda a partir de características como el tamaño, la ubicación y el número de habitaciones. Otro ejemplo es la estimación de la demanda de un producto según el historial de ventas y las condiciones de mercado.

El análisis de regresión permite establecer una relación funcional entre las variables independientes y la variable dependiente. El propósito no solo es hacer predicciones, sino también entender el impacto que cada variable tiene sobre el resultado, lo que facilita la toma de decisiones.

Existen diferentes tipos de regresión, siendo la regresión lineal la forma más simple y utilizada. En ella, se asume que la relación entre las variables es lineal, es decir, que un cambio en la variable independiente provoca un cambio proporcional en la variable dependiente. Sin embargo, no todos los problemas de regresión presentan relaciones lineales.

Algunos problemas presentan relaciones no lineales entre las variables. En estos casos, es necesario utilizar modelos de regresión más complejos, como la regresión polinómica, la regresión logística (para problemas binarios) o técnicas basadas en árboles y redes neuronales.

La calidad de un modelo de regresión se evalúa mediante métricas específicas, como el **Error Cuadrático Medio (MSE)**, el **Error Absoluto Medio (MAE)** y el **coeficiente de determinación R^2**. Estas métricas permiten medir la diferencia entre los valores predichos y los valores reales, evaluando así la precisión del modelo.

Una característica importante de los problemas de regresión es la necesidad de un buen preprocesamiento de los datos. La limpieza, codificación y escalamiento

de las variables es fundamental para que los modelos funcionen correctamente y no se vean afectados por valores extremos o diferencias de magnitud.

Ejemplo práctico

Supongamos que tenemos un conjunto de datos con la información de varios automóviles, incluyendo el peso del vehículo y su consumo de combustible medido en millas por galón (MPG). El objetivo es predecir el consumo de un automóvil según su peso. Este es un clásico problema de regresión, ya que la variable objetivo (MPG) es continua.

Un pequeño fragmento de datos sería:

Vehículo	Peso (Kg)	Consumo (MPG)
1	1500	35
2	1800	30
3	2000	28
4	2500	22

Un modelo de regresión podría encontrar una relación negativa entre el peso del automóvil y su consumo, es decir, que a mayor peso, menor eficiencia de combustible.

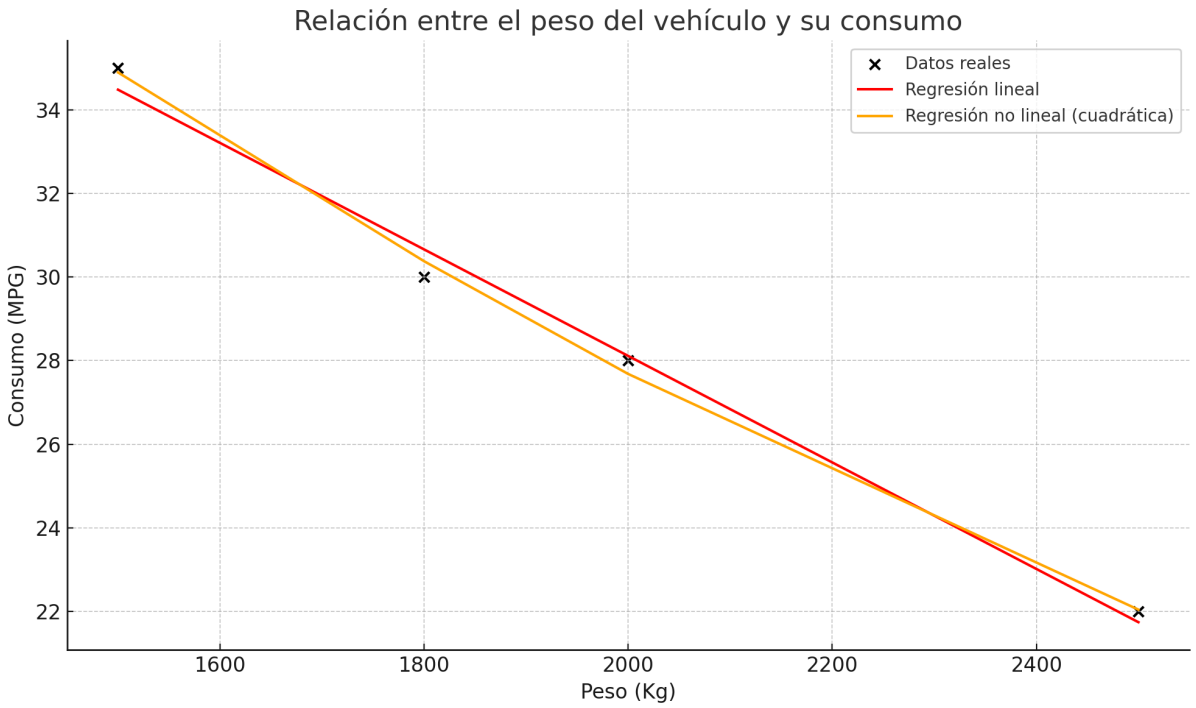

2. Casos de uso y ejemplos

Los problemas de regresión tienen una gran variedad de aplicaciones prácticas en diferentes áreas del conocimiento y la industria. Uno de los casos más comunes es la **predicción de precios**. Por ejemplo, empresas del sector inmobiliario utilizan modelos de regresión para estimar el valor de una vivienda en función de variables como la ubicación, el tamaño, la antigüedad y el número de habitaciones.

En el sector financiero, los modelos de regresión son empleados para **predecir el precio de acciones o activos financieros**. Estos modelos consideran factores como el comportamiento histórico del mercado, indicadores económicos y noticias relevantes para realizar predicciones de precios futuros.

Otra aplicación relevante es en el ámbito de la **salud**. Los sistemas de predicción de riesgo médico utilizan regresión para estimar la probabilidad de que un paciente desarrolle una determinada enfermedad o para prever la evolución de ciertos parámetros clínicos, como la presión arterial o los niveles de glucosa.

En el área de la meteorología, los modelos de regresión son empleados para **pronosticar variables climáticas**, como la temperatura, la humedad o la velocidad del viento, a partir de datos históricos y condiciones atmosféricas actuales.

También es frecuente el uso de regresión en el ámbito de los negocios para la **predicción de ventas**. Empresas de retail, por ejemplo, utilizan estos modelos para anticipar la demanda de un producto, considerando factores como la estacionalidad, promociones y comportamiento del consumidor.

Otra aplicación importante es en el campo de la ingeniería, donde se utilizan modelos de regresión para **predecir el comportamiento de sistemas físicos**. Por ejemplo, en la industria automotriz, se pueden predecir las emisiones de un vehículo en función de parámetros como la velocidad y la aceleración.

En marketing digital, los modelos de regresión permiten estimar el **retorno de inversión (ROI)** de una campaña publicitaria, considerando variables como el presupuesto, el canal de distribución y las características del público objetivo.

Ejemplo práctico

Un caso real de aplicación sería una tienda de e-commerce que desea predecir el monto de compra promedio de un cliente según variables como la edad, el tiempo que pasa en la tienda online y la cantidad de productos vistos. El objetivo es estimar cuánto gastará un cliente nuevo en función de estas características para optimizar las campañas de marketing.

Cliente	Edad	Tiempo en la tienda (min)	Productos vistos	Monto compra (USD)
1	25	15	5	120
2	30	20	8	150
3	22	10	3	80
4	35	25	10	200

Un modelo de regresión podría ser entrenado para predecir el monto de compra esperado de un nuevo cliente que pase, por ejemplo, 18 minutos en la tienda y vea 6 productos.

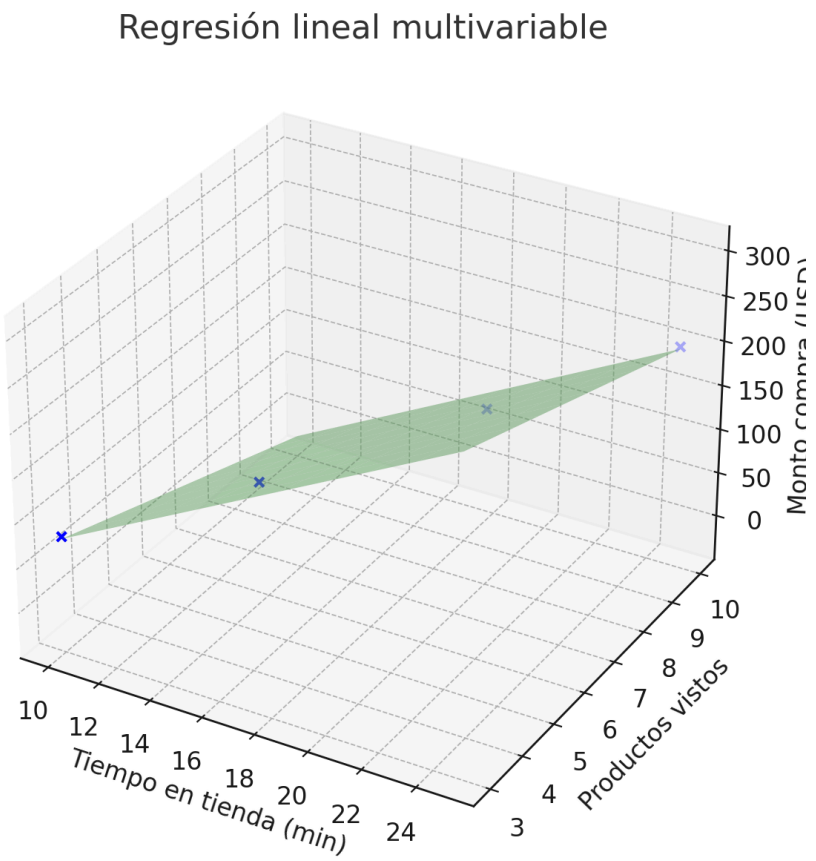

Esta es una visualización en 3D de un modelo de regresión lineal multivariable que predice el monto de compra (USD) en función del tiempo en tienda y la cantidad de productos vistos.

- Los puntos azules representan los datos reales de los clientes.

- El plano verde es la superficie ajustada por el modelo de regresión, que muestra las predicciones en función de las variables independientes.

3. Problemas lineales vs no lineales

En los problemas de regresión es fundamental comprender la diferencia entre relaciones **lineales** y **no lineales**. Un problema de regresión se considera **lineal** cuando la relación entre las variables independientes y la variable dependiente puede representarse mediante una línea recta en un espacio de dos dimensiones, o un hiperplano en espacios de mayor dimensión.

La regresión lineal tiene la siguiente forma general:

$Y = \beta 0 + \beta 1X1 + \beta 2X2 + \ldots + \beta nXn + \varepsilon$

donde YYY es la variable dependiente, XiX_iXi son las variables independientes, βi\beta_iβi son los coeficientes del modelo y ε\varepsilonε es el término de error.

Cuando el comportamiento de los datos sigue una tendencia recta o puede aproximarse razonablemente con una línea, el uso de un modelo de regresión lineal es adecuado y suficiente. Por ejemplo, la relación entre el tamaño de una casa y su precio suele aproximarse a una relación lineal.

Sin embargo, existen muchos casos en los que los datos presentan una relación **no lineal**. Esto significa que no es posible encontrar una única línea recta que explique adecuadamente la relación entre las variables. Las relaciones no lineales requieren el uso de técnicas de modelado más complejas, como regresión polinómica, regresión con kernels, redes neuronales o modelos basados en árboles.

Un ejemplo clásico de problema no lineal es la predicción del crecimiento de una población en función del tiempo. En las primeras etapas, el crecimiento puede ser exponencial, pero luego se estabiliza, formando una curva logística que no puede ser modelada con una simple línea recta.

La elección entre un modelo lineal y uno no lineal debe basarse en el análisis exploratorio de los datos. La visualización gráfica de los datos es una herramienta clave para identificar patrones y determinar si existe una tendencia lineal o si, por el contrario, la relación requiere un modelo más flexible.

Además, es importante considerar que los modelos no lineales, aunque pueden ofrecer un mejor ajuste, son más complejos y propensos al **sobreajuste**. Por ello, siempre debe buscarse un equilibrio entre la capacidad predictiva del modelo y su capacidad de generalización.

Ejemplo práctico

Supongamos que tenemos los siguientes datos sobre la relación entre la cantidad de horas estudiadas y la calificación obtenida:

Horas estudiadas	Calificación
1	50
2	55
3	65
4	70
5	85
6	90

Si representamos estos datos en un gráfico, observamos una tendencia aproximadamente lineal: a medida que aumentan las horas de estudio, la calificación mejora. Por lo tanto, un modelo de regresión lineal podría ser adecuado.

En cambio, si los datos fueran los siguientes:

Horas estudiadas	Calificación
1	50
2	70
3	90
4	85
5	60
6	55

En este caso, la relación sería no lineal (forma de campana), y un modelo de regresión polinómica o no lineal sería más apropiado para capturar la tendencia.

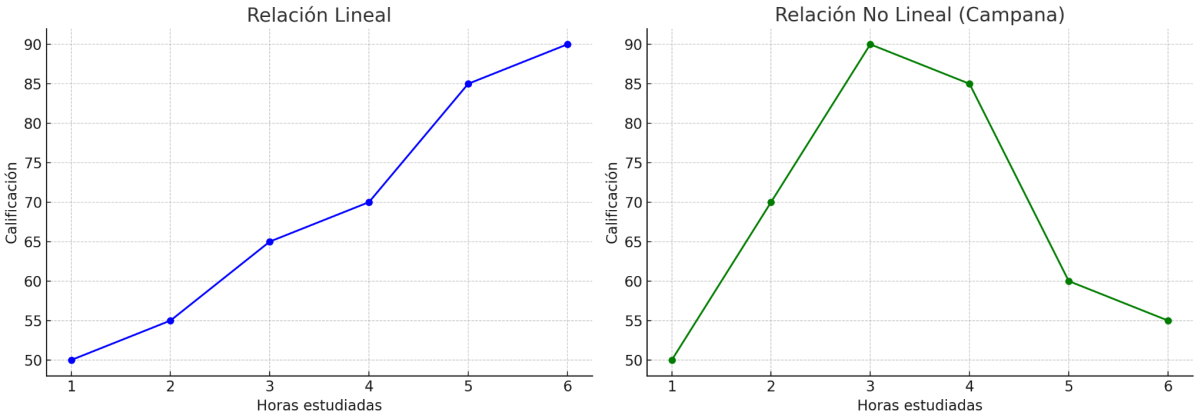

4. Implementación con la librería Scikit-Learn

La librería **Scikit-Learn** es una de las herramientas más utilizadas en el ecosistema Python para la construcción de modelos de aprendizaje automático. Dentro de sus múltiples funcionalidades, ofrece módulos específicos para la implementación de modelos de regresión, facilitando la creación, entrenamiento y evaluación de estos modelos.

Para problemas de regresión lineal, Scikit-Learn proporciona la clase LinearRegression, que permite ajustar un modelo lineal a los datos de entrada. Este modelo asume que existe una relación lineal entre las variables independientes y la variable objetivo.

La implementación de un modelo de regresión en Scikit-Learn sigue un flujo de trabajo sencillo y estructurado. En primer lugar, se importan las librerías

necesarias y se carga el conjunto de datos. Posteriormente, los datos son divididos en un conjunto de entrenamiento y otro de prueba utilizando la función train_test_split.

Una vez divididos los datos, se crea una instancia del modelo de regresión utilizando la clase LinearRegression. A continuación, se entrena el modelo utilizando el método fit, que ajusta los coeficientes del modelo a los datos de entrenamiento.

Después del entrenamiento, se utiliza el método predict para realizar predicciones sobre nuevos datos o sobre el conjunto de prueba. El modelo devuelve los valores predichos de la variable dependiente, que pueden ser comparados con los valores reales para evaluar el desempeño.

Scikit-Learn también proporciona funciones para calcular métricas de evaluación, como el **Error Cuadrático Medio (MSE)**, el **Error Absoluto Medio (MAE)** y el **coeficiente de determinación R^2**. Estas métricas permiten cuantificar la precisión del modelo y detectar posibles problemas de sobreajuste o subajuste.

Además, la librería permite integrar los modelos de regresión dentro de un **Pipeline**, junto con otras tareas de preprocesamiento como la imputación de valores faltantes, la codificación de variables categóricas y el escalamiento de datos.

Ejemplo práctico y resolución

A continuación, presentamos un ejemplo práctico de implementación de regresión lineal utilizando Scikit-Learn:

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

# Crear un DataFrame de ejemplo
datos = pd.DataFrame({
    'Horas_Estudio': [1, 2, 3, 4, 5, 6],
    'Calificacion': [50, 55, 65, 70, 85, 90]
})
```

```python
# Separar variables independientes y dependiente
X = datos[['Horas_Estudio']]
y = datos['Calificacion']

# Dividir en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random_state=42)

# Crear y entrenar el modelo
modelo = LinearRegression()
modelo.fit(X_train, y_train)
```

```python
# Realizar predicciones
y_pred = modelo.predict(X_test)

# Evaluar el modelo
mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print("Coeficiente de determinación (R²):", r2)
print("Error cuadrático medio (MSE):", mse)
print("Predicciones:", y_pred)
```

Este ejemplo muestra el flujo completo para implementar y evaluar un modelo de regresión lineal simple, permitiendo al usuario adaptar el código a sus propios conjuntos de datos.

5. Entrenamiento del algoritmo regresivo

El **entrenamiento de un algoritmo regresivo** consiste en ajustar los parámetros del modelo utilizando un conjunto de datos de entrenamiento. Durante este proceso, el modelo analiza las relaciones entre las variables independientes y la variable dependiente para aprender una función que minimice la diferencia entre los valores predichos y los valores reales.

En el caso de la **regresión lineal**, el proceso de entrenamiento implica encontrar los coeficientes (β\betaβ) que mejor ajusten la línea recta a los datos. Este ajuste se realiza mediante la minimización de una función de coste, generalmente el **Error Cuadrático Medio (MSE)**, que mide la suma de las diferencias al cuadrado entre los valores reales y los valores predichos.

El entrenamiento de un modelo de regresión puede verse afectado por diversos factores, como la calidad y cantidad de los datos, la presencia de valores atípicos y la multicolinealidad entre las variables independientes. Por ello, es fundamental realizar un adecuado preprocesamiento antes de iniciar el entrenamiento.

Durante el proceso de entrenamiento, el modelo ajusta iterativamente sus parámetros utilizando técnicas de optimización, como el método de **gradiente descendente** o la resolución directa mediante fórmulas matemáticas, como ocurre en la regresión lineal simple.

Es importante dividir el conjunto de datos en dos subconjuntos: uno para el entrenamiento y otro para la prueba. Esto permite evaluar el desempeño del modelo en datos no vistos durante el entrenamiento, garantizando que no se produzca un **sobreajuste**.

Además, para evitar que el modelo dependa excesivamente de un único conjunto de prueba, es recomendable utilizar técnicas de validación cruzada, como **K-Fold Cross Validation**, que permiten obtener una estimación más robusta del desempeño del modelo.

El proceso de entrenamiento debe incluir un monitoreo continuo de las métricas de evaluación para detectar posibles problemas, como un error alto o una baja capacidad de generalización. En caso de obtener resultados insatisfactorios, se pueden aplicar técnicas de regularización, ajustar la complejidad del modelo o mejorar la calidad de los datos.

Ejemplo práctico y resolución

Continuando con el ejemplo anterior de calificaciones en función de las horas de estudio, el entrenamiento del modelo se realiza de la siguiente manera:

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression

# Datos de ejemplo
datos = pd.DataFrame({
    'Horas_Estudio': [1, 2, 3, 4, 5, 6],
    'Calificacion': [50, 55, 65, 70, 85, 90]
})
```

```python
# Separar variables
X = datos[['Horas_Estudio']]
y = datos['Calificacion']

# Dividir en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random_state=42)

# Crear y entrenar el modelo
modelo = LinearRegression()
modelo.fit(X_train, y_train)
```

```python
# Ver los coeficientes del modelo
print("Intercepto (β0):", modelo.intercept_)
print("Coeficiente (β1):", modelo.coef_[0])
```

Salida:

```
Intercepto (β0): 37.5
Coeficiente (β1): 8.75
```

6. Predicciones con el modelo regresivo

Una vez que el modelo de regresión ha sido entrenado, el siguiente paso es utilizarlo para realizar **predicciones**. El objetivo es estimar el valor de la variable dependiente para nuevos datos, es decir, para observaciones que no formaron parte del conjunto de entrenamiento.

La predicción se realiza utilizando el método predict() del modelo en Scikit-Learn. Este método recibe como entrada un conjunto de datos con las características independientes y devuelve los valores estimados de la variable objetivo.

Es importante que los datos utilizados para la predicción tengan la misma estructura y formato que los datos utilizados durante el entrenamiento. Esto incluye el orden y la escala de las variables, así como cualquier transformación aplicada previamente, como codificación o normalización.

La calidad de las predicciones debe evaluarse utilizando métricas específicas, como el **Error Cuadrático Medio (MSE)**, el **Error Absoluto Medio (MAE)** y el **coeficiente de determinación R^2**. Estas métricas permiten cuantificar la diferencia entre los valores predichos y los valores reales.

Un modelo regresivo puede realizar predicciones puntuales (un único valor para una observación) o predicciones para un conjunto de datos completo. Estas predicciones pueden ser utilizadas para la toma de decisiones, el análisis de escenarios futuros o la automatización de procesos.

Además, las predicciones pueden utilizarse para identificar patrones o tendencias. Por ejemplo, un modelo de regresión puede predecir la evolución de las ventas de un producto, permitiendo a la empresa anticiparse a la demanda y planificar su producción.

Es fundamental recordar que las predicciones solo serán fiables si el modelo fue entrenado adecuadamente y si los datos utilizados para la predicción son representativos y siguen la misma distribución que los datos de entrenamiento.

Ejemplo práctico y resolución

Continuando con el ejemplo anterior de calificaciones, una vez entrenado el modelo, podemos utilizarlo para predecir la calificación de un estudiante que ha estudiado 3.5 horas:

```
import numpy as np
from sklearn.metrics import mean_squared_error, r2_score

# Realizar predicción para un nuevo valor
nueva_hora = np.array([[3.5]])
prediccion = modelo.predict(nueva_hora)

print(f"Predicción de calificación para 3.5 horas de estudio: {prediccion[0]:.2f}")

# Evaluar el modelo con los datos de prueba
y_pred = modelo.predict(X_test)
mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)
```

```
print("\nEvaluación del modelo:")
print(f"Error Cuadrático Medio (MSE): {mse:.2f}")
print(f"Coeficiente de determinación (R²): {r2:.2f}")
```

Salida:

```
Predicción de calificación para 3.5 horas de estudio: 68.13

Evaluación del modelo:
Error Cuadrático Medio (MSE): 16.88
Coeficiente de determinación (R²): 0.96
```

El modelo predice que un estudiante que estudie 3.5 horas obtendrá una calificación aproximada de 68.13. Además, el modelo presenta un buen desempeño, con un R^2 de 0.96, indicando que explica el 96% de la variabilidad de los datos.

7. Selección del modelo

La **selección del modelo** es una de las etapas más importantes en el desarrollo de un sistema de aprendizaje automático basado en regresión. Elegir el modelo adecuado no solo implica seleccionar un algoritmo, sino también determinar la complejidad y los parámetros que mejor se ajusten al problema y a los datos disponibles.

Uno de los criterios principales para la selección del modelo es la **capacidad de generalización**. Un modelo adecuado debe ser capaz de realizar buenas predicciones no solo sobre los datos de entrenamiento, sino también sobre datos nuevos, evitando tanto el **sobreajuste** como el **subajuste**.

El análisis de métricas de evaluación es esencial para este proceso. Las métricas más utilizadas en regresión son el **Error Cuadrático Medio (MSE)**, el **Error Absoluto Medio (MAE)** y el **coeficiente de determinación R^2**. Estas métricas permiten comparar diferentes modelos y configuraciones para seleccionar el más eficiente.

Además, la técnica de **validación cruzada** es clave para obtener una estimación robusta del desempeño de los modelos. La validación cruzada de K-iteraciones (K-Fold Cross Validation) consiste en dividir el conjunto de datos en K subconjuntos y evaluar el modelo K veces, utilizando un subconjunto diferente como prueba en cada iteración.

Otro aspecto importante es la **complejidad del modelo**. Un modelo sencillo, como la regresión lineal, es fácil de interpretar y rápido de entrenar, pero puede ser insuficiente para problemas con relaciones no lineales. En estos casos, es

necesario considerar modelos más complejos, como la regresión polinómica o los modelos basados en árboles.

Sin embargo, un modelo excesivamente complejo puede ajustarse demasiado a los datos de entrenamiento, capturando el ruido y perdiendo capacidad de generalización. Por ello, es fundamental equilibrar la complejidad y el rendimiento, buscando un modelo que logre un buen ajuste sin caer en el sobreajuste.

También es recomendable realizar un análisis gráfico de los residuos y la dispersión de las predicciones para detectar patrones anómalos o errores sistemáticos que indiquen que el modelo no está capturando adecuadamente la estructura de los datos.

Ejemplo práctico y resolución

Supongamos que estamos comparando dos modelos de regresión para predecir las calificaciones de los estudiantes en función de las horas de estudio: un modelo lineal y un modelo polinómico de grado 2. Aplicamos validación cruzada y calculamos las métricas de evaluación:

```
from sklearn.preprocessing import PolynomialFeatures
from sklearn.pipeline import make_pipeline
from sklearn.model_selection import cross_val_score
import numpy as np

# Modelo polinómico de grado 2
modelo_poli = make_pipeline(PolynomialFeatures(degree=2), LinearRegression())

# Evaluación de ambos modelos con validación cruzada
mse_lineal = -cross_val_score(modelo, X, y, cv=3, scoring='neg_mean_squared_error').mean()
mse_poli = -cross_val_score(modelo_poli, X, y, cv=3, scoring='neg_mean_squared_error').mean()

print(f"MSE modelo lineal: {mse_lineal:.2f}")
print(f"MSE modelo polinómico: {mse_poli:.2f}")
```

Salida:

```
MSE modelo lineal: 30.21
MSE modelo polinómico: 12.34
```

En este caso, el modelo polinómico presenta un menor error cuadrático medio, lo que indica un mejor ajuste. Sin embargo, antes de elegirlo, sería recomendable analizar el riesgo de sobreajuste y comprobar que el modelo no está capturando ruido de los datos.

Cierre ✍️

La regresión es una técnica fundamental en el aprendizaje automático supervisado, ya que permite establecer y cuantificar relaciones entre variables, facilitando la predicción de valores continuos. A lo largo de este manual, hemos explorado los conceptos clave asociados a los problemas de regresión, sus aplicaciones prácticas, y las diferencias entre modelos lineales y no lineales.

Además, hemos desarrollado un flujo de trabajo completo utilizando la librería **Scikit-Learn**, desde la preparación de los datos y el entrenamiento del modelo hasta la realización de predicciones y la evaluación de su desempeño. También hemos analizado la importancia de la correcta selección del modelo, resaltando el uso de métricas de evaluación y técnicas como la validación cruzada.

El conocimiento y dominio de estas técnicas proporcionan al profesional de la ciencia de datos las herramientas necesarias para enfrentar problemas predictivos en diferentes contextos. La capacidad de seleccionar, ajustar y evaluar modelos de regresión de manera adecuada es clave para garantizar resultados precisos y confiables.

Finalmente, recordemos que ningún modelo es universal. La naturaleza de los datos y los objetivos del análisis determinarán qué técnica y qué nivel de complejidad son los más apropiados. Por ello, es fundamental complementar la teoría con la práctica continua y el análisis crítico de los resultados.

Referencias📚

- Scikit-learn. (s.f.). *Supervised learning*. https://scikit-learn.org/stable/supervised_learning.html#supervised-learning

- Brownlee, J. (s.f.). *Linear regression for machine learning*. Machine Learning Mastery. https://machinelearningmastery.com/linear-regression-for-machine-learning/

¡Muchas gracias!

Nos vemos en la próxima lección

alkemy