Métricas de desempeño de un algoritmo

M6: Aprendizaje de máquina supervisado

|**AE6**: Aplicar métricas de desempeño para la evaluación de algoritmos de clasificación y regresión de acuerdo al caso planteado.

alkemy

Introducción👩‍💻

Evaluar el desempeño de un modelo de aprendizaje automático es un paso fundamental en cualquier proyecto de Machine Learning. Las métricas de evaluación permiten cuantificar la calidad de las predicciones realizadas por un modelo, ayudando a identificar su nivel de ajuste, su capacidad de generalización y su eficacia al resolver un problema específico.

Existen diversas métricas que pueden aplicarse dependiendo del tipo de problema: regresión o clasificación. En los problemas de regresión, el objetivo es predecir valores continuos, por lo que las métricas se enfocan en medir la diferencia entre los valores predichos y los valores reales. En cambio, en los problemas de clasificación, el objetivo es asignar una categoría, y las métricas se centran en evaluar la precisión y la capacidad del modelo para identificar correctamente las clases.

Este manual aborda las métricas de desempeño más utilizadas en ambos escenarios. Además, incluye ejemplos prácticos y la implementación detallada utilizando la librería **Scikit-Learn**, una de las herramientas más populares en el ecosistema Python para Machine Learning.

Aprendizaje esperado

Cuando finalices la lección serás capaz de:

- Comprender la importancia de las métricas de evaluación en un proyecto de Machine Learning.
- Identificar y calcular las métricas más utilizadas para modelos de regresión: MAE, MSE, RMSE y R^2.
- Identificar y calcular las métricas más relevantes en clasificación: matriz de confusión, precisión, exactitud, sensibilidad, especificidad y curva ROC-AUC.
- Interpretar los resultados obtenidos a partir de estas métricas para tomar decisiones informadas sobre la calidad del modelo.
- Implementar el cálculo de las métricas utilizando la librería **Scikit-Learn**.
- Aplicar las métricas en casos prácticos para la evaluación y comparación de modelos.

1. Métricas de desempeño de un modelo regresivo

Las métricas de desempeño en problemas de regresión permiten evaluar la diferencia entre los valores predichos por un modelo y los valores reales observados. Estas métricas cuantifican el error cometido por el modelo y proporcionan información valiosa sobre su precisión y capacidad de generalización.

Una de las métricas más utilizadas es el **Error Absoluto Medio (MAE)**. Esta métrica calcula la media de las diferencias absolutas entre los valores predichos y los reales. Su interpretación es sencilla, ya que indica en promedio cuánto se equivoca el modelo al realizar sus predicciones.

Otra métrica común es el **Error Cuadrático Medio (MSE)**. A diferencia del MAE, el MSE eleva al cuadrado las diferencias entre los valores predichos y los reales antes de promediarlas. Esto penaliza más los errores grandes, haciendo que el modelo intente evitar predicciones con grandes desviaciones.

La **Raíz del Error Cuadrático Medio (RMSE)** es simplemente la raíz cuadrada del MSE. Su ventaja es que mantiene la misma unidad de medida que la variable objetivo, facilitando la interpretación de los resultados.

El **coeficiente de determinación R^2** es una métrica que indica qué proporción de la variabilidad de la variable dependiente puede ser explicada por el modelo. Un valor de R^2 cercano a 1 indica que el modelo explica bien la variabilidad de los datos, mientras que un valor cercano a 0 sugiere que el modelo no captura la estructura de los datos.

Cada una de estas métricas tiene sus propias ventajas e inconvenientes. Por ejemplo, el MAE es menos sensible a los valores atípicos que el MSE o el RMSE, mientras que estas últimas penalizan fuertemente los errores grandes, lo que puede ser deseable en ciertos contextos.

Es recomendable utilizar varias métricas de manera conjunta para obtener una visión más completa del desempeño del modelo. La elección de la métrica adecuada dependerá de los objetivos del análisis y de las características del conjunto de datos.

Además, estas métricas deben ser calculadas utilizando un conjunto de prueba o mediante técnicas de validación cruzada para garantizar que reflejan la capacidad de generalización del modelo y no simplemente su desempeño en los datos de entrenamiento.

Ejemplo práctico

Supongamos que hemos construido un modelo de regresión para predecir el precio de un automóvil. Los precios reales y predichos para cinco autos son:

Auto	Precio real (USD)	Precio predicho (USD)
1	20000	1
2	25000	24000
3	30000	31000
4	22000	23000
5	27000	26500

Podemos calcular el MAE, MSE, RMSE y R^2 para evaluar el desempeño de este modelo y cuantificar su error promedio.

2. MAE, MSE, RMSE y R^2: definición y cálculo

El **Error Absoluto Medio (MAE)** es una métrica que calcula la media de las diferencias absolutas entre los valores predichos y los valores reales. Su fórmula es:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

donde yiy_iyi es el valor real, y^i\hat{y}_iy^i es el valor predicho y nnn es el número de observaciones. El MAE ofrece una interpretación directa: indica, en promedio, cuánto se equivoca el modelo.

El **Error Cuadrático Medio (MSE)** calcula la media de los errores al cuadrado:

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Esta métrica penaliza fuertemente los errores grandes, ya que las diferencias se elevan al cuadrado. Por ello, el MSE es útil cuando se desea evitar grandes desviaciones.

El **Raíz del Error Cuadrático Medio (RMSE)** es simplemente la raíz cuadrada del MSE:

$$RMSE = \sqrt{MSE}$$

El RMSE es útil porque expresa el error en la misma unidad que la variable objetivo, facilitando la interpretación para usuarios no técnicos.

El **coeficiente de determinación R²** mide la proporción de la varianza de la variable dependiente que es explicada por el modelo. Su fórmula es:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

donde y¯\bar{y}y¯ es la media de los valores reales. Un valor de R² cercano a 1 indica un modelo con buen ajuste, mientras que un valor cercano a 0 refleja un modelo que no explica la variabilidad de los datos.

Estas métricas pueden calcularse fácilmente utilizando la librería **Scikit-Learn**, que ofrece funciones específicas para cada una de ellas, como mean_absolute_error, mean_squared_error y r2_score.

Ejemplo práctico y resolución

Continuando con el ejemplo anterior de predicción de precios de automóviles:

```python
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
import numpy as np

# Valores reales y predichos
y_real = np.array([20000, 25000, 30000, 22000, 27000])
y_pred = np.array([19500, 24000, 31000, 23000, 26500])

# Cálculo de métricas
mae = mean_absolute_error(y_real, y_pred)
mse = mean_squared_error(y_real, y_pred)
rmse = np.sqrt(mse)
r2 = r2_score(y_real, y_pred)
```

```python
print(f"MAE: {mae:.2f}")
print(f"MSE: {mse:.2f}")
print(f"RMSE: {rmse:.2f}")
print(f"R²: {r2:.2f}")
```

Salida:

```
MAE: 600.00
MSE: 450000.00
RMSE: 670.82
R²: 0.94
```

Estos resultados indican que, en promedio, el modelo se equivoca por 600 dólares, con un error cuadrático medio de 450,000 dólares y un buen nivel de ajuste (R^2 de 0.94).

3. Métricas de desempeño en un algoritmo de clasificación

En los problemas de clasificación, el objetivo es asignar una etiqueta o categoría a cada observación. Para evaluar la calidad de un modelo de clasificación, es necesario utilizar métricas específicas que permitan cuantificar qué tan bien está funcionando el modelo al identificar correctamente las clases.

Una de las métricas fundamentales en clasificación es la **Matriz de Confusión**. Esta herramienta permite visualizar el rendimiento del modelo mostrando la cantidad de predicciones correctas e incorrectas, clasificadas según la clase real y la clase predicha. La matriz tiene cuatro elementos clave: Verdaderos Positivos (VP), Falsos Positivos (FP), Verdaderos Negativos (VN) y Falsos Negativos (FN).

A partir de la matriz de confusión, se pueden calcular varias métricas importantes. Una de ellas es la **Precisión (Precision)**, que mide la proporción de predicciones positivas correctas respecto al total de predicciones positivas realizadas por el modelo:

$$\text{Precisión} = \frac{VP}{VP + FP}$$

Otra métrica relevante es la **Exactitud (Accuracy)**, que mide la proporción de predicciones correctas sobre el total de predicciones:

$$\text{Exactitud} = \frac{VP + VN}{VP + FP + FN + VN}$$

La **Sensibilidad** o **Recall** indica la capacidad del modelo para identificar correctamente las observaciones positivas. Se calcula como:

$$\text{Sensibilidad} = \frac{VP}{VP + FN}$$

La **Especificidad** mide la capacidad del modelo para identificar correctamente las observaciones negativas:

$$\text{Especificidad} = \frac{VN}{VN + FP}$$

Estas métricas ofrecen una visión más detallada del desempeño del modelo, especialmente cuando las clases están desbalanceadas. Por ejemplo, en un problema donde una clase es mucho más frecuente que la otra, la exactitud puede ser engañosa y no reflejar la verdadera capacidad del modelo para identificar la clase minoritaria.

Ejemplo de matriz:

		Predicted Class: Positive	Predicted Class: Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) **Type II Error**	**Sensitivity** $\frac{TP}{(TP+FN)}$
	Negative	False Positive (FP) **Type I Error**	True Negative (TN)	**Specificity** $\frac{TN}{(TN+FP)}$
		Precision $\frac{TP}{(TP+FP)}$	**Negative Predictive Value** $\frac{TN}{(TN+FN)}$	**Accuracy** $\frac{TP+TN}{(TP+TN+FP+FN)}$

Ejemplo práctico y resolución

Supongamos que tenemos los siguientes datos de predicciones y clases reales:

Real	Predicho
1	1
0	0
1	0
0	0
1	1

La matriz de confusión sería:

	Predicho 0	Predicho 1
Real 0	**2**	**0**
Real 1	**1**	**2**

A partir de estos valores:

- VP = 2
- VN = 2
- FP = 0
- FN = 1

Las métricas serían:

- Precisión = 2 / (2 + 0) = 1.0
- Exactitud = (2 + 2) / 5 = 0.8
- Sensibilidad = 2 / (2 + 1) ≈ 0.67
- Especificidad = 2 / (2 + 0) = 1.0

Estas métricas permiten identificar las fortalezas y debilidades del modelo, como su alta precisión y especificidad, pero baja sensibilidad.

4. Curva ROC-AUC

La **Curva ROC (Receiver Operating Characteristic)** es una herramienta visual utilizada para evaluar el desempeño de un modelo de clasificación binaria. Esta curva representa la relación entre la **tasa de verdaderos positivos** (Sensibilidad) y la **tasa de falsos positivos** (1 - Especificidad) para diferentes umbrales de clasificación.

En un modelo de clasificación, el umbral por defecto para decidir si una predicción es positiva o negativa suele ser 0.5. Sin embargo, este umbral puede ajustarse para cambiar el comportamiento del modelo. La Curva ROC muestra cómo varían la sensibilidad y la especificidad a medida que se modifican estos umbrales.

El área bajo la curva ROC, conocida como **AUC (Area Under Curve)**, es una métrica que resume el desempeño del modelo en todos los posibles umbrales. El valor del AUC varía entre 0 y 1. Un AUC de 1 indica un modelo perfecto, mientras que un valor de 0.5 indica un modelo que no tiene capacidad de discriminación (equivalente a una predicción aleatoria).

La interpretación práctica de la curva ROC-AUC es clara: cuanto más cercana esté la curva al vértice superior izquierdo del gráfico, mejor es el desempeño del modelo. Un modelo ideal tendrá una curva que sube rápidamente hacia el 100% de sensibilidad y mantiene una baja tasa de falsos positivos.

Una ventaja importante de la curva ROC es que permite comparar modelos de clasificación independientemente del umbral seleccionado, facilitando la evaluación objetiva entre diferentes algoritmos o configuraciones.

Sin embargo, es importante tener en cuenta que la curva ROC puede ser menos informativa en contextos donde las clases están muy desbalanceadas. En estos casos, la **curva Precision-Recall** puede ser más adecuada, ya que se centra en la clase positiva.

El cálculo de la curva ROC y el AUC puede realizarse fácilmente utilizando la librería **Scikit-Learn**, que proporciona las funciones roc_curve() y roc_auc_score() para este propósito.

Ejemplo práctico y resolución

Supongamos que tenemos un modelo de clasificación binaria que genera las siguientes probabilidades de predicción para la clase positiva:

Real	Probabilidad
1	0.90
0	0.40
1	0.80
0	0.35
1	0.70

Podemos calcular y graficar la curva ROC-AUC de la siguiente manera:

```
from sklearn.metrics import roc_curve, roc_auc_score
import matplotlib.pyplot as plt

# Datos reales y probabilidades
y_real = [1, 0, 1, 0, 1]
y_proba = [0.9, 0.4, 0.8, 0.35, 0.7]

# Calcular curva ROC
fpr, tpr, thresholds = roc_curve(y_real, y_proba)
auc = roc_auc_score(y_real, y_proba)
```

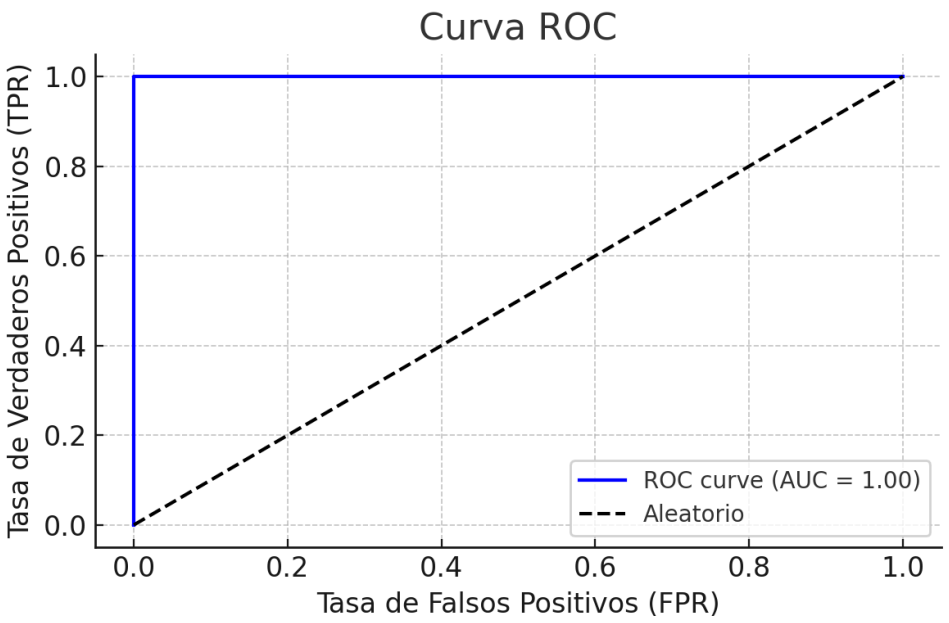


```
# Graficar
plt.plot(fpr, tpr, label=f'AUC = {auc:.2f}')
plt.plot([0, 1], [0, 1], 'k--')  # Línea aleatoria
plt.xlabel('Tasa de Falsos Positivos (1 - Especificidad)')
plt.ylabel('Tasa de Verdaderos Positivos (Sensibilidad)')
plt.title('Curva ROC')
plt.legend(loc='lower right')
plt.grid(True)
plt.show()
```

La curva obtenida permitirá visualizar el desempeño del modelo para distintos umbrales y, mediante el AUC, cuantificar su capacidad de clasificación.

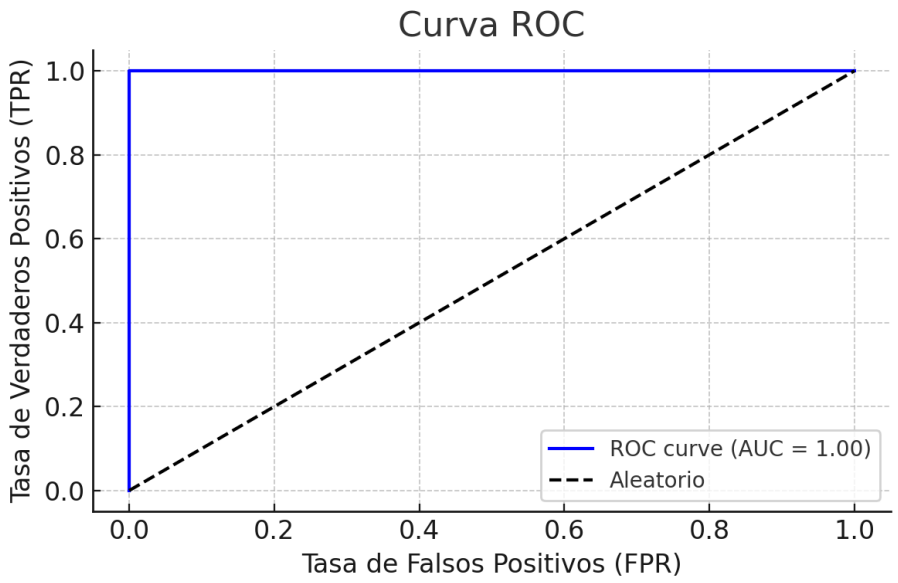

5. Cálculo de métricas utilizando la librería Scikit-Learn

La librería **Scikit-Learn** es una de las más utilizadas en el ecosistema Python para la implementación y evaluación de modelos de aprendizaje automático. Esta herramienta incluye funciones específicas para calcular todas las métricas de desempeño que hemos abordado en este manual, tanto para modelos de regresión como de clasificación.

Para los problemas de **regresión**, Scikit-Learn ofrece funciones como mean_absolute_error, mean_squared_error y r2_score, que permiten calcular el MAE, MSE, RMSE y R^2 de forma sencilla y eficiente. Estas funciones pueden aplicarse directamente a los valores reales y predichos.

En el caso de problemas de **clasificación**, la librería incluye funciones como confusion_matrix, accuracy_score, precision_score, recall_score, roc_curve y roc_auc_score. Estas herramientas permiten calcular la matriz de confusión, la exactitud, la precisión, la sensibilidad, la especificidad y la curva ROC-AUC.

Además, Scikit-Learn proporciona la función classification_report, que genera un informe detallado con varias métricas de evaluación, facilitando la interpretación y el análisis del desempeño del modelo.

Es recomendable integrar estas métricas dentro del flujo de trabajo de construcción del modelo, junto con el preprocesamiento de los datos y la validación cruzada. De esta forma, es posible garantizar que las métricas reflejan la capacidad real del modelo para generalizar a nuevos datos.

El uso adecuado de estas métricas permite detectar posibles problemas de sobreajuste o subajuste, comparar diferentes algoritmos y ajustar los parámetros del modelo para mejorar su desempeño.

Ejemplo práctico y resolución

A continuación, se presenta un ejemplo completo de cálculo de métricas de desempeño para un modelo de clasificación y otro de regresión utilizando Scikit-Learn:

```
from sklearn.metrics import (
    mean_absolute_error, mean_squared_error, r2_score,
    confusion_matrix, accuracy_score, precision_score, recall_score,
    roc_auc_score, classification_report
)

# Ejemplo regresión
y_real_reg = [20000, 25000, 30000, 22000, 27000]
y_pred_reg = [19500, 24000, 31000, 23000, 26500]
```

```
mae = mean_absolute_error(y_real_reg, y_pred_reg)
mse = mean_squared_error(y_real_reg, y_pred_reg)
rmse = mse ** 0.5
r2 = r2_score(y_real_reg, y_pred_reg)

print("Métricas de Regresión:")
print(f"MAE: {mae:.2f}")
print(f"MSE: {mse:.2f}")
print(f"RMSE: {rmse:.2f}")
print(f"R²: {r2:.2f}")
```

```python
# Ejemplo clasificación
y_real_clf = [1, 0, 1, 0, 1]
y_pred_clf = [1, 0, 0, 0, 1]
y_proba_clf = [0.9, 0.4, 0.3, 0.35, 0.8]

cm = confusion_matrix(y_real_clf, y_pred_clf)
accuracy = accuracy_score(y_real_clf, y_pred_clf)
precision = precision_score(y_real_clf, y_pred_clf)
recall = recall_score(y_real_clf, y_pred_clf)
roc_auc = roc_auc_score(y_real_clf, y_proba_clf)
```

```python
print("\nMétricas de Clasificación:")
print(f"Matriz de Confusión:\n{cm}")
print(f"Exactitud: {accuracy:.2f}")
print(f"Precisión: {precision:.2f}")
print(f"Sensibilidad (Recall): {recall:.2f}")
print(f"AUC: {roc_auc:.2f}")
print("\nReporte de Clasificación:\n", classification_report(y_real_clf, y_pred_clf))
```

Este flujo completo permite calcular e interpretar todas las métricas clave para evaluar modelos de regresión y clasificación, facilitando la toma de decisiones basada en datos.

Cierre ✍️

Las métricas de desempeño son un elemento esencial en todo proyecto de aprendizaje automático. A lo largo de este manual, hemos revisado las principales métricas utilizadas tanto en problemas de regresión como en clasificación, entendiendo su definición, interpretación y aplicación práctica.

En los modelos de regresión, métricas como el **MAE**, **MSE**, **RMSE** y **R^2** permiten cuantificar el error cometido por el modelo y evaluar su capacidad para aproximarse a los valores reales. Estas métricas ayudan a identificar problemas de ajuste y a tomar decisiones informadas sobre la selección y ajuste del modelo.

En los modelos de clasificación, herramientas como la **matriz de confusión**, la **precisión**, la **exactitud**, la **sensibilidad**, la **especificidad** y la **curva ROC-AUC** ofrecen una visión detallada del desempeño del modelo, permitiendo detectar desequilibrios y ajustar el umbral de decisión para mejorar la clasificación.

La implementación práctica de estas métricas utilizando la librería **Scikit-Learn** simplifica el proceso de evaluación y facilita la integración de estas métricas en el flujo de trabajo de Machine Learning. El dominio de estas herramientas es clave para garantizar el éxito de los proyectos y obtener modelos confiables y efectivos.

¡Nos vemos de nuevo, más adelante! 👋

Referencias📚

- Scikit-learn. (s. f.-a). *Model evaluation*. Recuperado el 25 de julio de 2025, de https://scikit-learn.org/stable/modules/model_evaluation.html
- Scikit-learn. (s. f.-b). *The scoring parameter: defining model evaluation rules*. Recuperado el 25 de julio de 2025, de https://scikit-learn.org/stable/modules/model_evaluation.html#scoring-parameter
- Google Developers. (s. f.). *Clasificación: precisión, recall, precisión y métricas relacionadas*. Recuperado el 25 de julio de 2025, de https://developers.google.com/machine-learning/crash-course/classification/accuracy
- Google Developers. (s. f.-b). *Clasificación: ROC y AUC*. Recuperado el 25 de julio de 2025, de https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc
- Google Developers. (s. f.-c). *Clasificación: Precisión y Recall*. Recuperado el 25 de julio de 2025, de https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall?hl=es-419
- DataSource.ai. (s. f.). *Métricas de evaluación de modelos en el aprendizaje automático*. Recuperado el 25 de julio de 2025, de https://www.datasource.ai/es/data-science-articles/metricas-de-evaluacion-de-modelos-en-el-aprendizaje-automatico
- Encord. (s. f.). *Confusion Matrix*. Recuperado el 25 de julio de 2025, de https://encord.com/glossary/confusion-matrix/

¡Muchas gracias!

Nos vemos en la próxima lección

alkemy