La red neuronal artificial

M8: Fundamentos de deep learning

|**AE1**: Explicar los conceptos fundamentales de las redes neuronales artificiales y su utilidad para la resolución de problemas de aprendizaje de máquina.

alkemy

Introducción🧑‍💻

Las redes neuronales artificiales (RNA) representan una de las herramientas más potentes dentro del aprendizaje automático. Inspiradas en el funcionamiento del cerebro humano, estas estructuras permiten a las máquinas aprender patrones, realizar predicciones y resolver problemas complejos sin necesidad de ser explícitamente programadas para cada tarea. Este manual busca introducir de manera clara y estructurada los fundamentos esenciales de las redes neuronales artificiales, desde su construcción más básica —el perceptrón— hasta los mecanismos internos de entrenamiento como la propagación hacia adelante y hacia atrás.

A través de esta lección, abordaremos cómo una red neuronal procesa información, cómo aprende a partir de datos, y cómo se estructura para resolver distintas clases de problemas. Además, entenderemos los elementos clave que componen estas redes, tales como funciones de activación, pesos, sesgos y su arquitectura interna. Este conocimiento es esencial para todo estudiante o profesional que desee iniciarse en el campo del aprendizaje profundo (Deep Learning) y comprender su base teórica.

Aprendizaje esperado

Cuando finalices la lección serás capaz de:

- Identificar y describir las partes que conforman un perceptrón.
- Relacionar el funcionamiento del perceptrón con el de una neurona biológica.
- Explicar las funciones de activación y su rol en las redes neuronales.
- Comprender los pasos del proceso de entrenamiento: forward pass y backpropagation.
- Reconocer la estructura de una red neuronal densa, incluyendo capas de entrada, ocultas y salida.

¿Qué es una Red Neuronal Artificial?

Una red neuronal artificial (RNA) es un modelo computacional inspirado en la estructura del cerebro humano. Estas redes están compuestas por unidades llamadas "neuronas artificiales", que se organizan en capas y se interconectan entre sí mediante pesos. Las redes neuronales son capaces de aprender a partir de datos, generalizando patrones y realizando predicciones con gran precisión.

A diferencia de los algoritmos tradicionales, donde las reglas son definidas explícitamente por el programador, en una RNA los parámetros se ajustan automáticamente a través del entrenamiento. Esta característica convierte a las redes en herramientas versátiles y adaptables a múltiples dominios como la visión por computadora, el procesamiento del lenguaje natural y el análisis financiero.

Las RNA pertenecen al grupo de los modelos de aprendizaje supervisado y no supervisado, dependiendo de cómo se les alimenten los datos. Entre sus ventajas destacan la capacidad de aprender relaciones no lineales complejas, su escalabilidad y su aplicabilidad a grandes volúmenes de datos.

En términos generales, una RNA consta de una capa de entrada, varias capas ocultas (opcionalmente), y una capa de salida. La complejidad de la red depende del número de capas y de neuronas en cada una, así como de las funciones de activación empleadas y el método de entrenamiento.

Finalmente, el potencial de las RNA ha sido probado en tareas como reconocimiento de voz, diagnóstico médico y detección de fraudes. Esto las posiciona como un pilar clave dentro del aprendizaje automático moderno.

Problemas que se pueden resolver con Redes Neuronales

Las redes neuronales son extremadamente útiles para resolver problemas en los que existen patrones complejos o relaciones no lineales entre las variables. Entre los más comunes se encuentran:

- **Clasificación:** asignar una etiqueta a una entrada, como clasificar correos como spam o no spam.
- **Regresión:** predecir un valor continuo, como el precio de una vivienda o la temperatura de mañana.
- **Reconocimiento de patrones:** identificar caras humanas en imágenes, reconocer escritura a mano, etc.
- **Series temporales:** como la predicción de demanda de energía o del valor de acciones.
- **Segmentación:** dividir una imagen en regiones significativas, útil en medicina o visión artificial.

Comparativamente, mientras que algoritmos como regresión lineal funcionan bien en relaciones simples, las RNA superan en rendimiento cuando los datos presentan interacciones complejas entre variables. Esta flexibilidad se debe a su estructura en capas y la capacidad de aprendizaje no lineal.

También se utilizan en entornos donde la programación explícita sería costosa o imposible, como juegos, traducción automática y sistemas de recomendación.

A pesar de sus capacidades, es importante considerar los costos computacionales y la necesidad de grandes volúmenes de datos para un entrenamiento efectivo. Además, son susceptibles al sobreajuste si no se aplican técnicas adecuadas de regularización.

En resumen, las redes neuronales son modelos versátiles y altamente efectivos cuando se aplican a problemas de alta complejidad y gran volumen de datos.

Elementos de una Red Neuronal: El Perceptrón

El perceptrón es la unidad básica de una red neuronal. Fue propuesto por Frank Rosenblatt en 1958 como un modelo computacional inspirado en la neurona biológica. En su forma más simple, un perceptrón toma varias entradas, las multiplica por pesos, las suma y pasa el resultado por una función de activación.

Analogía con la neurona biológica:

Neurona Biológica	Perceptrón Artificial

Dendritas	Entradas (X1, X2, ..., Xn)
Sinapsis	Pesos (w1, w2, ..., wn)
Soma	Suma ponderada + sesgo
Axón	Salida
Potencial de acción	Función de activación

Los perceptrones pueden resolver problemas linealmente separables, como la compuerta lógica AND o OR. Sin embargo, no pueden resolver problemas no lineales como XOR. Para eso, se requieren múltiples capas (redes multicapa).

Cada perceptrón tiene un sesgo (bias) que permite ajustar el umbral de activación, y es clave para el aprendizaje. Además, los pesos se modifican en el entrenamiento, permitiendo que el perceptrón "aprenda".

Este concepto es la base de redes más complejas. Una red neuronal puede considerarse como una pila de perceptrones conectados en capas.

Capas de Entrada, Salida y Capas Ocultas

Una red neuronal se compone de distintas capas:

1. **Capa de entrada:** recibe los datos en bruto. Su número de neuronas equivale al número de características de entrada.
2. **Capas ocultas:** procesan la información mediante funciones de activación. Pueden ser una o múltiples, dependiendo del problema.
3. **Capa de salida:** genera la predicción o resultado. Puede tener una o más neuronas, según la tarea (clasificación binaria, multiclase o regresión).

Comparativa entre tipos de capas:

Tipo de Capa	**Rol en la Red**	**Número de Neuronas**
Entrada	Recepción de datos	Igual al número de características

Oculta	Procesamiento intermedio	Variable, definido por el usuario
Salida	Resultado final del modelo	Según tarea (1 para binaria, n para multiclase)

Las capas ocultas son las responsables de capturar relaciones complejas. Cuantas más capas y neuronas haya, mayor será la capacidad de aprendizaje, aunque también aumenta el riesgo de sobreajuste y el costo computacional.

El diseño de la arquitectura (número de capas y neuronas) es crucial. Generalmente se determina empíricamente, evaluando el rendimiento con diferentes configuraciones.

Función de Activación

La función de activación introduce no linealidad al sistema, permitiendo que la red aprenda relaciones complejas. Sin estas funciones, la red sería equivalente a una simple combinación lineal de entradas.

Las funciones más comunes incluyen:

Función	**Fórmula**	**Usos comunes**
Sigmoide	1 / (1 + e^-x)	Clasificación binaria
Tanh	(e^x - e^-x) / (e^x + e^-x)	Redes antiguas
ReLU	max(0, x)	Redes profundas (deep)
Softmax	e^xi / ∑ e^xj	Clasificación multiclase

Cada una tiene ventajas y desventajas. ReLU, por ejemplo, es eficiente computacionalmente y ayuda a mitigar el problema del gradiente desvanecido, por eso es la más usada hoy en día en capas ocultas.

Elegir la función de activación adecuada es importante, pues afecta el comportamiento de la red durante el aprendizaje.

Pesos y Sesgos

Los **pesos** determinan la importancia de cada entrada en el resultado de una neurona. Se inicializan aleatoriamente y se ajustan durante el entrenamiento para minimizar el error.

El **sesgo** permite desplazar la función de activación hacia la izquierda o derecha. Es fundamental para que el modelo pueda representar correctamente ciertos patrones.

Matemáticamente, la salida de una neurona es:

```
y = f(w1*x1 + w2*x2 + ... + wn*xn + b)
```

Donde w son los pesos, x las entradas, b el sesgo, y f() la función de activación.

Los pesos se actualizan a través del algoritmo de backpropagation, lo que permite a la red "aprender" del error cometido.

Un mal ajuste de pesos puede hacer que el modelo no converja o aprenda patrones incorrectos. Por ello, existen técnicas como la inicialización de He o Xavier que buscan mejorar este proceso.

Arquitectura de una Red Neuronal Densa

Una red neuronal densa (también llamada totalmente conectada) es aquella en la que cada neurona de una capa está conectada a todas las neuronas de la siguiente.

Características clave:

- Las conexiones completas permiten una gran capacidad de aprendizaje.
- Se utilizan en tareas de clasificación y regresión general.
- No considera estructuras espaciales o temporales como sí lo hacen las redes convolucionales o recurrentes.

La arquitectura se define según:

- Número de capas ocultas.
- Número de neuronas por capa.
- Funciones de activación utilizadas.
- Estrategia de regularización (dropout, L2, etc.).

Esta estructura es versátil y representa el tipo de red más utilizado en contextos educativos y aplicaciones generales.

Entrenamiento de una Red Neuronal: Loss Function, Forward Pass y Backpropagation

Loss Function

Es una función que cuantifica el error entre la predicción de la red y el valor real. Las más comunes son:

- MSE (Error cuadrático medio): para regresión.
- Cross-Entropy: para clasificación.

Forward Pass

Proceso mediante el cual los datos pasan por la red, desde la capa de entrada hasta la de salida, generando una predicción. Se aplican funciones de activación y se computa la pérdida.

Backpropagation

Una vez calculado el error, este se propaga hacia atrás (backward pass), actualizando los pesos mediante el algoritmo de descenso de gradiente.

El ciclo completo:

1. Datos de entrada → Forward Pass → Predicción.
2. Comparación con la salida esperada → Cálculo de error (Loss).
3. Error → Backpropagation → Ajuste de pesos.

Este proceso se repite durante múltiples épocas hasta que la red alcanza una precisión adecuada.

Cierre ✍️

Las redes neuronales artificiales representan una de las técnicas más poderosas y versátiles en el campo del aprendizaje automático. A lo largo de este manual, exploramos sus componentes fundamentales, su arquitectura y los procesos que permiten su aprendizaje. Desde el perceptrón hasta el entrenamiento completo con backpropagation, cada elemento cumple un rol esencial en la capacidad predictiva de la red.

Entender estos conceptos es clave para poder construir, ajustar y evaluar redes neuronales de forma efectiva. En módulos futuros, estos conocimientos se profundizarán con implementaciones prácticas y casos reales.

¡Nos vemos de nuevo, más adelante! 👋

Referencias📚

- IBM. (s.f.). *What are artificial neural networks?* https://www.ibm.com/cloud/learn/neural-networks
- Google Developers. (s.f.). *Activation functions.* https://developers.google.com/machine-learning/glossary#activation_function
- PlatziTeam. (2025, 23 de junio). *Red neuronal artificial: ¿Qué es y cómo se entrena?* Platzi. Recuperado de https://platzi.com/blog/red-neuronal-artificial-que-es-y-como-se-entrena/
- DataScientest. (2022). *Perceptrón: ¿qué es y para qué sirve?* DataScientest. Recuperado de https://datascientest.com/es/perceptron-que-es-y-para-que-sirve
- Canle Fernández, E. (2022, 30 de junio). *¿Qué es y cómo funciona la backpropagation en redes neuronales?* Tokio School. Recuperado de https://www.tokioschool.com/noticias/backpropagation-redes-neuronales/
- KeepCoding. (2024?). *Backpropagation y perceptrón multicapa [Guía completa 2025].* KeepCoding. Recuperado de https://keepcoding.io/blog/backpropagation-solucion-perceptron-multicapas/
- Universidad Tecnológica Nacional, Facultad Regional Rosario. (2001?). *Redes neuronales: Conceptos básicos y aplicaciones.* UTN Rosario. Recuperado de https://www.frro.utn.edu.ar/repositorio/catedras/quimica/5_anio/orientadora1/monograias/matich-redesneuronales.pdf

¡Muchas gracias!

Nos vemos en la próxima lección

alkemy