Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😁

alkemy

Clase grabada

La red neuronal artificial - Parte II

Aprendizaje Esperado 1: Explicar los conceptos fundamentales las redes neuronales artificiales y su utilidad para la resolución de problemas de aprendizaje de máquina.

Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**

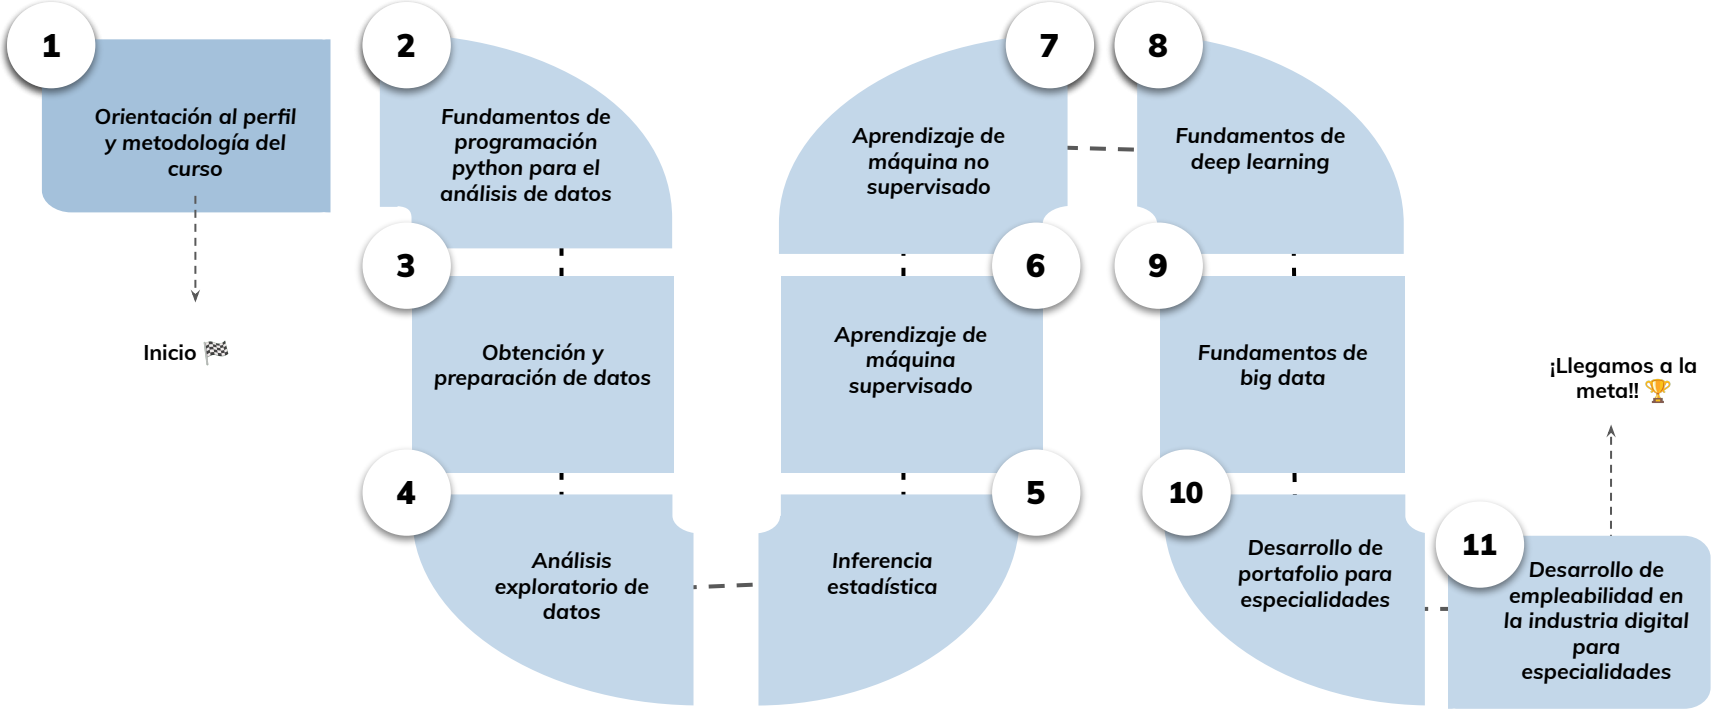

alkemy

Roadmap de lecciones

*¿Cuáles **lecciones** estaremos estudiando en este módulo?*

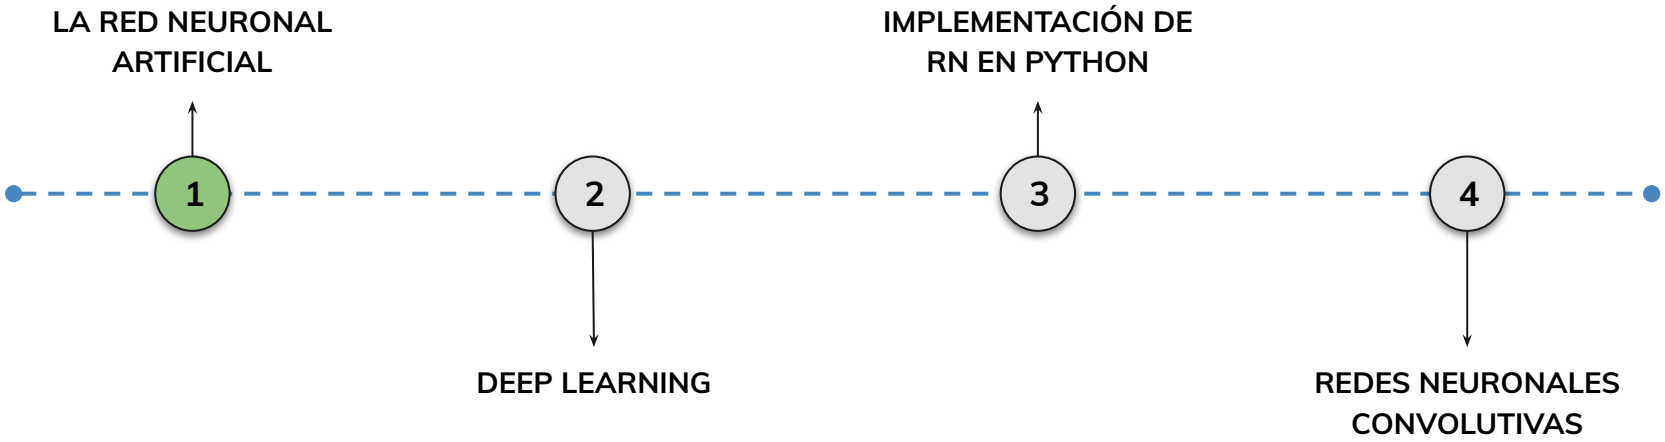

alkemy

Learning Path

¿Cuáles temas trabajaremos hoy?

1.

Procesos de entrenamiento y tipos de redes neuronales artificiales

Profundizaremos en cómo se entrenan las redes neuronales, los conceptos de forward pass, backpropagation y regularización. Además, conoceremos redes neuronales especializadas y aplicaciones avanzadas.

- **Entrenamiento de redes neuronales**
  - **Función de pérdida y su importancia.**
  - **Forward pass, cálculo del error y backpropagation.**
- **Redes neuronales especializadas y tendencias**
  - **CNN, RNN, GAN y aprendizaje por transferencia.**
  - **Evaluación, métricas y buenas prácticas.**

alkemy

Objetivos de aprendizaje

¿Qué aprenderás?

- Explicar cómo se entrena una red neuronal mediante forward pass y backpropagation.
- Comprender el papel de la función de pérdida y los algoritmos de descenso de gradiente.
- Conocer los hiperparámetros clave y técnicas de regularización para evitar sobreajuste.
- Identificar los tipos de redes neuronales especializadas (CNN, RNN, GAN) y sus aplicaciones.
- Reconocer los desafíos, buenas prácticas y tendencias actuales en el desarrollo de RNA.

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos 📚:

→ *Explicamos qué es una red neuronal artificial y cómo se inspira en el cerebro humano.*

→ *Conocimos los elementos fundamentales: neuronas artificiales, capas, pesos, sesgos y funciones de activación.*

→ *Analizamos el perceptrón como la unidad básica de procesamiento y sus limitaciones.*

→ *Exploramos la arquitectura de redes multicapa (MLP) y las redes densas.*

La red neuronal artificial

Entrenamiento de una Red Neuronal

Loss Function, Forward Pass y Backpropagation

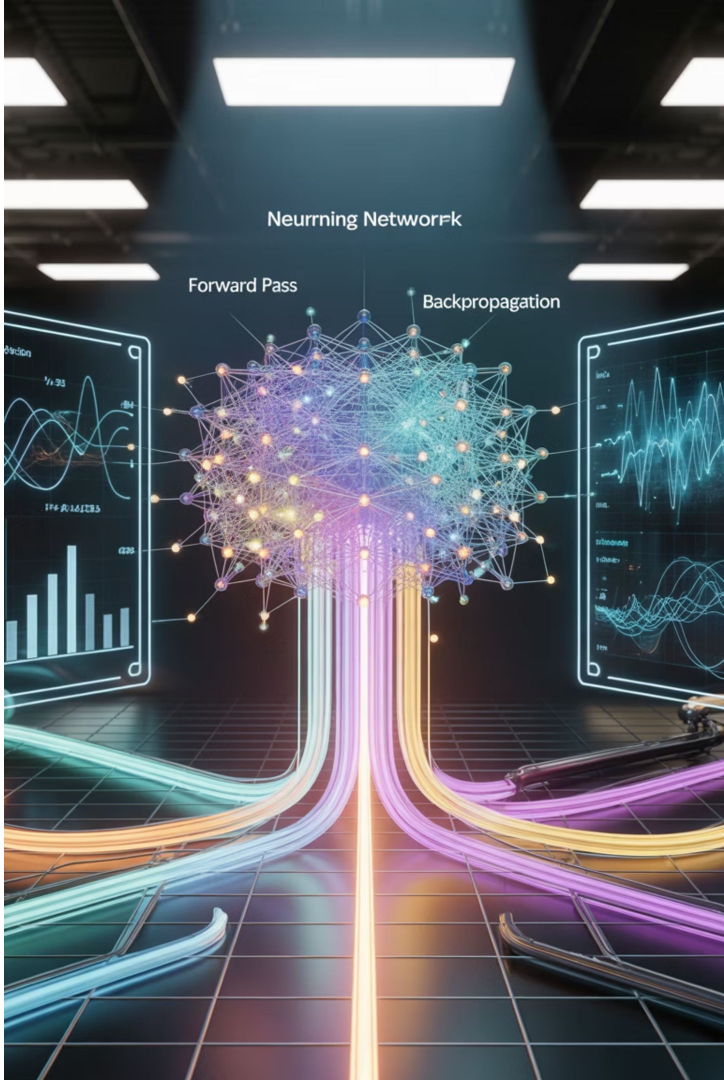

Loss Function (Función de Pérdida)

Es una función que cuantifica el error entre la predicción de la red y el valor real. Las más comunes son:

MSE (Error cuadrático medio)

Para problemas de regresión.

$$MSE = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

Cross-Entropy

Para problemas de clasificación.

$$CE = -\sum_{i=1}^{n} y_i \log(\hat{y}_i)$$

alkemy

Forward Pass (Propagación Hacia Adelante)

Proceso mediante el cual los datos pasan por la red, desde la capa de entrada hasta la de salida, generando una predicción. Se aplican funciones de activación y se computa la pérdida.

Backpropagation (Retropropagación)

Una vez calculado el error, este se propaga hacia atrás (backward pass), actualizando los pesos mediante el algoritmo de descenso de gradiente.

Ciclo Completo de Entrenamiento

Forward Pass

Datos de entrada → Forward Pass → Predicción.

Cálculo de Error

Comparación con la salida esperada → Cálculo de error (Loss).

Backpropagation

Error → Backpropagation → Ajuste de pesos.

Este proceso se repite durante múltiples épocas hasta que la red alcanza una precisión adecuada.

Descenso de Gradiente

El descenso de gradiente es el algoritmo que permite actualizar los pesos durante el backpropagation. Busca minimizar la función de pérdida ajustando los pesos en la dirección opuesta al gradiente.

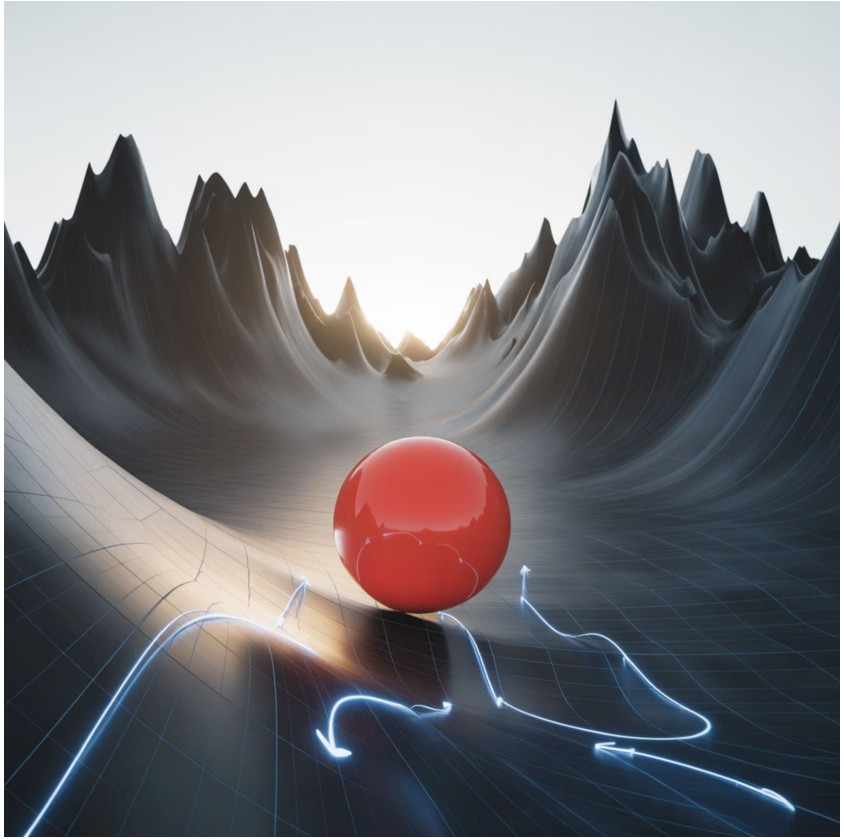

Variantes del Descenso de Gradiente

Batch Gradient Descent

Utiliza todo el conjunto de datos para calcular el gradiente en cada iteración.

Stochastic Gradient Descent

Utiliza un solo ejemplo para calcular el gradiente en cada iteración.

Mini-batch Gradient Descent

Utiliza un subconjunto de datos para calcular el gradiente en cada iteración.

Hiperparámetros en el Entrenamiento

Learning Rate (Tasa de Aprendizaje)

Controla el tamaño de los pasos en el descenso de gradiente. Un valor muy alto puede causar divergencia, mientras que uno muy bajo puede hacer que el entrenamiento sea muy lento.

Batch Size (Tamaño del Lote)

Número de ejemplos utilizados en cada iteración del descenso de gradiente.

Epochs (Épocas)

Número de veces que el algoritmo procesa todo el conjunto de datos de entrenamiento.

Optimizadores Avanzados

Existen optimizadores más avanzados que el descenso de gradiente básico, como:

- Adam
- RMSprop
- Adagrad
- Momentum

Estos algoritmos adaptan la tasa de aprendizaje durante el entrenamiento, lo que suele resultar en una convergencia más rápida y estable.

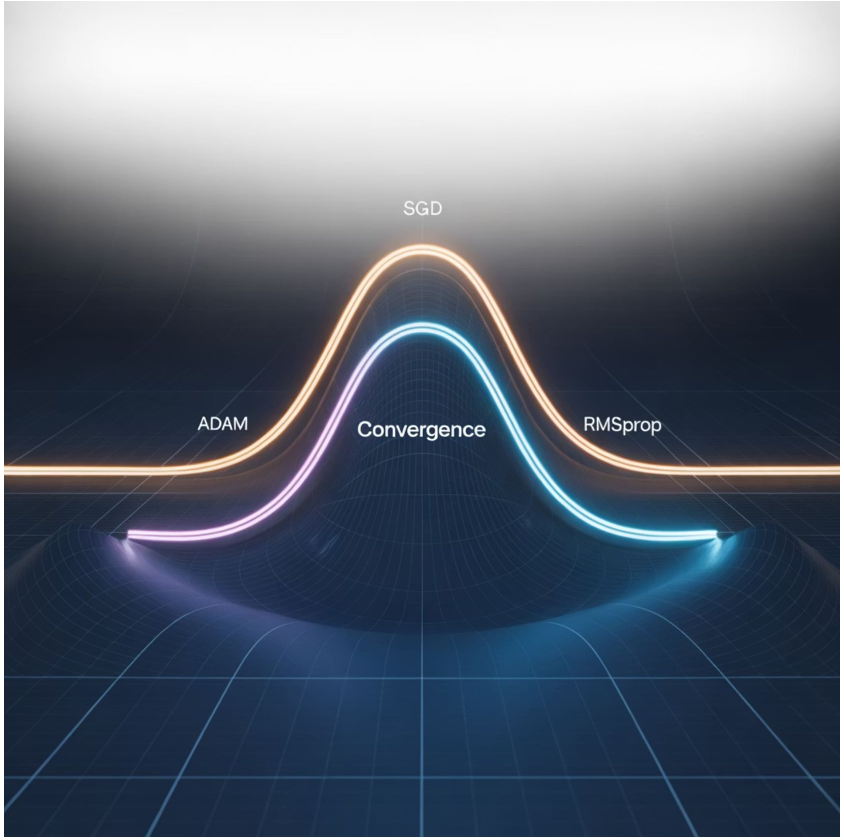

Regularización

La regularización es un conjunto de técnicas que ayudan a prevenir el sobreajuste (overfitting) en las redes neuronales.

Dropout

Desactiva aleatoriamente un porcentaje de neuronas durante el entrenamiento, forzando a la red a no depender demasiado de ninguna neurona específica.

L1/L2 Regularization

Añade un término de penalización a la función de pérdida basado en la magnitud de los pesos, favoreciendo modelos más simples.

Early Stopping

Detiene el entrenamiento cuando el rendimiento en el conjunto de validación comienza a deteriorarse.

Validación y Evaluación

Para evaluar el rendimiento de una red neuronal, es común dividir los datos en tres conjuntos:

- Entrenamiento: para ajustar los pesos de la red.
- Validación: para ajustar hiperparámetros y monitorear el sobreajuste.
- Prueba: para evaluar el rendimiento final del modelo.

Métricas de Evaluación

Clasificación

- Accuracy (Precisión)
- Precision (Exactitud)
- Recall (Sensibilidad)
- F1-Score
- AUC-ROC

Regresión

- Mean Squared Error (MSE)
- Root Mean Squared Error (RMSE)
- Mean Absolute Error (MAE)
- R^2 (Coeficiente de determinación)

Tipos de Redes Neuronales Especializadas

Redes Neuronales Convolucionales (CNN)

Especializadas en procesamiento de imágenes y datos con estructura espacial.

Redes Neuronales Recurrentes (RNN)

Diseñadas para procesar secuencias y datos temporales.

Redes Generativas Adversarias (GAN)

Utilizadas para generar nuevos datos similares a los de entrenamiento.

Redes Neuronales Convolucionales (CNN)

Las CNN son especialmente efectivas para el procesamiento de imágenes debido a su capacidad para detectar patrones espaciales. Sus componentes principales son:

- Capas convolucionales
- Capas de pooling
- Capas totalmente conectadas

Redes Neuronales Recurrentes (RNN)

Las RNN son ideales para procesar datos secuenciales como texto, audio o series temporales. Su característica distintiva es la capacidad de mantener un estado interno que actúa como "memoria" de entradas previas.

Variantes populares incluyen LSTM (Long Short-Term Memory) y GRU (Gated Recurrent Unit), que resuelven el problema del desvanecimiento del gradiente en secuencias largas.

Redes Generativas Adversarias (GAN)

Las GAN consisten en dos redes que compiten entre sí:

- Generador: crea datos sintéticos
- Discriminador: distingue entre datos reales y sintéticos

Esta competencia mejora continuamente la calidad de los datos generados, permitiendo crear imágenes, texto o audio realistas.

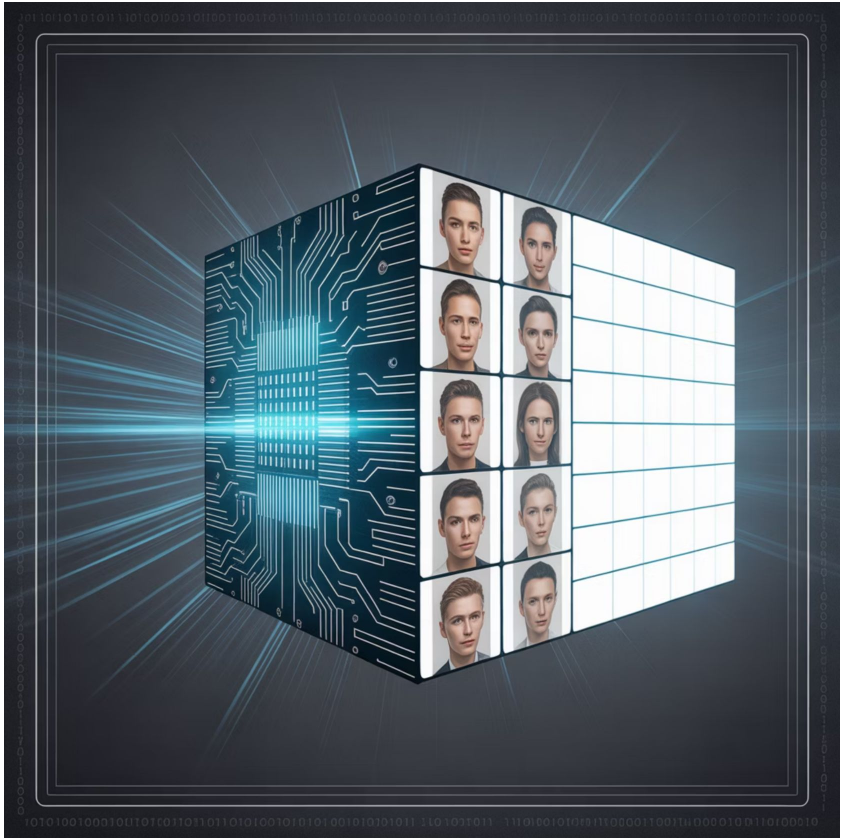

Aprendizaje por Transferencia

El aprendizaje por transferencia (transfer learning) permite aprovechar el conocimiento adquirido por una red neuronal en una tarea para aplicarlo a otra tarea relacionada.

Este enfoque es especialmente útil cuando se dispone de pocos datos para la nueva tarea, ya que permite partir de características ya aprendidas en lugar de comenzar desde cero.

Frameworks y Bibliotecas

TensorFlow

Desarrollado por Google, ofrece un ecosistema completo para el desarrollo de modelos de aprendizaje profundo.

PyTorch

Creado por Facebook, destaca por su flexibilidad y facilidad de uso en investigación.

Keras

API de alto nivel que funciona sobre TensorFlow, simplificando la creación de redes neuronales.

Desafíos en el Desarrollo de Redes Neuronales

Requerimientos Computacionales

El entrenamiento de redes complejas puede requerir hardware especializado como GPUs o TPUs.

Necesidad de Datos

Las redes neuronales suelen necesitar grandes cantidades de datos etiquetados para un entrenamiento efectivo.

Interpretabilidad

A menudo funcionan como "cajas negras", dificultando la comprensión de cómo llegan a sus predicciones.

Ajuste de Hiperparámetros

Encontrar la configuración óptima puede ser un proceso largo y costoso.

Tendencias Actuales

El campo de las redes neuronales continúa evolucionando rápidamente. Algunas tendencias actuales incluyen:

- Modelos cada vez más grandes (GPT, BERT)
- Arquitecturas eficientes para dispositivos móviles
- Aprendizaje auto-supervisado
- Redes neuronales cuánticas
- Interpretabilidad y explicabilidad

Aplicaciones en la Industria

Medicina

Diagnóstico por imagen, descubrimiento de fármacos, predicción de enfermedades.

Finanzas

Detección de fraudes, trading algorítmico, evaluación de riesgos.

Automoción

Vehículos autónomos, sistemas de asistencia al conductor, mantenimiento predictivo.

Retail

Sistemas de recomendación, previsión de demanda, optimización de inventario.

Consideraciones Éticas

Sesgos en los Datos

Las redes neuronales pueden perpetuar o amplificar sesgos presentes en los datos de entrenamiento.

Privacidad

El uso de datos personales para entrenar modelos plantea cuestiones sobre la privacidad y el consentimiento.

Impacto Laboral

La automatización mediante IA puede transformar el mercado laboral, requiriendo adaptación y nuevas habilidades.

Transparencia

La falta de interpretabilidad puede ser problemática en aplicaciones críticas como medicina o justicia.

Buenas Prácticas en el Desarrollo

Exploración de Datos

Comprender a fondo los datos antes de construir el modelo.

Preprocesamiento Adecuado

Normalización, manejo de valores faltantes, codificación de variables categóricas.

Arquitectura Incremental

Comenzar con modelos simples e ir aumentando la complejidad según sea necesario.

Validación Rigurosa

Utilizar técnicas como validación cruzada para evaluar el rendimiento de forma robusta.

Documentación

Registrar decisiones, experimentos y resultados para facilitar la reproducibilidad.

Resumen: Componentes Fundamentales

Perceptrón
Unidad básica de procesamiento

Entrenamiento
Forward pass y backpropagation

Capas
Entrada, ocultas y salida

Funciones de Activación
Introducen no linealidad

Pesos y Sesgos
Parámetros ajustables

alkemy

Resumen: Proceso de Entrenamiento

Preparación de Datos

Recopilación, limpieza y preprocesamiento de datos para el entrenamiento.

Diseño de la Red

Definición de la arquitectura, capas, neuronas y funciones de activación.

Entrenamiento

Forward pass, cálculo de error y backpropagation para ajustar pesos.

Evaluación

Validación del modelo con datos no vistos durante el entrenamiento.

Implementación

Despliegue del modelo en un entorno de producción para su uso.

Conclusiones

Las redes neuronales artificiales representan una de las técnicas más poderosas y versátiles en el campo del aprendizaje automático. A lo largo de este manual, exploramos sus componentes fundamentales, su arquitectura y los procesos que permiten su aprendizaje. Desde el perceptrón hasta el entrenamiento completo con backpropagation, cada elemento cumple un rol esencial en la capacidad predictiva de la red.

Entender estos conceptos es clave para poder construir, ajustar y evaluar redes neuronales de forma efectiva. En módulos futuros, estos conocimientos se profundizarán con implementaciones prácticas y casos reales.

Live Coding

¿En qué consistirá la Demo?

Analizaremos de forma conceptual el ciclo completo de entrenamiento de una red neuronal y los diferentes tipos de redes neuronales avanzadas.

1. *Forward pass: Cómo se propagan los datos desde la entrada hasta la salida.*
2. *Función de pérdida: Por qué se calcula el error y cómo afecta al aprendizaje.*
3. *Backpropagation: Cómo el error se propaga hacia atrás para ajustar los pesos.*
4. *Descenso de gradiente: Diferencias entre batch, mini-batch y stochastic.*
5. *Regularización: Dropout, L1/L2 y early stopping para prevenir sobreajuste.*
6. *Redes especializadas: Introducción a CNN, RNN y GAN con ejemplos conceptuales de sus aplicaciones.*

Tiempo: 25 Minutos

Momento:

Time-out!

⏰5 -10 min.

alkemy

Ejercicio N° 1

Investiga y explica el proceso de entrenamiento

Investiga y explica el proceso de entrenamiento

Contexto: 🙌

Queremos entender a profundidad cómo aprenden las redes neuronales y cómo se evalúan.

Consigna: ✍️

1. Describe los pasos del ciclo de entrenamiento: forward pass, cálculo de error y backpropagation.
2. Explica en qué consiste el descenso de gradiente y sus variantes.
3. Investiga los hiperparámetros más importantes: learning rate, batch size y épocas.
4. Describe al menos dos técnicas de regularización y su importancia.
5. Investiga qué son las CNN, RNN y GAN y da ejemplos de aplicaciones para cada una.

Paso a paso: ⚙️

1. Investiga el ciclo de entrenamiento paso a paso.
2. Resume el rol de cada elemento (función de pérdida, optimizador, hiperparámetros).
3. Explica la relación entre sobreajuste y regularización.
4. Identifica aplicaciones de redes especializadas en la industria.

Tiempo 🕐**:** *45 Minutos*

¿Alguna consulta?

alkemy

Resumen

¿Qué logramos en esta clase?

- ✓ ***Comprendimos el ciclo completo de entrenamiento de una RNA.***
- ✓ ***Estudiamos la función de pérdida, backpropagation y descenso de gradiente.***
- ✓ ***Identificamos técnicas de regularización y el ajuste de hiperparámetros.***
- ✓ ***Conocimos redes neuronales avanzadas (CNN, RNN, GAN) y sus aplicaciones.***
- ✓ ***Reflexionamos sobre buenas prácticas y desafíos en el uso de RNA.***

¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las ***actividades disponibles en la plataforma.*** *Estas propuestas son clave para afianzar lo trabajado y* ***forman parte obligatoria del recorrido de aprendizaje.***

💪 Análisis de caso ——— 💪 Selección Múltiple

💪 Comprensión lectora

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

alkemy

< ¡Muchas gracias! >

alkemy